GRUNDLAGEN DER DIGITALISIERUNG UND DIGITALEN TRANSFORMATION

Vorlesung 4
Datenmanagement – Exkursion



TBD

Vorlesung: Zeitplan

Vorlesung **mittwochs** von **08:15 – 09:45 Uhr**

Termin	Thema
29.10.25	Kickoff – Einführung und Übersicht
05.11.25	Technische Grundlagen
12.11.25	Datenmanagement – Basis
19.11.25	Datenmanagement – Exkursion
26.11.25	Betriebswirtschaftliche Anwendungssysteme (Grundlagen)
03.12.25	Betriebswirtschaftliche Anwendungssysteme (Planung, Realisierung und Einführung)
10.12.25	Management der Ressource IT & Digitaler Wandel
17.12.25	**Fällt aus!**
07.01.26	Gastvortrag – studentische Unternehmensberatung: consulting team
14.01.26	Wirtschaftlichkeit der Informationsverarbeitung
21.01.26	Potentieller Gastvortrag
28.01.26	Potentieller Gastvortrag
04.02.26	Repetitorium I
11.02.26	Repetitorium II
18.02.26	Klausur (8:00 – 10:00 Uhr; E-Prüfungsraum / CIP-Pools WiSo RZ)
31.03.26	Wiederholungsklausur (8:00 – 12:00 Uhr; E-Prüfungsraum / CIP-Pools WiSo RZ)

Praktikum: Zeitplan

Nr.	Termin	Übung	Themen
1	03.11.-06.11.2025	**Word 1**	Funktionsumfang und Benutzeroberfläche, Erfassen und Formatieren von Text, Rechtschreibprüfung, Silbentrennung, Thesaurus, Nachverfolgen, Kommentare
2	10.11.-13.11.2025	**Word 2**	Formatvorlagen, automatische Beschriftung, Inhalts- und Abbildungsverzeichnis, Kopf- und Fußzeilen, Fuß- und Endnoten, Querverweis, Feldfunktion
3	17.11.-20.11.2025	**PowerPoint**	Folienmaster, Erstellen von Grafiken, Einbinden von Objekten, Animationen, Hyperlinks und Schaltflächen, Referentenansicht
4	24.11.-27.11.2025	**Excel 1**	Einfache Formatierungen, Einfache Formeln, Zellbezüge
5	01.12.-04.12.2025	**Excel 2**	Logische, mathematische und statistische Funktionen
6	08.12.-11.12.2025	**Excel 3**	Verweisfunktionen, Diagramme und Trendlinien
7	15.12.-18.12.2025	**Excel 4**	Bedingte Formatierung, Filter, Pivot-Tabellen **(Online-Termin!)**
8	05.01.-08.01.2026	**Access 1**	Grundlagen und Begrifflichkeiten, Arbeiten mit Tabellen und Beziehungen, Abfragen erstellen
9	12.01.-15.01.2026	**Access 2**	SQL Grundlagen und einfache Selektionen, Erweiterte Selektionen und Abfragen über mehrere Tabellen, Abfragen in der SQL-Ansicht
10	19.01.-22.01.2026	**GenAI**	Grundlagen zu Prompting, Verwendungen im professionellen Kontext, Kompatibilität mit Microsoft Office
11	26.01.-29.01..2026		Selbstständige Wiederholung
12	02.02.-05.02.2026	**Repititorium und Fragestunde**	
-	18.02./31.03.2026	**Klausurtermine**	

Lernziele des Kapitels “Management von Daten”

NACH DIESEM KAPITEL SIND SIE IN DER LAGE:

- Die grundlegende Funktionsweise einer **Blockchain** zu erläutern
- Grundlegende Prinzipien **verteilter Datenbanksysteme** und **Data-Warehouse Lösungen** zu erläutern und zu bewerten
- Die Grundlagen und Anwendungsgebiete von **Big Data** zu erläutern
- Die Funktionsweise von **neuronalen Netzen** zu erklären
- Die **Potenziale und Gefahren** bei der Nutzung von GenAI und KI zu beschreiben

AGENDA

- Blockchain
- Data Warehouse
- Big Data
- Maschinelles Lernen
- Deep Learning
- GenAI
- LLMs
- Risiken von Daten & KI

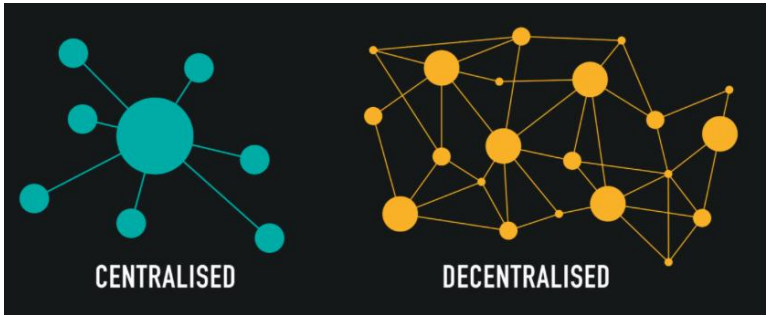
MOTIVATION BLOCKCHAIN

Früher:

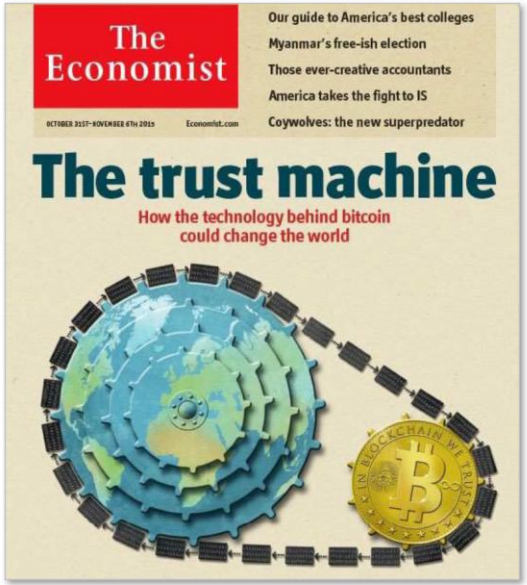
- Zentrale Institutionen wie Banken, Behörden oder Plattformen kontrollieren Daten und Transaktionen.

Durch Blockchain:

- Ersetzt vertrauenswürdige Dritte durch technische Sicherheit: Verhindert Manipulation & Streit bei Transaktionen
- Dezentrale Validierung & Transparenz: Jeder hat ein synchronisiertes, unverfälschbares Register
- Grundlage für digitale Währungen wie Bitcoin



BLOCKCHAIN ALS „TRUST MACHINE“

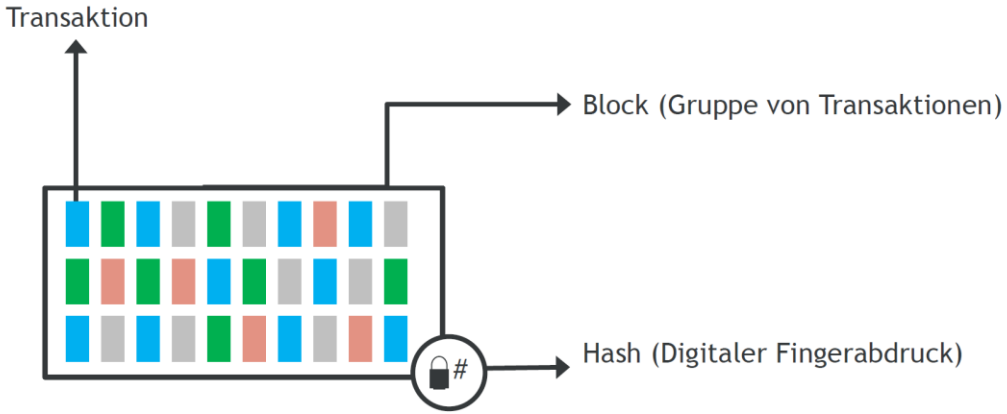


*“The blockchain **lets people** who have no particular confidence in each other **collaborate without** having to go through a **neutral central authority**. Simply put, it is a **machine for creating trust**.”*

- Economist (2015)

WIE FUNKTIONIERT DIE BLOCKCHAIN? (1)

- **Blockchain** = dezentrale Datenbank zur chronologischen Speicherung von Transaktionen
- Jede Transaktion ist ein eigener Eintrag in einem Block
- Mehrere Transaktionen werden zu einem Block zusammengefasst und gemeinsam verarbeitet
- Anzahl an Transaktionen je Block ist individuell nach Protokoll festgelegt, z.B. bestimmt durch Speicherplatz
- Jeder Block erhält einen digitalen Fingerabdruck (Hash):
  - Schon eine minimale Änderung in einer Transaktion verändert den gesamten Hash.
  - Dadurch wird der Block fälschungssicher.

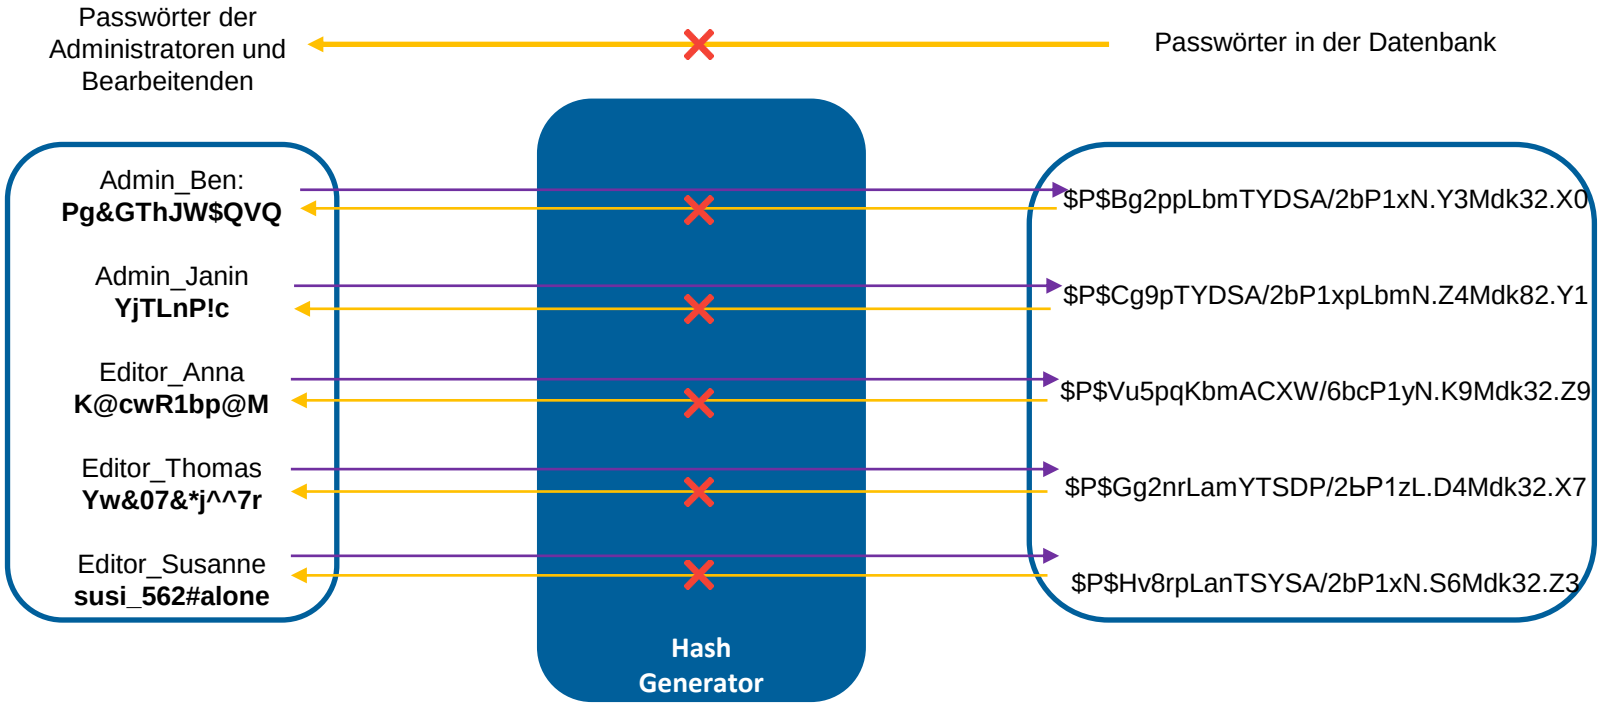


Quelle: in Anlehnung an Brody (2015)

EINSCHUB HASH-WERTE

- Ein Hash ist ein digitaler Fingerabdruck, der aus beliebigen Daten (z. B. einer Nachricht) durch eine Rechenfunktion erzeugt wird.
- **Hashwert:** Ergebnis einer math. Einwegfunktion, welche eine Eingabe (Nachricht) auf einen eindeutigen Hashwert abbildet
- **Eigenschaften:**
  - Eindeutig für jede Eingabe – kleine Änderungen an der Eingabe führen zu komplett anderen Hashwerten.
  - Hashwerte können zusammen mit dem Original gespeichert oder versendet werden, um spätere Verifikation zu ermöglichen.
  - Einwegmechanismus: es muss leicht sein, aus einer Nachricht einen Hashwert zu bestimmen, aber es sollte nahezu unmöglich sein, aus einem Hashwert auf die Nachricht zu schließen

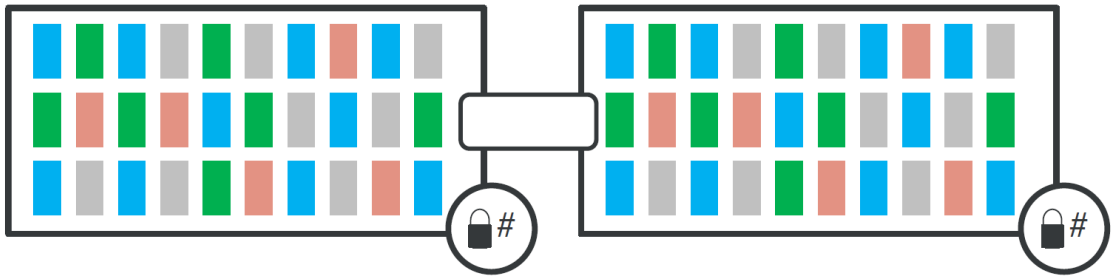
HASH-FUNKTION: PASSWORT-VERSCHLÜSSELUNG



Quelle: IONOS (2020)

WIE FUNKTIONIERT DIE BLOCKCHAIN? (2)

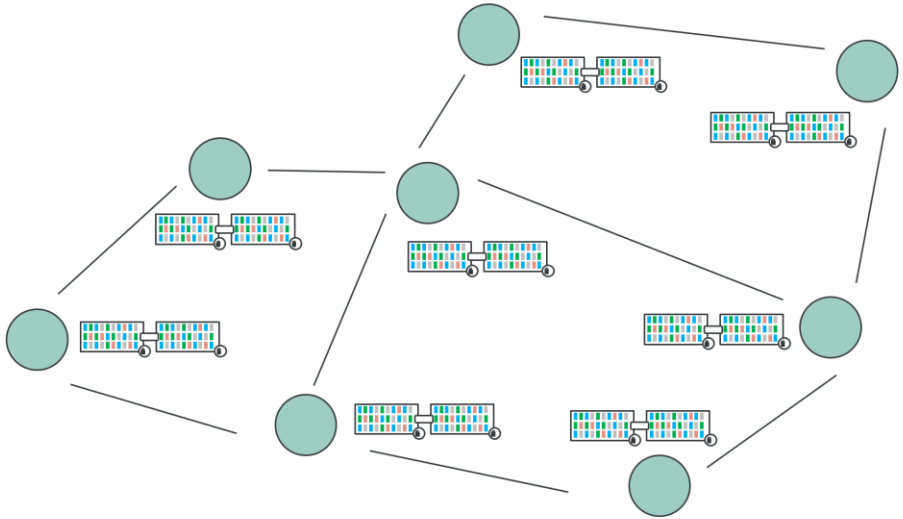
- Jeder Block in der Blockchain enthält Transaktionen und einen eigenen digitalen Fingerabdruck (Hash).
- Zusätzlich speichert jeder neue Block den Hash des vorherigen Blocks.
- Dadurch entsteht eine verkettete Struktur, in der jeder Block abhängig vom vorherigen ist.



Die Verkettung von Blocks ergibt eine Blockkette (“Blockchain”)

WIE FUNKTIONIERT DIE BLOCKCHAIN? (3)

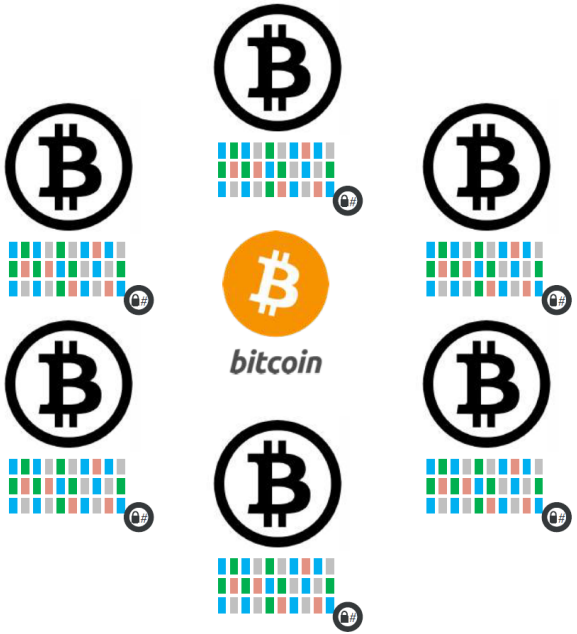
- Die Blockchain liegt nicht auf einem zentralen Server, sondern auf vielen Rechnern („Nodes“) rund um die Welt
- Jeder Node besitzt eine eigene vollständige Kopie der Blockchain.
- Neue Blöcke werden über das Peer-to-Peer-Netzwerk an alle Teilnehmer gesendet.
- Jeder Node überprüft eingehende Blöcke selbstständig und ergänzt sie in ihre eigene Kopie der Blockchain.
- Dadurch haben alle Nutzer denselben aktuellen Stand – auch ohne zentrale Instanz.
- Diese Verteilung macht die Blockchain hochgradig ausfallsicher und schützt vor Manipulation – denn ein Angreifer müsste gleichzeitig tausende Kopien verändern.



Die Blockchain wird über ein weltweites Netzwerk von Nutzern verteilt

Quelle: in Anlehnung an Brody (2015)

NUTZUNG DER BLOCKCHAIN



Als Zahlungsmittel

KONSENSMECHANISMUS – WIE WIRD ENTSCHIEDEN, WELCHER KNOTEN DEN NÄCHSTEN BLOCK ANHÄNGEN DARF?

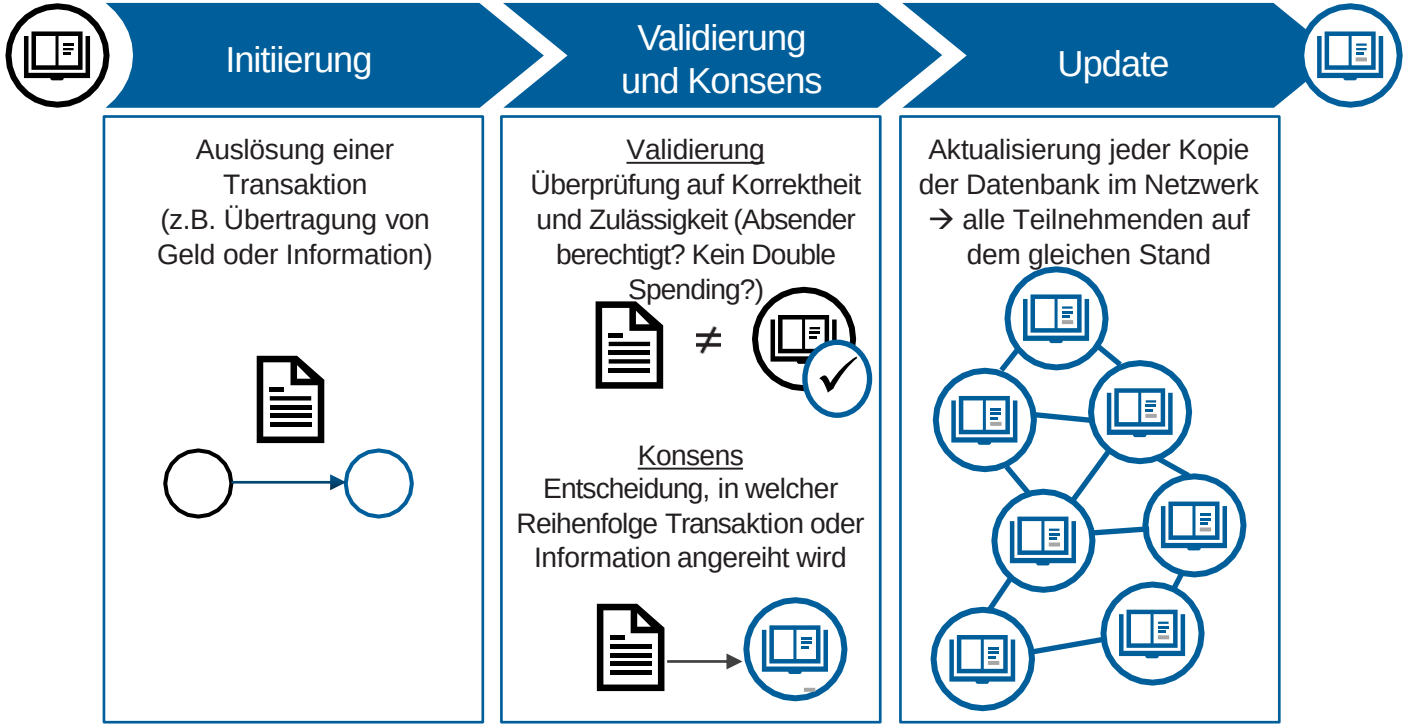
Ziel:

- Auch ohne zentrale Instanz muss das Netzwerk einen Weg finden, um zu bestimmen, welcher Knoten den nächsten Block hinzufügen darf

Lösung durch Proof-of-Work-Konzept:

- Eine komplexe Rechenaufgabe muss per Trial-and-Error gelöst werden
- Derjenige, der sie zuerst löst, veröffentlicht die Lösung und darf seinen Block an die Blockchain anhängen
- Alle anderen Knoten können die Lösung schnell verifizieren

BLOCKCHAIN (DISTRIBUTED LEDGER)



ZUSAMMENFASSUNG BLOCKCHAIN

- Keine zentrale Datenhaltung wie z.B. klassische Datenbanken, sondern verteilt über Netzwerk
- Struktur: Aneinanderreihung von Blocken
- Ermöglichen der Integrität der Daten über kryptografische Verfahren (Signaturen, Hashverfahren)
  → nachträgliche Manipulation nicht möglich
- Konsensmechanismus → alle im Netzwerk haben einheitlichen Stand

AGENDA

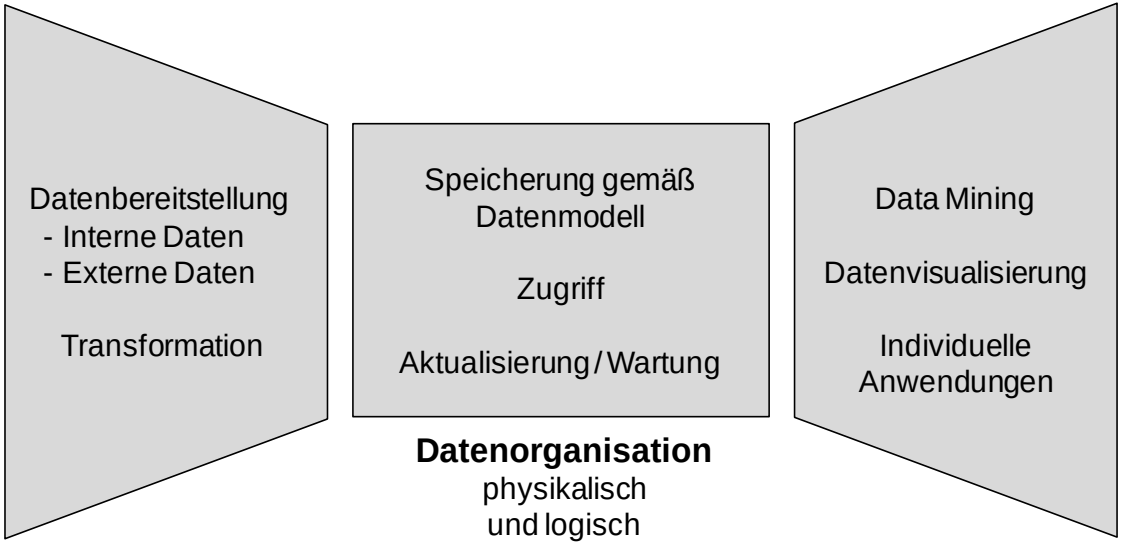
- Blockchain
- **Data Warehouse**
- Big Data
- Maschinelles Lernen
- Deep Learning
- GenAI
- LLMs
- Risiken von KI

DATA WAREHOUSE (DWH)

- Definition: „*Sammlung von integrierten, zeitabhängigen und nicht-volatilen Daten, aus denen Informationen für Managemententscheidungen gewonnen werden*“ (Mertens et al., 2012, S.)
- Herkömmliche Datenbanken enthalten meist Momentaufnahmen des operativen betrieblichen Geschehens
- Unternehmensführung benötigt oft Daten über größere Ausschnitte und längere Zeiträume
- Momentane Zustände müssen archiviert werden
- Ein DWH erlaubt Zeitvergleich und Analyse von Entwicklungen, daher zeitabhängige Daten

Quelle: Mertens et al. (2012): Grundzüge der Wirtschaftsinformatik, 11. Auflage, Springer, Berlin.

GRUNDKOMPONENTEN DES DATA WAREHOUSE



Datenmanagement
d. h. Zugang
und Umformung

Datenorganisation
physikalisch
und logisch

Aufbereitung / Auswertung

EXTERNE DATENBANKEN UND INTERNET

Einbinden externer Quellen (Internet und externe Datenbanken) zur Befriedigung der Informationsbedarfe eines Unternehmens:

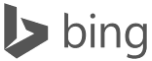
- Volltext- vs. Referenzdatenbanken
- Recherche anhand von Deskriptoren, Verknüpfung mit booleschen Operatoren (UND, ODER, NICHT,…)
- Im Internet mittels Suchmaschinen (Internet als Infrastruktur der betrieblichen Informationsversorgung)

SUCHMASCHINEN

Recherche nach Informationen im Internet

= Suche nach Informationen in einer Ansammlung chaotisch vernetzter Daten ohne Schemata

Beispiele:







- Komponenten:
  - Spider / Crawler: Softwareagenten zur Analyse von Internetseiten
  - Index / Katalog: Datenstruktur mit Informationen über gefundene Webseiten
  - Suchsoftware: Bearbeitung von Suchanfragen mit Hilfe des Katalogs und Darstellung der Ergebnisse

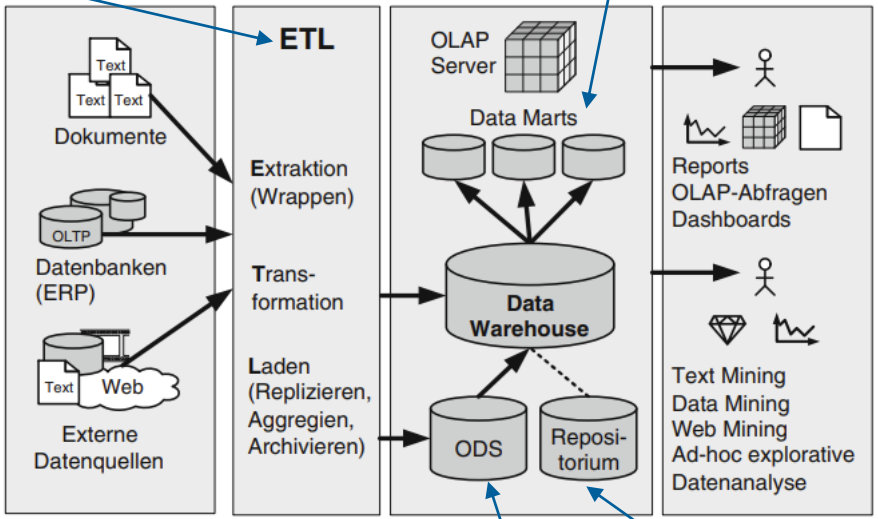
Arten der Suche:

- Volltext
- Schlagwort
- Meta-Tags der Webseiten

DATA WAREHOUSE REFERENZARCHITEKTUR

ETL: **Extract** (Auslesen aus versch. Quellen, z.B. einer DB) -> **Transform** (Umwandeln/Bereinigen), **Load** (Laden in das Zielsystem)

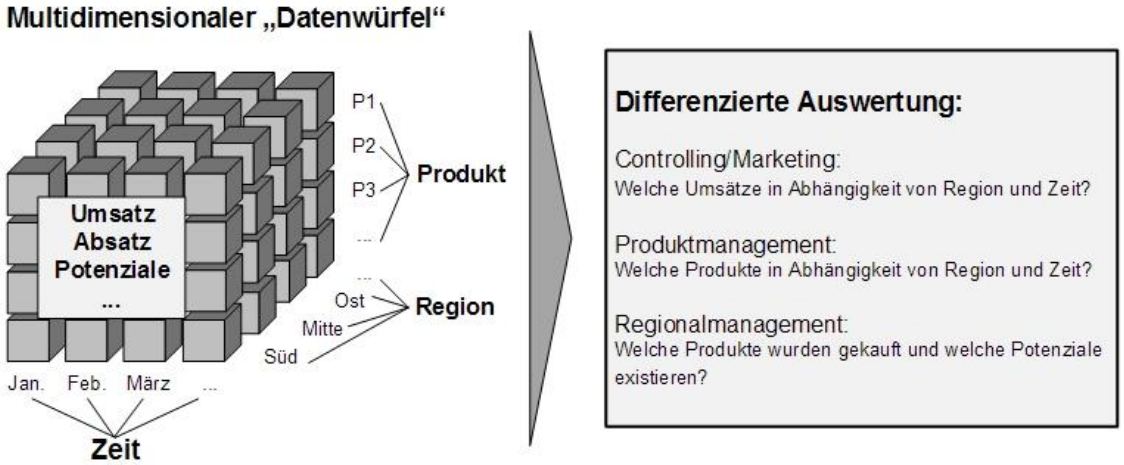
Data Marts: Teilmenge des DWHs, zugeschnitten auf Bedürfnisse des jeweiligen Fachbereichs



Optional: Repositorium -> Metadaten des DWHs

ODS: operational Data Store – Basisdatenbank

DATA MINING UND ONLINE ANALYTICAL PROCESSING (OLAP)



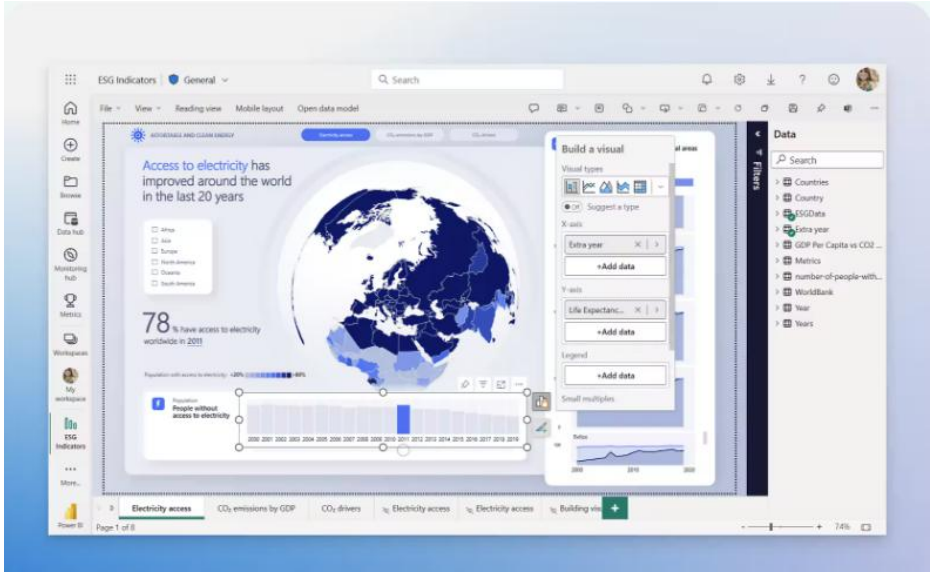
- Interaktiver Ansatz zu Datenanalyse für Fachabteilungen/Management
- Zugriff und Konsolidierung/Aggregation großer Datenmengen
- **Multidimensionale Darstellung** von Daten
  - Dimensionen: z. B. Zeit, Produkt, Region
  - Zellen enthalten Kennzahlen: Umsatz, Absatz, Potenziale
  - Zweck: Daten flexibel aus verschiedenen Blickwinkeln analysieren

ABFRAGE- UND BERICHTSSYSTEME: BEISPIEL MICROSOFT POWERBI

- OLAP wird in der Praxis weniger genutzt – Power BI hingegen sehr häufig, auch von BWLer im Berufsalltag

Typische Funktionen von Power BI

- Einbindung unterschiedlicher Datenquellen (lokal, Cloud, Excel, SQL etc.)
- Interaktive Visualisierung mithilfe vorgefertigter Diagramm-Elemente (z. B. Karten, Balken, Linien), aber auch durch eigene Formeln und benutzerdefinierte Visuals erweiterbar
- Zugriff und Freigabe von Dashboards ist cloudbasiert und kann innerhalb einer Organisation rollenbasiert gesteuert werden
- Echtzeitdatenverarbeitung möglich (z. B. für KPI-Dashboards)



Quelle: Microsoft (2025)

AGENDA

- Blockchain
- Data Warehouse
- **Big Data**
- Maschinelles Lernen
- Deep Learning
- GenAI
- LLMs
- Risiken von Daten & KI

BIG DATA - MOTIVATION

- Volumen aller weltweit bestehenden Daten verdoppelt sich laut aktuellen Berechnungen alle zwei Jahre

- Datenquellen
  - Webseiten, E-Commerce, Social Media
  - Wissenschaftliche & medizinische Instrumente
  - Finanztransaktionen, Börsendaten
  - Sensortechnologien und –netzwerke
  - u.v.m.



- Datenvolumen (Bsp. Deutschland pro Minute):
  - Ca. 100.000 Tweets, 650.000 Google-Suchanfragen,
    1,7 Mio. E-Mails, 3600 Amazon-Einkäufe, 36.000 EC-/Kreditkartenzahlungen

- Potenzial für ökonomischen Nutzen durch Auswertung von Datenbeständen
  - Verbessern der Entscheidungsfindung
  - Aufbau neuer datenbasierter Geschäftsmodelle
  - Verwendung von Big Data für Prognosemethoden zur vorbeugenden Instandhaltung, sog. *Predictive-Analytics* bzw. *Predictive-Maintenance*

BIG DATA - BEGRIFFSDEFINITION

- Bislang keine einheitliche Definition für „Big Data“-Begriff

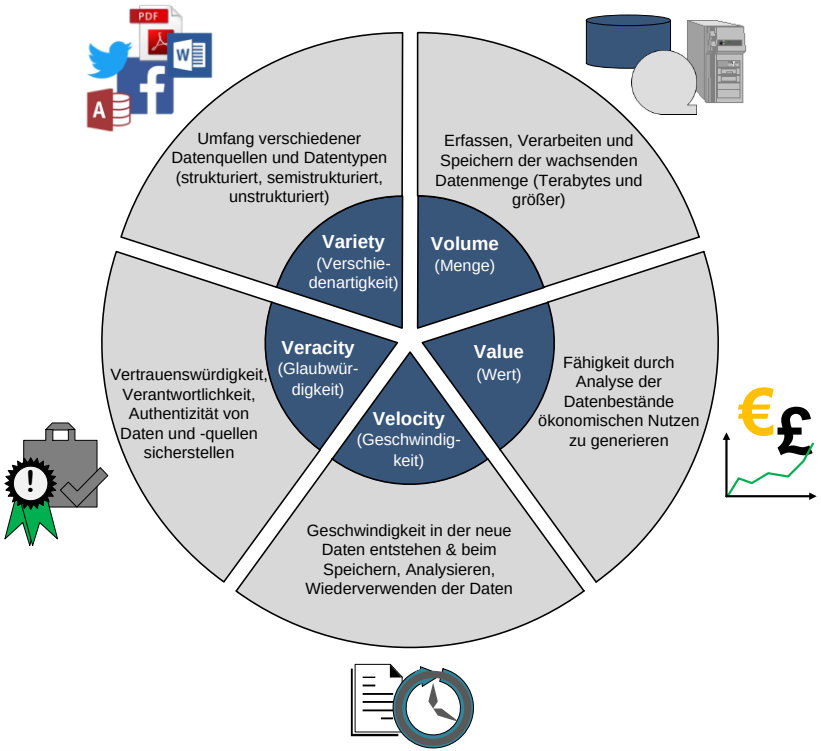
- Sammelbegriff für
  - Datenmengen, die zu
    - groß,
    - komplex,
    - schnelllebig oder
    - schwach strukturiert sind, um diese mit herkömmlichen Methoden der Datenverarbeitung auszuwerten



- „Neuartige“ Technologien zum Sammeln und Auswerten großer Datenmengen

- Analyse und Vermarktung dieser Datenbestände

ANFORDERUNGEN AN BIG DATA-ANWENDUNGEN: DIE 5-V



BIG DATA & MASCHINELLES LERNEN – DIE „WERTSCHÖPFUNGSKETTE“ VON BIG DATA

Datenquellen	Datenhaltung und -Zugriff	Analyse	Visualisierung
			
» Sensoren » Mobiltelefone » Browser » Offene Daten	» Hadoop / Map Reduce » CEP » Data Lake » Data Warehouse / SQL » In-Memory-DB » NoSQL	» Machine Learning » Data Mining » Predictive Analytics » NLP	» Dashboards » Java Script » Neue Diagrammtypen

ABGRENZUNG AI & BIG DATA/AI

- AI braucht Big Data zum Lernen – Maschinenlernmodelle benötigen große Datenmengen, um genau zu werden und verlässliche Vorhersagen zu treffen.

- Big Data braucht AI zur Analyse – KI-Algorithmen automatisieren das Erkennen von Mustern und Zusammenhängen in riesigen Datenbeständen, die Menschen nicht manuell auswerten können.



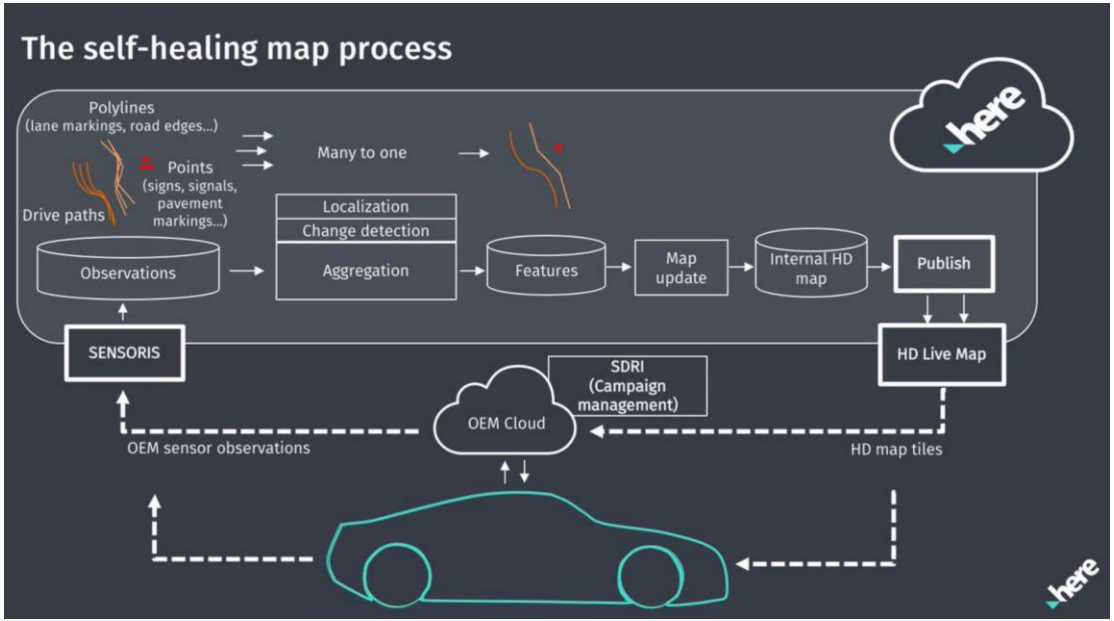
Bildquelle: https://resources.l-p.com/knowledge-center/big-data-and-artificial-intelligence-work-together

AKTUELLE TECH TRENDS (1/3): BMW-BEISPIEL – SENSORIK ALS DATENTREIBER



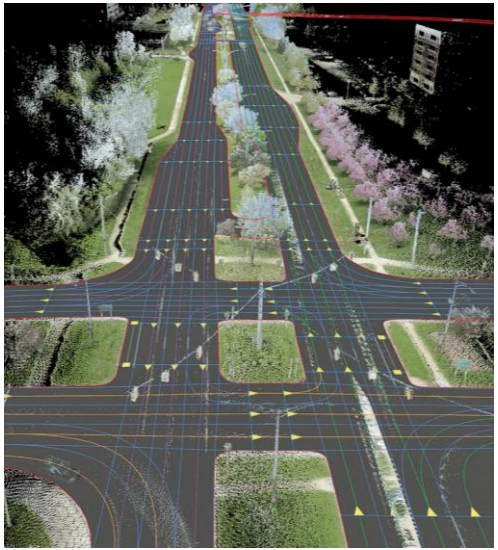
Quelle: BMW

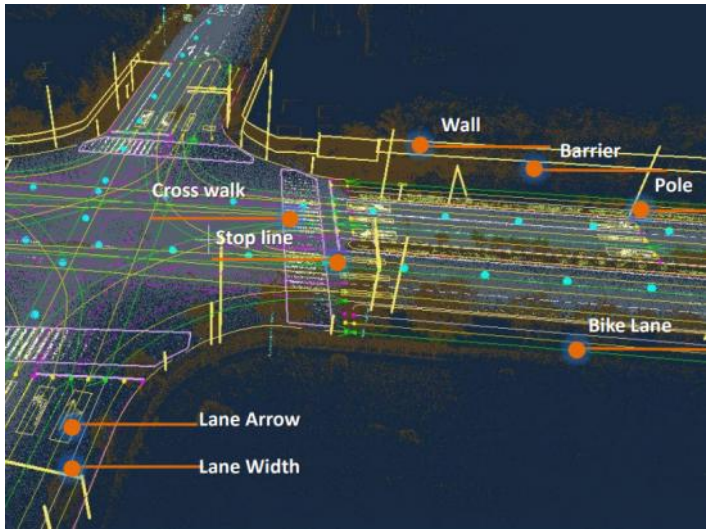
AKTUELLE TECH TRENDS (2/3): BMW-BEISPIEL – ERSTELLUNG VON HD MAPS



Quelle: BMW

AKTUELLE TECH TRENDS (3/3): BMW-BEISPIEL – ERSTELLUNG VON HD MAPS





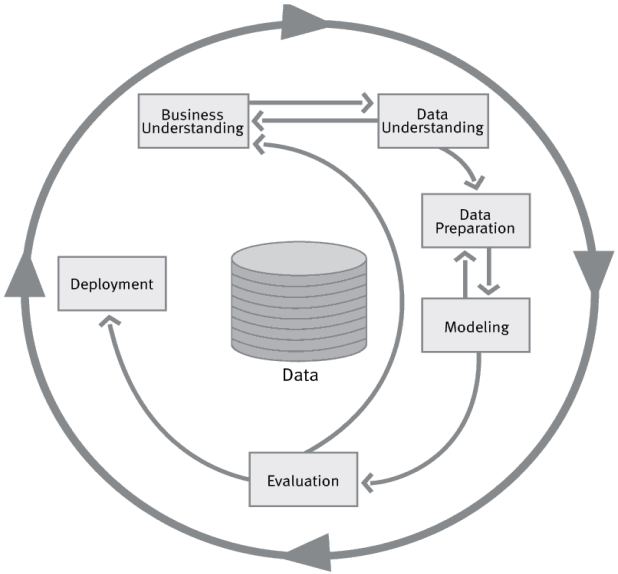
Quelle: BMW

DATA MINING

- Definition: **Data Mining** ist das semi-automatische Aufdecken von Mustern mittels Datenanalyseverfahren in meist sehr großen und hochdimensionalen Datenbeständen.
- Auswertung der Daten mithilfe von Statistik und KI

Cross Industry Standard Process for Data Mining (CRISP-DM):

- Business understanding
  - Ziele und Anforderungen des Projekts werden definiert
- Data understanding
  - Datenqualität wird geprüft
  - Daten werden analysiert
- Data preparation
  - Bereinigung der Daten
  - Konstruktion der Daten (Entwicklung hilfreicher Attribute, z.B. ergibt sich der BMI aus Größe und Gewicht)
  - Integration der Daten, z.B. Integration von 2 Datensätzen
- Modeling
  - Auswahl eines Algorithmus
  - Erstellen und Testen von Modellen
- Evaluation
  - Bewertung der Resultate
- Deployment
  - Einsatz und Überwachung der Modelle



Quelle: Cross Industry Standard Process for Data Mining (Wirth/Hipp 2000)

AGENDA

- Blockchain
- Data Warehouse
- Big Data
- **Maschinelles Lernen**
- Deep Learning
- GenAI
- LLMs
- Risiken von Daten & KI

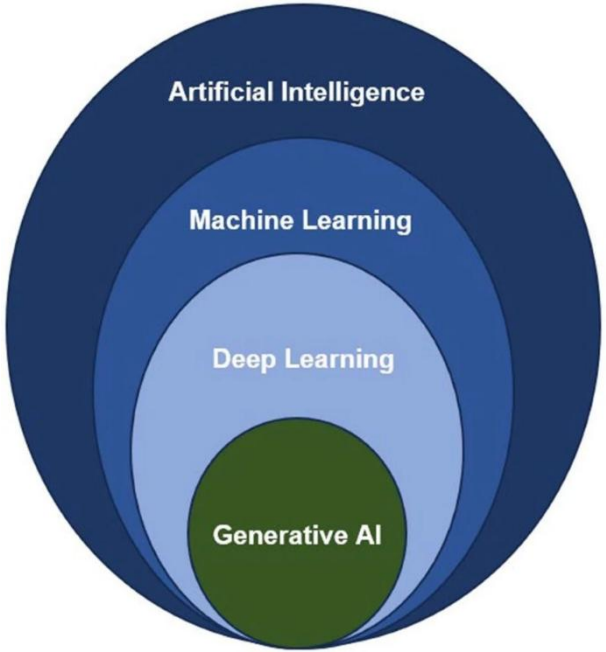
KÜNSTLICHE INTELLIGENZ

- Künstliche Intelligenz ist **keine einzelne Technologie**, sondern eine sich ständig weiterentwickelnde Grenze neuer rechnerischer Fähigkeiten.
- Die maschinellen Lernverfahren, verfügen über eine **große Autonomie**, tiefe **Lernfähigkeit** und sind **undurchsichtig**

Zentrale Konzepte der KI (Berente et al., 2021)

Konzept	**Definition**
Künstliche Intelligenz	Die Grenze rechnerischer Fortschritte, die sich auf menschliche Intelligenz beziehen, um immer komplexere Entscheidungsprobleme zu lösen.
Dimensionen der KI-Grenze	
Leistungsgrenze	Die stetig verbesserte Ausführung von Aufgaben, auf die KI angewendet wird.
Anwendungsbereichsgrenze	Die stetig erweiterte Bandbreite an Kontexten, auf die KI angewendet wird.
Aspekte der KI	
Autonomie	Handeln ohne menschliches Eingreifen.
Lernen	Verbesserung durch Daten und Erfahrung.
Unergründlichkeit	Für bestimmte Zielgruppen unverständlich sein.

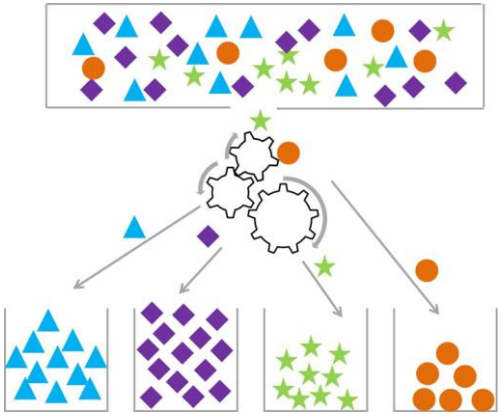
ZUSAMMENHANG VERSCHIEDENER KONZEPTE



MASCHINELLES LERNEN

Unterschiedliche Lernverfahren

- **Überwachtes Lernen** (Supervised Learning)
  - (jedes im Lernverfahren genutzte Datum hat ein Label und somit einen erwarteten Outcome)
- **Unüberwachtes Lernen** (Unsupervised Learning)
  - Identifiziert Abhängigkeiten zwischen Eingabedaten
  - Bildung von Clustern (von ähnlichen Objekten) oder Lösungen von Optimierungsproblemen
- **Verstärkendes Lernen** (Reinforcement Learning)
  - Es wird eine Zielfunktion angestrebt
  - Für ein gegebenes Problem wird eine optimale Strategie erlernt



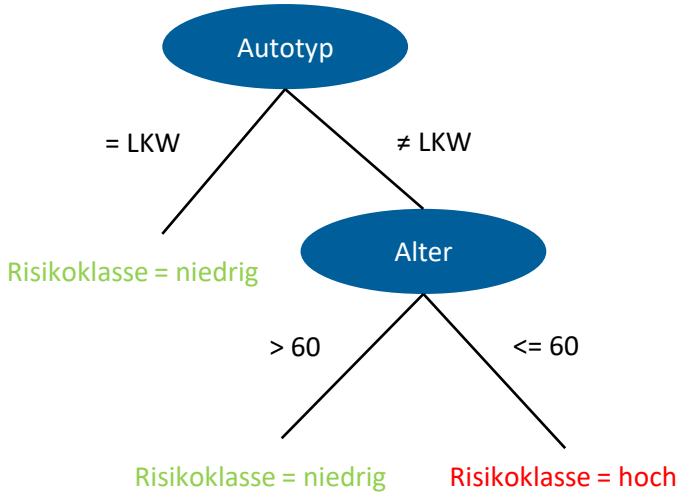
BEISPIEL FÜR EINEN SUPERVISED LEARNING ALGORITHMUS

- **Entscheidungsbaum zur Lösung von Klassifikationsproblemen**
  - innere Knoten repräsentieren Attribute
  - Kante repräsentieren einen Test auf dem Attribut
  - Blätter repräsentieren eine Klasse
- Konstruktion anhand der Datenbasis
- **Basis Algorithmus**
  - Am Anfang liegen alle Daten gemeinsam an der Wurzel des Baums.
  - Dann wird ein passendes Attribut ausgewählt, um die Daten aufzuteilen.
  - Mit diesem Merkmal werden die Daten in Gruppen aufgeteilt

BEISPIEL FÜR EINEN SUPERVISED LEARNING ALGORITHMUS

Beispiel für einen Entscheidungsbaum

ID	Alter	Autotyp	Risiko
1	23	Familie	hoch
2	17	Familie	hoch
3	43	Sport	hoch
4	68	Familie	niedrig
5	32	LKW	niedrig



ANWENDUNGSBEISPIELE FÜR ÜBERWACHTES LERNEN

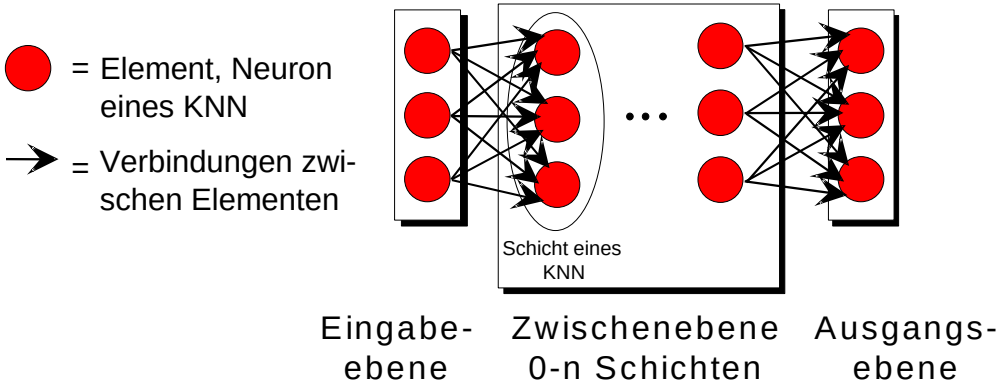
Anwendung	Trainingsform	Labels
Spamfilter	E-Mails	Spam & ungewöhnliche E-Mails
Kreditwürdigkeitsprüfung	Vergebene Kredite	Korrekte Transaktionen & Betrugsfälle
Visual Inspection	Bildaufnahmen	Korrekte & fehlerhafte Werkstücke
Intelligentes Ticket-Routing	Serviceanfragen	Ticket-Zuständigkeiten
Spracherkennung	Texte	Sprache
Krankheitserkennung	Gesundheitsdaten	Erkrankte & gesunde Patienten

AGENDA

- Blockchain
- Data Warehouse
- Big Data
- Maschinelles Lernen
- **Deep Learning**
- GenAI
- LLMs
- Risiken von Daten & KI

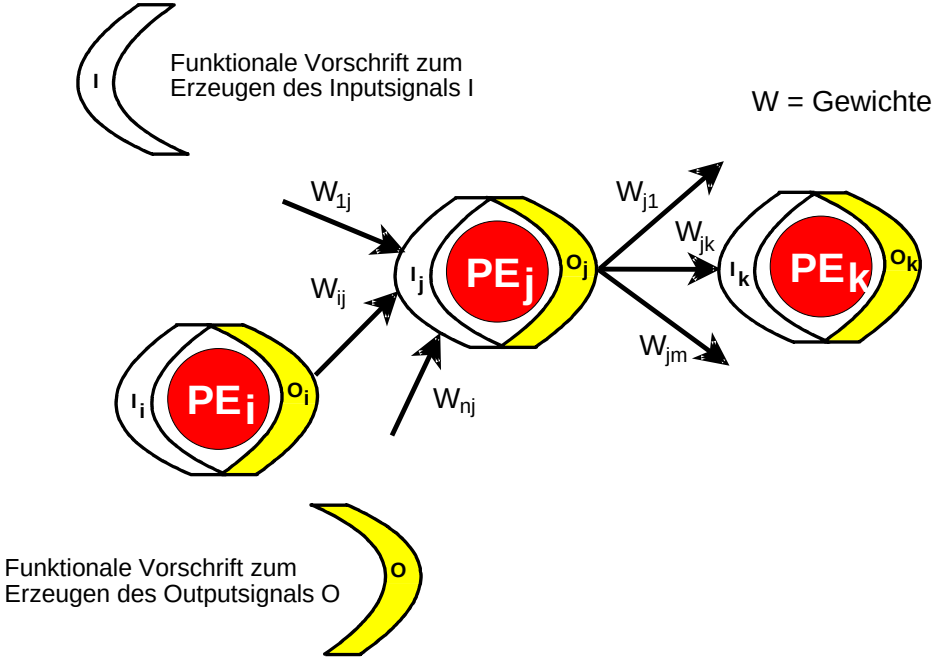
GRUNDLAGEN NEURONALES NETZ

- Künstliche neuronale Netze sind vom menschlichen Gehirn inspirierte Computerprogramme und erkennen Muster in Daten, indem sie Informationen durch miteinander verbundene Schichten von künstlichen Neuronen verarbeiten.
- Bei besonders vielen Schichten spricht man von Deep-Learning (deep = tief).
- Deep-Learning-Modelle werden für komplexe Aufgaben wie Bild- und Spracherkennung sowie für Anwendungen wie Sprachassistenten und medizinische Diagnosen eingesetzt.
- Gelernt wird durch das Anpassen der Gewichtungen zwischen den Neuronen, basierend auf Trainingsdaten.



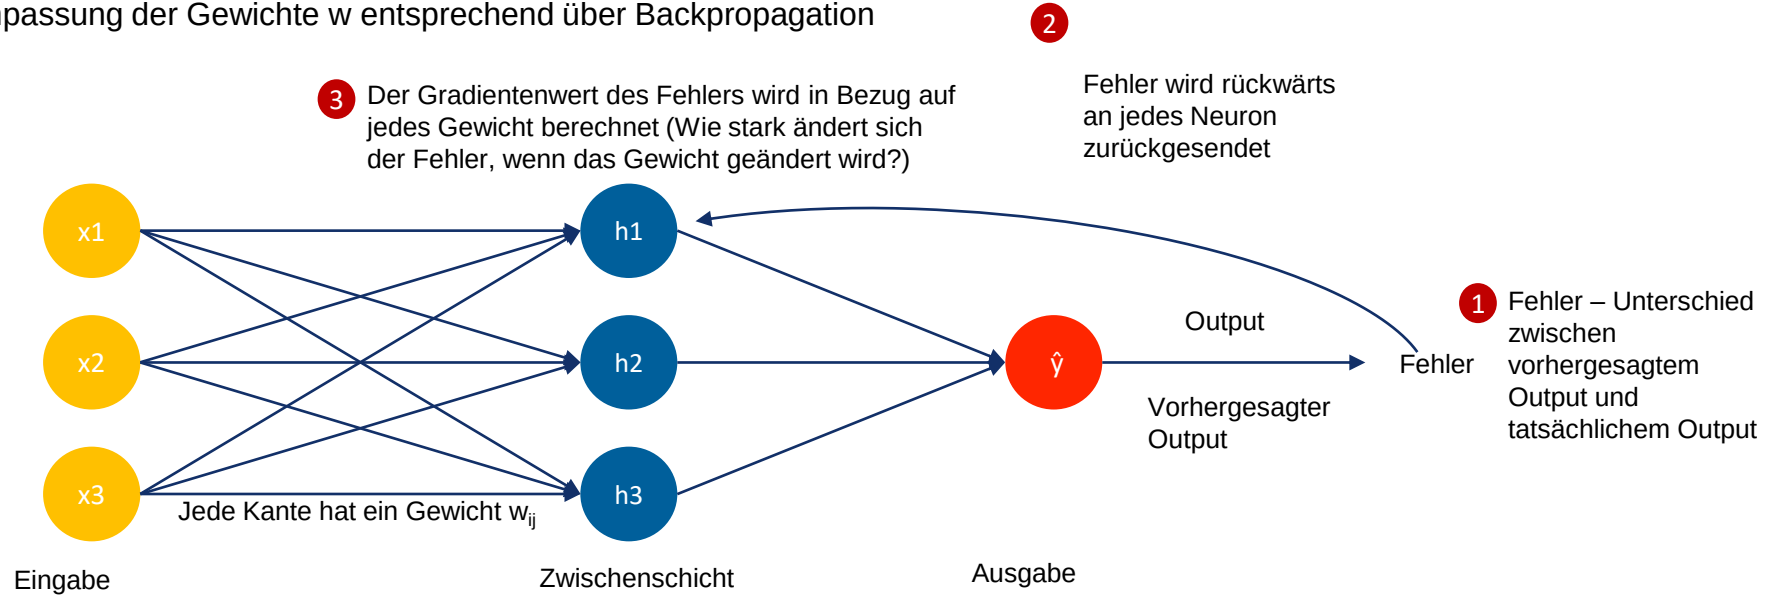
FUNKTIONSWEISE NEURONEN

- Neuronen bekommen Eingangssignale von anderen Neuronen, verarbeiten diese und geben dann Ausgangssignale weiter. Jedes Neuron erhält dabei mehrere Inputs, die über Gewichte verstärkt oder abgeschwächt werden.
- Diese Gewichte bestimmen, wie wichtig ein Signal ist.
- Das Neuron kombiniert die gewichteten Eingaben und erzeugt daraus einen neuen Output – über mathematische Funktionen (Aktivierungsfunktion).
- Die ausgegebenen Signale eines Neurons dienen wiederum als Inputs für andere Neuronen.



LERNPROZESS IM ÜBERWACHTEN LERNEN

- Zunächst sind Kantengewichte w zufällig initialisiert
- Modell lernt anhand gekennzeichneter Datenpaare (Trainingsdaten)
  - Veranschaulichung: für eine Eingabe x wird die Ausgabe y erwartet
- Anpassung der Gewichte w entsprechend über Backpropagation



LERNPROZESS IM ÜBERWACHTEN LERNEN

Lossfunction

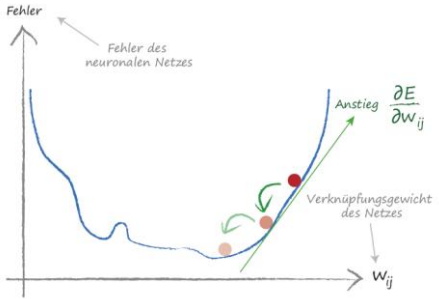
- Misst, wie gut/schlecht die Vorhersage ist
- Ziel im Lernprozess: Fehler minimieren
- Beispiel Lossfunction: Mean Squared Error (MSE) für lineare Regressionen

$$\frac{1}{N}\sum(tatsächlicherWert - prognostizierterWert)^2$$

Gradient Descent

- Ziel: optimale w ermitteln, um Fehler zu minimieren
- Analogie: Sie befinden sich in einem dunklen Tal und müssen den niedrigsten Punkt finden und tasten sich Stück für Stück vor





AGENDA

- Blockchain
- Data Warehouse
- Big Data
- Maschinelles Lernen
- Deep Learning
- **GenAI**
- LLMs
- Risiken von Daten & KI

GENAI - DEFINITION

Definiere generative KI!

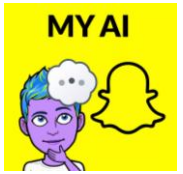
Generative Künstliche Intelligenz (generative KI) bezeichnet eine Klasse von KI-Systemen, die in der Lage sind, eigenständig neue Inhalte zu erzeugen – wie Texte, Bilder, Musik, Videos, Codes oder sogar 3D-Modelle. Dabei nutzt generative KI bestehende Daten als Trainingsbasis, um Muster zu erkennen und daraus Neues zu generieren, das dem Gelernten ähnlich, aber nicht identisch ist.

GENAI-NUTZUNG IN DEUTSCHLAND

2022		2023		2024	
ChatGPT	19%	ChatGPT	28%	ChatGPT	48%
DeepL	11%	Meta AI	12%	Google Gemini	20%
YouChat	6%	Snapchat My AI	10%	Snapchat My AI	18%
Simplified	5%	Google Gemini	10%	Meta AI	14%
Jasper	5%	DeepL	10%	DeepL	14%
DALL-E	4%	Microsoft Bing AI	8%	Microsoft Copilot	11%
Neeva	4%	Adobe Firefly	5%	Microsoft Bing AI	10%
Midjourney	4%	DALL-E	4%	Adobe Firefly	5%

ChatGPT

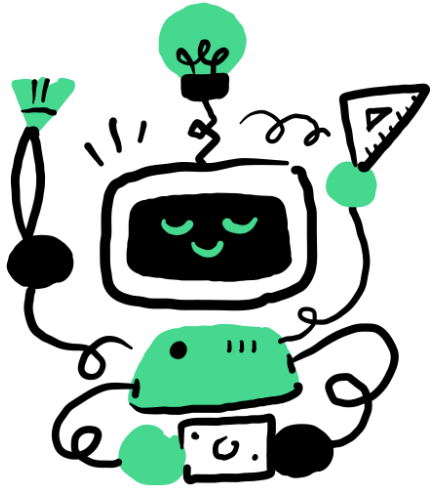




Quelle: https://de.statista.com/infografik/33526/nutzung-von-ki-tools-in-deutschland/

EINSATZPOTENZIALE VON GENAI

- Kreative Arbeit
  - Ideen generieren und ausbauen
- Recherche
- Schreiben
  - Hilfestellung bei E-Mails oder Protokollen
  - Formulierungen und Struktur
  - Aufbrechen von Schreibblockaden
- Analyse von Texten
  - Zusammenfassungen
  - Analyse auf bestimmte Merkmale
- Übersetzungen
- Bild/Video/Musik
- Hilfe bei Organisation von Tasks durch Strukturierung …

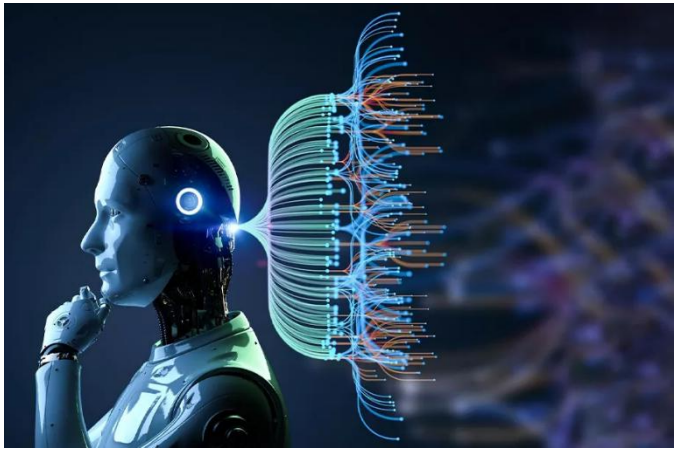


AGENDA

- Blockchain
- Data Warehouse
- Big Data
- Maschinelles Lernen
- Deep Learning
- GenAI
- **LLMs**
- Risiken von Daten & KI

WAS IST EIN LARGE LANGUAGE MODEL (LLM)?

- LLMs bilden die Grundlage von GenAI
- Aus den vielen Komponenten eines GenAI-Systems bildet das LLM das Herzstück
- Trainiert auf massiven Datensätzen, können LLMs Texte, Analysen, Code oder Inhalt in Echtzeit generieren
- Trainingsdaten reichen von breiten Textquellen (Web, Bücher) bis zu domänenspezifischen (z.B. Recht, Medizin, Marketing)
- LLMs verarbeiten Sprache in drei zentralen Schritten:
  1. Tokenisierung
  2. Embeddings
  3. Inference

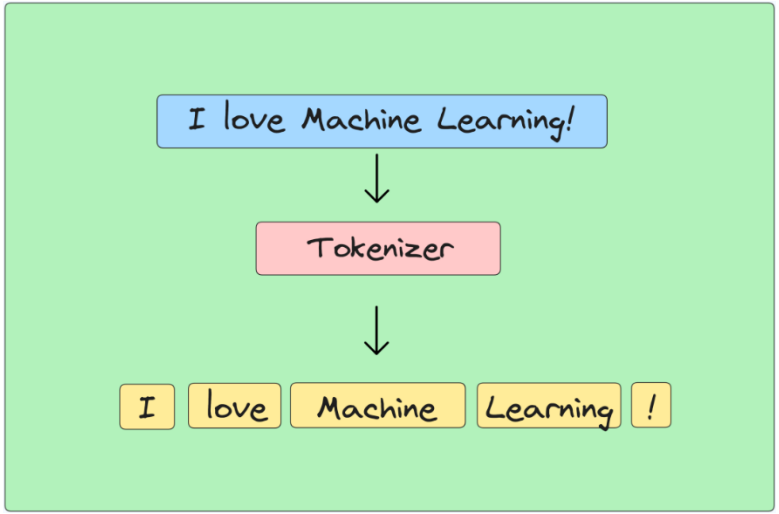


Bildquelle: https://www.xoriant.com/blog/developments-and-breakthroughs-in-large-language-model-research

Quelle: Blanchard et al. (2025). New Tools, New Rules: A Practical Guide to Effective and Responsible Generative AI Use for Surveys and Experiments in Research. Journal of Marketing, 89(6), 119–139. https://doi.org/10.1177/00222429251349882

1. TOKENISIERUNG: WIE TEXT „VERSTANDEN“ WIRD

- Text wird in Tokens zerlegt
- Tokens können z.B. ganze Wörter, Teilwörter oder Zeichen sein
- Beispiel: „Limited-time offer on unbelievably good deals!“
  - ➢ [Limited, -time, offer, on, unbelie, vably, good, deals, !]
- Häufige Wörter werden zu einem Token, seltenere werden zu mehreren Tokens aufgeteilt (z.B. „unbelievably“ -> „unbelie“ + „vably“)
- Vorteil: Auch seltene Wörter können verstanden werden, da das Modell Muster aus bekannten Wörtern erkennt



Bildquelle: https://www.linkedin.com/pulse/tokenization-nlp-basic-concepts-part-1-10-shariq-hameed-3yslf

Quelle: Blanchard et al. (2025). New Tools, New Rules: A Practical Guide to Effective and Responsible Generative AI Use for Surveys and Experiments in Research. Journal of Marketing, 89(6), 119–139. https://doi.org/10.1177/00222429251349882

2. VON TOKEN ZU EMBEDDINGS

- Grundidee: Wörter, welche in ähnlichen Kontexten vorkommen, haben eine ähnliche Bedeutung
- Jedes Token bekommt eine ID (z.B. „Limited“ = 75577)
- Über eine Embedding Matrix wird diese ID in einen hochdimensionalen Vektor (z.B. 4096 Werte) übersetzt
- Diese Vektoren liegen im gleichen Raum -> Modell kann Tokens vergleichen und Kontexte bilden
- Anfänglich sind die Vektoren aber nur Zahlenarrays, die erst durch Training eine Bedeutung erhalten

Quelle: Blanchard et al. (2025). New Tools, New Rules: A Practical Guide to Effective and Responsible Generative AI Use for Surveys and Experiments in Research. Journal of Marketing, 89(6), 119–139. https://doi.org/10.1177/00222429251349882

MODELLTRAINING: WIE LLMS LERNEN

- Ziel: LLM lernt, den Kontext zur Vorhersage des nächsten Tokens zu nutzen
- Beispiel: „model“ -> Modebranche oder Large Language **Model** -> Kontext entscheidet
- Training besteht aus iterativem Prozess aus Vorhersage + Feedback
- Inputs werden durch mehrere Layers geschickt, wodurch das Modell Beziehungen zwischen Tokens lernt
- Self-Attention: Weist jedem Token eine Bedeutungsgewichtung zu, abhängig vom Kontext
- Kontextlänge hat sich stark erhöht: GPT-2 (1024 Tokens) -> GPT-4o (128000 Tokens)

Quelle: Blanchard et al. (2025). New Tools, New Rules: A Practical Guide to Effective and Responsible Generative AI Use for Surveys and Experiments in Research. Journal of Marketing, 89(6), 119–139. https://doi.org/10.1177/00222429251349882

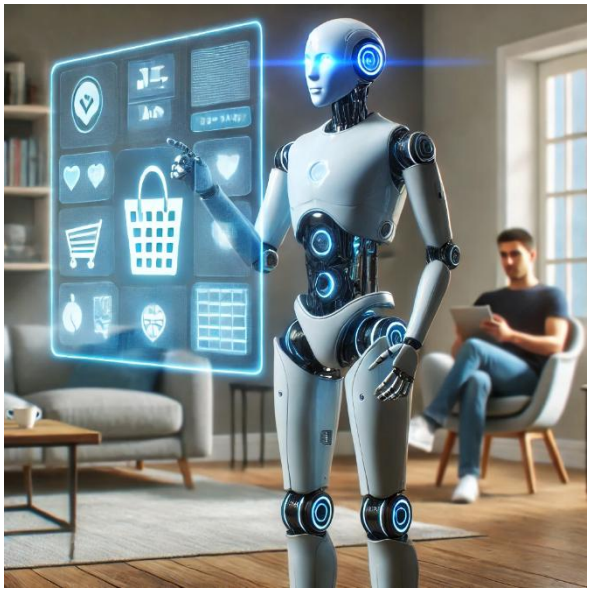
3. INFERENCE: WIE LLMS ANTWORTEN GENERIEREN

- Innerhalb der Inference-Phase (keine Lernphase mehr) können Outputs generiert werden
- Prompt wird tokenisiert -> Modell berechnet eine Wahrscheinlichkeitsverteilung für das nächste Token
- Beispiel: P(„Consider“) = 0.4, P(„Try“)= 0.2, P(„Use“)= 0.15 usw.
- Modell wählt Token -> fügt es an -> wiederholt den Prozess bis Antwort vollständig ist
- So entstehen Texte Token für Token

Quelle: Blanchard et al. (2025). New Tools, New Rules: A Practical Guide to Effective and Responsible Generative AI Use for Surveys and Experiments in Research. Journal of Marketing, 89(6), 119–139. https://doi.org/10.1177/00222429251349882

EINSCHUB AGENCY

- Agency beschreibt die Fähigkeit eines Akteurs (z. B. Mensch oder Maschine), autonom zu handeln und Entscheidungen zu treffen.
- Digitale Agency nach Ågerfalk (2020): *capability of machines to act autonomously, but on behalf of humans, organisations and institutions.*
- Digitale Agency beinhaltet kein eigenes Bewusstsein



Quelle: Ågerfalk, P. J. (2020). Artificial intelligence as digital agency. European Journal of Information Systems, 29(1), 1-8.

EINSCHUB AGENCY

Agentische Archetypen informationssystemischer Artefakte nach Baird & Maruping (2021)

Begrenzte Entscheidungskompetenz (reaktiv)

Umfassende Entscheidungskompetenz (autonom)

Agentische Archetypen	Beispiele	Was ist anders?
Reflexiv (d. h. reaktiv)	• Sensor- und Aktionsagenten (oder Warnagenten), z. B. Rebalancing eines Finanzportfolios, wenn die Allokation aus dem Gleichgewicht ist	Diese Agenten handeln reflexiv als direkte Reaktion auf relevante Reize. Entscheidungen sind auf Modelle beschränkt, die definieren, wie auf erwartete Reize zu reagieren ist.
Überwachend (d. h. Kontrollsystem)	• Systeme zur Verhaltensmodifikation (z. B. Entscheidungshilfen, Umgebungsintelligenz, Gesundheitshinweise, Finanzhandelsempfehlungen)	Überwachende Agenten bewerten Abweichungen von der Norm (oder dem Fortschritt eines Ziels) und versuchen, Entscheidungen zu lenken oder Maßnahmen zu ergreifen, die helfen, zur Norm zurückzukehren oder die Wahrscheinlichkeit des Fortschritts zu einem bestimmten Ziel zu erhöhen.
Antizipierend (d. h. proaktiv)	• Soziale Medienagenten zur Suche, Filterung und Präsentation von Inhalten • Digitale Inhaltszusammenstellung (z. B. automatische Erstellung von Videos oder Alben)	Antizipierende Agenten wenden modellbasiertes „Vorausdenken“ proaktiv an, um Bedürfnisse oder Wünsche zu erkennen (z. B. das Artefakt erstellt automatisch Medienzusammenstellungen).
Vorschreibend (d. h. autonome Entscheidungsfindung)	• Bots (z. B. Chatbots, Suchbots, Filter-Bots für Lebensläufe) • Autonome Fahrzeuge • Automatisiertes Finanzportfoliomanagement	Vorschreibende Agenten fungieren als Ersatz für verhaltens- oder ergebnisbasierte Entscheidungen, indem sie Handlungen vorschreiben oder Entscheidungen treffen.

AGENDA

- Blockchain
- Data Warehouse
- Big Data
- Maschinelles Lernen
- Deep Learning
- GenAI
- LLMs
- **Risiken von Daten & KI**

DIE BEDEUTUNG VON DATEN

- Für das Trainieren wird eine große Menge an gelabelten Daten benötigt
- Jedes KI-Modell ist nur so gut, wie die zugrunde liegende Datenbasis („garbage in, garbage out“-Prinzip)
- In Datensatz existierende Vorurteile werden mitgelernt
  → KI kann diskriminierend, unfair oder rassistisch sein
- Eine Hohe Datenqualität ist zentraler Erfolgsfaktor für KI-Anwendungen

AUSWAHL UNTERSCHIEDLICHER BIAS-TYPEN

- Bias = Verzerrung

- Historischer Bias
  Stereotype und Ungleichheiten aus der realen Welt werden auch dann reproduziert, wenn die Trainingsdaten objektiv korrekt sind.
  → *Vergangenheit wird unkritisch in die Zukunft fortgeschrieben.*

- Representation Bias
  Bestimmte Bevölkerungsgruppen sind in den Daten unterrepräsentiert.
  → *Das Modell „sieht" manche Menschen schlechter oder gar nicht.*

- Measurement Bias
  Fehlerhafte oder eingeschränkte Messung von Merkmalen oder Zielvariablen.
  → *Was nicht gut gemessen wird, wird auch nicht gut gelernt.*

- Aggregation Bias
  Unterschiedliche Gruppen werden mit demselben Modell behandelt, obwohl sie differenziert werden müssten.
  → *„One size fits all" funktioniert nicht für alle gleich gut.*

- Evaluation Bias
  Verzerrung durch unpassende Testdaten – z. B. andere Qualität oder Merkmalsverteilungen als im Training.
  → *Bewertung auf falscher Grundlage.*

SCHWÄCHEN & RISIKEN VON KI (1)

Schwächen von KI

- Opacity
  - Black Box Charakter
  - Fehlende Nachvollziehbarkeit bzgl. Wahrheitsgehalt durch hohe Komplexität der Modelle
- Autonomie und Verantwortung
  - Treffen von Entscheidungen durch die KI ohne menschliches Eingreifen
  - Verantwortung bei Fehlentscheidungen
  - Bsp: Autonomes Fahren – Was geschieht, wenn es durch einen Fehler zu einem Unfall kommt?
  - Machtverschiebung von Menschen zu Maschinen
- Fehlentscheidungen möglich, z.B. durch Bias



KI auf krimineller Angreiferseite nutzbar für:

- Passwort Cracking
- Social Engineering über Deepfakes

SCHWÄCHEN & RISIKEN VON KI (2)

Risiken beim Einsatz im Alltag:

- Verarbeitung personenbezogener/Sensibler Daten
  - Beispiel: Bewertung von Bewerbungen
- Übernahme des Outputs ohne Prüfung
  - Halluzination (insbesondere bei GenAI)
- Universitätskontext
  - Einsatz von GenAI ohne dessen Nennung als Hilfsmittel oder ohne Erlaubnis
- Berufliche Kontexte
  - Kundendatenverarbeitung ohne Kontrolle → DSGVO-Verstoß
  - Kreativinhalte (Marketing, Design) ohne Urheberprüfung → Copyright-Problem

EU-AI-Act zur Regulierung von KI in der EU:

https://www.europarl.europa.eu/topics/en/article/20230601STO93804/eu-ai-act-first-regulation-on-artificial-intelligence

LERNZIELE DES KAPITELS “MANAGEMENT VON DATEN”

NACH DIESEM KAPITEL SIND SIE IN DER LAGE:

- Die grundlegende Funktionsweise einer **Blockchain** zu erläutern
- Grundlegende Prinzipien **verteilter Datenbanksysteme** und **Data-Warehouse Lösungen** zu erläutern und zu bewerten
- Die Grundlagen und Anwendungsgebiete von **Big Data** zu erläutern
- Die Funktionsweise von **neuronalen Netzen** zu erklären
- Die **Potenziale und Gefahren** bei der Nutzung von GenAI und KI zu beschreiben

Q&A-SESSION





DANKE FÜR IHRE AUFMERKSAMKEIT!

Prof. Dr. Martin Adam

martin.adam@uni-goettingen.de