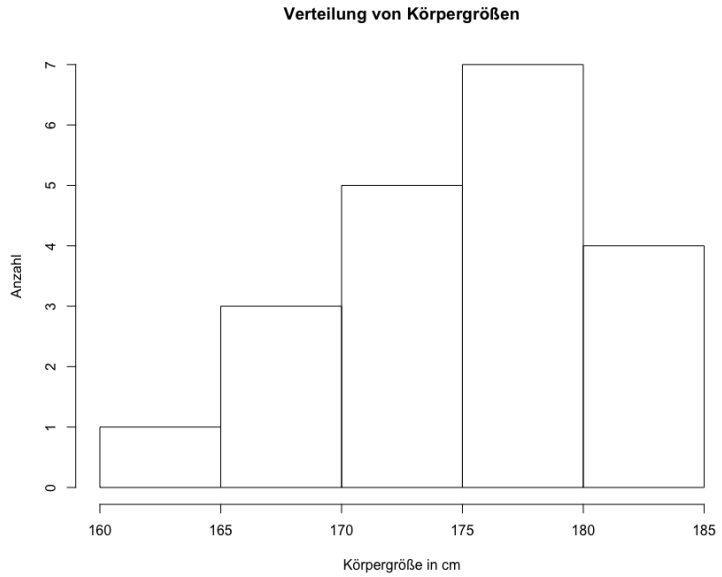
Deskriptive Statistik I

Notwendiges Vorwissen

- Kapitel Deskriptive Statistik 1
- Wissen über Stichproben

Aufgabe 1. *(knobel)*

In einer kleinen Umfrage wurden 20 Personen zu ihrer Körpergröße befragt. Das Ergebnis der Umfrage wurde in einer Grafik dargestellt.



(a) Schätzen Sie den Anteil von Beobachtungen in der Grundgesamtheit in den folgenden Intervallen mithilfe der Grafik.

(i) $[160, 172]$

(ii) $(167, 185]$

(iii) $(173, 184]$

(b) Nehmen Sie an, Sie sollen aus der Grafik ein (normiertes) Histogramm erstellen. Welche y-Werte würden Sie den einzelnen Säulen zuweisen?

(c) Ihr Kommilitone behauptet, dass bei einer Grundgesamtheit von $20\,000$ Personen $7\,000$ zwischen 175 und 180 cm groß sind. Stimmen Sie zu? Begründen Sie Ihre Entscheidung.

Hinweis zu Aufgabenteil (b): Bei einem (normierten) Histogramm ist die Fläche der einzelnen Säulen proportional zu der relativen oder absoluten Häufigkeit dieser Klasse. Zusätzlich muss der Flächeninhalt aller Säulen zusammen 1 ergeben.

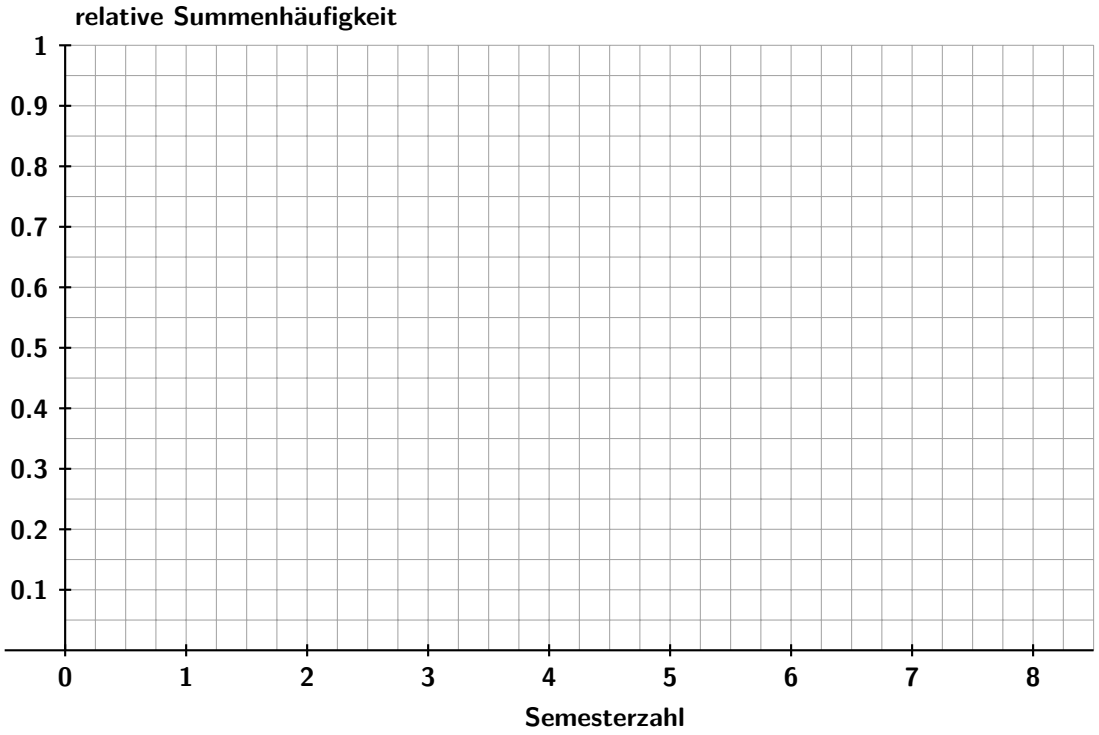
Aufgabe 2. *(basis)*
Die folgende Tabelle enthält die Semesterzahlen der Teilnehmer an der Klausur *Fortgeschrittene Mathematik für Wirtschaftswissenschaftler* am $11.02.2009$:

Semesterzahl:	2	3	4	5	6	7	$\sum$
h_j	1	7	5	5	1	4	
$f_j = {}^{h_j}/_{n}$							
H_j							-
$F_j = {}^{H_j}/_{n}$							-

Anmerkung:
$h_j =$ absolute Häufigkeit
$H_j =$ absolute Summenhäufigkeit (absolute kumulierte Häufigkeit)

(a) Vervollständigen Sie die obige Tabelle, indem Sie die relativen Häufigkeiten, absoluten und Summenhäufigkeiten berechnen.

(b) Zeichnen Sie die empirische Verteilungsfunktion der relativen Summenhäufigkeiten in die folgende Grafik.



(c) Bestimmen Sie die Anteile der Studierenden, deren Semesterzahl

(i) größer als 3,

(ii) mindestens 3,

(iii) kleiner als 4,

(iv) nicht größer als 5 ist.

Aufgabe 3.
Die R-Sammeldatei (R-Sammeldatei.R auf StudIP im Ordner Datensätze) enthält die Teildatensätze `Gewicht_m` und `Gewicht_w`. Diese enthalten Gewichtsangaben von männlichen und weiblichen Studierenden. Für diese Aufgaben wird der Teildatensatz männlicher Studierender benötigt.

(a) Stellen Sie den Teildatensatz `Gewicht_m` mithilfe des Befehls `hist()` in einem Diagramm mit absoluten Häufigkeiten auf der y-Achse in R dar, ohne Klassenbreiten vorzugeben. Wie breit sind die Klassen?

(b) Stellen Sie den Teildatensatz `Gewicht_m` in einem Diagramm mit absoluten Häufigkeiten auf der y-Achse in R dar. Geben Sie R die Klassengrenzen („`breaks`“) $40,\ 70,\ 100,\ 130$ und 160 vor. (Beschriften Sie zusätzlich die Achsen und geben Sie der Graphik eine Überschrift.)

(c) Benutzen Sie folgenden Befehl, nachdem Sie Aufgabe b) ausgeführt haben:
`axis(1, Gewicht_m)`
Beschreiben Sie, was dieser Befehl verändert. Welche Vor- und Nachteil gibt es?

(d) Lassen Sie sich die Kennzahlen des Diagramms in der R-Konsole ausgeben, ohne das Diagramm grafisch darzustellen. Füllen Sie mithilfe des Outputs folgende Tabelle aus:

Intervall	h_j	$f_j = {}^{h_j}/_{n}$	H_j	$F_j = {}^{H_j}/_{n}$
$[40, 70]$				
$(70, 100]$				
$(100, 130]$				
$(130, 160]$				

(e) Zeichnen Sie das zugehörige Diagramm mit absoluten Häufigkeiten auf der y-Achse per Hand. Überprüfen Sie ihr Ergebnis mithilfe von R.

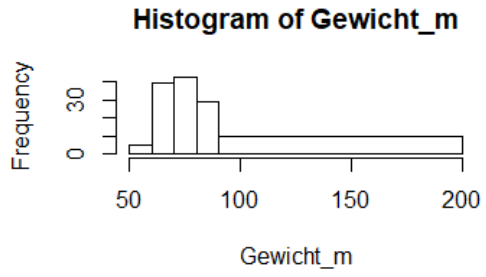
(f) Skalieren Sie die y-Achse so, dass die Gesamtfläche der Säulen 1 ergibt. Was müssen Sie hierfür auf der y-Achse abtragen?

(g) Bestimmen Sie jeweils den Anteil und die Anzahl von Beobachtungen, die

(i) kleiner gleich 100 sind,

(ii) zwischen 70 und 130 (einschließlich 130) liegen.

(h) Mit dem Befehl: `hist(Gewicht_m, breaks = c(50, 60, 70, 80, 90, 200), prob=F)` erhält man folgenden Output:



Wieso handelt es sich hierbei nicht um ein (normiertes) Histogramm? Was ist der Nachteil dieser Darstellung?

(i) Wie könnte der R-Befehl geändert werden, um ein (normiertes) Histogramm zu erhalten?

Aufgabe 4. *(basis)*
Erinnern Sie sich an Aufgabe 1: Die folgende Tabelle enthält die Semesterzahlen der Teilnehmer an der Klausur *Fortgeschrittene Mathematik für Wirtschaftswissenschaftler* am $11.02.2009$:

Semesterzahl:	2	3	4	5	6	7	$\sum$
h_j	1	7	5	5	1	4	23
$f_j = {}^{h_j}/_{n}$	${}^{1}/_{23}$	${}^{7}/_{23}$	${}^{5}/_{23}$	${}^{5}/_{23}$	${}^{1}/_{23}$	${}^{4}/_{23}$	1
H_j	1	8	13	18	19	23	-
$F_j = {}^{H_j}/_{n}$	${}^{1}/_{23}$	${}^{8}/_{23}$	${}^{13}/_{23}$	${}^{18}/_{23}$	${}^{19}/_{23}$	${}^{23}/_{23}$	-

Anmerkung:
$h_j =$ absolute Häufigkeit
$H_j =$ absolute Summenhäufigkeit (absolute kumulierte Häufigkeit)

Bestimmen Sie die folgenden Kennzahlen: Mittelwert, Median, Modus, Varianz und Standardabweichung.

Aufgabe 5. *(basis)*
In der Zeitschrift Forschung und Lehre, Heft $3/09$ berichtet Prof. Dr. M. Ferrari, Universität Erlangen-Nürnberg über eine im Zusammenhang mit der elektronisch durchgeführten Evaluation der Lehre durchgeführte Befragung der Studierenden an der Philosophischen Fakultät und am Fachbereich Theologie. Es gab die folgenden Antworten zu den Fragen:
Wie lange arbeiten Sie pro Woche während der Vorlesungszeit?
Wie lange haben Sie pro Woche zuletzt während der vorlesungsfreien Zeit gearbeitet?

Stunden	Vorlesungszeit	Vorlesungsfreie Zeit
$[0, 4]$	40.2%	25.4%
$(4, 8]$	19.6%	14.4%
$(8, 12]$	21.9%	16.5%
$(12, 16]$	18.3%	43.7%

(a) Welche Klasse ist jeweils die Modalklasse?

(b) Bestimmen Sie jeweils näherungsweise das arithmetische Mittel und die Varianz. Nutzen Sie die Mitten der Klassen als Hilfe.

Aufgabe 6. *(basis)*
Betrachten Sie die folgenden drei Datensätze.

	Datensatz I:	Datensatz II:	Datensatz III:
x_1	7	7	14
x_2	14	9	18
x_3	5	5	10
x_4	8	8	16
x_5	6	6	12

(a) Berechnen Sie zunächst jeweils das arithmetische Mittel und den Median der Datensätze I und II. Was fällt Ihnen auf? Erklären Sie das Ergebnis kurz.

(b) Versuchen Sie nun **ohne Berechnung der Varianz** einen Zusammenhang zwischen den Varianzen der Datensätze II und III zu formulieren. Überprüfen Sie diesen Zusammenhang danach rechnerisch, indem Sie die Varianzen ausrechnen.

Aufgabe 7.
Auf dem Campus wurden 20 Studierende gefragt, in welchem Semester sie sich aktuell befinden. Die Ergebnisse der Umfrage wurden in einer Tabelle aufbereitet.

i	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
x_i	4	2	1	6	3	1	1	7	13	4	6	6	1	14	5	9	3	2	6	3

(a) Zeichnen Sie den dazugehörigen Boxplot in R, indem Sie zuerst die Ergebnisse der Stichprobe in der Variablen x speichern und die Ergebnisse dann als Boxplot darstellen.

R benutzt folgende Methode, um die Whiskers zu bestimmen:
Sei $X \in \mathbb{R}^n$ ein Set, für den ein Boxplot erstellt werden soll. Die Whiskers werden dann folgendermaßen in R berechnet:
Obere Grenze:
Richtwert $x_{ROW} = \tilde{x}_{0.75} + 1.5 \cdot \text{IQR}$ (ROW = Richtwert Oberer Whisker)
Oberer Whisker $x_{OW} = max(\{x \in X : x \leq x_{ROW}\})$
Untere Grenze
Richtwert $x_{RUW} = \tilde{x}_{0.25} - 1.5 \cdot \text{IQR}$ (RUW = Richtwert Unterer Whisker)
Unterer Whisker $x_{UW} = min(\{x \in X : x \geq x_{RUW}\})$

(b) Benutzen Sie die von R verwendete Methode, um die Whiskers zu bestimmen. Überprüfen Sie Ihre Ergebnisse in R. Nutzen Sie dazu das optionale Argument `plot = F` in Ihrem Boxplot-Befehl.

(c) Betrachten Sie den Median im Verhältnis zu dem ersten und dritten Quartil. Was fällt Ihnen auf? Handelt es sich dabei um eine Besonderheit oder zeichnen sich alle Boxplots dadurch aus?