Deskriptive Statistik I

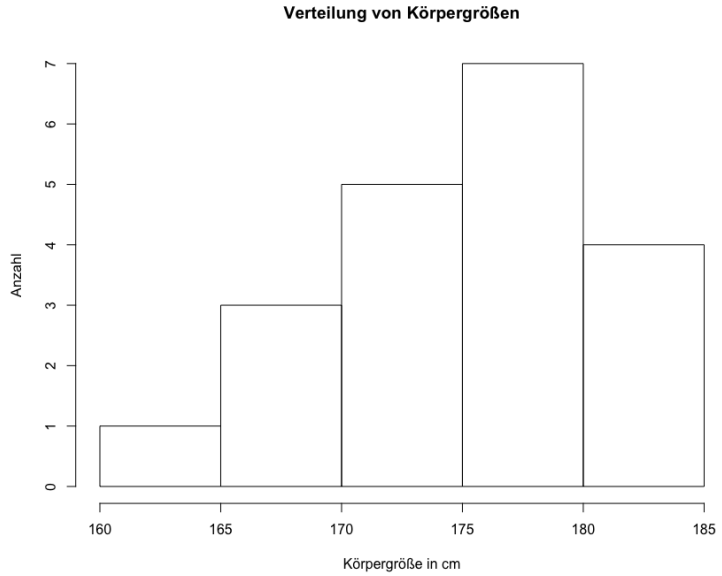
- Kontrollergebnisse -

Notwendiges Vorwissen

- Kapitel Deskriptive Statistik 1
- Wissen über Stichproben

Aufgabe 1. *(knobel)*

In einer kleinen Umfrage wurden 20 Personen zu ihrer Körpergröße befragt. Das Ergebnis der Umfrage wurde in einer Grafik dargestellt.



(a) Schätzen Sie den Anteil von Beobachtungen in der Grundgesamtheit in den folgenden Intervallen mithilfe der Grafik.

(i) $[160, 172]$

(ii) $(167, 185]$

(iii) $(173, 184]$

(b) Nehmen Sie an, Sie sollen aus der Grafik ein (normiertes) Histogramm erstellen. Welche y-Werte würden Sie den einzelnen Säulen zuweisen?

(c) Ihr Kommilitone behauptet, dass bei einer Grundgesamtheit von $20\,000$ Personen $7\,000$ zwischen 175 und 180 cm groß sind. Stimmen Sie zu? Begründen Sie Ihre Entscheidung.

Hinweis zu Aufgabenteil (b): Bei einem (normierten) Histogramm ist die Fläche der einzelnen Säulen proportional zu der relativen oder absoluten Häufigkeit dieser Klasse. Zusätzlich muss der Flächeninhalt aller Säulen zusammen 1 ergeben.

Kontrollergebnis 1.:

(a) (i) $\frac{1}{20} + \frac{3}{20} + \frac{2}{5} \cdot \frac{5}{20} = 0.30$ (ii) $\frac{3}{5} \cdot \frac{3}{20} + \frac{5}{20} + \frac{7}{20} + \frac{4}{20} = 0.89$ (iii) $\frac{2}{5} \cdot \frac{5}{20} + \frac{7}{20} + \frac{4}{5} \cdot \frac{4}{20} = 0.61$

getroffene Annahme: die Beobachtungen innerhalb der Klassen folgen einer stetigen Gleichverteilung (andere Annahmen zur Verteilung innerhalb der Klassen wären möglich)

(b) 0.01; 0.03; 0.05; 0.07; 0.04

(c) Die Stichprobe wurde zufällig gezogen. Es ist daher möglich (und wahrscheinlich), dass die Stichprobe die Grundgesamtheit nicht perfekt abbildet und dementsprechend die Anzahl der Personen in der Grundgesamtheit zwischen 175 und 180 cm von $7\,000$ abweichen kann.

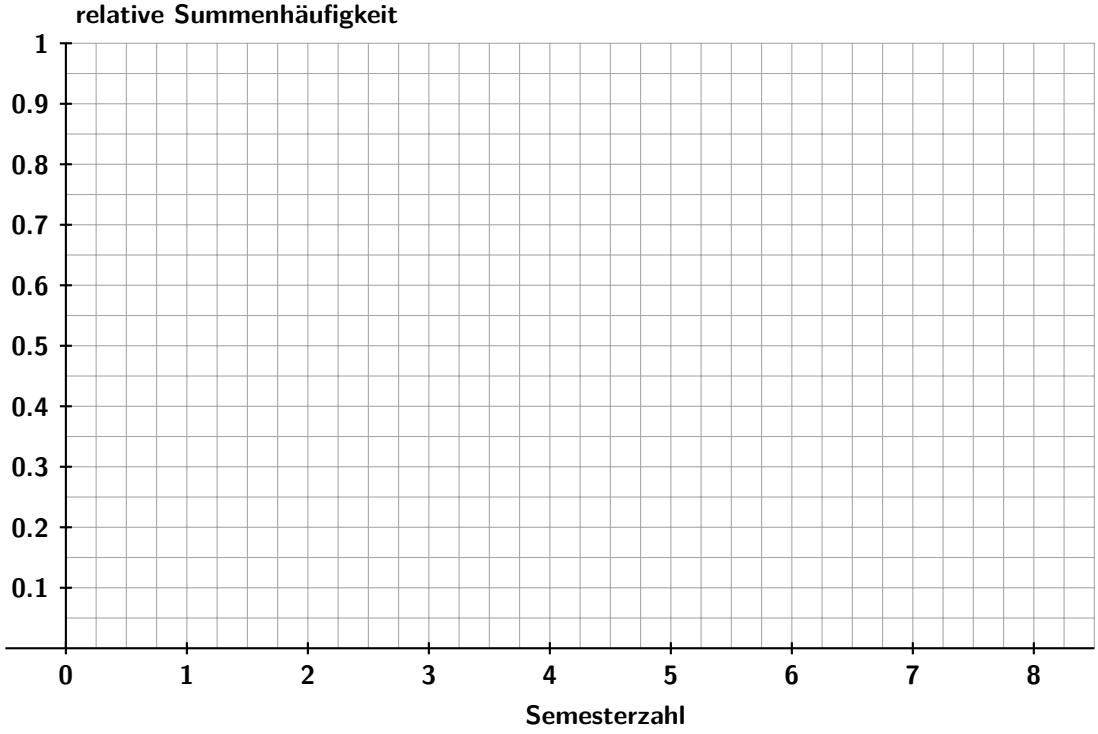
Aufgabe 2. *(basis)*
Die folgende Tabelle enthält die Semesterzahlen der Teilnehmer an der Klausur *Fortgeschrittene Mathematik für Wirtschaftswissenschaftler* am $11.02.2009$:

Semesterzahl:	2	3	4	5	6	7	$\sum$
h_j	1	7	5	5	1	4	
$f_j = {}^{h_j}/_{n}$							
H_j							-
$F_j = {}^{H_j}/_{n}$							-

Anmerkung:
$h_j =$ absolute Häufigkeit
$H_j =$ absolute Summenhäufigkeit (absolute kumulierte Häufigkeit)

(a) Vervollständigen Sie die obige Tabelle, indem Sie die relativen Häufigkeiten, absoluten und Summenhäufigkeiten berechnen.

(b) Zeichnen Sie die empirische Verteilungsfunktion der relativen Summenhäufigkeiten in die folgende Grafik.



(c) Bestimmen Sie die Anteile der Studierenden, deren Semesterzahl

(i) größer als 3,

(ii) mindestens 3,

(iii) kleiner als 4,

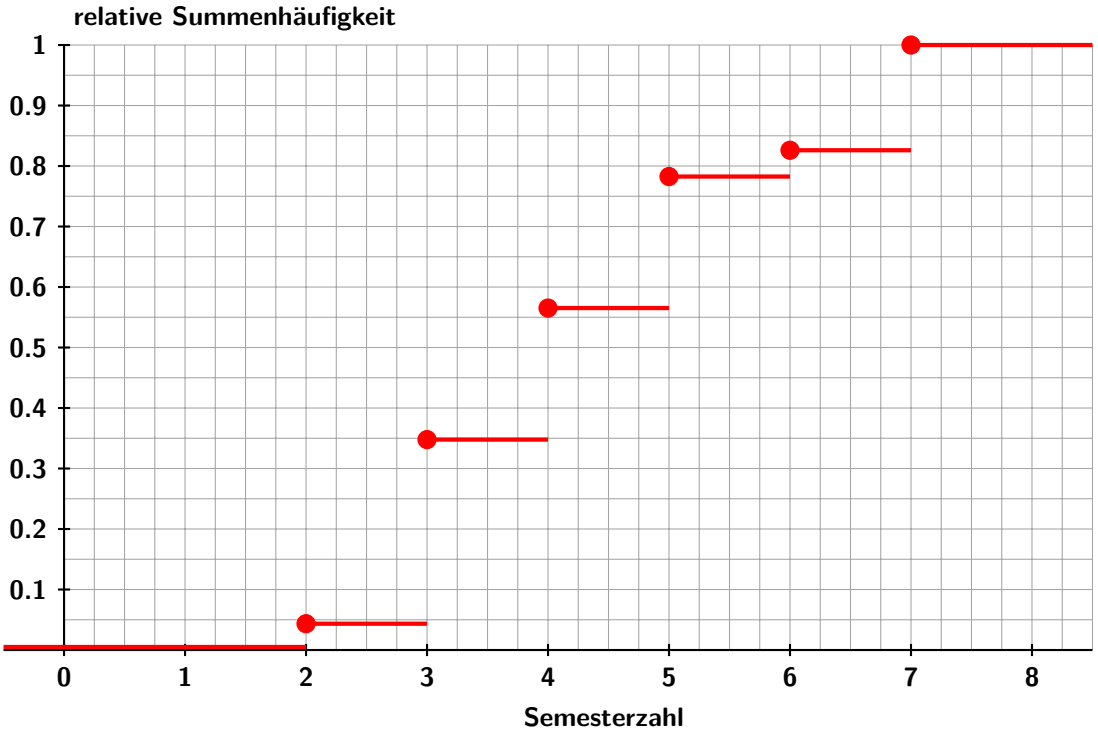
(iv) nicht größer als 5 ist.

Kontrollergebnis 2.:

(a)

Semesterzahl:	2	3	4	5	6	7	$\sum$
h_j	1	7	5	5	1	4	23
$f_j = {}^{h_j}/_{n}$	$^{1}/_{23}$	$^{7}/_{23}$	$^{5}/_{23}$	$^{5}/_{23}$	$^{1}/_{23}$	$^{4}/_{23}$	1
H_j	1	8	13	18	19	23	-
$F_j = {}^{H_j}/_{n}$	$^{1}/_{23}$	$^{8}/_{23}$	$^{13}/_{23}$	$^{18}/_{23}$	$^{19}/_{23}$	$^{23}/_{23}$	-

(b)



(c) (i) $\frac{15}{23}$, (ii) $\frac{22}{23}$, (iii) $\frac{8}{23}$, (iv) $\frac{18}{23}$.

Aufgabe 3.
Die R-Sammeldatei (R-Sammeldatei.R auf StudIP im Ordner Datensätze) enthält die Teildatensätze `Gewicht_m` und `Gewicht_w`. Diese enthalten Gewichtsangaben von männlichen und weiblichen Studierenden. Für diese Aufgaben wird der Teildatensatz männlicher Studierender benötigt.

(a) Stellen Sie den Teildatensatz `Gewicht_m` mithilfe des Befehls `hist()` in einem Diagramm mit absoluten Häufigkeiten auf der y-Achse in R dar, ohne Klassenbreiten vorzugeben. Wie breit sind die Klassen?

(b) Stellen Sie den Teildatensatz `Gewicht_m` in einem Diagramm mit absoluten Häufigkeiten auf der y-Achse in R dar. Geben Sie R die Klassengrenzen („`breaks`“) $40,\ 70,\ 100,\ 130$ und 160 vor. (Beschriften Sie zusätzlich die Achsen und geben Sie der Graphik eine Überschrift.)

(c) Benutzen Sie folgenden Befehl, nachdem Sie Aufgabe b) ausgeführt haben:
`axis(1, Gewicht_m)`
Beschreiben Sie, was dieser Befehl verändert. Welche Vor- und Nachteil gibt es?

(d) Lassen Sie sich die Kennzahlen des Diagramms in der R-Konsole ausgeben, ohne das Diagramm grafisch darzustellen. Füllen Sie mithilfe des Outputs folgende Tabelle aus:

Intervall	h_j	$f_j = {}^{h_j}/_{n}$	H_j	$F_j = {}^{H_j}/_{n}$
$[40, 70]$				
$(70, 100]$				
$(100, 130]$				
$(130, 160]$				

(e) Zeichnen Sie das zugehörige Diagramm mit absoluten Häufigkeiten auf der y-Achse per Hand. Überprüfen Sie ihr Ergebnis mithilfe von R.

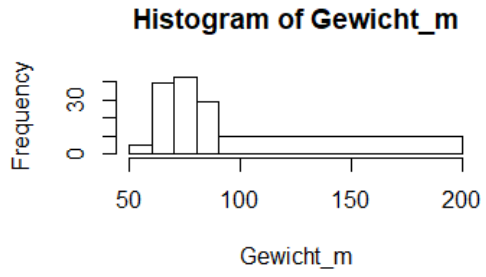
(f) Skalieren Sie die y-Achse so, dass die Gesamtfläche der Säulen 1 ergibt. Was müssen Sie hierfür auf der y-Achse abtragen?

(g) Bestimmen Sie jeweils den Anteil und die Anzahl von Beobachtungen, die

(i) kleiner gleich 100 sind,

(ii) zwischen 70 und 130 (einschließlich 130) liegen.

(h) Mit dem Befehl: `hist(Gewicht_m, breaks = c(50, 60, 70, 80, 90, 200), prob=F)` erhält man folgenden Output:



Wieso handelt es sich hierbei nicht um ein (normiertes) Histogramm? Was ist der Nachteil dieser Darstellung?

(i) Wie könnte der R-Befehl geändert werden, um ein (normiertes) Histogramm zu erhalten?

Kontrollergebnis 3.:

(a) `hist(Gewicht_m)`, Klassenbreite beträgt je 10.

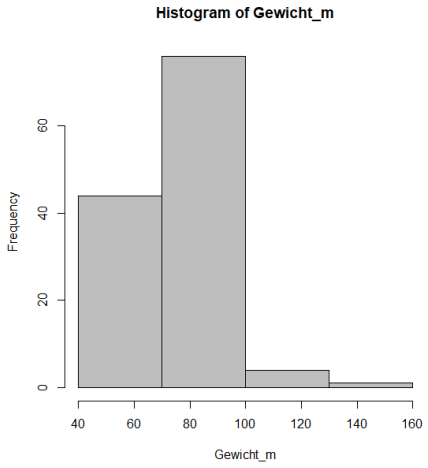
(b) `hist(Gewicht_m, main="Diagramm von Gewicht_m", xlab="Gewicht von männlichen Studenten", ylab="Absolute Häufigkeiten", breaks=c(40, 70, 100, 130, 160))`

(c) Der Befehl `axis(1, Gewicht_m)` führt dazu, dass die tatsächlich beobachteten Werte auf der x-Achse aufgeführt sind. Das Argument `1` steht hierbei für die x-Achse, das Argument `Gewicht_m` für den verwendeten Teildatensatz.
Vorteil: Man kann direkt wichtige Werte wie z.B. Minimum und Maximum im Histogramm ablesen.
Nachteil: Bei vielen Werten kann es schnell unübersichtlich werden.

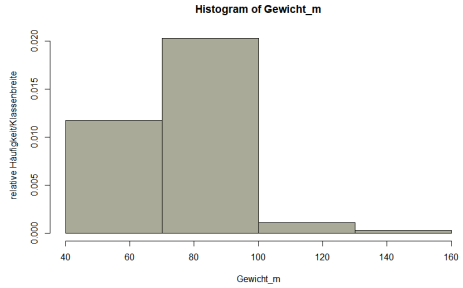
(d)

Intervall	h_j	$f_j = {}^{h_j}/_{n}$	H_j	$F_j = {}^{H_j}/_{n}$
$[40, 70]$	44	0.352	44	0.352
$(70, 100]$	76	0.608	120	0.96
$(100, 130]$	4	0.032	124	0.992
$(130, 160]$	1	0.008	125	1

(e) `hist(Gewicht_m, breaks=c(40, 70, 100, 130, 160))`



(f) Auf der y-Achse muss die Dichte= relative Häufigkeit/Klassenbreite stehen.



(g) (i) Anteil: 0.96, Anzahl: $0.96 \cdot 125 = 120$.

(ii) Anteil: 0.64, Anzahl: 80.

(h) Säulendiagramm, da absolute Häufigkeiten bei unterschiedlichen Klassenbreiten. Das Säulendiagramm führt zu einer verzerrten Darstellung.

(i) `hist(Gewicht_m, breaks=c(50, 60, 70, 80, 90, 200), prob=T)` bzw.
`hist(Gewicht_m, breaks=c(50, 60, 70, 80, 90, 200), freq=F)`
geben beide die Dichte = relative Klassenhäufigkeit / Klassenbreite auf der y-Achse aus.

Aufgabe 4. *(basis)*
Erinnern Sie sich an Aufgabe 1: Die folgende Tabelle enthält die Semesterzahlen der Teilnehmer an der Klausur *Fortgeschrittene Mathematik für Wirtschaftswissenschaftler* am $11.02.2009$:

Semesterzahl:	2	3	4	5	6	7	$\sum$
h_j	1	7	5	5	1	4	23
$f_j = {}^{h_j}/_{n}$	${}^{1}/_{23}$	${}^{7}/_{23}$	${}^{5}/_{23}$	${}^{5}/_{23}$	${}^{1}/_{23}$	${}^{4}/_{23}$	1
H_j	1	8	13	18	19	23	-
$F_j = {}^{H_j}/_{n}$	${}^{1}/_{23}$	${}^{8}/_{23}$	${}^{13}/_{23}$	${}^{18}/_{23}$	${}^{19}/_{23}$	${}^{23}/_{23}$	-

Anmerkung:
$h_j =$ absolute Häufigkeit
$H_j =$ absolute Summenhäufigkeit (absolute kumulierte Häufigkeit)

Bestimmen Sie die folgenden Kennzahlen: Mittelwert, Median, Modus, Varianz und Standardabweichung.

Kontrollergebnis 4.: 4.435, 4, 3, 2.246, 1.498

Aufgabe 5. *(basis)*
In der Zeitschrift Forschung und Lehre, Heft $3/09$ berichtet Prof. Dr. M. Ferrari, Universität Erlangen-Nürnberg über eine im Zusammenhang mit der elektronisch durchgeführten Evaluation der Lehre durchgeführte Befragung der Studierenden an der Philosophischen Fakultät und am Fachbereich Theologie. Es gab die folgenden Antworten zu den Fragen:
Wie lange arbeiten Sie pro Woche während der Vorlesungszeit?
Wie lange haben Sie pro Woche zuletzt während der vorlesungsfreien Zeit gearbeitet?

Stunden	Vorlesungszeit	Vorlesungsfreie Zeit
$[0, 4]$	40.2%	25.4%
$(4, 8]$	19.6%	14.4%
$(8, 12]$	21.9%	16.5%
$(12, 16]$	18.3%	43.7%

(a) Welche Klasse ist jeweils die Modalklasse?

(b) Bestimmen Sie jeweils näherungsweise das arithmetische Mittel und die Varianz. Nutzen Sie die Mitten der Klassen als Hilfe.

Kontrollergebnis 5.:

(a) Modalklasse Vorlesungszeit: $[0, 4]$; Modalklasse vorlesungsfreie Zeit: $(12, 16]$.

(b) Vorlesungszeit: $\bar{x} = 6.732$, $s^2 = 21.112$; Vorlesungsfreie Zeit: $\bar{x} = 9.14$, $s^2 = 24.812$.

Aufgabe 6. *(basis)*
Betrachten Sie die folgenden drei Datensätze.

	Datensatz I:	Datensatz II:	Datensatz III:
x_1	7	7	14
x_2	14	9	18
x_3	5	5	10
x_4	8	8	16
x_5	6	6	12

(a) Berechnen Sie zunächst jeweils das arithmetische Mittel und den Median der Datensätze I und II. Was fällt Ihnen auf? Erklären Sie das Ergebnis kurz.

(b) Versuchen Sie nun **ohne Berechnung der Varianz** einen Zusammenhang zwischen den Varianzen der Datensätze II und III zu formulieren. Überprüfen Sie diesen Zusammenhang danach rechnerisch, indem Sie die Varianzen ausrechnen.

Kontrollergebnis 6.:

(a) Für Datensatz II entspricht der Median dem arithmetischen Mittel: $\bar{x} = x_{med} = 7$. Für Datensatz I ist das arithmetische Mittel größer als der Median: $\bar{x} = 8 > 7 = x_{med}$.
Das kann durch den sogenannten *Ausreißer* in Datensatz I erklärt werden. Die beiden Datensätze sind identisch bis auf x_2, wo bei Datensatz I eine 14 und bei Datensatz II eine 9 beobachtet wurde. Der Median ist robust gegenüber solcher Ausreißer, da er als zentraler Wert der Beobachtungen zwar von der Anzahl der einzelnen Beobachtungen, nicht aber von deren Ausprägung abhängt. Das arithmetische Mittel wiederum ist als Durchschnitt aller Beobachtungen sehr wohl von den einzelnen Ausprägungen abhängig und damit anfällig für solche „extremen Werte“ bzw. Ausreißer.

(b) Datensatz III ergibt sich aus Datensatz II, multipliziert mit 2. Dadurch „verdoppelt“ sich auch der Abstand der einzelnen Beobachtungen zum arithmetischen Mittel, so dass die Standardabweichung von Datensatz III doppelt so groß ist wie die von Datensatz II. Die Varianz ergibt sich aus der quadrierten Standardabweichung. Dementsprechend ist die Varianz (s^2) von Datensatz III das Vierfache der Varianz von Datensatz II ($2^2 = 4$). Rechnerisch ergibt sich für Datensatz III eine Varianz von 8 und für Datensatz II eine Varianz von 2. Gleiches gilt für die Stichprobenvarianz s_*^2 : Diese ist für Datensatz III (10) vier mal so groß wie für Datensatz II (2.5).

Aufgabe 7.
Auf dem Campus wurden 20 Studierende gefragt, in welchem Semester sie sich aktuell befinden. Die Ergebnisse der Umfrage wurden in einer Tabelle aufbereitet.

i	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
x_i	4	2	1	6	3	1	1	7	13	4	6	6	1	14	5	9	3	2	6	3

(a) Zeichnen Sie den dazugehörigen Boxplot in R, indem Sie zuerst die Ergebnisse der Stichprobe in der Variablen x speichern und die Ergebnisse dann als Boxplot darstellen.

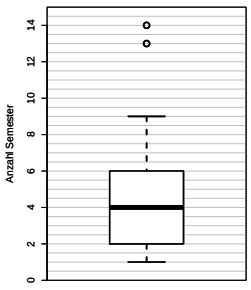
R benutzt folgende Methode, um die Whiskers zu bestimmen:
Sei $X \in \mathbb{R}^n$ ein Set, für den ein Boxplot erstellt werden soll. Die Whiskers werden dann folgendermaßen in R berechnet:
Obere Grenze:
Richtwert $x_{ROW} = \tilde{x}_{0.75} + 1.5 \cdot \text{IQR}$ (ROW = Richtwert Oberer Whisker)
Oberer Whisker $x_{OW} = max(\{x \in X : x \leq x_{ROW}\})$
Untere Grenze
Richtwert $x_{RUW} = \tilde{x}_{0.25} - 1.5 \cdot \text{IQR}$ (RUW = Richtwert Unterer Whisker)
Unterer Whisker $x_{UW} = min(\{x \in X : x \geq x_{RUW}\})$

(b) Benutzen Sie die von R verwendete Methode, um die Whiskers zu bestimmen. Überprüfen Sie Ihre Ergebnisse in R. Nutzen Sie dazu das optionale Argument `plot = F` in Ihrem Boxplot-Befehl.

(c) Betrachten Sie den Median im Verhältnis zu dem ersten und dritten Quartil. Was fällt Ihnen auf? Handelt es sich dabei um eine Besonderheit oder zeichnen sich alle Boxplots dadurch aus?

Kontrollergebnis 7.:

(a)
```
x <- c(1,1,1,1,2,2,3,3,3,4,4,5,6,6,6,6,7,9,13,14)
boxplot(x, main="Boxplot", ylab="Anzahl der Semester")
```



(b) $x_{ROW} = 6 + 1.5 \cdot (6 - 2) = 12; \quad x_{OW} = 9$
$x_{RUW} = 2 - 1.5 \cdot (6 - 2) = -4; \quad x_{UW} = x_{min} = 1$

Kontrolle in R: `boxplot(x, plot = F)`

(c) In diesem Fall liegt der Median ($\tilde{x}_{0.5} = 4$) genau in der Mitte zwischen dem ersten (2) und dem dritten Quartil (6). Diese Besonderheit ist allerdings rein zufällig. Der Median und die Quartile treffen nur Aussagen über die Verteilung des betrachteten Merkmales. Bei einer anderen Stichprobe könnte der Median zum Beispiel auch bei 3 oder 5 liegen.