# Deskriptive Statistik II

- Kontrollergebnisse -

**Aufgabe 1.**
Mit dem Befehl:
`set.seed(5)`
`Stichprobe <- sample(0:6, 20, replace=TRUE)`
wurde eine Stichprobe durchgeführt und abgespeichert.

(a) Lassen Sie sich mit den obigen Befehlen die gleiche Stichprobe ausgeben und speichern Sie diese ab. Nutzen Sie zur besseren Übersicht ebenfalls die Befehle: `table`, `sort` und `sum`

(b) Berechnen Sie per Hand die relative Häufigkeit von $3$, das arithmetische Mittel, den Median und die empirische Varianz. Überprüfen Sie anschließend Ihre Ergebnisse mithilfe von R. Wieso erhalten Sie mit R ein anderes Ergebnis für die Varianz und den Median?

(c) Lassen Sie sich mit dem R-Befehl `hist(Stichprobe, breaks=c(0,2,4,6))` ein Diagramm ausgeben. Was müssen Sie tun, um ein (normiertes) Histogramm zu erhalten? Berechnen Sie die $y$-Werte der einzelnen Klassen selbst per Hand.

**Kontrollergebnis 1.:**

(a) R-Befehle: `Stichprobe, table(Stichprobe), sort(Stichprobe), sum(Stichprobe)`

(b) relative Häufigkeiten: `prop.table(table(Stichprobe))`
arithmetisches Mittel: `mean(Stichprobe)`
Median: `median(Stichprobe)`
Varianz: `var(Stichprobe)`

Da $n = 20$ handelt es sich beim Median um ein Intervall. R gibt aber nicht dieses Intervall sondern den Mittelwert davon an. Dies wird zum Beispiel zur Zeichnung eines Boxplots benötigt.

Der Unterschied in der Varianz besteht darin, dass R die unverzerrte Varianz $s_*^2$ berechnet. Händisch wird meist der verzerrte Schätzer für die Varianz $s^2$ berechnet. Die Umrechnung ist mit folgender Formel möglich: $s^2 = s_*^2 \cdot \frac{n-1}{n}$

(c) `hist(Stichprobe, breaks=c(0,2,4,6), prob=T)` oder `hist(Stichprobe, breaks=c(0,2,4,6), freq=F)`
$y$-Achse $=$ Dichte $= \dfrac{\text{relative Häufigkeit}}{\text{Klassenbreite}}$

**Lösungsweg und Hinweise**

*Hinweis:* Der Befehl `set.seed(5)` in Kombination mit dem `sample()`-Befehl und dem Abspeichern in Stichprobe führt i.d.R. dazu, dass eine Stichprobe mit identischen Werten erzeugt wird, so dass jeder die gleiche Stichprobe beim Ausführen der Befehle erhält. Aufgrund anderer Versionen von RStudio kann es jedoch dazu kommen, dass Stichproben mit anderen Werten erzeugt werden. Daher hier einmal die Werte der Stichprobe, die für die Kontrolllösung der Aufgabe verwendet wurden:
1 2 0 6 2 0 0 4 5 6 6 2 2 5 1 6 4 3 1 4
Falls Sie eine andere Stichprobe erhalten haben, aber lieber mit diesen Werten arbeiten möchten, können Sie die Werte selbst abspeichern: `Stichprobe <- c(1,2,0,6,2,0,0,4,5,6,6,2,2,5,1,6,4,3,1,4)`

(a)
- Der R-Befehl `Stichprobe` gibt die Werte der Stichprobe aus, wenn die Stichprobe unter dem Namen `Stichprobe` abgespeichert wurde.
- Der R-Befehl `table()` gibt die absoluten Häufigkeiten in Tabellenform aus.
- Der R-Befehl `sort()` sortiert die Werte aufsteigend.
- Der R-Befehl `sum()` liefert die Summe der Werte.

(b)
- *relative Häufigkeit von $3$:*
  $f(3) = \dfrac{h_3}{n} = \dfrac{1}{20} = 0.05.$
  Dabei lässt sich $h_3$ (absolute Häufigkeit von $3$) aus der Tabelle von Aufgabenteil a) ablesen

*Hinweis zum R-Befehl*: `table()` liefert die absoluten Häufigkeiten, `prop.table(table())` liefert die relativen Häufigkeiten.

- *Arithmetisches Mittel:*
  $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{60}{20} = 3.$
  Dabei wurde $\sum_{i=1}^{n} x_i$ bereits in a) mit dem Befehl `sum()` berechnet.
- *Median:*
  Für die Ermittlung des Medians ist es hilfreich, die Werte aufsteigend zu sortieren (Urliste):
  $0\ 0\ 0\ 1\ 1\ 1\ 2\ 2\ 2\ 2\ 3\ 4\ 4\ 4\ 5\ 5\ 6\ 6\ 6\ 6$
  Für $n$ gerade ist der Median $x_{med} \in [x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}] = [x_{10}, x_{11}] = [2, 3]$
  R berechnet aus diesem Intervall den Mittelwert für den Median. Daher ist $x_{med} = \frac{2+3}{2} = 2.5$.
- *Varianz:*
  $s^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2 = \frac{1}{20}(1^2 + 2^2 + ... + 1^2 + 4^2) - 3^2 = 4.5$
  Alternativ über $s^2 = s_*^2 \cdot \frac{n-1}{n}$. Dann kann für die unverzerrte Varianz $s_*^2$ das Ergebnis des R-Befehls ($\texttt{var(Stichprobe)} = 4.736842$) verwendet werden.

(c) Damit in R ein (normiertes) Histogramm gezeichnet wird, kann entweder `prob=T` oder `freq=F` angegeben werden. Alternativ zu `T` und `F` kann auch `TRUE` bzw. `FALSE` geschrieben werden. Die R-Befehle lauten dann `hist(Stichprobe, breaks=c(0,2,4,6), prob=T)` oder `hist(Stichprobe, breaks=c(0,2,4,6), freq=F)`.

Bei einem (normierten) Histogramm ist die $y$-Achse $= \frac{\text{relative Häufigkeit}}{\text{Klassenbreite}}$, wobei rel. Häufigkeit $= \frac{\text{absolute Häufigkeit}}{n}$ ist.

- für die Klasse $[0, 2]$: rel. Häufigkeit $= \frac{10}{20} = 0.5$ und $\frac{\text{relative Häufigkeit}}{\text{Klassenbreite}} = \frac{0.5}{2} = 0.25$
- für die Klasse $(2, 4]$: rel. Häufigkeit $= \frac{4}{20} = 0.2$ und $\frac{\text{relative Häufigkeit}}{\text{Klassenbreite}} = \frac{0.2}{2} = 0.1$
- für die Klasse $(4, 6]$: rel. Häufigkeit $= \frac{6}{20} = 0.3$ und $\frac{\text{relative Häufigkeit}}{\text{Klassenbreite}} = \frac{0.3}{2} = 0.15$

*Hinweis*: Die absoluten Häufigkeiten kann man am Diagramm ablesen, wenn man das Diagramm mit dem R-Befehl `hist(Stichprobe, breaks = c(0,2,4,6))` zeichnet, oder aus der mit dem `table()`-Befehl erzeugten Tabelle.

**Häufige Fehler**

(b) Verwechselung der verzerrten Varianz $s^2$ und der unverzerrten Varianz $s_*^2$.
R berechnet immer die unverzerrte Varianz mit dem Befehl `var()`.

(c) Bei einem (normierten) Histogramm steht auf der $y$-Achse die $\frac{\text{relative Häufigkeit}}{\text{Klassenbreite}}$ und nicht $\frac{\text{absolute Häufigkeit}}{\text{Klassenbreite}}$.

**Verweis Informationsquellen**

(a) R-Skript S. 40 für `table()`, S. 32 für `sum()`

(b) relative Häufigkeit: SDS1V02 $1 - 7$; Arithmetisches Mittel: SDS01V02: Folie $20$ und R-Skript S. 32 ; Median: SDS01V02: Folie $20$ und R-Skript S. 32; Varianz: SDS01V02: Folie $35 - 36$ und R-Skript S. 32

(c) SDS01V02 Folie: $1 - 19$

**Aufgabe 2.**
Von $1000$ Verkehrsunfällen waren $380$ mit tödlichem Ausgang. Bei $160$ Unfällen mit Todesfolge war der Fahrer alkoholisiert. Insgesamt gab es $720$ Verkehrsunfälle, bei denen der Fahrer nicht alkoholisiert war.

(a) Erstellen Sie eine Kontingenztafel der absoluten Häufigkeitsverteilung mit Hilfe der im Text angegebenen Informationen.

(b) Berechnen Sie in den folgenden Szenarien jeweils den Anteil an der Gesamtzahl der Unfälle:

(i) Die Unfälle, die nicht tödlich endeten.

(ii) Die Unfälle mit Todesfolge, bei denen der Fahrer nicht alkoholisiert war.

**Kontrollergebnis 2.:**

(a)

| | $A$ | $\bar{A}$ | |
|---|---|---|---|
| $T$ | 160 | 220 | 380 |
| $\bar{T}$ | 120 | 500 | 620 |
| | 280 | 720 | 1000 |

(b) (i) $0.62$, (ii) $0.22$.

**Aufgabe 3.**
Anne und Bobo stehen vor einer neuen Aufgabe. Im Rahmen eines Forschungsprojektes wurden von fünf Männern Gewicht (in kg) und Größe (in cm) erfasst. Im Laufe des Projektes soll unter anderem der Zusammenhang zwischen Gewicht und Größe einer Person untersucht werden. Anne und Bobo wollen mithilfe der empirischen Kovarianz ein Maß für die Stärke des linearen Zusammenhangs berechnen.

(a) Anne hat ein Ergebnis von $153.88$ kg·cm für die empirische Kovarianz zwischen Gewicht und Größe, Bobo ein Ergebnis von $1.5388$ kg·m. Liegt einer der beiden falsch? Wodurch ließe sich der Unterschied in den Ergebnissen erklären?

(b) Mit welcher Größe könnten die beiden den linearen Zusammenhang zwischen zwei Merkmalen noch überprüfen? Warum würde man bei der gleichen Stichprobe damit unabhängig von der Skalierung auf dasselbe Ergebnis kommen?

(c) Berechnen Sie die Größe aus (b) aus den Rohdaten:

| Person | 1 | 2 | 3 | 4 | 5 |
|---|---|---|---|---|---|
| Gewicht | 93 | 72 | 83 | 104 | 76 |
| Größe | 198 | 160 | 167 | 199 | 182 |

**Hinweis:** Die Formel für die Kovarianz lautet: $\widehat{Cov(X,Y)} = s_{XY} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x}) \cdot (y_i - \bar{y})$

Auch hier ist die Anwendung des Verschiebungssatzes möglich: $s_{XY} = \frac{1}{n}\sum_{i=1}^{n}(x_i y_i) - \bar{x}\bar{y}$

**Kontrollergebnis 3.:**

(a) Anne liegt "richtiger" als Bobo: Anne hat die Kovarianz mit der Größe in cm berechnet, während Bobo mit der Größe in Metern gerechnet hat. Inhaltlich sind beide Ergebnisse richtig. Allerdings lässt sich die Einheit der Kovarianz schlecht interpretieren.

(b) Der Pearson'sche Korrelationskoeffizient ist eine auf das Intervall $[-1;1]$ standardisierte Größe zur Messung eines linearen Zusammenhangs zwischen zwei Merkmalen. Der Pearson'sche Korrelationskoeffizient ist dimensionslos, er hat also keine Einheit. Durch die Standardisierung erhält man unabhängig von der Skalierung hier das gleiche Ergebnis.

(c) $\hat{\rho}_{\text{Größe Gewicht}} = 0.836$.

**Aufgabe 4.**
Betrachten Sie die folgende Tabelle, in der die Bewertungen von $10$ Filmen aus den Jahren $2015$ und $2016$ der Portale *Metacritic* und *Rotten Tomatoes* zusammengetragen wurden. Die Filme wurden auf einer Skala von $1$ bis $10$ bewertet:

| Film \ Portal | Metacritic | Rotten Tomatoes |
|---|---|---|
| Star Wars: Rogue One | $6.5$ | $8.5$ |
| Hacksaw Ridge | $7.1$ | $8.6$ |
| Arrival | $8.1$ | $9.4$ |
| La La Land | $9.3$ | $9.2$ |
| Zoomania | $7.8$ | $9.8$ |
| Star Wars: Das Erwachen der Macht | $8.1$ | $9.2$ |
| Raum | $8.6$ | $9.4$ |
| Spotlight | $9.3$ | $9.6$ |
| Alles steht Kopf | $9.4$ | $9.8$ |
| Mad Max: Fury Road | $9.0$ | $9.7$ |

(a) Stellen Sie die Daten in R graphisch dar. Lässt die Abbildung auf einen Zusammenhang zwischen den Bewertungen der Filme auf den beiden Portalen schließen?

(b) Berechnen Sie den Pearson'schen Korrelationskoeffizienten und den Spearman'schen Rangkorrelationskoeffizienten der Stichprobe per Hand und mit Hilfe von R.

(c) Bestätigt Ihr Ergebnis aus (b) Ihre Vermutung aus (a)? Über welche Art von Zusammenhängen trifft der Korrelationskoeffizient eine Aussage?

**Kontrollergebnis 4.:**

(a) Es kann ein Zusammenhang vermutet werden. Filme, die auf einem Portal hoch bewertet werden, werden tendenziell auch auf dem anderen Portal hoch bewertet.

(b) Pearson'scher Korrelationskoeffizient: $\hat{\rho}_{meta,rotten} = 0.752$
Spearman'scher Rangkorrelationskoeffizient: $\hat{\rho}_{rk(meta),rk(rotten)} = 0.551$

(c) Da der berechnete Korrelationskoeffizient (nach Pearson) mit $0.752$ einen *starken* Zusammenhang aufzeigt, lässt sich die Vermutung eines Zusammenhanges bestätigen. Es handelt sich hierbei um einen positiven linearen Zusammenhang. Im Hinblick auf andere Zusammenhänge (z.B. quadratische) lässt der Korrelationskoeffizient keine Interpretation zu.

**Aufgabe 5.**
Gegeben seien zwei Maschinen $X$ und $Y$, deren Ausfallhäufigkeit an $100$ Tagen beobachtet wird.
Jede Maschine kann pro Tag maximal zweimal ausfallen, da durch die hierdurch bedingten Verzögerungen der Reparatur eine weitere Produktion am jeweiligen Tag und damit weitere Ausfälle nicht möglich sind.
Jede der beiden Maschinen weist folglich die Merkmalsausprägungen „0-mal ausgefallen", „1-mal ausgefallen" und „2-mal ausgefallen" auf. Also können sowohl Merkmal $X$ (Ausfallhäufigkeit der Maschine $X$/Tag) als auch Merkmal $Y$ (Ausfallhäufigkeit der Maschine $Y$/Tag) die Ausprägungen „$0$", „$1$" und „$2$" annehmen.
Die gemeinsamen absoluten und relativen Häufigkeiten, mit denen die oben angeführten Merkmalsausprägungen der konkreten Ausfallhäufigkeiten für Maschine $X$ bzw. Maschine $Y$ auftreten, ergeben sich aus folgender Häufigkeitstabelle.

- $X =$ Anzahl der Ausfälle pro Tag bei $X$
- $Y =$ Anzahl der Ausfälle pro Tag bei $Y$

| Maschine $X$ \ Maschine $Y$ | $Y=0$ | $Y=1$ | $Y=2$ | $\sum$ |
|---|---|---|---|---|
| $X=0$ | 30 | 14 | 2 | 46 |
| $X=1$ | 18 | 10 | 2 | 30 |
| $X=2$ | 12 | 6 | 6 | 24 |
| $\sum$ | 60 | 30 | 10 | 100 |

(a) Bestimmen Sie in R die relative Häufigkeitstabelle.

(b) Bestimmen Sie (händisch) die nachfolgenden Größen: $f_{22},\ f_{2\bullet},\ \bar{X},\ \bar{Y},\ s_Y^2,\ s_Y,\ s_X^2,\ s_X$
Nach Vorlesungsnotation gilt: $f =$ relative Häufigkeit.

(c) Berechnen Sie die empirische Kovarianz der Ausfallhäufigkeiten der beiden Maschinen. Was bedeutet das Vorzeichen bei der ermittelten Kovarianz? Kann der Wert der Kovarianz interpretiert werden?

(d) Berechnen Sie die Stärke des geschätzten Zusammenhangs mit einer geeigneten Größe.

**Kontrollergebnis 5.:**

(a)

| Maschine $X$ \ Maschine $Y$ | $Y=0$ | $Y=1$ | $Y=2$ | $\sum$ |
|---|---|---|---|---|
| $X=0$ | 0.30 | 0.14 | 0.02 | 0.46 |
| $X=1$ | 0.18 | 0.10 | 0.02 | 0.30 |
| $X=2$ | 0.12 | 0.06 | 0.06 | 0.24 |
| $\sum$ | 0.60 | 0.30 | 0.10 | 1.0 |

(b) $f_{22} = 0.1$
$f_{2\bullet} = 0.3$
$\bar{X} = 0.78$
$\bar{Y} = 0.5$
$s_Y^2 = 0.45$
$s_Y \approx 0.671$
$s_X^2 \approx 0.652$
$s_X \approx 0.807$

(c) $\widehat{Cov(X,Y)} = 0.11$
Das positive Vorzeichen der empirischen Kovarianz impliziert, dass eine positive lineare Abhängigkeit zwischen den Ausfallhäufigkeiten beider Maschinen bestehen könnte. Allerdings kann von der Höhe der empirischen Kovarianz nicht auf die Stärke des Zusammenhangs der Merkmale $X$ und $Y$ geschlossen werden. Eine nähere Interpretation der empirischen Kovarianz ist somit nicht gegeben. Das Ergebnis ist mit Vorsicht zu betrachten, da der Zufall diese positive empirische Kovarianz hervorgerufen haben kann. Dies gilt für alle Schätzer.

(d) $\hat{\rho}_{X,Y} = 0.203$
Die Merkmale $X$ und $Y$ weisen eine positive Beziehung auf. Der Pearson Korrelationskoeffizient ($\hat{\rho}_{X,Y}$) bewegt sich bei positiver linearer Abhängigkeit von $X$ und $Y$ grundsätzlich im Intervall $(0 < \hat{\rho}_{X,Y} \leq 1)$. Im gegebenen Beispiel liegt der Wert von $\hat{\rho}_{X,Y}$ im unteren Bereich des Intervalls, so dass eine schwache positive, lineare Korrelation zwischen den Ausfällen/Tag der Maschine $X$ und den Ausfällen/Tag der Maschine $Y$ besteht.

**Aufgabe 6.**
Drei Teildatensätze aus der R-Sammeldatei finden in dieser Aufgabe Verwendung.

- Der Datensatz `groegewicht` enthält die Größe und Gewicht von $227$ Studierenden aus dem Jahr $2000$.
- Der Datensatz `schein` enthält die Anzahl an Neuzulassungen von Personenkraftwagen und die Anzahl an Gefangenen in Deutschland von den Jahren $1998 - 2007$.
- Der Datensatz `QF` enthält $1000$ Zufallszahlen einer Rechteckverteilung im Intervall $[-1, 1]$ und deren Quadrate.

(a) Stellen Sie die Punktwolken der drei Datensätze dar. Was sagt der Korrelationskoeffizient aus? Raten Sie die jeweiligen Korrelationskoeffizienten.

(b) Bestimmen Sie für die drei Datensätze die Korrelationskoeffizienten mit Hilfe von R. Welche Schlüsse können Sie ziehen? Gehen Sie auf Korrelation vs. Kausalität ein.

**Hinweis:** Mit dem R-Befehl: `par(mfrow=c(nr, nc))` bzw. `par(mfcol=c(nr, nc))` können mehrere Plots in einer einzelnen Grafik abgebildet werden. `mfrow` bewirkt dabei eine Darstellung in Zeilen, `mfcol` in Spalten. Der Vektor `c(nr, nc)` gibt die Anzahl an Zeilen (r) und Spalten (c) an. Mit dem Befehl `dev.off()` kann diese Einstellung wieder gelöscht werden. Dadurch werden aber auch die zuvor erstellten Plots wieder gelöscht.

**Kontrollergebnis 6.:**

(a)
```
par(mfrow=c(3,1))
plot(schein)
plot(groegewicht)
plot(QF)
(dev.off() um die Einstellung "3 Plots untereinander"wieder zu löschen)
```

Korrelationskoeffizient: normiertes Maß für die Stärke des linearen Zusammenhangs
- Datensatz `schein`: Vermutlich geringe bis keine Korrelation, kleiner Korrelationskoeffizient
- Datensatz `groegewicht`: vermutlich Korrelation, großer Korrelationskoeffizient
- Datensatz `QF`: keine Korrelation, da kein linearer Zusammenhang, Korrelationskoeffizient um $0$

(b)
```
cor(schein)
cor(groegewicht)
cor(QF)
```

Man kann nicht von unkorreliert auf unabhängig schließen. Datensatz `QF` hat eine sehr geringe Korrelation. Da der $y$-Wert aber das Quadrat des $x$-Wertes ist, sind $x$ und $y$ nicht unabhängig. Hier besteht ein quadratischer Zusammenhang.
Datensatz `schein` hat eine mittlere Korrelation, allerdings haben die Anzahl Neuzulassung PKW und die Anzahl Gefangene kaum direkten Einfluss aufeinander.

**Aufgabe 7.**

Installieren Sie das Paket `dslabs` in `R`.
```
install.packages("dslabs")
library("dslabs")
```

Sie haben nun Zugriff auf den Teildatensatz `divorce_margarine`. Dieser enthält Informationen über den Margarineverbrauch und die Scheidungsrate im US-Bundesstaat Maine in den Jahren $2000$ bis $2009$.

(a) Lassen Sie sich die Namen der Merkmale von `divorce_margarine` ausgeben.

(b) Lassen Sie sich in einer Grafik die Daten als Punktewolke ausgeben, mit Margarineverbrauch auf der $x$- und Scheidungsrate auf der $y$-Achse

(c) Berechnen Sie mit `R` den Pearson- und den Spearman- Korrelationskoeffizienten

(d) Wie würden Sie den Zusammenhang der beiden Variablen anhand der Korrelationskoeffizienten beschreiben?

(e) Der Gouverneurin von Maine wurde die von Ihnen erstellte Statistik mit der geschätzten Korrelation zugestellt. Als Verfechterin der wahren Liebe würde sie gerne die Scheidungsrate in ihrem Bundesstaat senken. Auf Grundlage der Statistik erlässt sie ein Margarineverbot. Für wie sinnvoll halten Sie den neuen Erlass? Denken Sie das Margarineverbot verringert die Scheidungsrate?

(f) Haben Sie eine mögliche Erklärung für den Zusammenhang zwischen Margarineverbrauch und Scheidungsrate? Denken Sie auch über eine andere Variable nach, die sowohl den Margarineverbrauch als auch die Scheidungsrate beeinflussen könnte.

**Kontrollergebnis 7.:**

(a) `names(divorce_margarine)`

(b) `plot(divorce_margarine$margarine_consumption_per_capita,divorce_margarine$divorce_rate_maine)`

(c) `cor(divorce_margarine$margarine_consumption_per_capita,divorce_margarine$divorce_rate_maine)`
$= 0.9925585$
*Hinweis*: Im Befehl `cor` ist die Methode Pearson die default-Einstellung und muss daher nicht explizit aufgeschrieben werden.

```
cor(divorce_margarine$margarine_consumption_per_capita,
divorce_margarine$divorce_rate_maine,method="spearman")
```
$= 0.9847319$

(d) Die beiden Korrelationskoeffizienten sind beide sehr nah an $1$, somit würde man auf einen starken positiven linearen Zusammenhang schließen.

(e) Trotz der hohen Korrelation zwischen Margarineverbrauch und Scheidungsrate ist es sehr unwahrscheinlich, dass es einen kausalen Zusammenhang zwischen beiden Variablen gibt.

(f) Ein direkter kausaler Zusammenhang ist sehr unwahrscheinlich (Scheinkorrelation). Häufig gibt es bei einer Scheinkorrelation eine dritte Variable, von der die anderen beiden abhängig sind. Dies wäre in diesem Fall denkbar. Z.B. wird in wirtschaftlich schlechten Zeiten mehr Margarine gekauft, da sie günstiger ist als Butter, und in wirtschaftlich schlechten Zeiten gibt es mehr Scheidungen. Es ist bei Scheinkorrelationen allerdings auch genauso gut möglich, dass der Zusammenhang reiner Zufall ist.