Spezielle Verteilungsmodelle

- Kontrollergebnisse -

Aufgabe 1.
Betrachten Sie ein Zufallsexperiment, bei dem zwei faire Würfel einmal gleichzeitig geworfen werden. Die Zufallsvariable X nehme den Wert „1“ an, falls die Summe der beiden Augenzahlen glatt durch 4 teilbar ist. Ansonsten sei X gleich „0“.

(a) Geben Sie die Verteilung von X an.

(b) Nehmen Sie an, die Würfel werden 10 Mal geworfen. Die Zufallsvariable Y gebe die Zahl der Würfe an, bei denen die Summe der beiden Augenzahlen glatt durch 4 teilbar ist. Geben Sie die Verteilung von Y an und berechnen Sie $E(Y)$ und $Var(Y)$.

(c) Berechnen Sie folgende Wahrscheinlichkeiten per Hand.

(i) $P(Y = 1)$

(ii) $P(Y = 2)$

(iii) $P(Y \leq 2)$.

(d) Verwenden Sie `R` für die Berechnung folgender Wahrscheinlichkeiten.

(i) $P(Y = 7)$

(ii) $P(Y < 4)$

(iii) $P(Y > 5)$

(iv) $P(2 < Y < 6)$.

Kontrollergebnis 1.:

(a) $X \sim Be(0.25)$.

(b) $Y \sim B(10, 0.25)$; $E(Y) = 2.5$, $Var(Y) = 1.875$.

(c) (i) 0.188; (ii) 0.282; (iii) 0.526.

(d) (i) 0.003; (ii) 0.776; (iii) 0.020; (iv) 0.455.

Aufgabe 2.
Jedes Jahr wird uniweit ein Fußballturnier zwischen den verschiedenen Lehrstühlen veranstaltet. Dabei schießt der Lehrstuhl für Statistik Tore mit einer Rate von $\lambda = 2$ pro Spiel. Der Lehrstuhl für Ökonometrie schießt Tore mit einer Rate von $\lambda = 1.8$ pro Spiel.

a) Wie sind die Zufallsvariablen $X =$ „Anzahl der Tore des Lehrstuhls für Statistik pro Spiel“ und $Y =$ „Anzahl der Tore des Lehrstuhls für Ökonometrie pro Spiel“ verteilt? Ist diese Verteilung diskret oder stetig?

b) Bestimmen Sie den Erwartungswert und die Varianz von X und Y.

c) Wie groß ist die Wahrscheinlichkeit für den jeweiligen Lehrstuhl, genau drei Tore in einem Spiel zu schießen? Berechnen Sie per Hand.

d) Berechnen Sie die folgenden Wahrscheinlichkeiten mit R.

   (i) Mit welcher Wahrscheinlichkeit schießt der Lehrstuhl für Statistik in einem Spiel mindestens zwei Tore?

   (ii) Mit welcher Wahrscheinlichkeit schießt der Lehrstuhl für Ökonometrie in einem Spiel weniger als ein Tor?

e) Vor dem Spiel wird per Wurf einer fairen Münze entschieden, welcher Lehrstuhl den Anstoß ausführen darf. Geben Sie die Verteilung der Zufallsvariablen $W =$ „Lehrstuhl für Statistik darf anstoßen“ an.

f) Der Statistik-Lehrstuhl hat als Sponsor ein Unternehmen gefunden, welches Geld für einen guten Zweck spendet. Die Zufallsvariable Z beschreibt die Anzahl der gesponserten Lebensmittelgutscheine pro Spiel. Es gilt $Z = 2X + 4$. Berechnen Sie $E(Z)$ und $Var(Z)$.

g) Nehmen Sie nun an, dass es einen weiteren, privaten Sponsor gibt, der die Mannschaft direkt unterstützt. Die Zufallsvariable V beschreibt die Anzahl der gesponserten kühlen Erfrischungsgetränke pro Spiel. Es gilt $V = 2X + 1$. Berechnen Sie $E(V)$ und $Var(V)$ und treffen Sie eine Aussage, ob die Zufallsvariable V ebenfalls poissonverteilt ist.

Kontrollergebnis 2.:

(a) Die Anzahl an Toren ist abzählbar und ist somit diskret. Die Zufallsvariablen sind poissonverteilt, weil es sich um die Anzahl von Ereignissen in einem Zeitraum handelt. $X \sim Po(2)$, $Y \sim Po(1.8)$.

(b) $E(X) = Var(X) = 2$ und $E(Y) = Var(Y) = 1.8$.

(c) $P(X = 3) = 0.180$ und $P(Y = 3) = 0.161$.

(d) (i) 0.594; (ii) 0.165.

(e) $W \sim Be(0.5)$.

(f) $E(Z) = 8$, $Var(Z) = 8$.

(g) $E(V) = 5$, $Var(V) = 8$.
$E(V) \neq Var(V)$, damit ist V nicht mehr poissonverteilt.

Aufgabe 3.
Sie sollen anhand der Zufallsvariablen Y die Zeit in Monaten zwischen zwei Gewittern untersuchen.

(a) Welche Verteilung bietet sich für Y an?

(b) Es tritt erwartungsgemäß alle 3 Monate ein Gewitter auf. Bestimmen Sie den/die Parameter von Y und berechnen Sie $Var(Y)$.

(c) In dem Teildatensatz `verteilung1` aus der R-Sammeldatei sind Beobachtungen aus der betrachteten Gegend gesammelt. Stellen Sie die Daten in einem normierten Histogramm dar und zeichnen Sie eine mit 100 Datenpunkten über den Wertebereich approximierte Dichtefunktion in die Grafik. Verwenden Sie dabei Ihre Ergebnisse aus Teil (a) und (b) für die Verteilung.

(d) Nehmen Sie an, in der Gegend gab es aktuell ein Gewitter. Wie hoch ist die Wahrscheinlichkeit, dass es länger als vier Monate bis zum nächsten Gewitter dauert? Berechnen Sie mit R.

(e) Kennzeichnen Sie die Wahrscheinlichkeit aus Aufgabenteil (d) in Ihrer Grafik aus (c) (z.B. durch Verwendung von `segments()` und `arrows()`).

(f) Schreiben Sie in R eine Funktion `predict_thunder`, die für ein beliebiges λ die Wahrscheinlichkeit ausgibt, dass die Zeit zwischen zwei Gewittern größer als y ist.

(g) Berechnen Sie mit `predict_thunder` die Wahrscheinlichkeiten für die folgenden y. Nutzen Sie den in Aufgabenteil b) berechneten Wert für λ.

(i) $y = 1$

(ii) $y = 6$

(h) Nun möchten Sie die Wahrscheinlichkeit berechnen, dass die Zeit zwischen zwei Gewittern zwischen einem und sechs Monaten liegt. Ein Kollege von Ihnen hat die folgende Berechnung mit R durchgeführt:

```
> y <- 1:6
> lambda <- 1/3
> pexp(y,lambda)
[1] 0.2834687 0.4865829 0.6321206 0.7364029 0.8111244
[6] 0.8646647
> dexp(y,lambda)
[1] 0.23884377 0.17113904 0.12262648 0.08786571 0.06295853
[6] 0.04511176
> sum(dexp(y,lambda))
[1] 0.7285453
```

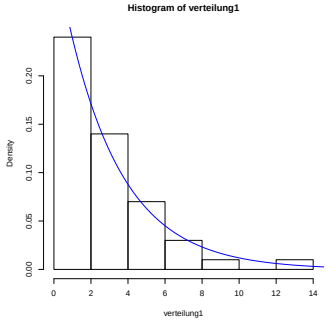
Stimmen Sie mit seinem Ergebnis überein? Begründen Sie und geben Sie, falls nötig, den korrekten R-Befehl sowie das korrekte Ergebnis an.

Kontrollergebnis 3.:

(a) $Y \sim Exp(\lambda)$.

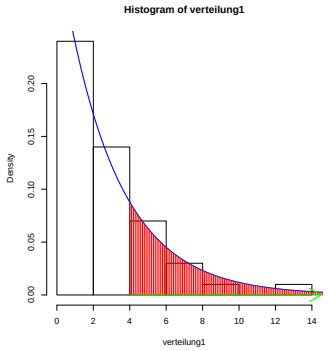
(b) $\lambda = \frac{1}{3}$, $Var(Y) = 9$.

(c) Lösungsvorschlag:



(d) 0.264

(e) Lösungsvorschlag:



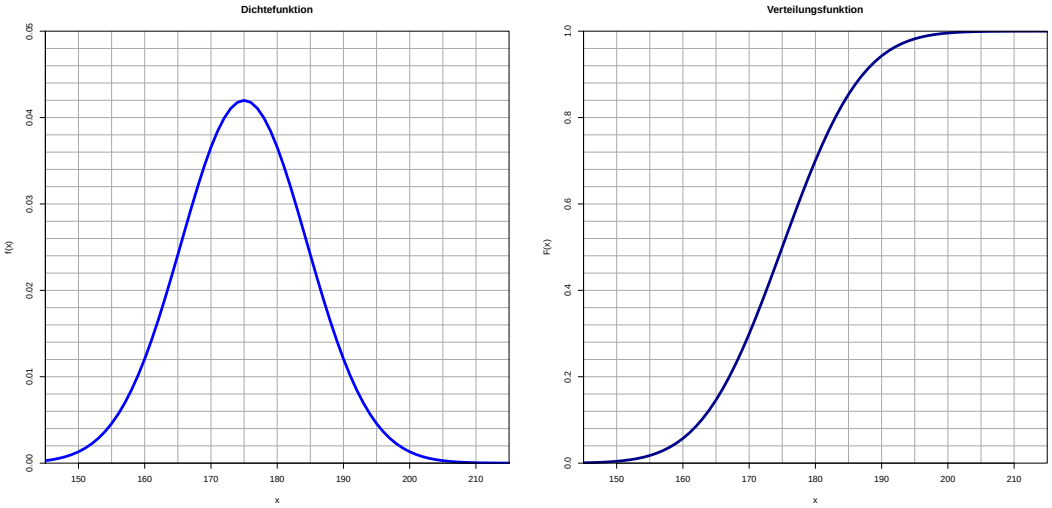
(f) Beipielhafter Lösungsvorschlag:

```
> predict_thunder <- function(y,lambda) {
>    res <- 1 - pexp(y,lambda)
>    return(res)
> }
```

(g) (i) `predict_thunder(1,1/3)` $= 0.717$, (ii) `predict_thunder(6,1/3)` $= 0.135$.

(h) Die Berechnung ist falsch, da sie nur die Werte der Dichtefunktion für die entsprechenden y aufsummiert. Die Werte der Dichtefunktion sind nicht als Wahrscheinlichkeiten zu interpretieren. Man müsste die Fläche unter der Dichtefunktion zwischen $Y = 1$ und $Y = 6$ berechnen oder die entsprechenden Werte der Verteilungsfunktion subtrahieren: `pexp(6,1/3)-pexp(1,1/3)`. Daraus ergibt sich $P(1 < X < 6) = 0.581$.

Aufgabe 4.
Betrachten Sie die Dichte- und Verteilungsfunktion der Zufallsvariablen $X =$ Körpergröße in cm.



(a) Bestimmen Sie μ mithilfe der Graphik und geben Sie die Verteilung von X an ($\sigma = 9.5$).

(b) Berechnen Sie mit R die Wahrscheinlichkeit, dass die Körpergröße den Erwartungswert um mehr als das Doppelte der Standardabweichung übersteigt.

(c) Simulieren Sie mit R eine zufällige Stichprobe mit 50 Beobachtungen aus der betrachteten Verteilung.

(d) Betrachten Sie den folgenden R-Output. Was ist speziell an dieser Normalverteilung? Wie können Sie diesen Befehl auch formulieren?

```
> pnorm(seq(-1.5,1.5,0.5),0,1)
[1] 0.0668072 0.1586553 0.3085375 0.5000000 0.6914625 0.8413447 0.9331928
```

Kontrollergebnis 4.:

(a) $\mu = 175 \Rightarrow X \sim N(175, 90.25)$.
.

(b) 0.023

(c) `rnorm(50,175,9.5)`

(d) Es handelt sich hier um eine Standardnormalverteilung, also $N(0, 1)$. Sie ist in R die default-Normalverteilung, also würde hier auch der Befehl `pnorm(seq(-1.5,1.5,0.5))` ausreichen.

Aufgabe 5.
Betrachtet wird der Wasser- und Kaloriengehalt von Zuckerrohr. Dafür wird der Datensatz "Zuckerrohr.csv" benötigt. Es handelt sich um eine bivariate Normalverteilung: $(X, Y) \sim N(\mu_x, \mu_y, \sigma_x^2, \sigma_y^2, \rho)$.
Die Zufallsvariable X gibt den Wassergehalt und die Zufallsvariable Y den Kaloriengehalt von Zuckerrohr an.

(a) Lesen Sie den Datensatz "Zuckerrohr.csv" in R ein, speichern Sie Ihn als `Zuckerrohr` ab. Verschaffen Sie sich einen Überblick über die ersten 8 Zeilen des Datensatzes. Benutzen Sie dafür einen R-Befehl.

(b) Bestimmen Sie die geschätzten Parameter der bivariaten Normalverteilung sowie die Kovarianz von X und Y mithilfe von R. Versuchen Sie, so wenig R-Befehle wie möglich zu verwenden.

(c) Geben Sie die geschätzte Randverteilung von X und Y an.

(d) Stellen Sie die Randverteilung von Y im Bereich von 0 bis 25 grafisch in R dar. Beschriften Sie die Achsen, geben Sie dem Plot eine Überschrift und verändern Sie die Farbe der Randverteilung.

(e) Wie groß ist der Anteil an Zuckerrohrstücken mit einem Kaloriengehalt zwischen 12 und 15? Arbeiten Sie zunächst mit der Verteilungstabelle der Standardnormalverteilung. Überprüfen Sie Ihr Ergebnis danach mit R.

(f) Welcher Anteil der Zuckerrohrstücke mit 10% Wassergehalt hat einen Kaloriengehalt zwischen 12 und 15? Benutzen Sie R.

(g) Stellen Sie die bedingte Randverteilung von Y für $X = 10$ grafisch in R dar. Erstellen Sie anschließend einen Plot, der die Randverteilung von Y aus (c) und die bedingte Randfunktion von Y für $X = 10$ enthält. Fügen Sie eine Legende hinzu.

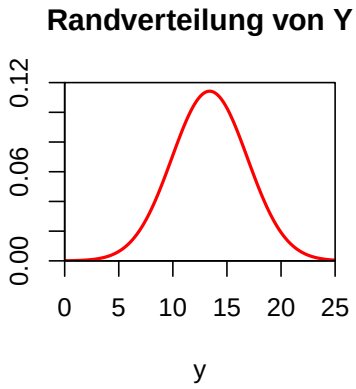
Kontrollergebnis 5.:

(a)
```
Zuckerrohr <- read.csv("Zuckerrohr.csv")
head(Zuckerrohr, 8)
```

(b) $\hat{\mu}_x = 30.915$
$\hat{\mu}_y = 13.423$
$\hat{\sigma}_x^2 = 341.435$
$\hat{\sigma}_y^2 = 12.589$
$\widehat{Cov(X, Y)} = -65.280$
$\hat{\rho} = -0.996$

(c) $X \sim N(30.915, 341.435)$
$Y \sim N(13.423, 12.589)$

(d)



(e) $P(12 < Y < 15)$
Mit Tabelle: 0.325
Mit R: 0.327

(f) geschätzte bedingte Verteilung von Y gegeben $X = 10$ ist $N(17.422, 0.108)$
$P(12 < Y < 15|X = 10) \approx 0$

(g)

