GEORG-AUGUST-UNIVERSITÄT GÖTTINGEN
Campus Institute Data Science · Statistik und Data Science I

Klausur A

Daten- und Merkmalstypen · Versuchsplanung · Stichproben

Sommersemester 2026 · Dr. Alexander Silbersdorff

Modul:	Statistik und Data Science I (SDS I)
Klausur:	A (Transferorientiert, 6 Aufgaben)
Bearbeitungszeit:	90 Minuten
Hilfsmittel:	Keine (geschlossenes Buch)
Gesamtpunktzahl:	60 Punkte (je Aufgabe 10 Punkte)

Hinweis: Diese Klausur prüft konzeptuelles Verständnis und Transferleistung. Begründungen sind zwingend erforderlich – bloßes Benennen von Begriffen ohne Erläuterung wird nicht bewertet. Achten Sie auf vollständige und methodisch korrekte Argumentation.

Aufg.	Themenbereich	Pkt.
A1	Grundbegriffe & Operationalisierung	10
A2	Merkmale & Datentypen	10
A3	Skalenniveaus & Informationsgehalt	10
A4	Versuchsplanung & Störvariablen	10
A5	Stichprobentechniken	10
A6	Kreislauf der Datenanalyse	10
Gesamt		**60**

Aufgabe A1 · Grundbegriffe & Operationalisierung [10 Punkte]

■ Szenario & Aufgabenstellung

Ein Pharmaunternehmen möchte untersuchen, ob ein neu entwickeltes Medikament die Schlafqualität von Menschen mit chronischen Schlafstörungen verbessert. Dazu wird folgendes Design entworfen:

- Die Studie wird an 300 freiwilligen Patientinnen und Patienten einer einzigen Universitätsklinik in Hamburg durchgeführt.
- Gemessen wird die subjektiv empfundene Schlafqualität anhand eines standardisierten Fragebogens (Pittsburgh Sleep Quality Index, PSQI).
- Das Unternehmen möchte aus den Ergebnissen eine allgemeine Aussage über die Wirksamkeit des Medikaments bei allen Menschen mit chronischen Schlafstörungen ableiten.

Aufgabe: (a) Identifizieren und begründen Sie die statistischen Einheiten, die Grundgesamtheit und die Stichprobe für diese Studie präzise. (b) Die Grundgesamtheit ist in diesem Fall nur hypothetischer Natur. Erklären Sie, was damit gemeint ist und welche Konsequenzen das für die Interpretation der Studienergebnisse hat. (c) Identifizieren Sie einen konkreten methodischen Fehler im Studiendesign, der die Repräsentativität der Stichprobe gefährdet, und benennen Sie ihn mit dem korrekten Fachbegriff.

■ Erwartete Musterlösung

(a) Identifikation der Grundbegriffe:

- **Statistische Einheiten:** Einzelne Personen mit diagnostizierten chronischen Schlafstörungen (jede Person ist ein Untersuchungsobjekt, an dem die Schlafqualität erhoben wird).
- **Grundgesamtheit:** Alle Menschen weltweit, die an chronischen Schlafstörungen leiden – also die Gesamtheit aller Personen, für die das Medikament grundsätzlich relevant ist.
- **Stichprobe:** Die 300 freiwilligen Patientinnen und Patienten der Universitätsklinik Hamburg, die tatsächlich an der Studie teilnehmen.

(b) Hypothetischer Charakter der Grundgesamtheit:

Die Grundgesamtheit aller Menschen mit chronischen Schlafstörungen ist nicht vollständig auflistbar – sie umfasst gegenwärtige und zukünftige Erkrankte weltweit und lässt sich nicht physisch abgrenzen oder registrieren. Damit ist sie eine hypothetische Population. Die Konsequenz: Es ist prinzipiell unmöglich, eine echte Zufallsstichprobe aus dieser Population zu ziehen. Aussagen über die Wirksamkeit des Medikaments tragen daher grundsätzlich eine Annahme in sich – nämlich, dass die Studienpopulation der hypothetischen Grundgesamtheit ähnlich genug ist, um Schlussfolgerungen zu rechtfertigen.

(c) Methodischer Fehler – Selbstselektion (Volunteer Bias / Convenience Sampling):

Die Stichprobe besteht ausschließlich aus freiwilligen Teilnehmenden einer einzigen Klinik in Hamburg. Dadurch entstehen zwei systematische Verzerrungen: Erstens haben nicht alle Elemente der Grundgesamtheit die gleiche Chance, in die Stichprobe zu gelangen (fehlende Zufälligkeit). Zweitens ist die geografische und institutionelle Einschränkung ein Beispiel für *Klumpenverzerrung*. Da Freiwillige sich systematisch von Nicht-Freiwilligen unterscheiden können (z. B. höhere Therapiemotivation), ist die Stichprobe nicht repräsentativ.

■ Korrekturkriterien

- **(a) Vollständig:** Alle drei Begriffe korrekt benannt und inhaltlich begründet (nicht nur aufgezählt). Wichtig: Grundgesamtheit muss als 'alle Menschen mit chronischen Schlafstörungen' formuliert sein, nicht als 'alle Hamburger Patienten'.
- **(b) Verständnis des hypothetischen Charakters:** Studierende müssen erklären, dass die Population nicht physisch auflistbar ist und welche Einschränkungen das für Schlussfolgerungen hat.
- **(c) Fachbegriff:** Mindestens 'Selbstselektion', 'fehlende Zufälligkeit' oder 'Convenience Sampling' mit korrekter inhaltlicher Erklärung. Keine Punkte für bloßes Benennen ohne Begründung.

■ Transfer-Aspekt

Die Aufgabe überträgt das Konzept der hypothetischen Grundgesamtheit auf ein biomedizinisches Szenario, das im Skript nicht vorkommt. Studierende müssen selbstständig erkennen, dass eine nicht-physisch-abgrenzbare Population besondere Anforderungen an die Interpretation stellt – und dürfen dies nicht mit 'unbekannter' Grundgesamtheit verwechseln. Teil (c) fordert aktive Fehlerdiagnose, kein Wiedererkennen.

Aufgabe A2 · Merkmale & Datentypen [10 Punkte]

■ Szenario & Aufgabenstellung

Eine Forschungsgruppe erhebt im Rahmen einer Studie zur urbanen Mobilität folgende Variablen für 5.000 Pendlerinnen und Pendler in deutschen Großstädten:

(1) **Pendelzeit** (in Minuten, auf die nächste Minute gerundet)

(2) **Verkehrsmittel** (Auto, ÖPNV, Fahrrad, zu Fuß)

(3) **Anzahl der Umstiege** beim ÖPNV (0, 1, 2, 3, ...)

(4) **Strecke** (in km, auf zwei Dezimalstellen genau gemessen)

(5) **Altersklasse** (18–30, 31–45, 46–60, 60+)

Aufgabe: (a) Klassifizieren Sie jede Variable als diskret oder stetig und begründen Sie Ihre Entscheidung jeweils präzise. (b) Variable (1) und Variable (4) messen ähnliche Konzepte (Zeit, Distanz) mit endlicher Messgenauigkeit. Erklären Sie, wie die Statistik mit dieser Diskrepanz zwischen theoretischer Natur und praktischer Messung umgeht und welche Konsequenz das für die Analyse hat. (c) Variable (5) entstand durch nachträgliche Kategorisierung von Variable (4). Diskutieren Sie einen konkreten Informationsverlust, der durch diese Kategorisierung entsteht.

■ Erwartete Musterlösung

(a) Klassifikation:

- **(1) Pendelzeit:** Theoretisch *stetig* (Zeit ist ein kontinuierliches Merkmal im reellen Zahlenraum). In der Praxis wird sie diskret erhoben (ganzzahlige Minuten). Wird dennoch als stetig behandelt.
- **(2) Verkehrsmittel:** *Diskret* – endlich viele, klar abgrenzbare Kategorien ohne natürliche Ordnung.
- **(3) Anzahl der Umstiege:** *Diskret* – abzählbar unendliche Menge (0, 1, 2, ...), ganzzahlige Werte, kein Wert 'zwischen 1 und 2' möglich.
- **(4) Strecke:** *Stetig (metrisch)* – alle reellen Werte in einem positiven Intervall theoretisch möglich; Messung auf zwei Dezimalstellen ist eine praktische Einschränkung.
- **(5) Altersklasse:** *Diskret* – durch Kategorisierung entstanden; endlich viele, geordnete Klassen.

(b) Diskrepanz zwischen theoretischer Stetigkeit und endlicher Messgenauigkeit:

Stetige Merkmale wie Zeit oder Strecke werden in der Praxis immer nur mit endlicher Genauigkeit erfasst. Die Statistik behandelt diese Variablen dennoch als stetig, weil (i) die zugrundeliegende Skala kontinuierlich ist, (ii) die Messungenauigkeit vernachlässigbar klein ist und (iii) für stetige Merkmale leistungsfähigere Analysemethoden (z. B. Mittelwert, Standardabweichung, Regression) zur Verfügung stehen. Eine Behandlung als diskret würde unnötig Informationen vernichten.

(c) Informationsverlust durch Kategorisierung:

Wenn die Streckenvariable (4) zu Altersklassen (5) kategorisiert wird – analog zu jeder Kategorisierung stetiger Merkmale – gehen Abstände und Verhältnisse innerhalb einer Klasse verloren. Konkret: Eine Person mit 30,1 km und eine mit 44,9 km Pendelstrecke landen beide in der Klasse '31–45 km' und werden statistisch gleichbehandelt, obwohl ein Unterschied von fast 15 km vorliegt. Variationsanalysen innerhalb einer Klasse sind dann nicht mehr möglich.

■ Korrekturkriterien

• **(a):** Volle Punkte nur bei korrekter Klassifikation UND trennschaft begründeter Argumentation. Besonders geprüft: Kann der/die Studierende erklären, warum (1) theoretisch stetig ist, aber diskret erhoben wird?

• **(b):** Drei Aspekte müssen erkennbar sein: Grundsatz der Behandlung als stetig, Begründung der Zweckmäßigkeit, Konsequenz für Analysemethoden.

• **(c):** Konkretes Beispiel mit Zahlenwerten aus der Aufgabe ist Pflicht. Pauschale Antworten ('man verliert Information') werden nicht anerkannt.

■ Transfer-Aspekt

Das Szenario der Mobilitätsstudie kommt nicht im Skript vor. Studierende müssen eigenständig entscheiden, wie eine auf Minuten gerundete Zeit zu klassifizieren ist – eine Grenzfallentscheidung, die das Skript thematisiert, aber nicht für dieses Beispiel auflöst. Teil (c) fordert aktive Konstruktion eines Gegenbeispiels, kein Definitionsabruf.

Aufgabe A3 · Skalenniveaus & Informationsgehalt [10 Punkte]

■ Szenario & Aufgabenstellung

Ein Sportverein erhebt für seine Mitglieder folgende Informationen und plant, statistische Auswertungen durchzuführen:

- **X■:** Platzierung beim letzten Vereinswettkampf (1., 2., 3., ...)
- **X■:** Trainingseinheiten pro Woche (ganze Zahlen, z. B. 3, 5, 7)
- **X■:** Lieblingssportart des Mitglieds (Fußball, Tennis, Schwimmen, ...)
- **X■:** Zufriedenheit mit dem Vereinsangebot auf einer Skala von 1 (sehr unzufrieden) bis 5 (sehr zufrieden)

Aufgabe: (a) Bestimmen Sie für jede Variable das Skalenniveau und begründen Sie Ihre Zuordnung. (b) Der Vereinsvorstand möchte für X■ und X■ jeweils den Durchschnitt berechnen. Beurteilen Sie für jede Variable, ob und warum diese Berechnung sinnvoll oder problematisch ist. (c) Ein Mitglied schlägt vor, X■ numerisch zu kodieren (Fußball = 1, Tennis = 2, Schwimmen = 3) und anschließend den Mittelwert zu berechnen. Bewerten Sie dieses Vorgehen kritisch und nennen Sie eine zulässige Alternative.

■ Erwartete Musterlösung

(a) Skalenniveaus:

- **X■ (Platzierung):** *Ordinalskala* – die Ränge lassen sich der Größe nach ordnen (1. ist besser als 2.), aber die Abstände sind nicht interpretierbar (der Abstand zwischen Platz 1 und 2 ist nicht notwendigerweise gleich dem zwischen Platz 2 und 3).
- **X■ (Trainingseinheiten):** *Kardinalskala* – ganzzahlige, sinnvoll interpretierbare Zahlenwerte; Abstände und Verhältnisse sind bedeutsam (6 Einheiten = doppelt so viel wie 3).
- **X■ (Lieblingssportart):** *Nominalskala* – verschiedene Bezeichnungen ohne natürliche Ordnung und ohne sinnvolle numerische Interpretation.
- **X■ (Zufriedenheitsskala 1–5):** *Ordinalskala* – die Ausprägungen lassen sich ordnen, aber die Abstände zwischen den Stufen sind nicht gleichmäßig und damit nicht sinnvoll interpretierbar.

(b) Mittelwertberechnung:

- **X■ (Platzierung):** Problematisch. Da nur Ordinalskala vorliegt, sind Differenzen nicht sinnvoll interpretierbar. Der Mittelwert der Ränge setzt gleiche Abstände voraus – eine Annahme, die hier nicht gerechtfertigt ist. Besser: Median.

• **X■ (Trainingseinheiten):** Sinnvoll. Kardinalskala erlaubt Differenzen und Quotienten. Der arithmetische Mittelwert ist inhaltlich bedeutsam und korrekt interpretierbar.

(c) Numerische Kodierung von X■:

Das Vorgehen ist **nicht zulässig**. Die Kodierung Fußball=1, Tennis=2, Schwimmen=3 suggeriert eine Ordnung und gleiche Abstände, die inhaltlich nicht existieren. Der Mittelwert 1,7 hätte keine sinnvolle Interpretation (es gibt keine Sportart 'zwischen Fußball und Tennis'). Zulässige Alternative: Berechnung von **absoluten und relativen Häufigkeiten** pro Kategorie (Nominalskala erlaubt Häufigkeitsauswertungen). Für einen Vergleich wäre der Modalwert (häufigste Sportart) eine sinnvolle Kennzahl.

■ Korrekturkriterien

• **(a):** X■ muss als Ordinal begründet werden – ein häufiger Fehler ist die Einstufung als kardinal. Begründung muss auf fehlende Interpretierbarkeit der Abstände eingehen.

• **(b):** Unterschied zwischen X■ und X■ muss klar herausgearbeitet werden. Angabe 'Median' als Alternative für X■ ist Pflicht für volle Punktzahl.

• **(c):** Kritik muss explizit machen, dass eine numerische Kodierung eine Ordnung impliziert, die nicht existiert. Alternative mit Begründung zwingend erforderlich.

■ Transfer-Aspekt

Zufriedenheitsskalen (Likert-Skalen) sind in der Forschungspraxis ein dauerhaft diskutiertes Grenzproblem. Die Aufgabe konfrontiert Studierende mit der Frage, ob X■ als ordinal oder kardinal zu behandeln ist – eine Entscheidung, die das Skript nicht für diesen konkreten Fall trifft. Teil (c) erfordert eigenständige Kritik eines plausibel klingenden, aber methodisch falschen Vorgehens.

Aufgabe A4 · Versuchsplanung & Störvariablen [10 Punkte]

■ Szenario & Aufgabenstellung

Eine Universität möchte evaluieren, ob die Einführung von wöchentlichen freiwilligen Übungsgruppen den Klausurerfolg in der Statistikvorlesung verbessert. Dazu wird folgendes Design verwendet:

• Studierende, die freiwillig an den Übungsgruppen teilnehmen, werden mit Studierenden verglichen, die nicht teilnehmen.

• Als Messgröße dient die Klausurnote am Ende des Semesters.

• Es nehmen 120 Studierende an den Übungsgruppen teil und 180 nehmen nicht teil.

Aufgabe: (a) Identifizieren Sie mindestens drei konkrete Störvariablen, die in diesem Design unkontrolliert bleiben, und erläutern Sie jeweils, warum sie den gemessenen Effekt verzerren könnten. (b) Schlagen Sie für jede identifizierte Störvariable eine passende Kontrollstrategie vor (Homogenisierung, Randomisierung oder statistische Modellierung) und begründen Sie Ihre Wahl. (c) Warum ist Randomisierung in diesem konkreten Studiendesign nicht direkt anwendbar? Beschreiben Sie eine modifizierte Studienanlage, die Randomisierung ermöglichen würde.

■ **Erwartete Musterlösung**

(a) Störvariablen:

- **Vorwissen / Mathematische Vorkenntnisse:** Studierende mit stärkerem Mathematikhintergrund nehmen möglicherweise häufiger an Übungsgruppen teil UND schneiden besser in der Klausur ab. Der gemessene Effekt würde dann das Vorwissen widerspiegeln, nicht die Übungsgruppe.
- **Lernmotivation / Selbstdisziplin:** Die freiwillige Teilnahme selektiert motiviertere Studierende. Diese würden auch ohne Übungsgruppe besser abschneiden (Selbstselektionsbias).
- **Zeitbudget / Erwerbstätigkeit:** Studierende mit Nebenjob haben weniger Zeit für Übungsgruppen und möglicherweise auch weniger Lernzeit insgesamt – ein direkter Confounder.

(b) Kontrollstrategien:

- **Vorwissen → Homogenisierung:** Zerlegung der Studierenden in Gruppen ähnlichen Vorwissens (z. B. anhand Abiturnote oder Eingangstest) und getrennte Analyse pro Gruppe.
- **Lernmotivation → Statistische Modellierung:** Da Motivation schwer direkt zu kontrollieren ist, kann sie über einen Proxy (z. B. frühere Studienleistungen) in ein Regressionsmodell aufgenommen werden.
- **Zeitbudget → Homogenisierung oder stat. Modellierung:** Erhebung der Erwerbstätigkeit als Kovariable und explizite Berücksichtigung in der Analyse.

(c) Problem der Randomisierung und Lösung:

Randomisierung ist hier nicht möglich, weil die Gruppenzuweisung (Übungsgruppe ja/nein) auf freiwilliger Selbstselektion basiert. Die Universität kann Studierende nicht gegen ihren Willen einer Gruppe zuweisen. Modifiziertes Design: Zu Semesterbeginn werden Studierende, die grundsätzlich bereit sind teilzunehmen, per Zufallsverfahren auf Behandlungs- (Übungsgruppe) und Kontrollgruppe (kein Zugang) aufgeteilt. Nur so lässt sich die Selbstselektion ausschalten und ein kausaler Effekt schätzen.

■ **Korrekturkriterien**

• **(a):** Störvariablen müssen inhaltlich erläutert werden (Wirkungsrichtung!). Pauschale Nennung ohne Bezug zur Verzerrungsrichtung gibt keine vollen Punkte.

• **(b):** Zuordnung der Methode muss begründet sein. Warum ist für Lernmotivation stat. Modellierung geeigneter als Homogenisierung? Diese Abwägung muss erkennbar sein.

• **(c):** Das Stichwort 'Selbstselektion' muss als Hindernis für Randomisierung benannt werden. Die modifizierte Studienanlage muss das Freiwilligkeitsproblem lösen, nicht nur 'Randomisierung' erwähnen.

■ Transfer-Aspekt

Das Design einer freiwilligen Übungsgruppe ist ein klassisches Quasi-Experiment aus der Bildungsforschung. Studierende müssen nicht nur Störvariablen benennen, sondern für jede einen passenden Kontrollansatz wählen und begründen – eine echte Abwägungsaufgabe. Teil (c) erfordert, die Grenzen einer Methode zu verstehen und ein alternatives Design zu konstruieren.

Aufgabe A5 · Stichprobentechniken [10 Punkte]

■ Szenario & Aufgabenstellung

Das Statistische Bundesamt plant eine Studie zur Einkommenssituation von Haushalten in Deutschland. Es stehen drei alternative Stichprobenstrategien zur Diskussion:

Strategie I: Aus dem offiziellen Einwohnermelderegister werden zufällig 10.000 Personen ausgewählt.

Strategie II: Deutschland wird in 400 Gemeinden unterteilt. Es werden zunächst per Zufall 50 Gemeinden ausgewählt; in jeder ausgewählten Gemeinde werden anschließend zufällig 200 Personen befragt.

Strategie III: Die Stichprobe wird so zusammengesetzt, dass der Anteil von Haushalten in verschiedenen Einkommensschichten (Unterschicht, Mittelschicht, Oberschicht) dem bekannten Anteil in der Gesamtbevölkerung entspricht.

Aufgabe: (a) Ordnen Sie jede Strategie einer der im Kurs behandelten Stichprobentechniken zu und begründen Sie Ihre Zuordnung. (b) Für welche Strategie ist die Voraussetzung, dass 'die Klumpen untereinander möglichst homogen sein sollen', am kritischsten? Erläutern Sie, was diese Voraussetzung konkret bedeutet und ob sie bei deutschen Gemeinden erfüllt ist. (c) Das Amt möchte besonders präzise Aussagen über Haushalte im obersten Einkommensdezil (Top 10%) machen, die in der Bevölkerung selten sind. Welche Strategie würden Sie empfehlen und welche Modifikation wäre sinnvoll?

■ Erwartete Musterlösung

(a) Zuordnung der Strategien:

• **Strategie I → Einfache Zufallsstichprobe:** Jede Person im Einwohnermelderegister hat die gleiche Wahrscheinlichkeit, gezogen zu werden. Keine vorab gebildeten Gruppen oder Klumpen.

• **Strategie II → Klumpenstichprobe (zweistufig):** Zunächst werden Klumpen (Gemeinden) per Zufall ausgewählt, dann erfolgt innerhalb der Klumpen eine einfache Zufallsstichprobe. Typisches Merkmal: geografische Einheiten als Klumpen.

• **Strategie III → Geschichtete Stichprobe:** Die Grundgesamtheit wird anhand der Einkommensschichten (bekannte Gruppen) vorab in Schichten eingeteilt; jede Schicht ist proportional in der Stichprobe vertreten.

(b) Homogenitätsvoraussetzung bei Strategie II:

Bei der Klumpenstichprobe sollen die Klumpen (Gemeinden) untereinander möglichst homogen sein, d. h. jede Gemeinde soll die Gesamtpopulation ähnlich gut repräsentieren. Konkret: Das Einkommensniveau sollte sich zwischen den Gemeinden nicht systematisch unterscheiden. In Deutschland ist diese Voraussetzung **kritisch verletzt**: Zwischen ländlichen Gemeinden in Ostdeutschland und wohlhabenden Stadtteilen in München oder Hamburg bestehen erhebliche, strukturelle Einkommensunterschiede. Dies kann zu Verzerrungen führen, wenn die ausgewählten 50 Gemeinden zufällig überwiegend einkommensstarke oder -schwache Regionen umfassen.

(c) Empfehlung für Aussagen über das oberste Einkommensdezil:

Empfehlung: **Geschichtete Stichprobe (Strategie III) mit disproportionaler Schichtung (Überrepräsentation)**. Da das oberste Einkommensdezil nur 10% der Bevölkerung ausmacht, würde eine proportionale Stichprobe nur ~1.000 Haushalte dieser Gruppe liefern – zu wenig für präzise Aussagen. Durch gezielte Überrepräsentation der Einkommensoberschicht (z. B. 30% der Stichprobe) können stabilere Schätzungen für diese Gruppe erzielt werden. Bei der Hochrechnung auf die Gesamtbevölkerung müssen dann Gewichtungsfaktoren angewendet werden.

■ Korrekturkriterien

- **(a):** Alle drei Strategien korrekt zugeordnet mit inhaltlicher Begründung (nicht nur Namensnennung). Wichtig: Strategie II muss als Klumpen- und nicht als geschichtete Stichprobe identifiziert werden.
- **(b):** Die Homogenitätsbedingung muss inhaltlich erklärt und anschließend kritisch auf Deutschland angewendet werden. Konkrete Beispiele (Ost/West, urban/rural) sind notwendig.
- **(c):** Der Begriff 'disproportionale Schichtung / Überrepräsentation' oder eine gleichwertige Beschreibung ist erforderlich. Hinweis auf notwendige Gewichtung bei der Auswertung für volle Punkte.

■ Transfer-Aspekt

Das Szenario kombiniert alle vier Stichprobentechniken in einer realistischen Planungssituation und fordert vergleichende Abwägung. Teil (c) geht über die im Skript beschriebene proportionale geschichtete Stichprobe hinaus und erfordert das eigenständige Schließen auf die disproportionale Variante – ein echter Transfer des Grundprinzips.

Aufgabe A6 · Kreislauf der Datenanalyse [10 Punkte]

■ Szenario & Aufgabenstellung

Ein Forschungsteam veröffentlicht eine Studie zur Frage, ob höhere Bildungsausgaben pro Schüler:in zu besseren PISA-Ergebnissen führen. Der folgende Ablauf wird beschrieben:

Schritt 1: Die Forschenden laden öffentlich verfügbare PISA-Ergebnisse der Jahre 2015–2023 von der OECD-Website herunter.

Schritt 2: Sie berechnen Korrelationen zwischen Bildungsausgaben und PISA-Punkten und finden eine positive Korrelation.

Schritt 3: Sie schlussfolgern: 'Mehr Bildungsausgaben verursachen bessere PISA-Ergebnisse.'

Schritt 4: Sie veröffentlichen ihre Ergebnisse in einem Blog-Beitrag, ohne den Analysecode oder die Rohdaten beizufügen.

Aufgabe: (a) Ordnen Sie die vier Schritte den Phasen des Kreislaufs der Datenanalyse zu. Welche Phasen fehlen vollständig? (b) Identifizieren und erläutern Sie mindestens zwei methodische Fehler in diesem Ablauf – beziehen Sie sich dabei explizit auf Konzepte aus der Vorlesung (Störvariablen, Stichprobe, Skalenniveaus etc.). (c) Welche konkreten Maßnahmen hätten im Rahmen der Versuchsplanung (Phase 1) ergriffen werden müssen, um die Studie methodisch zu verbessern? Nennen Sie mindestens zwei spezifische Maßnahmen.

■ **Erwartete Musterlösung**

(a) Zuordnung zu Phasen des Kreislaufs:

• Schritt 1 → **Datenerhebung** (Verwendung bereits vorhandener Sekundärdaten)

• Schritt 2 → **Datenanalyse** (statistische Berechnung der Korrelation)

• Schritt 3 → **Interpretation der Ergebnisse** (Schlussfolgerung aus der Analyse)

• Schritt 4 → **Publikation** (unvollständig, ohne Daten und Code)

Fehlende Phasen: Planung, Aufbereitung und Prüfung der Daten, Wiederverwendung der Daten und Ergebnisse.

(b) Methodische Fehler:

• **Fehler 1 – Kausalitätsschluss aus Korrelation (Schritt 3):** Eine positive Korrelation zwischen Bildungsausgaben und PISA-Punkten belegt keine Kausalität. Zahlreiche Störvariablen (z. B. Wohlstand des Landes, Bildungskultur, Lehrerqualität) könnten sowohl höhere Ausgaben als auch bessere PISA-Ergebnisse erklären. Ohne Kontrolle dieser Confounders ist der kausale Schluss methodisch unzulässig.

• **Fehler 2 – Fehlende Planung (Phase 'Planung' übersprungen):** Die Forschenden haben keine Vorab-Festlegung getroffen, welche Variablen als Störvariablen kontrolliert werden sollen. Das öffnet die Tür für selektive Analyse ('cherry picking') und p-Hacking.

• **Fehler 3 – Fehlende Reproduzierbarkeit (Schritt 4):** Ohne Veröffentlichung von Code und Rohdaten ist die Studie nicht reproduzierbar und der Kreislauf der Datenanalyse (Phase: Wiederverwendung) wird unterbrochen.

(c) Verbesserungen durch Versuchsplanung:

• **Präregistrierung:** Vorab verbindlich festlegen, welche Variablen analysiert werden und welche Hypothesen getestet werden – verhindert nachträgliche Anpassung der Fragestellung.

• **Identifikation und Operationalisierung von Störvariablen:** Bereits in der Planungsphase relevante Confounder (BIP pro Kopf, Bildungssystem, Lehrkräftemangel) benennen und in die Datenerhebung einbeziehen.

• **Open-Data-Plan:** Festlegen, dass Code und Daten offen zugänglich publiziert werden (entspricht der Phase 'Publikation von Daten + Code' im Kreislauf).

■ Korrekturkriterien

• **(a):** Alle vier Schritte müssen korrekt zugeordnet sein. Die fehlenden Phasen müssen vollständig und namentlich benannt werden.

• **(b):** Fehler müssen mit Fachbegriffen aus der Vorlesung verknüpft werden (Störvariablen, Kausalität vs. Korrelation, Reproduzierbarkeit). Allgemeine Kritik ohne konzeptuellen Bezug wird nicht anerkannt.

• **(c):** Maßnahmen müssen konkret und umsetzbar sein. 'Bessere Planung machen' ist keine anerkannte Antwort. Bezug auf den Kreislauf der Datenanalyse ist erwünscht.

■ Transfer-Aspekt

Das Szenario präsentiert eine realitätsnahe, fehlerhafte Studie, wie sie in populärwissenschaftlichen Kontexten häufig vorkommt. Studierende müssen den gesamten Kreislauf der Datenanalyse als Prüfraster anwenden, methodische Schwächen aktiv identifizieren und Verbesserungsmaßnahmen konstruieren – kein Konzept daraus wurde in dieser Kombination im Skript behandelt.