Deskriptive Statistik zur Beschreibung von Merkmalen

Statistik und Data Science I – Vorlesung 2

Dr. Alexander Silbersdorff | Sommersemester 2026 | Georg-August-Universität Göttingen

---

Lernziele

1. **Wie lässt sich die Verteilung eines Merkmals** in einem gegebenen Datensatz beschreiben?
2. **Welche Maßzahlen** beschreiben verschiedene Aspekte dieser Verteilung?
3. **Wie können Verteilungen grafisch dargestellt und typisiert werden?**

---

1. Häufigkeiten und Häufigkeitsverteilungen

Grundbegriffe

Gegeben seien Beobachtungen $x_1, \ldots, x_n$ zu einem Merkmal X, wobei n den **Stichprobenumfang** bezeichnet.
Seien $a_1, \ldots, a_J$, $J \leq n$, die möglichen **Ausprägungen** des Merkmals X.
Für mindestens ordinale Merkmale gilt: $a_1 < a_2 < \cdots < a_J$.

Absolute und relative Häufigkeiten

Symbol	Bedeutung
$h(a_j) = h_j$	**Absolute Häufigkeit** der Ausprägung a_j (Anzahl der x_i mit $x_i = a_j$)
$f(a_j) = f_j = \dfrac{h_j}{n}$	**Relative Häufigkeit** von a_j

- **Verteilung der absoluten Häufigkeiten:** $h_1, \ldots, h_J$
- **Verteilung der relativen Häufigkeiten:** $f_1, \ldots, f_J$

> **Wichtig:** Es gilt stets $\sum_{j=1}^{J} f_j = 1$.

Klasseneinteilung bei stetigen Merkmalen

Bei stetigen Daten mit vielen Ausprägungen werden Klassen (Intervalle) gebildet:

$$[c_0, c_1],\ (c_1, c_2],\ \ldots,\ (c_{J-1}, c_J]$$

Beispiel – Landwirtschaftliche Flächen (Wesermarsch, $n = 1\,565$):

Anbaufläche (ha)	Abs. Häufigkeit	Rel. Häufigkeit
$0 < x \leq 10$	421	0,2690
$10 < x \leq 20$	127	0,0812
$20 < x \leq 30$	134	0,0856
$30 < x \leq 50$	302	0,1930
$50 < x \leq 75$	365	0,2332
$75 < x \leq 100$	159	0,1016
$100 < x \leq 125$	38	0,0243
$125 < x \leq 150$	14	0,0089
$150 < x \leq 200$	5	0,0032
Summe	**1565**	**1,0000**

2. Grafische Darstellung von Häufigkeitsverteilungen

2.1 Säulendiagramm

- Jede Klasse wird durch ein Rechteck repräsentiert, dessen **Höhe** proportional zur absoluten oder relativen Häufigkeit ist:

$$H_j \propto h_j \quad \text{bzw.} \quad H_j \propto f_j$$

- **Nachteil:** Die visuelle Darstellung ist abhängig von der gewählten Klassenbreite. Unterschiedliche Breiten führen zu unterschiedlichen optischen Eindrücken, auch wenn dieselben Daten zugrunde liegen.

2.2 Histogramm *(Goldstandard)*

- Die **Flächen** der Rechtecke sind proportional zu den relativen Häufigkeiten:

$$F_j \propto f_j$$

- Die **Höhen** (Dichte) ergeben sich als:

$$\text{Dichte}_j = \frac{\text{relative Häufigkeit}_j}{\text{Breite der Klasse}_j}$$

- **Gesamtfläche des Histogramms** = 1 (da alle Anteile zusammen 1 ergeben).
- **Flächeninterpretation:** Der Anteil der Beobachtungen zwischen a und b lässt sich schätzen als:

$$\int_a^b H_x \, dx$$

wobei H_x die Höhe des Histogramms an der Stelle x ist.

- **Vorteil gegenüber Säulendiagramm:** Die Darstellung ist weitaus weniger abhängig von der gewählten Klassenbreite.

> **Bias-Variance-Trade-Off:** Bei der Wahl der Klassenanzahl J muss mit Bedacht vorgegangen werden. Zu wenige Klassen → Informationsverlust (Bias). Zu viele Klassen → Überanpassung an Zufälligkeit (Varianz).

---

3. Typisierung von Häufigkeitsverteilungen

Anhand von Histogrammen können Verteilungen klassifiziert werden:

3.1 Modalität

Typ	Beschreibung
Unimodal	Ein einziger Gipfel (häufigste Form)
Bimodal/Multimodal	Zwei oder mehr lokale Gipfel

3.2 Schiefe (Symmetrie)

Typ	Beschreibung	Beziehung der Lagemaße
Symmetrisch	Linke und rechte Seite spiegelbildlich	$\bar{x} \approx x_{\text{med}} \approx x_{\text{mod}}$
Rechtsschief / linkssteil	Langer Ausläufer nach rechts	$\bar{x} > x_{\text{med}} > x_{\text{mod}}$
Linksschief / rechtssteil	Langer Ausläufer nach links	$\bar{x} < x_{\text{med}} < x_{\text{mod}}$

---

4. Lagemaße

Lagemaße beschreiben das **Zentrum** bzw. die **zentrale Tendenz** der Daten.

4.1 Arithmetisches Mittel $\bar{x}$

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \sum_{j=1}^{J} a_j f_j$$

- **Eigenschaft:** $\sum_{i=1}^{n}(x_i - \bar{x}) = 0$ (Abweichungen links und rechts heben sich auf)
- **Skalenniveau:** Kardinale Merkmale (auch sinnvoll für binäre 0/1-Merkmale)
- **Lineare Transformation:** $y_i = a + bx_i \Rightarrow \bar{y} = a + b\bar{x}$

Arithmetisches Mittel bei Schichtenbildung:

$$\bar{x} = \frac{1}{n}(n_1\bar{x}_1 + \cdots + n_r\bar{x}_r) = \frac{1}{n}\sum_{j=1}^{r} n_j\bar{x}_j$$

Das Gesamtmittel ist der **gewichtete Durchschnitt** der Schichtmittel.

4.2 Median x_{med}

$$x_{\text{med}} = \begin{cases} x_{\left(\frac{n+1}{2}\right)} & n \text{ ungerade} \\ \in \left[x_{\left(\frac{n}{2}\right)}, x_{\left(\frac{n}{2}+1\right)}\right] & n \text{ gerade} \end{cases}$$

wobei $x_{(1)} \leq x_{(2)} \leq \cdots \leq x_{(n)}$ die **geordneten Beobachtungen** (Rangwerte) sind.

- **Eigenschaft:** Mindestens 50 % der Beobachtungen liegen links, mindestens 50 % rechts des Medians.
- **Skalenniveau:** Ab Ordinalskala
- **Monotone Transformation:** $y_i = g(x_i) \Rightarrow y_{\text{med}} = g(x_{\text{med}})$

4.3 Modus x_{mod}

$$x_{\text{mod}} = \text{häufigste Merkmalsausprägung}$$

- **Skalenniveau:** Beliebiges Skalenniveau
- Bei metrischen Merkmalen mit vielen Ausprägungen häufig nicht sinnvoll interpretierbar.

Übersicht: Voraussetzungen der Lagemaße

Maß	Mindest-Skalenniveau	Robustheit gegenüber Ausreißern
Arithmetisches Mittel	Kardinal	Gering
Median	Ordinal	Hoch
Modus	Nominal	Sehr hoch

5. Quantile

Definition

Das λ-Quantil ($0 \leq \lambda \leq 1$) ist jene Zahl, für die gilt:
mindestens $\lambda \cdot 100\,\%$ der Daten sind **kleiner oder gleich** und $(1-\lambda) \cdot 100\,\%$ sind **größer oder gleich**.

$$x_\lambda = \begin{cases} x_{([n\lambda]+1)} & n\lambda \notin \mathbb{N} \\ \in \left[x_{(n\lambda)},\, x_{(n\lambda+1)}\right] & n\lambda \in \mathbb{N} \end{cases}$$

Dabei ist $[n\lambda]$ die zu $n\lambda$ nächstkleinere ganze Zahl.

- **Voraussetzung:** Mindestens ordinalskaliertes Merkmal.

Häufig verwendete Quantile

Bezeichnung	Quantile
Median	$x_{0,5}$
Quartile	$x_{0,25}, x_{0,5}, x_{0,75}$
Dezile	$x_{0,1}, x_{0,2}, \ldots, x_{0,9}$
Vingtile	$x_{0,05}, x_{0,95}$

Beispiel: Mietspiegel ($n = 26$ Wohnungen)

Geordnete Nettomieten (in €):

$$77{,}31 \quad 104{,}14 \quad 116{,}48 \quad \ldots \quad 400{,}05 \quad 533{,}92$$

Berechnung der Quartile:

- **Unteres Quartil** $x_{0,25}$: $0{,}25 \cdot 26 = 6{,}5 \notin \mathbb{N} \rightarrow$ aufrunden auf 7:

$$x_{0,25} = x_{(7)} = 170{,}04\ €$$

- **Median** $x_{0,50}$: $0{,}5 \cdot 26 = 13 \in \mathbb{N} \rightarrow$ Mittelwert aus $x_{(13)}$ und $x_{(14)}$:

$$x_{0,50} = \frac{243{,}44 + 255{,}75}{2} = 249{,}60\ €$$

- **Oberes Quartil** $x_{0,75}$: $0{,}75 \cdot 26 = 19{,}5 \notin \mathbb{N} \rightarrow$ aufrunden auf 20:

$$x_{0,75} = x_{(20)} = 311{,}87\ €$$

---

6. Streuungsmaße

Streuungsmaße beschreiben die **Variabilität** der Daten um das Zentrum.

6.1 Varianz S^2

$$S^2 = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})^2$$

Verschiebungssatz (zur einfacheren Berechnung):

$$S^2 = \frac{1}{n} \sum_{i=1}^{n} x_i^2 - \bar{x}^2$$

Variante mit besseren theoretischen Eigenschaften (Schätzer, mehr dazu in SDS1-V09):

$$S_*^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2$$

6.2 Standardabweichung S

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})^2}$$

- **Vorteil:** S hat dieselbe **Einheit** wie das betrachtete Merkmal.

6.3 Interquartilsabstand (IQR)

$$\text{IQR} = d_{Qn} = x_{0,75} - x_{0,25}$$

- Robustes Streuungsmaß, nicht durch Ausreißer beeinflusst.
- Basiert auf Quartilen, nicht auf dem Mittelwert.

Eigenschaften bei linearer Transformation ($y_i = a + bx_i$)

Maß	Transformationsregel
Varianz S^2	$S^2 \to b^2 S^2$
Standardabweichung S	$S \to b \cdot S$
Interquartilsabstand	$\text{IQR} \to b \cdot \text{IQR}$

> **Beachte:** Die additive Konstante a hat keinen Einfluss auf Streuungsmaße!

Beispiel: Mietspiegel

Für die Stichprobe der 26 Wohnungen ($\bar{x} = 250{,}02$ €):

$$\frac{1}{n}\sum_{i=1}^{n} x_i^2 = 72\,616{,}82 \quad \Rightarrow \quad S^2 = 72\,616{,}82 - (250{,}02)^2 = 10\,106{,}82$$

$$S = \sqrt{10\,106{,}82} \approx 100{,}53 \text{ €}$$

Standardabweichungen nach Wohnungsgröße (absolute Nettomiete):

Gruppe	S
Gesamt	241,92 €
Kleine Wohnungen	67,53 €
Mittlere Wohnungen	166,20 €
Große Wohnungen	262,76 €

→ Kleine Wohnungen sind in Bezug auf die absolute Nettomiete **homogener**.

---

7. Boxplots

Ein Boxplot ist eine **grafische Fünf-Punkte-Zusammenfassung** einer Verteilung:

Bestandteil	Wert
Minimum	$x_{\min}$
Unteres Quartil	$x_{0,25}$
Median	x_{med}
Oberes Quartil	$x_{0,75}$
Maximum	$x_{\max}$

Ausreißerregel: Beobachtungen, die mehr als $1{,}5 \cdot \text{IQR}$ vom jeweiligen Quartil entfernt sind, werden als Ausreißer separat eingezeichnet.

Informationen, die ein Boxplot liefert:

- Zentrale Tendenz (Lage des Medians)
- Variabilität (Breite der Box und der Whisker)
- Schiefe (asymmetrische Lage des Medians innerhalb der Box)
- Extreme Werte / Ausreißer

---

8. Transformationen – Zusammenfassung

Lineare Transformation $y_i = a + bx_i$

Maß	Regel
Arithmetisches Mittel	$\bar{y} = a + b\bar{x}$
Median	$y_{\text{med}} = a + b \cdot x_{\text{med}}$
Varianz	$S_y^2 = b^2 S_x^2$
Standardabweichung	$S_y = b \cdot S_x$
IQR	$\text{IQR}_y = b \cdot \text{IQR}_x$

Monotone (nichtlineare) Transformation $y_i = g(x_i)$

- Der **Median** wird mittransformiert: $y_{\text{med}} = g(x_{\text{med}})$

- Das **arithmetische Mittel** wird im Allgemeinen **nicht** mittransformiert: $\bar{y} \neq g(\bar{x})$

---

9. Take-Home-Messages

1. **Diskrete Merkmale** lassen sich durch **Häufigkeitsverteilungen** (Tabellen, Säulendiagramme) darstellen; für **stetige Merkmale** sind **Histogramme** der Goldstandard.
2. Neben der grafischen Darstellung bieten **Maßzahlen für Lage und Streuung** eine kompakte Beschreibung der Verteilung.
3. Die Maßzahlen haben unterschiedliche **Voraussetzungen an das Skalenniveau** und unterschiedliche Robustheitseigenschaften (z. B. ist der Median robuster gegenüber Ausreißern als das arithmetische Mittel).
4. **Quantile** geben einen strukturierten Überblick über einen Datensatz; **Boxplots** visualisieren diesen Überblick grafisch und erlauben schnelle Vergleiche zwischen Gruppen.

Voraussetzungen: Summenzeichen & mathematische Notation (M-V03), Skalenniveaus (SDS1-V01)
Vertiefung: Dichte und stetige Verteilungen (SDS1-V05), Schätzer und Stichprobenvarianz (SDS1-V09)