Vorlesungszusammenfassung

Deskriptive Statistik zur Beschreibung von Zusammenhängen

Kurs: Statistik und Data Science I | **Vorlesung:** 3 | **Semester:** Sommersemester 2026

Lernziele

- Wie lassen sich Zusammenhänge zwischen Merkmalen untersuchen und statistisch darstellen?
- Wie lassen sich Zusammenhänge quantitativ in geeigneten Maßzahlen ausdrücken?
- Wie unterscheiden sich Ansätze je nach Skalenniveau der Merkmale?
- Was unterscheidet statistische und kausale Zusammenhänge?

1 Motivation – Cholera-Epidemie in London

Mitte des 19. Jahrhunderts grassierte in London eine schwere Cholera-Epidemie. Die damals vorherrschende Miasma-Theorie (Verbreitung durch krankmachende Luft) erwies sich als falsch. John Snow konnte durch die systematische gemeinsame Betrachtung von Wasserversorger und Erkrankungsrate einen statistischen Zusammenhang herstellen und die Wasserversorgung als Übertragungsweg identifizieren. Dies gilt als Geburtsstunde der modernen Epidemiologie.

Kernidee	Erst die gemeinsame Verteilung zweier Merkmale erlaubt Rückschlüsse auf deren Zusammenhang.

2 Gemeinsame Verteilung und Randverteilung

Die gemeinsame Verteilung zweier Merkmale X und Y beschreibt, wie sich beide Merkmale gemeinsam verhalten. Grundlage sind Beobachtungspaare (x_i, y_i) für dieselben statistischen Einheiten $i = 1, \ldots, n$.

- Randverteilungen ergeben sich, wenn nur ein Merkmal betrachtet wird.
- Die gemeinsame Verteilung bestimmt die Randverteilungen eindeutig – aber nicht umgekehrt.
- Nur bei Unabhängigkeit von X und Y lässt sich die gemeinsame Verteilung aus den Randverteilungen rekonstruieren.

3 Kontingenztafel (nominale / ordinale Merkmale)

Sind beide Merkmale diskret oder geeignet gruppiert, stellt man ihre gemeinsame Häufigkeitsverteilung in einer Kontingenztafel dar. Die Einträge hjk geben an, wie viele Beobachtungen gleichzeitig die Ausprägung aj für X und bk für Y aufweisen.

3.1 Absolute und relative Häufigkeiten

Die absoluten Häufigkeiten hjk werden durch Division durch n zu relativen Häufigkeiten fjk = hjk / n. Zeilen- bzw. Spaltensummen liefern die Randverteilungen.

3.2 Bedingte Verteilungen

Durch zeilenweises Normieren der Kontingenztafel erhält man die bedingte Verteilung von Y gegeben X = aj. Unterscheiden sich diese bedingten Verteilungen je nach Bedingung, liegt ein Zusammenhang vor.

Beispiel: Ausbildung vs. Arbeitslosigkeit (n = 447)

Die folgende Tabelle zeigt die absoluten Häufigkeiten aus einer Teilstichprobe des Sozioökonomischen Panels (SOEP):

Ausbildungsniveau	Kurzzeitarbeitslos.	Mittelfristig	Langzeitarbeitslos.	Gesamt
Keine Ausbildung	86	19	18	123
Lehre	170	43	20	233
Fachspez. Ausbildung	40	11	5	56
Hochschulabschluss	28	4	3	35
Gesamt	**324**	**77**	**46**	**447**

Ergebnis der bedingten Verteilungen: Mit steigendem Ausbildungsniveau nimmt die Wahrscheinlichkeit für Kurzzeitarbeitslosigkeit zu, jene für Langzeitarbeitslosigkeit ab.

4 χ^2-Koeffizient

Um die Stärke des Zusammenhangs für kategoriale Merkmale quantitativ zu messen, vergleicht man die beobachteten Häufigkeiten hjk mit den unter Unabhängigkeit erwarteten Häufigkeiten h̃jk.

4.1 Erwartete Häufigkeiten unter Unabhängigkeit

Unter Unabhängigkeit gilt hjk / hj• = h•k / n, woraus folgt:

$$\tilde{h}_{jk} = h_{j\bullet} \cdot h_{\bullet k} / n$$

4.2 Formel

$$\chi^2 = \sum_j \sum_k \frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}}$$

Interpretation	$\chi^2 \approx 0 \rightarrow$ Merkmale sind (näherungsweise) unabhängig | χ^2 groß $\rightarrow$ starker Zusammenhang

Im Beispiel (Ausbildung vs. Arbeitslosigkeit) ergibt sich $\chi^2 \approx 4{,}51$ – ein schwacher bis moderater Zusammenhang.

5 Streudiagramm (metrische Merkmale)

Für metrische Merkmale stellt man die Beobachtungspaare (x_i, y_i) als Punkte in einem Koordinatensystem dar. Aus dem Streudiagramm lassen sich ablesen:

- Richtung: gleichgerichteter vs. gegengerichteter Zusammenhang
- Form: linearer vs. nichtlinearer Zusammenhang
- Stärke: enge vs. breite Punktwolke

Für mehrere Merkmale gleichzeitig verwendet man eine Streudiagrammmatrix (Scatterplot-Matrix), die alle paarweisen Zusammenhänge auf einen Blick zeigt.

6 Kovarianz

Die Kovarianz misst die durchschnittliche Konkordanz bzw. Diskordanz der Beobachtungen relativ zum Mittelpunkt $(\bar{x}, \bar{y})$ der Daten:

- Konkordant: $(x_i - \bar{x})(y_i - \bar{y}) > 0 \rightarrow$ beide Abweichungen gleichgerichtet
- Diskordant: $(x_i - \bar{x})(y_i - \bar{y}) < 0 \rightarrow$ Abweichungen entgegengesetzt

6.1 Formel

$$\mathrm{Cov}(X, Y) = 1/n \cdot \Sigma_i (x_i - \bar{x})(y_i - \bar{y})$$

6.2 Eigenschaften

- $\mathrm{Cov}(X, Y) > 0 \rightarrow$ positiver linearer Zusammenhang
- $\mathrm{Cov}(X, Y) < 0 \rightarrow$ negativer linearer Zusammenhang
- $\mathrm{Cov}(X, Y) = 0 \rightarrow$ kein linearer Zusammenhang (X und Y unkorreliert)
- $\mathrm{Cov}(X, X) = \mathrm{Var}(X) \rightarrow$ Kovarianz verallgemeinert die Varianz
- Maßabhängig: Interpretation der Stärke des Zusammenhangs schwierig
- Nichtlineare Zusammenhänge werden nicht notwendigerweise erkannt

7 Korrelationskoeffizient nach Bravais-Pearson

Durch Normierung der Kovarianz mit den Standardabweichungen beider Merkmale erhält man einen maßunabhängigen Zusammenhang:

7.1 Formel

$$\rho(X, Y) = \mathrm{Cov}(X, Y) \,/\, \sqrt{\mathrm{Var}(X) \cdot \mathrm{Var}(Y)}$$

7.2 Eigenschaften

Wertebereich	$-1 \le \rho(X, Y) \le 1$ | $\rho = 0$: kein linearer Zusammenhang | $\lvert\rho\rvert = 1$: perfekter linearer Zusammenhang

- ρ ist maßunabhängig (skalierungsinvariant)
- Misst ausschließlich lineare Zusammenhänge
- Setzt metrische Merkmale voraus

7.3 Beispiel: Mietspiegel (paarweise Korrelationen)

Merkmal	Nettomiete	Wohnflaeche	Zimmerzahl	NM/qm
Nettomiete	–	0.721	0.567	0.430
Wohnflaeche	0.721	–	0.854	−0.255
Zimmerzahl	0.567	0.854	–	−0.294
NM/qm	0.430	−0.255	−0.294	–

Der hohe Wert zwischen Wohnfläche und Zimmerzahl ($\rho = 0{,}854$) zeigt einen stark positiven linearen Zusammenhang. Der negative Wert zwischen Wohnfläche und Nettomiete/qm ($\rho = -0{,}255$) weist auf einen schwachen negativen Zusammenhang hin.

8 Rangkorrelation nach Spearman

Die Pearson-Korrelation setzt metrische Merkmale voraus. Für ordinalskalierte Merkmale oder nichtlineare (aber monotone) Zusammenhänge verwendet man den Spearman-Rangkorrelationskoeffizienten.

8.1 Vorgehen

- Beobachtungen x_i und y_i werden durch ihre Ränge ersetzt.
- Auf den Rängen wird dann die Pearson-Formel angewendet.
- Bei Bindungen (gleiche Ausprägung) werden Durchschnittsränge vergeben.

8.2 Unterschied zu Pearson

Vergleich	Pearson misst lineare Zusammenhänge | Spearman misst monotone Zusammenhänge (auch nichtlinear)

Beispiel: Beim streng monoton-nichtlinearen Zusammenhang $y = e^x$ ergibt Pearson $\rho = 0{,}48$, Spearman jedoch exakt $\rho = 1$ – da der Zusammenhang monoton ist, erkennt Spearman ihn vollständig.

9 Kausalität vs. Korrelation

Ein statistischer Zusammenhang impliziert keine Kausalität. Korrelation bedeutet lediglich, dass zwei Merkmale gemeinsam variieren – nicht, dass das eine das andere verursacht.

9.1 Voraussetzungen für Kausalitätsnachweis

- Gezielte Manipulation der Ursachenvariable X
- Kontrolle aller weiteren beeinflussenden Variablen, z.B. durch Randomisierung

Merksatz	Statistische Analysen liefern in der Regel den Nachweis eines statistischen Zusammenhangs – aber keiner Kausalität.

10 Ökologischer Fehlschluss

Als ökologischen Fehlschluss bezeichnet man den unzulässigen Schluss von aggregierten Gruppendaten auf das individuelle Verhalten. Der Begriff geht auf William S. Robinson (1950) zurück.

10.1 Beispiel: EHEC-Infektionen 2011

In Hamburg zeigte sich auf Bezirksebene eine Korrelation zwischen dem Anteil der Grünen-Wähler und der EHEC-Erkrankungsrate. Der ökologische Fehlschluss wäre, daraus zu schließen, dass Grünen-Wähler häufiger erkranken.

Tatsächlich lagen zwei Probleme vor:

- Aus der Assoziation auf Makroebene (Bezirke) kann nicht auf das individuelle Verhalten auf der Mikroebene geschlossen werden.
- Eine nicht beachtete Drittvariable (Ernährungsverhalten: Konsum von Sprossengemüse) war die eigentliche Ursache.

11 Take-Home Messages

1	Die gemeinsame Verteilung enthält mehr Information als die einzelnen Randverteilungen – sie erlaubt Rückschlüsse auf Abhängigkeiten.

2	Die Wahl des Zusammenhangsmaßes richtet sich nach dem Skalenniveau: χ^2 für nominale/ordinale Merkmale, Kovarianz/Pearson für metrische, Spearman für ordinale oder monoton-nichtlineare Zusammenhänge.
3	Statistische Zusammenhänge sind nicht mit kausalen Zusammenhängen gleichzusetzen. Für Kausalitätsnachweis sind Randomisierung und Kontrolle von Störvariablen erforderlich.
4	Ökologische Fehlschlüsse entstehen, wenn von Gruppenebene unzulässig auf Individualebene geschlossen wird.

Anhang: Formelübersicht

Maßzahl	Formel / Wertebereich
Erwartete Häufigkeit	$\tilde{h}_{jk} = h_{j\bullet} \cdot h_{\bullet k} / n$
χ^2-Koeffizient	$\chi^2 = \sum_j \sum_k (h_{jk} - \tilde{h}_{jk})^2 / \tilde{h}_{jk}$ | $\chi^2 \geq 0$
Kovarianz	$\mathrm{Cov}(X,Y) = 1/n \cdot \sum_i (x_i - \bar{x})(y_i - \bar{y})$
Pearson-Korrelation	$\rho = \mathrm{Cov}(X,Y) / \sqrt{\mathrm{Var}(X) \cdot \mathrm{Var}(Y)}$ | $-1 \leq \rho \leq 1$
Spearman-Korrelation	Pearson-Formel auf Rängen | $-1 \leq \rho_s \leq 1$