1. Das Big Picture (Chunking)

Das Kapitel entwickelt die grundlegende Sprache statistischer Untersuchungen: Es klärt, **welche Objekte untersucht werden, welche Eigenschaften gemessen werden, welche Art von Daten entsteht und wie eine geeignete Stichprobe erhoben wird**. Im Kern geht es darum, eine reale Fragestellung so zu strukturieren, dass aus beobachteten Daten methodisch zulässige Aussagen entstehen. Das ist entscheidend, weil die Statistik meist nicht die gesamte Grundgesamtheit beobachten kann, sondern von einer Stichprobe unter Berücksichtigung statistischer Unsicherheit auf die Grundgesamtheit schließen muss.

2. Zentrale Definitionen

Untersuchungsobjekte und Datenstruktur

Statistische Einheit

- **Fachliche Definition:** Eine statistische Einheit ist ein für die Fragestellung relevantes Objekt, an dem Merkmale erhoben werden. Sie kann eine Person, ein Unternehmen, ein Produkt, ein Zeitpunkt oder auch eine abstrakte Größe sein.
- **Feynman-Übersetzung:** Das ist das einzelne „Ding“, über das wir etwas lernen möchten. Bei einer Wahlumfrage ist es eine wahlberechtigte Person, bei einer Emissionsstudie eine Firma.

Grundgesamtheit beziehungsweise Population

- **Fachliche Definition:** Die Grundgesamtheit $\mathcal{P}$ ist die Menge aller statistischen Einheiten, auf die sich die Fragestellung und die gewünschten Schlussfolgerungen beziehen.
- **Feynman-Übersetzung:** Das sind **alle**, über die wir am Ende etwas sagen wollen — auch wenn wir sie nicht alle beobachten können.

Die Grundgesamtheit muss nicht zwingend eine vollständig vorhandene, auflistbare Menge sein. Sie kann hypothetisch sein, etwa die Menge aller möglichen Anwendungen eines Düngemittels unter vergleichbaren Bedingungen.

Stichprobe

- **Fachliche Definition:** Eine Stichprobe S ist eine tatsächlich untersuchte Teilmenge der Grundgesamtheit:

$S \subseteq \mathcal{P}$.

- **Feynman-Übersetzung:** Weil wir nicht alle untersuchen können, betrachten wir eine kleinere Gruppe und hoffen, aus ihr etwas über die große Gruppe zu lernen.

Zielpopulation und Auswahlrahmen

- **Fachliche Definition:** Die Zielpopulation ist die theoretisch interessierende Grundgesamtheit. Der Auswahlrahmen ist die praktisch verfügbare Liste oder Menge, aus der die Stichprobe gezogen werden kann.
- **Feynman-Übersetzung:** Die Zielpopulation sind alle, die uns interessieren. Der Auswahlrahmen sind alle, die wir tatsächlich erreichen und auswählen können.

Diese Mengen können voneinander abweichen. Fehlen bestimmte Einheiten im Auswahlrahmen, können sie niemals in die Stichprobe gelangen.

Merkmal

- **Fachliche Definition:** Ein Merkmal X ist eine interessierende Eigenschaft statistischer Einheiten. Formal kann es als Abbildung geschrieben werden:

  $X : \mathcal{P} \to \mathcal{X},$

  wobei $\mathcal{X}$ die Menge möglicher Merkmalsausprägungen ist.

- **Feynman-Übersetzung:** Ein Merkmal ist die Frage, die wir an jedes Untersuchungsobjekt stellen, zum Beispiel: „Wie alt bist du?“ oder „Welche Partei bevorzugst du?“

Merkmalsausprägung

- **Fachliche Definition:** Die Merkmalsausprägung x_i ist der konkret beobachtete Wert des Merkmals X für die statistische Einheit u_i:

  $x_i = X(u_i).$

- **Feynman-Übersetzung:** Das Merkmal ist „Alter“. Die Ausprägung einer bestimmten Person ist beispielsweise 23 Jahre.

Merkmale werden üblicherweise mit Großbuchstaben wie X, Y oder Z bezeichnet, die beobachteten Ausprägungen mit Kleinbuchstaben wie x, y oder z.

Datentypen

Diskretes Merkmal

- **Fachliche Definition:** Ein Merkmal ist diskret, wenn es endlich oder höchstens abzählbar unendlich viele mögliche Ausprägungen besitzt.
- **Feynman-Übersetzung:** Die möglichen Werte kann man theoretisch einzeln aufzählen — auch wenn die Liste sehr lang oder unendlich ist.

Beispiele sind Parteipräferenz, Studienfach und die Anzahl der Likes eines Beitrags. Zwischen 17 und 18 Likes gibt es keinen sinnvollen Zwischenwert wie $17{,}4$ Likes.

Stetiges Merkmal

- **Fachliche Definition:** Ein Merkmal ist stetig, wenn innerhalb eines Werteintervalls theoretisch jeder reelle Wert als Ausprägung möglich ist.
- **Feynman-Übersetzung:** Egal, wie genau man misst, zwischen zwei verschiedenen Messwerten könnte theoretisch immer noch ein weiterer Wert liegen.

Beispiele sind Körpergröße, Gewinn oder Bruttosozialprodukt. In der Praxis werden stetige Merkmale nur mit begrenzter Genauigkeit gemessen, aber dennoch häufig als stetig modelliert.

Kategorisierung eines stetigen Merkmals

- **Fachliche Definition:** Bei der Kategorisierung wird ein stetiger Wertebereich in disjunkte Intervalle oder Klassen zerlegt.
- **Feynman-Übersetzung:** Statt das genaue Alter zu verwenden, schreiben wir nur „unter 30“, „30 bis 49“ oder „ab 50“.

Dadurch wird das beobachtete Merkmal diskret beziehungsweise kategorial, obwohl das ursprüngliche Merkmal stetig war.

Skalenniveaus

Nominalskala

- **Fachliche Definition:** Nominalskalierte Ausprägungen sind lediglich unterschiedliche Bezeichnungen. Es existiert keine natürliche Rangordnung.
- **Feynman-Übersetzung:** Die Werte sind Namensschilder. Man kann prüfen, ob zwei

Schilder gleich sind, aber nicht, welches „größer“ ist.

Beispiele sind Parteipräferenz, Nationalität und Kreditzweck.

Ordinalskala

- **Fachliche Definition:** Ordinalskalierte Ausprägungen können sinnvoll geordnet werden. Die Größe der Abstände zwischen den Rangstufen ist jedoch nicht interpretierbar.
- **Feynman-Übersetzung:** Wir wissen, wer vor wem liegt, aber nicht, wie groß der Vorsprung ist.

Beispiele sind Schulnoten, Zufriedenheitsstufen und Platzierungen.

Kardinalskala

- **Fachliche Definition:** Kardinalskalierte Ausprägungen können numerisch interpretiert werden. Insbesondere sind Differenzen und — bei einem sachlich begründeten Nullpunkt — auch Verhältnisse sinnvoll.
- **Feynman-Übersetzung:** Die Zahlen sind echte Messwerte. Ein Abstand von 10 Einheiten bedeutet überall dasselbe; bei einer Verhältnisskala kann zusätzlich „doppelt so viel“ sinnvoll sein.

Beispiele aus der Vorlesung sind Alter, Körpergröße und Jahreseinkommen. Das Skalenniveau legt fest, welche Rechnungen und statistischen Verfahren zulässig sind.

Versuchsplanung und Störvariablen

Versuchsplanung

- **Fachliche Definition:** Versuchsplanung umfasst die Festlegung des Untersuchungsziels, die geplanten statistischen Methoden, die Datenerhebung und verbindliche Regeln zur Durchführung.
- **Feynman-Übersetzung:** Man entscheidet vorab, welche Frage beantwortet werden soll, welche Daten man benötigt und wie man verhindert, dass man sich nachträglich die passendste Geschichte aussucht.

Störvariable

- **Fachliche Definition:** Eine Störvariable Z beeinflusst die interessierende Ergebnisgröße Y und hängt gleichzeitig mit der untersuchten Einflussgröße D zusammen, ohne

selbst der primäre Untersuchungsgegenstand zu sein.

- **Feynman-Übersetzung:** Eine Störvariable ist ein versteckter dritter Faktor, der so tut, als wäre die untersuchte Maßnahme für einen Unterschied verantwortlich.

Bei der Untersuchung einer didaktischen Maßnahme können beispielsweise Vorwissen, Lernverhalten oder Alter den Lernerfolg beeinflussen.

Homogenisierung

- **Fachliche Definition:** Die Grundgesamtheit wird anhand relevanter Störvariablen in möglichst vergleichbare Teilgruppen zerlegt.
- **Feynman-Übersetzung:** Man vergleicht nur Personen, die sich hinsichtlich wichtiger Hintergrundmerkmale ähneln.

Randomisierung

- **Fachliche Definition:** Einheiten werden zufällig unterschiedlichen Behandlungsgruppen zugewiesen. Dadurch sollen sich bekannte und unbekannte Störvariablen im Erwartungswert gleichmäßig verteilen.
- **Feynman-Übersetzung:** Der Zufall entscheidet, wer die Maßnahme erhält. Dadurch kann niemand systematisch die „leichteren Fälle“ in eine bestimmte Gruppe stecken.

Statistische Modellierung

- **Fachliche Definition:** Störvariablen werden explizit als erklärende Größen in ein statistisches Modell aufgenommen.
- **Feynman-Übersetzung:** Man versucht rechnerisch, Personen mit ähnlichen Hintergrundbedingungen zu vergleichen.

Homogenisierung, Randomisierung und statistische Modellierung sind die in der Vorlesung genannten zentralen Kontrollansätze.

Stichprobenverfahren

Repräsentative Stichprobe

- **Fachliche Definition:** Eine Stichprobe ist hinsichtlich der untersuchungsrelevanten Eigenschaften repräsentativ, wenn sie keine systematischen Abweichungen von der Zielpopulation aufweist.
- **Feynman-Übersetzung:** Die Stichprobe ist ein brauchbares verkleinertes Abbild der

großen Gruppe.

Repräsentativität bedeutet nicht, dass jede Häufigkeit exakt mit der Grundgesamtheit übereinstimmt. Zufällige Abweichungen sind unvermeidbar.

Einfache Zufallsstichprobe

- **Fachliche Definition:** Bei einer einfachen Zufallsstichprobe ohne Zurücklegen besitzt jede mögliche Stichprobe der Größe n dieselbe Auswahlwahrscheinlichkeit.
- **Feynman-Übersetzung:** Alle möglichen Gruppen mit gleich vielen Mitgliedern haben dieselbe Chance, gezogen zu werden.

Daraus folgt, dass jede einzelne Einheit dieselbe Chance besitzt, Teil der Stichprobe zu sein.

Geschichtete Stichprobe

- **Fachliche Definition:** Die Population wird zunächst in Schichten aufgeteilt. Anschließend wird aus jeder Schicht eine eigene Zufallsstichprobe gezogen.
- **Feynman-Übersetzung:** Man bildet wichtige Untergruppen und sorgt dafür, dass aus jeder Untergruppe Personen in der Stichprobe vorkommen.

Die Schichten sollten innerhalb möglichst ähnlich sein und sich untereinander hinsichtlich des interessierenden Merkmals unterscheiden.

Klumpenstichprobe

- **Fachliche Definition:** Die Population wird in natürliche Gruppen beziehungsweise Klumpen eingeteilt. Einige Klumpen werden zufällig ausgewählt; innerhalb dieser Klumpen erfolgt eine Vollerhebung oder eine weitere Stichprobenziehung.
- **Feynman-Übersetzung:** Statt einzelne Schüler aus dem ganzen Land auszuwählen, wählt man einige Schulklassen aus und untersucht die Schüler dieser Klassen.

Idealerweise ähnelt jeder Klumpen einer kleinen Ausgabe der Gesamtpopulation: hohe Variation innerhalb der Klumpen, geringe Unterschiede zwischen den Klumpen.

Bewusste Auswahl beziehungsweise Quotenverfahren

- **Fachliche Definition:** Einheiten werden nicht zufällig ausgewählt, sondern so, dass vorher festgelegte Quoten erfüllt werden.
- **Feynman-Übersetzung:** Man sucht so lange Personen, bis bestimmte Gruppenzahlen

erreicht sind.

Das Einhalten von Quoten erzeugt allein noch keine Zufallsstichprobe.

Induktive Statistik

- **Fachliche Definition:** Die induktive Statistik verwendet Stichprobendaten, um unter expliziter Berücksichtigung der Stichprobenunsicherheit Aussagen über die Grundgesamtheit abzuleiten.
- **Feynman-Übersetzung:** Wir sehen nur einen kleinen Ausschnitt und versuchen ehrlich anzugeben, was dieser Ausschnitt über das große Ganze verrät — einschließlich unserer Unsicherheit.

3. Formeln, Beweise & Intuition

Die Vorlesung ist überwiegend konzeptionell und enthält noch kaum explizite Rechenformeln. Die folgenden Formeln formalisieren die Aussagen der Folien und machen sichtbar, **warum** die beschriebenen Regeln gelten.

3.1 Formale Anatomie einer statistischen Untersuchung

Die Formel

Für eine endliche Grundgesamtheit kann geschrieben werden:

$$\mathcal{P} = u_1, u_2, \ldots, u_N.$$

Eine Stichprobe der Größe n ist:

$$S \subseteq \mathcal{P}, \qquad |S| = n.$$

Ein Merkmal ist eine Abbildung:

$$X : \mathcal{P} \to \mathcal{X}.$$

Der Wert für Einheit u_i lautet:

$$x_i = X(u_i).$$

Dekonstruktion

- $\mathcal{P}$: Grundgesamtheit.
- u_i: die i-te statistische Einheit.

- N: Anzahl der Einheiten in der Grundgesamtheit.
- S: ausgewählte Stichprobe.
- n: Stichprobenumfang.
- X: untersuchtes Merkmal.
- $\mathcal{X}$: Menge aller möglichen Ausprägungen.
- x_i: beobachtete Ausprägung für Einheit u_i.

Der Beweis / Die Herleitung

1. Zuerst wird festgelegt, über welche Objekte eine Aussage getroffen werden soll. Diese Objekte bilden $\mathcal{P}$.
2. Weil meist nicht alle Einheiten beobachtet werden können, wird eine Teilmenge S ausgewählt.
3. Die Forschungsfrage bestimmt, welche Eigenschaft X jeder Einheit untersucht werden soll.
4. Die Datenerhebung liefert nicht das abstrakte Merkmal X, sondern konkrete Werte x_i.
5. Der Datensatz besteht somit aus Zuordnungen der Form:

$$u_i \longmapsto x_i.$$

Die Grundbegriffe „Einheit“, „Population“, „Stichprobe“, „Merkmal“ und „Ausprägung“ sind daher keine isolierten Vokabeln, sondern Teile einer einzigen Abbildungskette.

Die Analogie & Mechanik

Stelle dir ein Lager mit N Produkten vor. Die Produkte sind die Einheiten u_i, das Lager ist $\mathcal{P}$, eine Qualitätsprüfung von n Produkten ist S, das Merkmal X ist das Gewicht und x_i das tatsächlich gemessene Gewicht eines Produkts.

Ist $\mathcal{P}$ falsch definiert, beantwortet selbst eine perfekte Messung die falsche Frage. Ist S schlecht ausgewählt, sind die Messwerte möglicherweise korrekt, aber nicht auf $\mathcal{P}$ übertragbar.

3.2 Diskrete und stetige Wertebereiche

Die Formel

Ein Merkmal ist diskret, wenn seine Ausprägungsmenge höchstens abzählbar ist:

$$|\mathcal{X}| \leq |\mathbb{N}|.$$

Das bedeutet, dass die möglichen Ausprägungen als Folge dargestellt werden können:

$$\mathcal{X} = x_1, x_2, x_3, \ldots.$$

Ein typisches stetiges Merkmal besitzt dagegen einen Wertebereich, der ein vollständiges reelles Intervall enthält:

$$[a, b] \subseteq \mathcal{X}.$$

Damit gilt für zwei verschiedene mögliche Werte $x_1 < x_2$, dass weitere mögliche Werte dazwischenliegen, beispielsweise:

$$x_1 < \frac{x_1 + x_2}{2} < x_2.$$

Dekonstruktion

- $\mathcal{X}$: Menge möglicher Ausprägungen.
- $\mathbb{N}$: Menge der natürlichen Zahlen.
- $|\mathcal{X}|$: Mächtigkeit, also Größe der Menge.
- $[a, b]$: Intervall aller reellen Werte zwischen a und b.
- x_1, x_2: zwei mögliche Merkmalswerte.

Der Beweis / Die Herleitung

Bei einem diskreten Merkmal kann theoretisch eine vollständige Liste der möglichen Werte erzeugt werden. Für die Anzahl der Likes lautet diese Liste beispielsweise:

$$0, 1, 2, 3, \ldots$$

Bei einem stetigen Merkmal funktioniert das nicht. Zwischen zwei verschiedenen reellen Zahlen liegt immer eine weitere reelle Zahl. Wählt man den Mittelwert,

$$m = \frac{x_1 + x_2}{2},$$

dann liegt m strikt zwischen x_1 und x_2. Derselbe Schritt kann zwischen x_1 und m erneut durchgeführt werden. Es entstehen immer weitere Zwischenwerte.

Die Analogie & Mechanik

Diskrete Werte ähneln Treppenstufen: Man steht auf einer Stufe oder auf der nächsten, aber nicht auf einer „halben Stufe“ des Zählvorgangs.

Stetige Werte ähneln einer Rampe: Zwischen zwei Positionen gibt es theoretisch beliebig viele weitere Positionen.

Eine Waage, die nur auf volle Kilogramm rundet, macht das zugrunde liegende Gewicht nicht wirklich diskret. Sie macht lediglich die **Aufzeichnung** gröber. Die Folien betonen genau diese Trennung zwischen theoretischem Merkmal und endlicher Messgenauigkeit.

3.3 Warum das Skalenniveau die zulässigen Rechnungen bestimmt

Die Formel

Eine Umcodierung eines Merkmals kann als Transformation

$$f : \mathcal{X} \to \mathcal{X}'$$

verstanden werden.

Für unterschiedliche Skalen müssen unterschiedliche Strukturen erhalten bleiben.

Nominalskala

Nur Gleichheit und Verschiedenheit müssen erhalten bleiben:

$$x_i = x_j \iff f(x_i) = f(x_j).$$

Jede eindeutige Umbenennung ist zulässig.

Ordinalskala

Die Reihenfolge muss erhalten bleiben:

$$x_i < x_j \Longrightarrow f(x_i) < f(x_j).$$

Daher sind streng monoton steigende Transformationen zulässig.

Kardinalskala mit interpretierbaren Differenzen

Bei einer Intervallskala sind Transformationen der Form

$$f(x) = a + bx, \qquad b > 0$$

zulässig.

Für Differenzen gilt:

$$f(x_2) - f(x_1) = b(x_2 - x_1).$$

Kardinalskala mit interpretierbaren Verhältnissen

Bei einer Verhältnisskala ist der Nullpunkt sachlich festgelegt. Zulässig sind nur Skalierungen:

$$f(x) = bx, \qquad b > 0.$$

Dann gilt:

$$\frac{f(x_2)}{f(x_1)} = \frac{bx_2}{bx_1}\frac{x_2}{x_1}.$$

Dekonstruktion

- f: Umcodierung oder Wechsel der Maßeinheit.
- x_i, x_j: ursprüngliche Ausprägungen.
- $f(x_i)$, $f(x_j)$: transformierte Ausprägungen.
- a: Verschiebung des Nullpunkts.
- b: Veränderung der Maßeinheit.
- $b > 0$: Bedingung, damit die Rangfolge erhalten bleibt.

Der Beweis / Die Herleitung

Warum man Nominalwerte nicht mitteln darf

Angenommen, Parteien werden codiert als:

$$\text{Partei A} = 1, \qquad \text{Partei B} = 2, \qquad \text{Partei C} = 3.$$

Eine andere Person könnte ebenso zulässig codieren:

$$\text{Partei A} = 20, \qquad \text{Partei B} = 5, \qquad \text{Partei C} = 100.$$

Die Kategorien sind unverändert, aber ein Mittelwert der Codes würde sich drastisch verändern. Eine Kennzahl, deren Ergebnis von einer willkürlichen Codierung abhängt, besitzt keine sachliche Bedeutung.

Warum bei Ordinaldaten Abstände nicht sicher interpretierbar sind

Aus

$$x_1 < x_2 < x_3$$

folgt nur eine Rangfolge. Es folgt nicht:

$$x_2 - x_1 = x_3 - x_2.$$

Die Abstände zwischen „unzufrieden“, „neutral“ und „zufrieden“ müssen psychologisch nicht gleich groß sein.

Warum ein verschiebbarer Nullpunkt Verhältnisse zerstört

Für eine Transformation mit $a \neq 0$ gilt im Allgemeinen:

$$\frac{a + bx_2}{a + bx_1} \neq \frac{x_2}{x_1}.$$

Deshalb ist bei Temperaturen in Grad Celsius die Aussage „20 Grad sind doppelt so warm wie 10 Grad“ nicht sinnvoll. Nach einer Umrechnung in eine andere Temperaturskala würde das Verhältnis nicht erhalten bleiben.

Die Analogie & Mechanik

- **Nominal:** verschiedenfarbige Ordner. Die Farbe dient nur zur Unterscheidung.
- **Ordinal:** Plätze bei einem Wettkampf. Platz 1 ist besser als Platz 2, aber der Leistungsabstand ist unbekannt.
- **Intervallskala:** eine Landkarte mit frei gewähltem Nullpunkt. Abstände bleiben sinnvoll, der Ursprung ist aber verschiebbar.
- **Verhältnisskala:** ein Lineal mit einem echten Nullpunkt. 0 Zentimeter bedeutet keine Länge; deshalb sind Aussagen wie „doppelt so lang“ sinnvoll.

Die Vorlesung fasst die numerisch interpretierbaren Skalen unter „Kardinalskala“ zusammen. Die Unterteilung in Intervall- und Verhältnisskala erklärt genauer, wann Quotienten tatsächlich sinnvoll sind.

3.4 Einfache Zufallsstichprobe: Anzahl und Wahrscheinlichkeit möglicher Stichproben

Die Formel

Aus einer Population mit N Einheiten können ohne Zurücklegen

$$\binom{N}{n} = \frac{N!}{n!(N-n)!}$$

verschiedene ungeordnete Stichproben der Größe n gezogen werden.

Bei einer einfachen Zufallsstichprobe besitzt jede dieser Stichproben die Wahrscheinlichkeit

$$P(S = s) = \frac{1}{\binom{N}{n}}.$$

Dekonstruktion

- N: Größe der Grundgesamtheit.
- n: Stichprobenumfang.
- $\binom{N}{n}$: Anzahl der Möglichkeiten, n Einheiten aus N Einheiten auszuwählen.
- $N!$: Fakultät von N.
- s: eine konkrete mögliche Stichprobe.
- $P(S = s)$: Wahrscheinlichkeit, genau diese Stichprobe zu erhalten.

Der Beweis / Die Herleitung

Bei einer geordneten Ziehung ohne Zurücklegen gibt es zunächst:

$$N(N-1)(N-2)\cdots(N-n+1) = \frac{N!}{(N-n)!}$$

mögliche Ziehungsfolgen.

Jede ungeordnete Stichprobe erscheint dabei in $n!$ verschiedenen Reihenfolgen. Daher wird durch $n!$ geteilt:

$$\frac{N!}{(N-n)!n!} = \binom{N}{n}.$$

Sind alle möglichen Stichproben gleich wahrscheinlich, müssen sich ihre Wahrscheinlichkeiten zu 1 addieren:

$$\binom{N}{n} \cdot P(S = s) = 1.$$

Daraus folgt:

$$P(S = s) = \frac{1}{\binom{N}{n}}.$$

Die Analogie & Mechanik

Stelle dir einen Lostopf mit N verschiedenen Namen vor. Es werden n Namen gezogen, wobei die Reihenfolge keine Rolle spielt.

Wird N bei konstantem n sehr groß, wächst $\binom{N}{n}$ stark. Die Wahrscheinlichkeit einer ganz bestimmten Stichprobe wird dadurch extrem klein. Das ist kein Problem: Entscheidend ist nicht, dass eine bestimmte Stichprobe wahrscheinlich ist, sondern dass **keine mögliche Stichprobe systematisch bevorzugt wird**.

3.5 Auswahlwahrscheinlichkeit einer einzelnen Einheit

Die Formel

Die Wahrscheinlichkeit, dass eine bestimmte Einheit u_i in einer einfachen Zufallsstichprobe enthalten ist, beträgt:

$$P(u_i \in S) = \frac{\binom{N-1}{n-1}}{\binom{N}{n}} \frac{n}{N}.$$

Dekonstruktion

- u_i: eine bestimmte Einheit.
- $\binom{N-1}{n-1}$: Anzahl der Stichproben, die u_i enthalten.
- $\binom{N}{n}$: Anzahl aller möglichen Stichproben.
- n/N: Anteil der Population, der ausgewählt wird.

Der Beweis / Die Herleitung

Soll u_i sicher in der Stichprobe enthalten sein, müssen nur noch $n-1$ weitere Einheiten aus den verbleibenden $N-1$ Einheiten ausgewählt werden. Dafür existieren

$$\binom{N-1}{n-1}$$

Möglichkeiten.

Da insgesamt $\binom{N}{n}$ Stichproben möglich sind:

$$P(u_i \in S) = \frac{\binom{N-1}{n-1}}{\binom{N}{n}}.$$

Einsetzen der Fakultäten ergibt:

$$\frac{\frac{(N-1)!}{(n-1)!(N-n)!}}{\frac{N!}{n!(N-n)!}} = \frac{(N-1)!}{(n-1)!(N-n)!} \cdot \frac{n!(N-n)!}{N!}.$$

Kürzen liefert:

$$P(u_i \in S) = \frac{n}{N}.$$

Die Analogie & Mechanik

Wenn aus 100 Personen 10 zufällig ausgewählt werden, hat jede Person die Auswahlwahrscheinlichkeit:

$$\frac{10}{100} = 0{,}1.$$

- Steigt n bei konstantem N, steigt die Auswahlwahrscheinlichkeit.
- Steigt N bei konstantem n, sinkt sie.
- Für $n = N$ gilt:

$$P(u_i \in S) = 1.$$

Jede Einheit wird dann beobachtet; es handelt sich um eine Vollerhebung.

Die Gleichheit der Auswahlchancen und die Gleichwahrscheinlichkeit aller Stichproben sind Kerneigenschaften der einfachen Zufallsstichprobe in der Vorlesung.

3.6 Warum der Stichprobenmittelwert die Grundgesamtheit im Mittel korrekt trifft

Die Formel

Der Mittelwert der Grundgesamtheit lautet:

$$\mu = \frac{1}{N} \sum_{i=1}^{N} x_i.$$

Definiere den Auswahlindikator:

$$I_i = \Big\{ 1, \quad u_i \in S,\ 0,\ u_i \notin S.$$

Dann kann der Stichprobenmittelwert geschrieben werden als:

$$\overline{X}_S = \frac{1}{n} \sum_{i=1}^{N} I_i x_i.$$

Unter einer einfachen Zufallsstichprobe gilt:

$$\mathbb{E}[\overline{X}_S] = \mu.$$

Dekonstruktion

- μ: Mittelwert der gesamten Grundgesamtheit.
- $\overline{X}_S$: Mittelwert der zufällig gezogenen Stichprobe.
- I_i: Indikator, ob Einheit u_i ausgewählt wurde.
- $\mathbb{E}[\overline{X}_S]$: durchschnittlicher Stichprobenmittelwert über alle möglichen Stichproben.
- x_i: fester Merkmalswert der Einheit u_i.

Der Beweis / Die Herleitung

Aus der Auswahlwahrscheinlichkeit folgt:

$$\mathbb{E}[I_i] = P(I_i = 1) \frac{n}{N}.$$

Damit:

$$\mathbb{E}[\overline{X}_S] = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^{N} I_i x_i \right].$$

Wegen der Linearität des Erwartungswertes:

$$\mathbb{E}[\overline{X}_S] = \frac{1}{n} \sum_{i=1}^{N} \mathbb{E}[I_i] x_i.$$

Einsetzen von $\mathbb{E}[I_i] = n/N$:

$$\mathbb{E}[\overline{X}_S] = \frac{1}{n} \sum_{i=1}^{N} \frac{n}{N} x_i.$$

Kürzen ergibt:

$$\mathbb{E}[\overline{X}_S] = \frac{1}{N} \sum_{i=1}^{N} x_i = \mu.$$

Der Stichprobenmittelwert ist somit unter diesem Auswahlverfahren **erwartungstreu** für den Populationsmittelwert.

Die Analogie & Mechanik

Eine einzelne Stichprobe kann zu hoch oder zu niedrig liegen. Würde man die Zufallsziehung jedoch sehr oft wiederholen, lägen die Stichprobenmittelwerte symmetrisch um den wahren Populationsmittelwert.

Erwartungstreue bedeutet daher nicht:

$$\overline{X}_S = \mu$$

für jede einzelne Stichprobe.

Sie bedeutet:

$$\text{durchschnittliche Abweichung über alle möglichen Stichproben} = 0.$$

3.7 Unsicherheit des Stichprobenmittelwertes

Die Formel

Definiere die Streuung der Werte in der Population als:

$$S^2 = \frac{1}{N-1}\sum_{i=1}^{N}(x_i - \mu)^2.$$

Für eine einfache Zufallsstichprobe ohne Zurücklegen gilt:

$$\mathrm{Var}(\overline{X}_S) = \left(1 - \frac{n}{N}\right)\frac{S^2}{n}.$$

Der Faktor

$$1 - \frac{n}{N}$$

heißt Endlichkeitskorrektur.

Dekonstruktion

- $\mathrm{Var}(\overline{X}_S)$: Streuung möglicher Stichprobenmittelwerte.
- S^2: Variabilität der Populationswerte.
- n: Stichprobenumfang.

- N: Populationsgröße.
- n/N: Anteil der Population, der beobachtet wird.

Der Beweis / Die Herleitung

Ohne Zurücklegen sind die Auswahlindikatoren verschiedener Einheiten negativ abhängig: Wird eine Einheit gezogen, stehen weniger Plätze für andere Einheiten zur Verfügung.

Für zwei verschiedene Einheiten gilt:

$$P(I_i = 1, I_j = 1) = \frac{\binom{N-2}{n-2}}{\binom{N}{n}} \frac{n(n-1)}{N(N-1)}.$$

Daraus folgt:

$$\operatorname{Cov}(I_i, I_j) = -\frac{n(N-n)}{N^2(N-1)}.$$

Die negative Kovarianz reduziert die Varianz gegenüber einer Ziehung mit Zurücklegen. Setzt man die Varianzen und Kovarianzen der Auswahlindikatoren in

$$\operatorname{Var}\left(\frac{1}{n}\sum_{i=1}^{N} I_i x_i\right)$$

ein und fasst die Terme zusammen, erhält man:

$$\operatorname{Var}(\overline{X}_S) = \left(1 - \frac{n}{N}\right)\frac{S^2}{n}.$$

Die Analogie & Mechanik

Die Formel enthält drei zentrale Mechanismen:

1. **Heterogenität der Population**

   Je größer S^2 ist, desto stärker unterscheiden sich die Einheiten. Zufällig ausgewählte Stichproben können dann stärker voneinander abweichen.

2. **Stichprobenumfang**

   Je größer n ist, desto kleiner wird der Term S^2/n. Mehr Beobachtungen stabilisieren den Mittelwert.

3. **Beobachteter Populationsanteil**

   Nähert sich n/N dem Wert 1, nähert sich

$$1 - \frac{n}{N}$$

dem Wert 0.

Für $n = N$ gilt:

$$\mathrm{Var}(\overline{X}_S) = 0,$$

weil die gesamte Population beobachtet wird.

Ist N im Verhältnis zu n sehr groß, gilt näherungsweise:

$$1 - \frac{n}{N} \approx 1.$$

Dann ist:

$$\mathrm{Var}(\overline{X}_S) \approx \frac{S^2}{n}.$$

Diese Formel formalisiert die Aussage der Vorlesung, dass beim Schluss von der Stichprobe auf die Grundgesamtheit Unsicherheit berücksichtigt werden muss.

3.8 Gewichtung bei geschichteten Stichproben

Die Formel

Sei die Population in H Schichten aufgeteilt. Für Schicht h gelten:

- Populationsgröße N_h,
- Populationsmittelwert μ_h,
- Stichprobenumfang n_h,
- Stichprobenmittelwert $\overline{x}_h$.

Die Populationsgewichte lauten:

$$W_h = \frac{N_h}{N}.$$

Der Gesamtmittelwert der Population kann zerlegt werden als:

$$\mu = \sum_{h=1}^{H} W_h \mu_h.$$

Der geschichtete Schätzer lautet:

$$\widehat{\mu}_{\text{str}} = \sum_{h=1}^{H} W_h \overline{x}_h.$$

Dekonstruktion

- H: Anzahl der Schichten.
- N_h: Anzahl der Populationseinheiten in Schicht h.
- N: Gesamtgröße der Population.
- W_h: tatsächlicher Populationsanteil der Schicht h.
- μ_h: wahrer Mittelwert der Schicht h.
- $\overline{x}_h$: beobachteter Stichprobenmittelwert der Schicht h.
- $\widehat{\mu}_{\text{str}}$: geschätzter Gesamtmittelwert.

Der Beweis / Die Herleitung

Der Populationsmittelwert ist:

$$\mu = \frac{1}{N} \sum_{h=1}^{H} \sum_{i=1}^{N_h} x_{hi}.$$

Innerhalb jeder Schicht gilt:

$$\sum_{i=1}^{N_h} x_{hi} = N_h \mu_h.$$

Daher:

$$\mu = \frac{1}{N} \sum_{h=1}^{H} N_h \mu_h.$$

Umformen ergibt:

$$\mu = \sum_{h=1}^{H} \frac{N_h}{N} \mu_h = \sum_{h=1}^{H} W_h \mu_h.$$

Da μ_h unbekannt ist, wird es durch $\overline{x}_h$ geschätzt:

$$\widehat{\mu}_{\text{str}} = \sum_{h=1}^{H} W_h \overline{x}_h.$$

Die Analogie & Mechanik

Angenommen, eine kleine Gruppe bildet nur 10 der Population, wurde aber bewusst so stark befragt, dass sie 50 der Stichprobe ausmacht. Ein ungewichteter Mittelwert würde dieser kleinen Gruppe fünfmal zu viel Einfluss geben.

Die Gewichte korrigieren das:

$$W_h = \frac{\text{Größe der Schicht in der Population}}{\text{Größe der gesamten Population}}.$$

- Wird W_h groß, beeinflusst die Schicht den Gesamtwert stärker.
- Ist W_h klein, darf auch eine große Teilstichprobe dieser Schicht den Gesamtwert nicht übermäßig dominieren.
- Bei proportionaler Auswahl gilt ungefähr:

  $$\frac{n_h}{n} = \frac{N_h}{N}.$$

  Dann stimmt die Stichprobenzusammensetzung bereits mit der Populationszusammensetzung überein.

Die Vorlesung weist darauf hin, dass Schichten gezielt überrepräsentiert werden können, sofern Gruppenanteile und Gruppenzugehörigkeiten bekannt sind.

3.9 Der Kreislauf der Datenanalyse

Das Diagramm auf Seite 24 stellt Datenanalyse nicht als einmalige Rechenoperation, sondern als Kreislauf dar:

$$\text{Planung} \to \text{Datenerhebung} \to \text{Aufbereitung und Prüfung} \to \text{Analyse} \to \text{Interpretation}$$

Die Mechanik ist zirkulär: Neue Analysen oder wiederverwendete Daten erzeugen häufig neue Fragen, die eine überarbeitete Planung erforderlich machen. Eine statistisch korrekte Berechnung kann ein schlecht geplantes Untersuchungsdesign nicht nachträglich reparieren.

4. Häufige Missverständnisse & Edge Cases

„Eine Zahl ist automatisch metrisch.“

Denkfehler: Parteipräferenzen werden mit den Zahlen 1, 2 und 3 codiert. Deshalb könne man ihren Mittelwert bilden.

Korrektur: Die Zahlen sind nur Etiketten. Eine numerische Codierung verändert das Skalenniveau nicht. Entscheidend ist die Bedeutung der Ausprägungen, nicht ihre Darstellung im Datensatz.

„Diskret bedeutet qualitativ, stetig bedeutet quantitativ."

Denkfehler: Alle diskreten Merkmale seien Kategorien ohne Zahlenbedeutung.

Korrektur: Die Anzahl der Kinder ist diskret, aber quantitativ und metrisch. Parteipräferenz ist ebenfalls diskret, aber nominal. Diskretheit und Skalenniveau sind zwei verschiedene Klassifikationsachsen.

„Eine gerundete Messung ist ein diskretes Merkmal."

Denkfehler: Weil Körpergröße nur auf Zentimeter genau gespeichert wird, sei Körpergröße diskret.

Korrektur: Die gespeicherten Messwerte sind diskretisiert. Das zugrunde liegende theoretische Merkmal kann weiterhin stetig sein.

„Durch Kategorisierung wird nichts Wesentliches verändert."

Denkfehler: Genaue Einkommen und Einkommensklassen enthielten dieselbe Information.

Korrektur: Durch Kategorisierung gehen Abstände und Unterschiede innerhalb der Klassen verloren. Personen knapp unter und knapp über einer Klassengrenze können künstlich stark verschieden erscheinen, während sehr unterschiedliche Personen innerhalb derselben Klasse als gleich behandelt werden.

„Auf einer Ordinalskala kann man gleiche Abstände unterstellen."

Denkfehler: Der Abstand zwischen den Schulnoten 1 und 2 sei genauso groß wie zwischen 4 und 5.

Korrektur: Die Noten liefern eine Reihenfolge, aber keine garantierten gleich großen Leistungsabstände. Rechnungen mit Abständen benötigen zusätzliche Annahmen.

„Auf jeder Kardinalskala sind Quotienten sinnvoll.“

Denkfehler: Sobald Differenzen sinnvoll sind, müsse auch „doppelt so viel“ sinnvoll sein.

Korrektur: Quotienten benötigen einen sachlich festen Nullpunkt. Bei Celsius-Temperaturen sind Differenzen interpretierbar, Verhältnisse jedoch nicht. Die Vorlesung formuliert deshalb vorsichtig, dass bei Kardinalskalen „in der Regel“ auch Verhältnisse interpretierbar sind.

„Zufällig ausgewählt bedeutet exakt repräsentativ.“

Denkfehler: Eine Zufallsstichprobe müsse genau dieselben Anteile und Mittelwerte wie die Population besitzen.

Korrektur: Zufällige Stichproben können zufällig abweichen. Randomisierung verhindert systematische Bevorzugung, nicht jede Abweichung. Repräsentativität ist eine Eigenschaft des Auswahlprozesses und der realisierten Datenqualität, keine Garantie perfekter Übereinstimmung.

„Eine große Stichprobe beseitigt jeden Bias.“

Denkfehler: Bei sehr großem n seien Auswahlprobleme unwichtig.

Korrektur: Ein großer Stichprobenumfang reduziert zufällige Unsicherheit, aber nicht automatisch systematische Fehler. Werden nur bestimmte Bevölkerungsgruppen erreicht, kann eine riesige Stichprobe sehr präzise die falsche Population beschreiben.

„Alle Mitglieder der Zielpopulation können automatisch ausgewählt werden.“

Denkfehler: Sobald eine Population definiert wurde, habe jede Einheit eine positive Auswahlchance.

Korrektur: Einheiten können im Auswahlrahmen fehlen. Ebenso kann die Stichprobe Einheiten enthalten, die gar nicht zur Zielpopulation gehören. Die Vorlesung nennt beide Probleme ausdrücklich.

„Random Sampling und Randomisierung sind dasselbe.“

Denkfehler: Eine zufällige Stichprobe und eine zufällige Zuweisung zu Behandlungsgruppen hätten dieselbe Funktion.

Korrektur:

- Zufällige **Stichprobenziehung** unterstützt die Übertragbarkeit von der Stichprobe auf die Population.
- Zufällige **Behandlungszuweisung** unterstützt die kausale Interpretation eines Gruppenunterschieds.

Eine Studie kann das eine besitzen, ohne das andere zu besitzen.

„Kontrolle einer Variablen kann niemals schaden."

Denkfehler: Je mehr Kontrollvariablen in ein Modell aufgenommen werden, desto glaubwürdiger sei der geschätzte Effekt.

Korrektur: Kontrolliert werden sollten echte, vor der Behandlung liegende Störvariablen. Wird eine Variable erst durch die untersuchte Maßnahme verursacht, kann ihre Kontrolle einen Teil des tatsächlichen Effekts entfernen oder neue Verzerrungen erzeugen.

„Statistische Modellierung entfernt Störvariablen automatisch."

Denkfehler: Sobald Alter und Vorwissen in einem Modell stehen, sei der Maßnahmeneffekt kausal identifiziert.

Korrektur: Modellbasierte Kontrolle funktioniert nur für beobachtete, sinnvoll gemessene und korrekt modellierte Störvariablen. Unbeobachtete Störfaktoren und falsche Modellannahmen können weiterhin Verzerrungen verursachen.

„Schichtung und Klumpenbildung verfolgen dasselbe Ziel."

Denkfehler: Beide Verfahren teilten die Population lediglich in Gruppen.

Korrektur: Die ideale innere Struktur ist nahezu entgegengesetzt:

- **Schichten:** innerhalb möglichst homogen, zwischen den Schichten unterschiedlich.
- **Klumpen:** innerhalb möglichst vielfältig, zwischen den Klumpen möglichst ähnlich.

Bei einer geschichteten Stichprobe wird aus jeder Schicht gezogen. Bei einer Klumpenstichprobe werden nur einige Klumpen ausgewählt.

„Viele Personen aus einem Klumpen sind so informativ wie gleich viele unabhängige Personen.“

Denkfehler: 100 Schüler aus einer Schule lieferten dieselbe Informationsmenge wie 100 Schüler aus vielen zufällig ausgewählten Schulen.

Korrektur: Personen desselben Klumpens ähneln sich häufig. Zusätzliche Beobachtungen aus demselben Klumpen liefern dann weniger neue Information. Die effektive Stichprobengröße kann deutlich kleiner als die nominelle Stichprobengröße sein.

„Quoten machen eine Stichprobe automatisch repräsentativ.“

Denkfehler: Stimmen Geschlechts- und Altersanteile mit der Population überein, müsse auch der Rest der Stichprobe repräsentativ sein.

Korrektur: Innerhalb der Quoten können weiterhin systematisch bestimmte Personen ausgewählt werden. Bekannte Randverteilungen zu treffen garantiert nicht, dass unbeobachtete Eigenschaften korrekt verteilt sind.

„Datenanalyse beginnt mit dem fertigen Datensatz.“

Denkfehler: Statistik bestehe hauptsächlich darin, nach der Erhebung ein Verfahren auf die Daten anzuwenden.

Korrektur: Zieldefinition, Skalenniveau, Auswahlverfahren, Störvariablenkontrolle und Erhebungsqualität müssen vor der eigentlichen Analyse geklärt werden. Das Kreislaufdiagramm der Vorlesung zeigt außerdem, dass Prüfung, Interpretation, Publikation und Wiederverwendung zur Datenanalyse gehören.

5. Active Recall (Wissenstest)

1. In einer Wahlumfrage wird das Alter nur in vollendeten Jahren erfasst und die Parteipräferenz durch die Codes 1 bis 7 gespeichert. Ordne beide Merkmale jeweils hinsichtlich Diskretheit und Skalenniveau ein. Erkläre, weshalb die technische

Speicherung der Werte nicht automatisch den theoretischen Merkmalstyp festlegt, und leite daraus ab, welche Rechnungen jeweils sinnvoll sind.

2. Aus einer Population mit N Einheiten wird eine einfache Zufallsstichprobe der Größe n ohne Zurücklegen gezogen. Leite die Auswahlwahrscheinlichkeit einer bestimmten Einheit her und erkläre anschließend, warum gleiche Auswahlwahrscheinlichkeiten einzelner Einheiten allein nicht bei jedem denkbaren Stichprobendesign garantieren, dass alle möglichen Stichproben gleich wahrscheinlich sind.

3. Eine Universität führt eine freiwillige neue Lernplattform ein. Studierende, die sie verwenden, erzielen später bessere Prüfungsergebnisse. Entwickle drei alternative Erklärungen für diesen Unterschied und beschreibe, wie Homogenisierung, Randomisierung und statistische Modellierung jeweils helfen würden. Erläutere außerdem die wichtigste Grenze jedes Ansatzes.

4. Für eine bundesweite Untersuchung des Lernerfolgs stehen Informationen über Bundesländer, Schulen und Schulklassen zur Verfügung. Entwirf einmal eine geschichtete Stichprobe und einmal eine Klumpenstichprobe. Begründe für beide Designs, wie die Gruppen idealerweise zusammengesetzt sein sollten und weshalb eine Verwechslung der beiden Logiken die statistische Präzision verschlechtern kann.

5. Eine kleine Bevölkerungsgruppe macht 5 der Population, aber 40 einer geschichteten Stichprobe aus. Erkläre mathematisch, weshalb der einfache ungewichtete Stichprobenmittelwert den Populationsmittelwert im Allgemeinen nicht korrekt schätzt. Leite den geeigneten gewichteten Schätzer her und erläutere, unter welcher Stichprobenzusammensetzung beide Mittelwerte übereinstimmen würden.

6. Lösungen zum Active Recall

1. Das theoretische Alter ist grundsätzlich stetig und kardinal beziehungsweise verhältnisskaliert; durch die Erfassung in vollen Jahren entstehen diskretisierte Beobachtungen. Parteipräferenz ist diskret und nominal, unabhängig davon, ob die Kategorien mit Zahlen codiert werden. Für Alter sind Differenzen, Mittelwerte und Verhältnisse grundsätzlich interpretierbar; für Parteipräferenz nur Gleichheit, Verschiedenheit und Häufigkeiten.

2. Eine Einheit ist in $\binom{N-1}{n-1}$ von insgesamt $\binom{N}{n}$ Stichproben enthalten. Daher gilt:

$$P(u_i \in S) = \frac{\binom{N-1}{n-1}}{\binom{N}{n}} \frac{n}{N}.$$

Gleiche marginale Auswahlwahrscheinlichkeiten bestimmen nicht vollständig die gemeinsame Auswahlstruktur. Unterschiedliche Designs können jeder Einheit dieselbe Einzelchance geben, aber bestimmte Kombinationen bevorzugen oder ausschließen.

3. Mögliche Alternativen sind höheres Vorwissen, stärkere Motivation und mehr verfügbare Lernzeit der Plattformnutzer. Homogenisierung vergleicht ähnliche Studierende, kann aber zu kleinen Gruppen führen. Randomisierung gleicht beobachtete und unbeobachtete Störvariablen im Erwartungswert aus, kann aber praktisch oder ethisch schwierig sein. Modellierung kontrolliert beobachtete Merkmale rechnerisch, bleibt aber gegenüber unbeobachteten Störvariablen und Modellfehlern empfindlich.

4. Bei der Schichtung könnten Bundesländer oder Schultypen als Schichten dienen; aus jeder Schicht wird zufällig gezogen. Die Einheiten innerhalb einer Schicht sollten bezüglich relevanter Merkmale ähnlich sein. Bei der Klumpenstichprobe könnten Schulen oder Klassen zufällig ausgewählt und anschließend vollständig untersucht werden. Klumpen sollten intern möglichst vielfältig und untereinander ähnlich sein. Homogene Klumpen erzeugen stark korrelierte Beobachtungen und damit geringe zusätzliche Information.

5. Der ungewichtete Mittelwert gibt der kleinen Gruppe ein Gewicht von $0{,}40$ statt ihres Populationsgewichts von $0{,}05$. Der korrekte Schätzer ist:

$$\widehat{\mu}_{\mathrm{str}} = \sum_{h=1}^{H} \frac{N_h}{N} \overline{x}_h.$$

Der ungewichtete und der gewichtete Mittelwert stimmen bei proportionaler Auswahl überein, also wenn für jede Schicht näherungsweise gilt:

$$\frac{n_h}{n} = \frac{N_h}{N}.$$