1. Das Big Picture (Chunking)

Dieses Kapitel beantwortet die Frage, wie eine große Menge einzelner Beobachtungen so verdichtet werden kann, dass ihre **Verteilung, typische Lage, Streuung und Form** erkennbar werden. Dazu werden Häufigkeitstabellen und Grafiken wie Histogramme und Boxplots mit Kennzahlen wie Mittelwert, Median, Quantilen, Varianz und Interquartilsabstand kombiniert.

Der Kern besteht darin, eine Verteilung niemals nur durch eine einzige Zahl zu beschreiben: Eine sinnvolle Analyse betrachtet mindestens **Lage, Streuung und Form** und berücksichtigt dabei das Skalenniveau des Merkmals.

2. Zentrale Definitionen

Merkmal und Beobachtung

Fachliche Definition: Ein Merkmal X ist eine untersuchte Eigenschaft statistischer Einheiten. Für n Einheiten liegen die beobachteten Merkmalswerte

$$x_1, \ldots, x_n$$

vor. Die Zahl n heißt Stichprobenumfang.

Feynman-Übersetzung: Wir untersuchen dieselbe Eigenschaft bei mehreren Fällen. Zum Beispiel messen wir bei n Wohnungen jeweils die Nettomiete. Jede einzelne gemessene Miete ist eine Beobachtung.

Merkmalsausprägung

Fachliche Definition: Die möglichen oder tatsächlich beobachteten Werte eines Merkmals werden als Merkmalsausprägungen bezeichnet:

$$a_1, \ldots, a_J,$$

wobei $J \leq n$ gilt. Bei mindestens ordinalskalierten Merkmalen können die Ausprägungen geordnet werden:

$$a_1 < \ldots < a_J.$$

Feynman-Übersetzung: Die Ausprägungen sind die verschiedenen Antworten oder Werte,

die in den Daten vorkommen können. Wenn zehn Personen befragt werden, aber nur die drei Antworten „niedrig“, „mittel“ und „hoch“ vorkommen, gilt $n = 10$ und $J = 3$.

Absolute Häufigkeit

Fachliche Definition: Die absolute Häufigkeit h_j einer Ausprägung a_j ist die Anzahl der Beobachtungen, für die $x_i = a_j$ gilt:

$$h(a_j) = h_j.$$

Formal kann sie mithilfe einer Indikatorfunktion geschrieben werden:

$$h_j = \sum_{i=1}^{n} 1x_i = a_j.$$

Feynman-Übersetzung: Die absolute Häufigkeit sagt schlicht: „Wie oft kommt dieser Wert vor?“

Relative Häufigkeit

Fachliche Definition: Die relative Häufigkeit f_j ist der Anteil der Beobachtungen mit der Ausprägung a_j:

$$f(a_j) = f_j = \frac{h_j}{n}.$$

Dabei gilt:

$$\sum_{j=1}^{J} f_j = 1.$$

Feynman-Übersetzung: Die relative Häufigkeit macht die Anzahl vergleichbar. Statt „20 Personen“ sagt sie beispielsweise „20 aller Personen“.

Die Vorlesung führt absolute und relative Häufigkeiten als grundlegende Darstellung einer Verteilung ein.

Häufigkeitsverteilung

Fachliche Definition: Eine Häufigkeitsverteilung ordnet jeder Merkmalsausprägung ihre absolute oder relative Häufigkeit zu:

$$(a_j, h_j)$$

beziehungsweise

$$(a_j, f_j).$$

Feynman-Übersetzung: Eine Häufigkeitsverteilung ist eine vollständige Zählübersicht: Welcher Wert kommt wie oft oder mit welchem Anteil vor?

Klasse und Klassenbreite

Fachliche Definition: Bei stetigen Merkmalen werden die möglichen Werte häufig in Intervalle beziehungsweise Klassen aufgeteilt:

$$(c_{j-1}, c_j].$$

Die Breite der j-ten Klasse ist

$$w_j = c_j - c_{j-1}.$$

Feynman-Übersetzung: Wenn fast jeder Wert verschieden ist, zählt man nicht jeden Wert einzeln. Man baut stattdessen Schubladen, beispielsweise „mehr als 10 bis einschließlich 20“.

Die Klasseneinteilung stetiger Beobachtungen wird im Material über Intervalle mit eindeutig festgelegten Grenzen definiert.

Säulendiagramm

Fachliche Definition: Bei einem Säulendiagramm ist die Höhe einer Säule proportional zur absoluten oder relativen Häufigkeit:

$$H_j \propto h_j$$

oder

$$H_j \propto f_j.$$

Feynman-Übersetzung: Eine doppelt so hohe Säule bedeutet eine doppelt so große

Häufigkeit.

Wichtige Einschränkung: Bei unterschiedlich breiten Klassen kann ein solches Diagramm optisch irreführend sein, weil die Fläche einer Säule dann nicht mehr nur von der Häufigkeit abhängt.

Histogramm

Fachliche Definition: Ein Histogramm ist eine flächenproportionale Darstellung einer klassierten Häufigkeitsverteilung. Die Fläche des Rechtecks über der j-ten Klasse entspricht ihrer relativen Häufigkeit:

$$F_j = f_j.$$

Daher muss die Höhe des Rechtecks gleich

$$H_j = \frac{f_j}{w_j}$$

sein.

Feynman-Übersetzung: Im Histogramm zählt nicht die Höhe allein, sondern die gesamte Rechtecksfläche. Eine breite Klasse braucht deshalb eine niedrigere Höhe, um denselben Anteil darzustellen wie eine schmale Klasse.

Das Skript hebt ausdrücklich hervor, dass Histogramme über die **Flächen** und nicht über die bloßen Balkenhöhen interpretiert werden.

Dichte im Histogramm

Fachliche Definition: Die Histogrammhöhe

$$H_j = \frac{f_j}{w_j}$$

gibt die relative Häufigkeit pro Einheit der Merkmalsachse an. Sie ist eine empirische Dichte.

Feynman-Übersetzung: Die Dichte beantwortet: „Wie stark konzentrieren sich die Beobachtungen in diesem Bereich?“

Eine hohe Dichte bedeutet nicht automatisch, dass die Klasse den größten Gesamtanteil enthält. Dafür muss zusätzlich ihre Breite berücksichtigt werden.

Modalität

Fachliche Definition: Die Modalität beschreibt die Anzahl deutlich erkennbarer Häufungszentren einer Verteilung:

- unimodal: ein Häufungszentrum,
- bimodal: zwei Häufungszentren,
- multimodal: mehrere Häufungszentren.

Feynman-Übersetzung: Man schaut, wie viele „Berge“ die Verteilung besitzt.

Mehrere Berge können darauf hinweisen, dass eigentlich unterschiedliche Gruppen vermischt wurden.

Symmetrie und Schiefe

Fachliche Definition: Eine Verteilung ist symmetrisch, wenn ihre linke und rechte Seite annähernd spiegelbildlich sind.

Bei einer rechtsschiefen beziehungsweise linkssteilen Verteilung liegt der lange Ausläufer rechts. Bei einer linksschiefen beziehungsweise rechtssteilen Verteilung liegt der lange Ausläufer links.

Feynman-Übersetzung: Die Schiefe wird nach der Richtung benannt, in die der lange dünne Schwanz zeigt.

- Langer Schwanz nach rechts: rechtsschief.
- Langer Schwanz nach links: linksschief.

Arithmetisches Mittel

Fachliche Definition: Das arithmetische Mittel ist die Summe aller Beobachtungen geteilt durch den Stichprobenumfang:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

Es kann auch mithilfe relativer Häufigkeiten berechnet werden:

$$\bar{x} = \sum_{j=1}^{J} a_j f_j.$$

Feynman-Übersetzung: Man wirft die gesamte beobachtete Menge in einen gemeinsamen Topf und verteilt sie anschließend gleichmäßig auf alle Fälle.

Median

Fachliche Definition: Der Median x_{med} teilt die geordneten Beobachtungen so, dass mindestens 50 der Werte nicht größer und mindestens 50 der Werte nicht kleiner als der Median sind.

Für

$$x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(n)}$$

gilt bei ungeradem n:

$$x_{\text{med}} = x_{\left(\frac{n+1}{2}\right)}.$$

Bei geradem n ist grundsätzlich jeder Wert aus

$$\left[x_{\left(\frac{n}{2}\right)}, x_{\left(\frac{n}{2}+1\right)}\right]$$

ein Median. Häufig wird als eindeutige Konvention der Mittelpunkt verwendet:

$$x_{\text{med}} = \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}.$$

Feynman-Übersetzung: Man stellt alle Beobachtungen der Größe nach auf. Der Median steht in der Mitte der Reihe.

Modus

Fachliche Definition: Der Modus x_{mod} ist eine Merkmalsausprägung mit maximaler Häufigkeit:

$$x_{\text{mod}} \in \arg\max_{a_j} h_j.$$

Feynman-Übersetzung: Der Modus ist der häufigste Wert.

Es können mehrere Modi existieren, wenn mehrere Werte gleich häufig am häufigsten auftreten.

Mittelwert, Median und Modus werden im Material als verschiedene Beschreibungen der zentralen Tendenz eingeführt.

Quantil

Fachliche Definition: Ein α-Quantil x_α ist ein Wert, für den mindestens $\alpha \cdot 100$ der Beobachtungen kleiner oder gleich und mindestens $(1-\alpha) \cdot 100$ größer oder gleich sind.

Dabei gilt:

$$0 \leq \alpha \leq 1.$$

Feynman-Übersetzung: Ein Quantil ist eine Schnittmarke in einer sortierten Datenreihe. Das $0{,}25$-Quantil markiert ungefähr den Punkt, unter dem das untere Viertel der Daten liegt.

Häufig verwendete Quantile sind:

$$x_{0,25}, \qquad x_{0,5}, \qquad x_{0,75}.$$

Sie heißen unteres Quartil, Median und oberes Quartil.

Varianz

Fachliche Definition: Die Varianz ist die mittlere quadrierte Abweichung der Beobachtungen vom arithmetischen Mittel:

$$S^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

Feynman-Übersetzung: Die Varianz misst, wie weit die Werte typischerweise vom Mittelpunkt entfernt liegen. Die Abstände werden quadriert, damit sich positive und negative Abweichungen nicht gegenseitig aufheben.

Standardabweichung

Fachliche Definition: Die Standardabweichung ist die positive Quadratwurzel der Varianz:

$$S = \sqrt{S^2}.$$

Feynman-Übersetzung: Die Standardabweichung übersetzt die quadrierte Varianz zurück in die ursprüngliche Maßeinheit.

Wenn die Daten in Euro gemessen werden, besitzt auch S die Einheit Euro, während S^2 die Einheit Euro zum Quadrat besitzt.

Korrigierte Stichprobenvarianz

Fachliche Definition: Eine häufig verwendete Variante der Varianz ist

$$S_*^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

Sie wird insbesondere verwendet, wenn anhand einer Stichprobe die Varianz einer größeren Grundgesamtheit geschätzt werden soll.

Feynman-Übersetzung: Weil das Mittel bereits aus denselben Daten geschätzt wurde, ist ein Freiheitsgrad verbraucht. Deshalb teilt man durch $n-1$ statt durch n.

Das Material stellt beide Varianzdefinitionen gegenüber und verweist für die theoretische Begründung der Variante mit $n-1$ auf eine spätere Vorlesung.

Interquartilsabstand

Fachliche Definition: Der Interquartilsabstand ist die Differenz zwischen oberem und unterem Quartil:

$$\mathrm{IQR} = x_{0{,}75} - x_{0{,}25}.$$

Er beschreibt die Breite der mittleren 50 der Beobachtungen.

Feynman-Übersetzung: Man entfernt gedanklich das unterste und das oberste Viertel der Daten. Der Interquartilsabstand misst, wie weit die übrig gebliebenen mittleren Werte

auseinanderliegen.

Boxplot

Fachliche Definition: Ein Boxplot visualisiert zentrale Quantile einer Verteilung. Die Box reicht von $x_{0,25}$ bis $x_{0,75}$, eine Linie kennzeichnet den Median, und sogenannte Whisker zeigen den Bereich der nicht als Ausreißer eingeordneten Werte.

Typische Ausreißergrenzen sind:

$$L = x_{0,25} - 1{,}5\,\mathrm{IQR}$$

und

$$U = x_{0,75} + 1{,}5\,\mathrm{IQR}\,.$$

Feynman-Übersetzung: Ein Boxplot ist eine stark komprimierte Landkarte der Verteilung: Mitte, typische Breite, mögliche Schiefe und ungewöhnlich extreme Beobachtungen sind auf einen Blick sichtbar.

Die Boxplots auf den Seiten 45 und 46 des Materials zeigen beispielsweise, dass absolute Nettomieten bei größeren Wohnungen sowohl höher als auch stärker gestreut sind.

3. Formeln, Beweise & Intuition

Absolute und relative Häufigkeiten

Die Formel

$$h_j = \sum_{i=1}^{n} 1x_i = a_j$$

und

$$f_j = \frac{h_j}{n}.$$

Außerdem gilt:

$$\sum_{j=1}^{J} h_j = n$$

und

$$\sum_{j=1}^{J} f_j = 1.$$

Dekonstruktion

- x_i: Beobachtung der i-ten statistischen Einheit.
- a_j: j-te mögliche Merkmalsausprägung.
- n: Anzahl aller Beobachtungen.
- J: Anzahl verschiedener Ausprägungen.
- h_j: absolute Häufigkeit von a_j.
- f_j: relative Häufigkeit von a_j.
- $1x_i = a_j$: nimmt den Wert 1 an, wenn $x_i = a_j$ gilt, andernfalls den Wert 0.

Der Beweis / Die Herleitung

Jede Beobachtung gehört genau einer Merkmalsausprägung an. Deshalb wird jede Beobachtung in genau einer der absoluten Häufigkeiten gezählt:

$$\sum_{j=1}^{J} h_j = n.$$

Teilt man beide Seiten durch n, erhält man:

$$\frac{1}{n} \sum_{j=1}^{J} h_j = 1.$$

Wegen

$$f_j = \frac{h_j}{n}$$

folgt:

$$\sum_{j=1}^{J} f_j = 1.$$

Die Analogie & Mechanik

Stelle dir n Münzen vor, die vollständig auf J Schachteln verteilt werden. h_j ist die Anzahl der Münzen in Schachtel j; f_j ist der Anteil aller Münzen in dieser Schachtel.

Ein großes h_j führt bei festem n zu einem großen f_j. Ein großes n kann dagegen dazu führen, dass dieselbe absolute Häufigkeit nur einen kleinen Anteil darstellt.

Beispiel:

$$\frac{20}{40} = 0{,}5, \qquad \frac{20}{1000} = 0{,}02.$$

Die absolute Häufigkeit ist in beiden Fällen gleich, ihre Bedeutung ist jedoch völlig verschieden.

Häufigkeiten bei klassierten Daten

Die Formel

Für die Klasse

$$(c_{j-1}, c_j]$$

gilt:

$$h_j = \sum_{i=1}^{n} 1 c_{j-1} < x_i \leq c_j$$

und

$$f_j = \frac{h_j}{n}.$$

Dekonstruktion

- c_{j-1}: untere Klassengrenze.
- c_j: obere Klassengrenze.
- $w_j = c_j - c_{j-1}$: Klassenbreite.
- h_j: Anzahl der Beobachtungen innerhalb der Klasse.
- f_j: Anteil der Beobachtungen innerhalb der Klasse.

Der Beweis / Die Herleitung

Bei stetigen Daten kann fast jede Beobachtung einen anderen Wert besitzen. Eine Häufigkeit für jeden einzelnen exakten Wert wäre deshalb wenig informativ.

Man ersetzt die Frage

$$x_i = a_j$$

durch die Frage

$$c_{j-1} < x_i \leq c_j.$$

Die halb offene Intervallschreibweise verhindert, dass ein Wert auf einer Klassengrenze doppelt gezählt wird.

Die Analogie & Mechanik

Die Klassen sind Schubladen. Jede Beobachtung darf in genau eine Schublade gelegt werden.

Werden die Schubladen breiter, landen automatisch mehr Beobachtungen in ihnen. Deshalb darf man bei ungleichen Klassenbreiten nicht allein die absoluten Häufigkeiten oder Balkenhöhen vergleichen.

Histogrammhöhe und Histogrammfläche

Die Formel

Die Fläche der j-ten Säule soll der relativen Häufigkeit entsprechen:

$$F_j = f_j.$$

Für ein Rechteck gilt:

$$F_j = H_j w_j.$$

Daraus folgt:

$$H_j w_j = f_j$$

und damit:

$$\boxed{H_j = \frac{f_j}{w_j}}.$$

Dekonstruktion

- F_j: Fläche des Histogrammrechtecks.

- H_j: Höhe beziehungsweise Dichte der Klasse.
- w_j: Breite der Klasse.
- f_j: relativer Anteil der Beobachtungen in der Klasse.

Der Beweis / Die Herleitung

Aus der geometrischen Flächenformel

$$\text{Fläche} = \text{Höhe} \cdot \text{Breite}$$

und der Forderung

$$\text{Fläche} = \text{relative Häufigkeit}$$

ergibt sich unmittelbar:

$$H_j \cdot w_j = f_j.$$

Division durch w_j liefert:

$$H_j = \frac{f_j}{w_j}.$$

Für die Gesamtfläche gilt:

$$\sum_{j=1}^{J} F_j = \sum_{j=1}^{J} f_j 1.$$

Die Analogie & Mechanik

Stelle dir vor, ein Anteil von 20 müsse als rechteckige Fläche dargestellt werden.

Bei einer Breite von 10 muss die Höhe

$$\frac{0{,}2}{10} = 0{,}02$$

betragen.

Bei einer Breite von 20 muss die Höhe dagegen nur

$$\frac{0{,}2}{20} = 0{,}01$$

betragen.

Obwohl die zweite Säule halb so hoch ist, repräsentieren beide Säulen denselben Anteil.

Wird der Zähler f_j groß, steigt die Säule. Wird der Nenner w_j sehr klein, steigt die Säule ebenfalls stark. Ein extrem schmaler Balken kann deshalb sehr hoch sein, obwohl er nur einen kleinen Gesamtanteil enthält.

Im Landwirtschaftsbeispiel besitzt die Klasse von 0 bis 10 Hektar den Anteil

$$f_1 = 0{,}2690$$

und die Breite

$$w_1 = 10.$$

Ihre Histogrammhöhe beträgt daher:

$$H_1 = \frac{0{,}2690}{10} = 0{,}02690.$$

Die Klasse von 50 bis 75 Hektar besitzt zwar den Anteil

$$f = 0{,}2332,$$

aber die größere Breite

$$w = 25.$$

Daher gilt:

$$H = \frac{0{,}2332}{25} = 0{,}009328.$$

Die zweite Klasse enthält fast ebenso viele Beobachtungen, erscheint aber deutlich niedriger, weil sich diese Beobachtungen über einen breiteren Wertebereich verteilen.

Die Histogramme auf den Seiten 14 bis 18 verdeutlichen genau diesen Unterschied zwischen Balkenhöhe und Balkenfläche.

Anteil innerhalb eines Intervalls

Die Formel

Sei $H(x)$ die Höhe des Histogramms an der Stelle x. Dann kann der Anteil der Beobachtungen zwischen a und b durch

$$\int_a^b H(x)\,\mathrm{d}x$$

bestimmt beziehungsweise geschätzt werden.

Dekonstruktion

- $H(x)$: Histogrammdichte an der Stelle x.
- a: untere Grenze des interessierenden Bereichs.
- b: obere Grenze des interessierenden Bereichs.
- $\mathrm{d}x$: infinitesimal kleine Breite.
- $\int_a^b H(x), \mathrm{d}x$: Fläche unter dem Histogramm zwischen a und b.

Der Beweis / Die Herleitung

Innerhalb einer Histogrammklasse ist $H(x)$ konstant. Liegt ein vollständiges Klassenintervall zwischen a und b, gilt:

$$\int_{c_{j-1}}^{c_j} H(x), \mathrm{d}x = H_j(c_j - c_{j-1}).$$

Wegen

$$H_j = \frac{f_j}{c_j - c_{j-1}}$$

folgt:

$$\int_{c_{j-1}}^{c_j} H(x), \mathrm{d}x = f_j.$$

Über mehrere Klassen addieren sich die Flächen und damit die relativen Häufigkeiten.

Die Analogie & Mechanik

Die Fläche ist wie Wasser unter einer Dachlinie. Der Anteil zwischen a und b entspricht der Wassermenge in diesem Abschnitt.

Ein hoher, aber sehr schmaler Bereich kann weniger Wasser enthalten als ein niedriger, aber breiter Bereich.

Wichtig: Schneidet das Intervall eine Klasse nur teilweise, unterstellt die Histogrammschätzung, dass die Beobachtungen innerhalb dieser Klasse gleichmäßig verteilt sind. Diese Information ist in den klassierten Daten tatsächlich nicht vorhanden.

Wahl der Klassenanzahl und Bias-Variance-Trade-off

Die zentrale Mechanik

Bei wenigen, breiten Klassen entsteht eine sehr glatte Darstellung:

- zufällige Schwankungen werden unterdrückt,
- wichtige Strukturen können verschwinden,
- unterschiedliche Verteilungen können gleich aussehen.

Das entspricht einem hohen systematischen Glättungsfehler beziehungsweise hohen Bias.

Bei sehr vielen, schmalen Klassen entsteht eine stark gezackte Darstellung:

- lokale Besonderheiten werden sichtbar,
- zufällige Stichprobenschwankungen werden möglicherweise überinterpretiert,
- das Bild verändert sich stark bei kleinen Datenänderungen.

Das entspricht hoher Varianz.

Die Analogie

Eine zu geringe Klassenanzahl ist wie ein unscharfes Foto: Das Rauschen ist gering, aber Details fehlen.

Eine zu hohe Klassenanzahl ist wie ein extrem überschärftes Foto: Jedes Staubkorn wirkt wie ein wichtiges Objekt.

Das Material illustriert beide Extreme auf Seite 18.

Arithmetisches Mittel

Die Formel

$$\boxed{\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i}$$

Dekonstruktion

- x_i: Wert der i-ten Beobachtung.

- n: Anzahl der Beobachtungen.
- $\sum_{i=1}^{n} x_i$: Gesamtsumme aller Werte.
- $\bar{x}$: gleichmäßig verteilter Wert pro Beobachtung.

Der Beweis / Die Herleitung über einen Ausgleichswert

Gesucht ist ein gemeinsamer Wert m, der die Gesamtsumme der Daten erhält:

$$nm = \sum_{i=1}^{n} x_i.$$

Division durch n ergibt:

$$m = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

Dieser Wert ist definitionsgemäß das arithmetische Mittel:

$$m = \bar{x}.$$

Die Analogie & Mechanik

Das arithmetische Mittel ist ein Umverteilungswert.

Besitzen vier Personen zusammen

$$10 + 20 + 30 + 100 = 160$$

Einheiten, so erhält bei gleichmäßiger Verteilung jede Person:

$$\bar{x} = \frac{160}{4} = 40.$$

Ein extrem großer Wert im Zähler zieht das Mittel deutlich nach oben. Genau deshalb reagiert das arithmetische Mittel empfindlich auf Ausreißer.

Mittelwert aus einer Häufigkeitsverteilung

Die Formel

$$\boxed{\bar{x} = \sum_{j=1}^{J} a_j f_j}$$

Dekonstruktion

- a_j: j-te Merkmalsausprägung.
- h_j: absolute Häufigkeit von a_j.
- $f_j = h_j/n$: relative Häufigkeit von a_j.
- J: Anzahl unterschiedlicher Ausprägungen.

Der Beweis / Die Herleitung

Wenn der Wert a_j insgesamt h_j-mal vorkommt, trägt er

$$h_j a_j$$

zur Gesamtsumme bei. Daher gilt:

$$\sum_{i=1}^{n} x_i = \sum_{j=1}^{J} h_j a_j.$$

Einsetzen in die Mittelwertformel ergibt:

$$\bar{x} = \frac{1}{n} \sum_{j=1}^{J} h_j a_j.$$

Da

$$f_j = \frac{h_j}{n}$$

gilt:

$$\bar{x} = \sum_{j=1}^{J} a_j f_j.$$

Die Analogie & Mechanik

Jeder mögliche Wert erhält ein Gewicht entsprechend seinem Anteil. Ein Wert mit großem f_j hat starken Einfluss, ein selten vorkommender Wert mit kleinem f_j nur geringen Einfluss.

Mittelwert eines binären Merkmals

Für ein als 0 und 1 kodiertes Merkmal gilt:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

Da jede Beobachtung mit Wert 1 genau eine Einheit zur Summe beiträgt, entspricht die Summe der Anzahl h_1 der Einsen:

$$\sum_{i=1}^{n} x_i = h_1.$$

Somit:

$$\boxed{\bar{x} = \frac{h_1}{n} = f_1}$$

Das arithmetische Mittel eines binären Merkmals ist also der Anteil der Beobachtungen mit dem Wert 1.

Schwerpunktseigenschaft des arithmetischen Mittels

Die Formel

$$\boxed{\sum_{i=1}^{n} (x_i - \bar{x}) = 0}$$

Der Beweis / Die Herleitung

Ausmultiplizieren liefert:

$$\sum_{i=1}^{n} (x_i - \bar{x}) = \sum_{i=1}^{n} x_i - \sum_{i=1}^{n} \bar{x}.$$

Da $\bar{x}$ nicht von i abhängt, gilt:

$$\sum_{i=1}^{n} \bar{x} = n\bar{x}.$$

Somit:

$$\sum_{i=1}^{n} (x_i - \bar{x}) = \sum_{i=1}^{n} x_i - n\bar{x}.$$

Aus der Definition

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

folgt:

$$n\bar{x} = \sum_{i=1}^{n} x_i.$$

Daher:

$$\sum_{i=1}^{n}(x_i - \bar{x}) = 0.$$

Die Analogie & Mechanik

Das arithmetische Mittel ist der Gleichgewichtspunkt einer Wippe. Beobachtungen links vom Mittel erzeugen negative Abweichungen, Beobachtungen rechts davon positive Abweichungen. Am Mittelwert gleichen sich beide Seiten exakt aus.

Mittelwert als Minimierer quadratischer Abweichungen

Eine besonders wichtige, im Skript nicht vollständig hergeleitete Eigenschaft lautet:

$$\boxed{\bar{x} = \arg,\min *m \sum *i = 1^n (x_i - m)^2}$$

Der Beweis / Die Herleitung

Definiere:

$$Q(m) = \sum_{i=1}^{n}(x_i - m)^2.$$

Ableiten nach m:

$$Q'(m) = -2\sum_{i=1}^{n}(x_i - m).$$

Für ein Minimum muss gelten:

$$Q'(m) = 0.$$

Also:

$$\sum_{i=1}^{n}(x_i - m) = 0.$$

Daraus folgt:

$$\sum_{i=1}^{n} x_i - nm = 0$$

und damit:

$$m = \frac{1}{n}\sum_{i=1}^{n} x_i = \bar{x}.$$

Die zweite Ableitung ist:

$$Q''(m) = 2n > 0.$$

Damit handelt es sich tatsächlich um ein Minimum.

Die Analogie & Mechanik

Der Mittelwert ist genau der Punkt, bei dem die Summe aller quadrierten Entfernungen am kleinsten wird. Große Abweichungen werden durch das Quadrieren besonders stark bestraft. Deshalb reagiert der Mittelwert empfindlich auf extreme Werte.

Gewichteter Mittelwert bei Schichtenbildung

Die Formel

Für r Gruppen beziehungsweise Schichten mit Umfängen $n_1, \ldots, n_r$ und Gruppenmitteln $\bar{x}_1, \ldots, \bar{x}_r$ gilt:

$$\boxed{\bar{x} = \frac{1}{n}\sum_{j=1}^{r} n_j \bar{x}_j}$$

mit

$$n = \sum_{j=1}^{r} n_j.$$

Äquivalent gilt mit den Gewichten

$$w_j = \frac{n_j}{n} :$$

$$\bar{x} = \sum_{j=1}^{r} w_j \bar{x}_j.$$

Dekonstruktion

- r: Anzahl der Gruppen.
- n_j: Beobachtungszahl in Gruppe j.
- $\bar{x}_j$: Mittelwert innerhalb der Gruppe j.
- w_j: Anteil der Gruppe j an der Gesamtstichprobe.
- $\bar{x}$: Mittelwert über alle Gruppen.

Der Beweis / Die Herleitung

Für die Summe innerhalb der Gruppe j gilt:

$$\sum_{i \in G_j} x_i = n_j \bar{x}_j.$$

Die Gesamtsumme aller Beobachtungen ist deshalb:

$$\sum_{i=1}^{n} x_i = \sum_{j=1}^{r} n_j \bar{x}_j.$$

Division durch n liefert:

$$\bar{x} = \frac{1}{n} \sum_{j=1}^{r} n_j \bar{x}_j.$$

Die Analogie & Mechanik

Ein Gruppenmittel ist eine Stimme. Große Gruppen müssen bei der Berechnung des Gesamtmittels mehr Stimmgewicht erhalten als kleine Gruppen.

Der einfache Ausdruck

$$\frac{\bar{x}_1 + \bar{x}_2}{2}$$

ist nur korrekt, wenn beide Gruppen gleich groß sind.

Das Gesamtmittel als gewichteter Durchschnitt der Schichtmittel wird im Mietspiegelbeispiel ausdrücklich behandelt.

Median und geordnete Beobachtungen

Die Formel

Für ungerades n:

$$x_{\text{med}} = x_{\left(\frac{n+1}{2}\right)}.$$

Für gerades n:

$$x_{\text{med}} \in \left[x_{\left(\frac{n}{2}\right)}, x_{\left(\frac{n}{2}+1\right)}\right].$$

Die häufige Mittelpunktkonvention lautet:

$$x_{\text{med}} = \frac{x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}}{2}.$$

Dekonstruktion

- $x_{(i)}$: i-kleinste Beobachtung.
- x_{med}: Median.
- n: Anzahl der Beobachtungen.

Der Beweis / Die Herleitung

Bei ungeradem n existiert eine einzelne mittlere Position:

$$\frac{n+1}{2}.$$

Vor dieser Position liegen

$$\frac{n-1}{2}$$

Beobachtungen, und hinter ihr liegen ebenfalls

$$\frac{n-1}{2}$$

Beobachtungen.

Bei geradem n gibt es keine einzelne mittlere Beobachtung. Die beiden zentralen Positionen sind:

$$\frac{n}{2}$$

und

$$\frac{n}{2} + 1.$$

Jeder Wert zwischen diesen beiden Beobachtungen trennt die Daten in eine untere und eine obere Hälfte.

Die Analogie & Mechanik

Der Median hängt nur von der Reihenfolge ab. Wie weit ein extremer Wert vom Rest entfernt ist, spielt keine Rolle.

Bei

$$1,\ 2,\ 3,\ 4,\ 100$$

ist der Median:

$$x_{\text{med}} = 3.$$

Ersetzt man 100 durch $1,000,000$, bleibt der Median unverändert:

$$x_{\text{med}} = 3.$$

Der Mittelwert verändert sich dagegen drastisch.

Median als Minimierer absoluter Abweichungen

Eine fundamentale Eigenschaft lautet:

$$\boxed{x_{\text{med}} \in \arg,\min *m \sum *i = 1^n |x_i - m|}$$

Intuitive Herleitung

Bewegt man einen Kandidatenwert m ein kleines Stück nach rechts, werden alle Abstände zu links liegenden Beobachtungen größer und alle Abstände zu rechts liegenden Beobachtungen kleiner.

- Liegen mehr Beobachtungen rechts von m, lohnt sich eine Bewegung nach rechts.
- Liegen mehr Beobachtungen links von m, lohnt sich eine Bewegung nach links.

- Ein Minimum wird erreicht, sobald auf beiden Seiten mindestens die Hälfte der Beobachtungen liegt.

Genau diese Eigenschaft definiert den Median.

Die Analogie & Mechanik

Der Median ist ein geeigneter Standort für eine Rettungsstation, wenn die Summe der einfachen Wegstrecken minimiert werden soll. Der Mittelwert wäre dagegen der geeignete Standort, wenn quadrierte Wegstrecken bestraft werden.

Quantile

Die Formel

Für geordnete Beobachtungen und $0 < \alpha < 1$ verwendet das Material folgende Definition:

Falls $n\alpha \notin \mathbb{N}$:

$$\boxed{x_\alpha = x_{(\lfloor n\alpha \rfloor + 1)}}$$

Falls $n\alpha \in \mathbb{N}$:

$$\boxed{x_\alpha \in \left[x_{(n\alpha)}, x_{(n\alpha+1)}\right]}$$

Dekonstruktion

- α: gewünschter Anteil unterhalb des Quantils.
- $n\alpha$: theoretische Trennposition.
- $\lfloor n\alpha \rfloor$: größte ganze Zahl, die nicht größer als $n\alpha$ ist.
- $x_{(k)}$: Beobachtung an Position k der sortierten Stichprobe.

Der Beweis / Die Herleitung

Ist $n\alpha$ keine ganze Zahl, muss auf die nächste Beobachtungsposition aufgerundet werden, damit mindestens αn Beobachtungen kleiner oder gleich dem Quantil sind:

$$\lceil n\alpha \rceil = \lfloor n\alpha \rfloor + 1.$$

Ist $n\alpha$ ganzzahlig, liegen genau $n\alpha$ Beobachtungen bis zur Position $n\alpha$. Jeder Wert zwischen der Beobachtung an Position $n\alpha$ und der folgenden Beobachtung erfüllt die

Quantilsbedingung.

Beispiel aus dem Mietspiegel

Bei $n = 26$ gilt für das untere Quartil:

$$n\alpha = 26 \cdot 0{,}25 = 6{,}5.$$

Daher:

$$x_{0,25} = x_{(7)}170{,}04.$$

Für den Median gilt:

$$n\alpha = 26 \cdot 0{,}5 = 13.$$

Damit ist grundsätzlich jedes Element des Intervalls

$$[243{,}44;, 255{,}75]$$

ein Median. Mit der Mittelpunktkonvention ergibt sich:

$$x_{0,5} = \frac{243{,}44 + 255{,}75}{2}249{,}595 \approx 249{,}60.$$

Für das obere Quartil gilt:

$$n\alpha = 26 \cdot 0{,}75 = 19{,}5$$

und damit:

$$x_{0,75} = x_{(20)}311{,}87.$$

Das Rechenbeispiel und die zugehörige empirische Verteilungsfunktion werden auf den Seiten 33 bis 35 dargestellt.

Lageparameter und Schiefe

Bei einer annähernd symmetrischen, unimodalen Verteilung gilt häufig:

$$\bar{x} \approx x_{\text{med}} \approx x_{\text{mod}}.$$

Bei einer typischen rechtsschiefen Verteilung gilt häufig:

$$x_{\text{mod}} < x_{\text{med}} < \bar{x}.$$

Bei einer typischen linksschiefen Verteilung gilt häufig:

$$\bar{x} < x_{\text{med}} < x_{\text{mod}}.$$

Die Mechanik

Der Modus liegt am höchsten Punkt der Verteilung.

Der Median richtet sich nach der Anzahl der Beobachtungen auf beiden Seiten.

Der Mittelwert berücksichtigt zusätzlich die Größe jeder Beobachtung. Extreme Werte im langen Ausläufer ziehen ihn deshalb am stärksten in Richtung der Schiefe.

Wichtige Einordnung

Diese Reihenfolgen sind typische Muster, aber keine allgemeingültigen mathematischen Gesetze. Es existieren rechtsschiefe Verteilungen, bei denen die Reihenfolge nicht exakt erfüllt ist.

Das Skript nutzt diese Beziehungen zur anschaulichen Charakterisierung schiefer Verteilungen.

Lineare Transformation des Mittelwerts

Die Formel

Für

$$y_i = a + bx_i$$

gilt:

$$\boxed{\bar{y} = a + b\bar{x}}$$

Dekonstruktion

- x_i: ursprüngliche Beobachtung.
- y_i: transformierte Beobachtung.
- a: additive Verschiebung.
- b: multiplikative Skalierung.
- $\bar{x}$: ursprüngliches Mittel.

- $\bar{y}$: transformiertes Mittel.

Der Beweis / Die Herleitung

$$\bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i.$$

Einsetzen von $y_i = a + bx_i$:

$$\bar{y} = \frac{1}{n}\sum_{i=1}^{n} (a + bx_i).$$

Aufteilen der Summe:

$$\bar{y} = \frac{1}{n}\left(\sum_{i=1}^{n} a + b\sum_{i=1}^{n} x_i\right).$$

Da

$$\sum_{i=1}^{n} a = na,$$

folgt:

$$\bar{y} = \frac{na}{n} + b\frac{1}{n}\sum_{i=1}^{n} x_i = a + b\bar{x}.$$

Die Analogie & Mechanik

Wird zu jeder Beobachtung derselbe Betrag a addiert, verschiebt sich der gesamte Datensatz einschließlich seines Mittels um a.

Werden alle Werte mit b multipliziert, vergrößern oder verkleinern sich auch ihre durchschnittliche Größe und ihr Abstand vom Ursprung mit b.

Transformation des Medians

Für eine streng monoton steigende Funktion g gilt:

$$y_i = g(x_i) \quad \Longrightarrow \quad y_{\text{med}} = g(x_{\text{med}}).$$

Herleitung

Eine streng monoton steigende Transformation erhält die Reihenfolge:

$$x_{(1)} \leq \ldots \leq x_{(n)}$$

führt zu

$$g(x_{(1)}) \leq \ldots \leq g(x_{(n)}).$$

Die mittlere Rangposition bleibt daher dieselbe.

Die Analogie & Mechanik

Stelle dir eine Rangliste von Läufern vor. Werden alle Laufzeiten mit derselben streng steigenden Funktion umgerechnet, ändert sich zwar die Skala, aber niemand überholt eine andere Person.

Unterschied zum Mittelwert

Für eine nichtlineare Funktion gilt im Allgemeinen nicht:

$$\overline{g(x)} = g(\bar{x}).$$

Beispielsweise ist normalerweise:

$$\overline{\log(x)} \neq \log(\bar{x}).$$

Der Median hängt von Rangpositionen ab und wird deshalb durch monotone Transformationen wesentlich stabiler mitgeführt als das arithmetische Mittel. Das Material demonstriert diesen Unterschied anhand einer logarithmischen Transformation auf Seite 30.

Varianz

Die Formel

$$\boxed{S^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Dekonstruktion

- $x_i - \bar{x}$: Abweichung der Beobachtung vom Mittelwert.
- $(x_i - \bar{x})^2$: quadrierte Abweichung.

- $\sum_{i=1}^{n}(x_i - \bar{x})^2$: gesamte quadrierte Abweichung.
- S^2: durchschnittliche quadrierte Abweichung.

Warum werden die Abweichungen quadriert?

Die einfache Summe der Abweichungen ist immer:

$$\sum_{i=1}^{n}(x_i - \bar{x}) = 0.$$

Sie kann daher keine Streuung messen.

Durch das Quadrieren gilt:

$$(x_i - \bar{x})^2 \geq 0.$$

Positive und negative Abweichungen können sich nicht mehr aufheben.

Die Analogie & Mechanik

Die Varianz ist ein Strafmaß für Entfernung vom Zentrum. Doppelte Entfernung führt wegen

$$(2d)^2 = 4d^2$$

zur vierfachen Strafe.

Ein einzelner extremer Wert kann deshalb die Varianz sehr stark vergrößern.

Verschiebungssatz der Varianz

Die Formel

$$\boxed{S^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2}$$

Der Beweis / Die Herleitung

Ausgangspunkt:

$$S^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

Binomische Formel:

$$(x_i - \bar{x})^2 = x_i^2 - 2x_i\bar{x} + \bar{x}^2.$$

Einsetzen:

$$S^2 = \frac{1}{n}\sum_{i=1}^{n}\left(x_i^2 - 2x_i\bar{x} + \bar{x}^2\right).$$

Summen trennen:

$$S^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 \frac{2\bar{x}}{n}\sum_{i=1}^{n} x_i + \frac{1}{n}\sum_{i=1}^{n}\bar{x}^2.$$

Es gilt:

$$\sum_{i=1}^{n} x_i = n\bar{x}$$

und

$$\sum_{i=1}^{n}\bar{x}^2 = n\bar{x}^2.$$

Daher:

$$S^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 \frac{2\bar{x}}{n}\cdot n\bar{x} + \frac{1}{n}\cdot n\bar{x}^2.$$

Vereinfachen:

$$S^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 2\bar{x}^2 + \bar{x}^2.$$

Somit:

$$S^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 \bar{x}^2.$$

Die Analogie & Mechanik

Die Formel vergleicht zwei Größen:

$\text{Mittel der Quadrate} - \text{Quadr}$

Wenn alle Beobachtungen gleich sind, stimmen beide Größen überein und die Varianz ist 0

.

Je stärker sich die Beobachtungen unterscheiden, desto größer wird das Mittel der Quadrate im Verhältnis zum Quadrat des Mittels.

Numerischer Hinweis

Bei sehr großen, fast identischen Werten werden in der Verschiebungsformel möglicherweise zwei sehr große, fast gleiche Zahlen voneinander abgezogen. In Computerberechnungen kann das Rundungsprobleme verursachen, obwohl die Formel algebraisch korrekt ist.

Standardabweichung

Die Formel

$$\boxed{S = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}}$$

Die Herleitung

Die Varianz besitzt die quadrierte Einheit der Ausgangsdaten. Durch die Quadratwurzel wird die ursprüngliche Einheit wiederhergestellt:

$$S = \sqrt{S^2}.$$

Die Analogie & Mechanik

Die Standardabweichung ist eine in die ursprüngliche Sprache der Daten zurückübersetzte Streuung.

Bei Mieten in Euro ist eine Standardabweichung von

$$S = 100{,}53$$

als Größenordnung einer typischen Abweichung verständlich. Eine Varianz von

$$S^2 = 10,106{,}82$$

ist wegen der quadrierten Einheit deutlich weniger unmittelbar interpretierbar.

Das Mietspiegelbeispiel im Material berechnet genau diese Werte.

Warum bei der korrigierten Varianz durch $n-1$ geteilt wird

Die Formel

$$S_*^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2.$$

Die fundamentale Intuition

Die Abweichungen erfüllen zwingend:

$$\sum_{i=1}^{n}(x_i - \bar{x}) = 0.$$

Sind die ersten $n-1$ Abweichungen bekannt, ist die letzte Abweichung bereits festgelegt:

$$x_n - \bar{x} = -\sum_{i=1}^{n-1}(x_i - \bar{x}).$$

Es existieren deshalb nur $n-1$ frei wählbare Abweichungen. Man spricht von $n-1$ Freiheitsgraden.

Warum ist die Korrektur für Schätzungen relevant?

Das aus der Stichprobe berechnete $\bar{x}$ liegt besonders günstig innerhalb derselben Stichprobe. Dadurch erscheinen die Abstände

$$x_i - \bar{x}$$

im Durchschnitt etwas kleiner als die Abstände zum unbekannten Mittelwert der Grundgesamtheit.

Die Division durch $n-1$ statt durch n gleicht diese systematische Unterschätzung aus.

Edge Case

Für $n = 1$ ist

$$n - 1 = 0.$$

Die korrigierte Stichprobenvarianz ist dann nicht definiert. Mit nur einer Beobachtung

kann die Streuung einer Grundgesamtheit nicht geschätzt werden.

Lineare Transformation der Varianz

Die Formel

Für

$$y_i = a + bx_i$$

gilt:

$$\boxed{S_y^2 = b^2 S_x^2}$$

Der Beweis / Die Herleitung

Zunächst gilt:

$$\bar{y} = a + b\bar{x}.$$

Damit:

$$y_i - \bar{y} = (a + bx_i) - (a + b\bar{x}).$$

Die Verschiebung a fällt weg:

$$y_i - \bar{y} = b(x_i - \bar{x}).$$

Quadrieren:

$$(y_i - \bar{y})^2 = b^2(x_i - \bar{x})^2.$$

Somit:

$$S_y^2 = \frac{1}{n}\sum_{i=1}^{n} b^2(x_i - \bar{x})^2.$$

Da b^2 konstant ist:

$$S_y^2 = b^2 \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = b^2 S_x^2.$$

Die Analogie & Mechanik

Eine Verschiebung verändert die Abstände zwischen den Beobachtungen nicht. Deshalb hat a keinen Einfluss auf die Varianz.

Eine Verdopplung aller Abstände führt dagegen zur Vervierfachung der quadrierten Abstände:

$$2^2 = 4.$$

Ein negatives b spiegelt die Daten zusätzlich, aber wegen

$$(-b)^2 = b^2$$

ändert die Spiegelung die Varianz nicht.

Lineare Transformation der Standardabweichung

Die Formel

Aus

$$S_y^2 = b^2 S_x^2$$

folgt:

$$S_y = \sqrt{b^2 S_x^2}.$$

Daher gilt allgemein:

$$\boxed{S_y = |b| S_x}$$

Wichtige Präzisierung zum Skript

Das Material schreibt sinngemäß:

$$S_y = bS_x.$$

Diese Schreibweise ist nur für

$$b \geq 0$$

vollständig korrekt. Da eine Standardabweichung niemals negativ sein kann, muss im allgemeinen Fall der Betrag verwendet werden:

$$S_y = |b| S_x.$$

Die Transformationsregeln der Streuungsmaße werden im Skript auf Seite 42 behandelt.

Interquartilsabstand

Die Formel

$$\boxed{\mathrm{IQR} = x_{0{,}75} - x_{0{,}25}}$$

Die Mechanik

Zwischen $x_{0{,}25}$ und $x_{0{,}75}$ liegen ungefähr die mittleren 50 der Beobachtungen.

Extreme Beobachtungen außerhalb dieses Bereichs beeinflussen den Interquartilsabstand nicht direkt. Deshalb ist der Interquartilsabstand robuster gegenüber Ausreißern als die Standardabweichung.

Transformation

Für $b > 0$ gilt:

$$y_{0{,}25} = a + b x_{0{,}25}$$

und

$$y_{0{,}75} = a + b x_{0{,}75}.$$

Daher:

$$\mathrm{IQR}_y = y_{0{,}75} - y_{0{,}25}$$

$$(a + b x_{0{,}75}) - (a + b x_{0{,}25})$$

$$b(x_{0{,}75} - x_{0{,}25})$$

und somit:

$$\mathrm{IQR}_y = b\,\mathrm{IQR}_x\,.$$

Allgemein, einschließlich negativer Skalierungen, gilt:

$$\boxed{\mathrm{IQR}_y = |b|\,\mathrm{IQR}_x}$$

Bei $b < 0$ wird die Reihenfolge umgekehrt, sodass sich unteres und oberes Quartil vertauschen.

Boxplot-Ausreißergrenzen

Die Formel

Untere Grenze:

$$L = x_{0,25} 1{,}5\,\mathrm{IQR}\,.$$

Obere Grenze:

$$U = x_{0,75} + 1{,}5\,\mathrm{IQR}\,.$$

Beobachtungen mit

$$x_i < L$$

oder

$$x_i > U$$

werden typischerweise separat als potenzielle Ausreißer markiert.

Die Analogie & Mechanik

Die Box beschreibt den zentralen Datenkörper. Die Ausreißergrenzen bauen um diesen Körper einen Sicherheitsabstand auf.

Ein großer Interquartilsabstand führt zu weit entfernten Grenzen. Eine stark streuende Verteilung erlaubt also auch weiter außen liegende Werte, ohne sie sofort als Ausreißer zu markieren.

Ein kleiner Interquartilsabstand führt zu engen Grenzen. Dann können schon mäßige Abweichungen außerhalb des typischen Bereichs markiert werden.

Wichtig: Die Regel erklärt einen Wert nicht automatisch zu einem Fehler. Sie kennzeichnet ihn nur als ungewöhnlich im Verhältnis zur mittleren Streuung.

4. Häufige Missverständnisse & Edge Cases

„Der höchste Histogrammbalken enthält automatisch die meisten Beobachtungen.“

Falsch. Im Histogramm entspricht die **Fläche** einer relativen Häufigkeit:

$$f_j = H_j w_j.$$

Eine hohe, schmale Klasse kann einen kleineren Anteil enthalten als eine niedrige, breite Klasse.

Nur bei identischen Klassenbreiten ist der Vergleich der Höhen zugleich ein Vergleich der Häufigkeiten.

„Säulendiagramm und Histogramm sind dasselbe."

Falsch.

Beim Säulendiagramm repräsentiert typischerweise die Höhe die Häufigkeit. Beim Histogramm repräsentiert die Fläche die Häufigkeit.

Bei diskreten Kategorien sind Säulendiagramme natürlich. Bei stetigen, klassierten Daten sind Histogramme grundsätzlich geeigneter.

„Die Klassenbreite ist nur eine kosmetische Entscheidung."

Falsch. Die Klassenanzahl steuert, welche Strukturen sichtbar werden.

- Zu wenige Klassen können Mehrgipfligkeit oder Schiefe verdecken.
- Zu viele Klassen können zufälliges Rauschen als Struktur erscheinen lassen.

Ein Histogramm zeigt deshalb nicht die „wahre Verteilung", sondern eine von der Klasseneinteilung abhängige Zusammenfassung.

„Innerhalb einer Histogrammklasse kenne ich die genaue Verteilung."

Falsch. Durch Klassierung gehen Informationen verloren.

Kennt man nur, dass 100 Beobachtungen zwischen 20 und 30 liegen, weiß man nicht, ob

sie gleichmäßig verteilt sind oder fast alle bei $20{,}1$ liegen.

Eine Teilfläche innerhalb einer Klasse beruht daher auf einer Gleichverteilungsannahme innerhalb dieser Klasse.

„Der Mittelwert ist immer der typische Wert.“

Falsch. Bei einer stark schiefen oder multimodalen Verteilung kann der Mittelwert in einem Bereich liegen, in dem kaum Beobachtungen vorkommen.

Beispielsweise können die Werte

$$1,\ 1,\ 1,\ 10,\ 10,\ 10$$

das Mittel

$$\bar{x} = 5{,}5$$

besitzen, obwohl kein einziger Wert auch nur nahe bei $5{,}5$ liegt.

„Der Median verwendet die Größe aller Beobachtungen.“

Falsch. Der Median verwendet primär ihre Rangordnung.

Ob der größte Wert 100 oder $1,000,000$ beträgt, ist für den Median häufig bedeutungslos, solange seine Position in der Reihenfolge gleich bleibt.

Diese Robustheit ist ein Vorteil bei Ausreißern, aber auch ein Informationsverlust: Der Median ignoriert, wie extrem ein Wert ist.

„Bei geradem Stichprobenumfang existiert genau ein mathematisch zwingender Median.“

Nicht unbedingt. Bei geradem n erfüllt jedes Element des Intervalls

$$\left[x_{\left(\frac{n}{2}\right)}, x_{\left(\frac{n}{2}+1\right)}\right]$$

die grundlegende Medianbedingung.

Der Mittelpunkt ist eine verbreitete Konvention, aber nicht die einzige mögliche Definition.

„Quantile sind in jeder Software identisch.“

Falsch. Es existieren verschiedene Quantilsdefinitionen und Interpolationsregeln.

Je nach Software kann ein empirisches Quantil

- eine tatsächliche Beobachtung,
- der Mittelwert zweier Beobachtungen,
- oder ein interpolierter Zwischenwert

sein.

Bei großen Stichproben sind die Unterschiede oft klein, bei kleinen Stichproben können sie sichtbar sein. Deshalb muss bei exakten Rechnungen die verwendete Definition angegeben werden.

„Die Reihenfolge von Mittelwert, Median und Modus beweist die Schiefe.“

Nein. Beziehungen wie

$$x_{\text{mod}} < x_{\text{med}} < \bar{x}$$

sind typische Muster rechtsschiefer, unimodaler Verteilungen, aber keine allgemeingültigen Definitionen oder Beweise.

Insbesondere bei multimodalen oder ungewöhnlich geformten Verteilungen kann die Beziehung scheitern.

„Der Modus ist immer eindeutig.“

Falsch.

Eine Verteilung kann

- keinen klaren Modus,

- einen Modus,
- zwei Modi,
- oder mehrere Modi

besitzen.

Bei stetigen Rohdaten kommt außerdem häufig jeder exakte Wert nur einmal vor. Der Modus einzelner Rohwerte ist dann wenig sinnvoll; ein Histogrammmodus hängt wiederum von der Klasseneinteilung ab.

„Ein arithmetisches Mittel ist für jedes Skalenniveau sinnvoll.“

Falsch.

Das arithmetische Mittel setzt grundsätzlich sinnvolle Abstände zwischen Werten voraus und eignet sich daher vor allem für kardinalskalierte Merkmale.

Der Median verlangt mindestens eine sinnvolle Ordnung und ist daher ab der Ordinalskala anwendbar.

Der Modus kann bereits für nominalskalierte Merkmale bestimmt werden. Diese Voraussetzungen werden im Material ausdrücklich unterschieden.

„Man kann Gruppenmittel einfach ungewichtet mitteln.“

Nur bei gleich großen Gruppen.

Korrekt ist:

$$\bar{x} = \frac{\sum_{j=1}^{r} n_j \bar{x} * j}{\sum * j = 1^{r} n_j}.$$

Eine kleine Gruppe darf das Gesamtmittel nicht genauso stark beeinflussen wie eine sehr große Gruppe.

„Varianz und Standardabweichung sind austauschbar.“

Sie messen dieselbe grundlegende Streuung, besitzen aber unterschiedliche Einheiten:

$$S^2$$

hat die quadrierte Einheit, während

$$S$$

die ursprüngliche Einheit besitzt.

Die Standardabweichung ist daher meist leichter inhaltlich zu interpretieren.

„Eine Standardabweichung kann negativ sein.“

Falsch:

$$S \geq 0.$$

Da die Varianz aus quadrierten Abweichungen besteht, gilt:

$$S^2 \geq 0.$$

Die Standardabweichung ist die nichtnegative Quadratwurzel.

„Eine Varianz von 0 bedeutet, dass die Werte nahe beieinanderliegen.“

Sie bedeutet sogar mehr: Alle Werte sind exakt gleich.

Aus

$$S^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = 0$$

folgt, dass jeder nichtnegative Summand gleich 0 sein muss:

$$(x_i - \bar{x})^2 = 0$$

für alle i. Somit gilt:

$$x_i = \bar{x}$$

für alle i.

„Die Variante mit $n-1$ ist grundsätzlich richtiger als die Variante mit n.“

Falsch. Beide Formeln beantworten unterschiedliche Fragen.

Für die rein deskriptive Streuung der vorliegenden Daten ist

$$S^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

vollkommen konsistent.

Für die unverzerrte Schätzung einer unbekannten Populationsvarianz wird häufig

$$S_*^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

verwendet.

„Bei einer Transformation gilt immer $S_y = bS_x$.“

Nur für

$$b \geq 0.$$

Allgemein gilt:

$$S_y = |b|S_x.$$

Bei

$$b = -2$$

wird die Verteilung gespiegelt und in ihren Abständen verdoppelt. Die Standardabweichung wird daher verdoppelt und nicht negativ:

$$S_y = 2S_x.$$

„Jede monotone Transformation erhält jedes Quantil

unverändert in derselben Quantilsrichtung.“

Bei streng monoton steigenden Transformationen bleibt die Rangordnung erhalten:

$$y_\alpha = g(x_\alpha).$$

Bei streng monoton fallenden Transformationen wird die Rangordnung umgekehrt. Dann entspricht ein unteres Quantil der transformierten Daten einem oberen Quantil der ursprünglichen Daten.

Der Median ist wegen seiner mittleren Position ein Sonderfall und wird unter geeigneter Definition auch bei einer fallenden Transformation mittransformiert.

„Der Interquartilsabstand berücksichtigt alle Beobachtungen.“

Falsch. Er wird ausschließlich aus

$$x_{0,25}$$

und

$$x_{0,75}$$

gebildet.

Das macht ihn robust gegenüber Extremwerten, bedeutet aber zugleich, dass Veränderungen außerhalb der mittleren 50 möglicherweise keinerlei Einfluss auf ihn haben.

„Ein im Boxplot markierter Ausreißer ist ein Datenfehler.“

Falsch. Die Regel

$$x_i < x_{0,25} - 1{,}5\,\mathrm{IQR}$$

oder

$$x_i > x_{0,75} + 1{,}5\,\mathrm{IQR}$$

ist lediglich eine Auffälligkeitsregel.

Ein markierter Wert kann

- ein Messfehler,
- ein Eingabefehler,
- ein seltener, aber korrekter Fall,
- oder ein Hinweis auf eine andere Teilpopulation

sein.

Er muss untersucht und darf nicht automatisch gelöscht werden.

„Die Whisker eines Boxplots reichen immer bis zum Minimum und Maximum.“

Nicht bei der üblichen Ausreißerdarstellung.

Werden Ausreißer separat markiert, reichen die Whisker normalerweise bis zur kleinsten beziehungsweise größten Beobachtung, die noch innerhalb der Ausreißergrenzen liegt. Minimum und Maximum können außerhalb der Whisker als einzelne Punkte erscheinen.

„Standardabweichungen können ohne Weiteres zwischen beliebigen Merkmalen verglichen werden.“

Nur wenn Einheit und Größenordnung sinnvoll vergleichbar sind.

Eine Standardabweichung von

$$10 \text{ Euro}$$

und eine Standardabweichung von

$$10 \text{ Quadratmetern}$$

sind nicht direkt gegeneinander interpretierbar.

Auch bei gleicher Einheit kann eine Standardabweichung von 10 relativ klein oder groß sein, je nachdem, ob der Mittelwert bei 20 oder bei $10,000$ liegt.

5. Active Recall (Wissenstest)

1. Im Landwirtschaftsbeispiel besitzt die Klasse von 0 bis 10 Hektar die relative Häufigkeit $0{,}2690$, während die Klasse von 50 bis 75 Hektar die relative Häufigkeit $0{,}2332$ besitzt. Berechne die zugehörigen Histogrammhöhen und erkläre, weshalb die erste Säule deutlich höher ist, obwohl sich die relativen Häufigkeiten weniger stark unterscheiden.

2. Betrachte die Daten

   $$2,\ 3,\ 3,\ 4,\ 8.$$

   Ersetze anschließend den Wert 8 durch 800. Untersuche qualitativ und quantitativ, wie sich arithmetisches Mittel, Median, Spannweite, Varianz und Interquartilsabstand verändern. Erkläre anhand der Definitionen, weshalb die Kennzahlen unterschiedlich reagieren.

3. Leite den Verschiebungssatz

   $$S^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2$$

   vollständig aus der Varianzdefinition her. Erkläre zusätzlich, weshalb die einfache Summe der Abweichungen vom Mittelwert nicht als Streuungsmaß geeignet ist.

4. Drei Wohnungsgruppen besitzen die Umfänge

   $$n_1 = 20, \qquad n_2 = 80, \qquad n_3 = 400$$

   und die mittleren Quadratmetermieten

   $$\bar{x}_1 = 14, \qquad \bar{x}_2 = 10, \qquad \bar{x}_3 = 8.$$

   Bestimme das Gesamtmittel. Erkläre, weshalb der ungewichtete Mittelwert der drei Gruppenmittel eine falsche Antwort liefert und welche allgemeine statistische Gefahr hinter diesem Fehler steckt.

5. Für eine Stichprobe seien

   $$\bar{x} = 10, \qquad x_{\text{med}} = 8, \qquad S = 3, \qquad \text{IQR} = 4.$$

   Die Daten werden durch

   $$y_i = 100 - 2x_i$$

   transformiert. Bestimme $\bar{y}$, y_{med}, S_y und IQR_y. Erkläre genau, welche Eigenschaften durch die Verschiebung, Skalierung und Spiegelung verändert werden und weshalb

beim Transformieren der Streuungsmaße ein Betrag erforderlich ist.

6. Lösungen zum Active Recall

1. Für die erste Klasse gilt:

$$H_1 = \frac{0{,}2690}{10} = 0{,}02690.$$

Für die zweite Klasse gilt:

$$H_2 = \frac{0{,}2332}{25} = 0{,}009328.$$

Die erste Klasse ist vor allem deshalb höher, weil ihr Anteil auf eine deutlich kleinere Klassenbreite konzentriert ist. Die Fläche und nicht die Höhe entspricht der relativen Häufigkeit.

2. Ursprünglich gilt:

$$\bar{x} = 4, \qquad x_{\text{med}} = 3, \qquad \text{Spannweite} = 6.$$

Nach dem Ersatz gilt:

$$\bar{x} = 162{,}4, \qquad x_{\text{med}} = 3, \qquad \text{Spannweite} = 798.$$

Varianz und Spannweite wachsen massiv, weil sie die Größe des Extremwerts berücksichtigen. Median und Interquartilsabstand reagieren wesentlich schwächer beziehungsweise je nach Quantilskonvention gar nicht, weil sie auf Rangpositionen beruhen.

3. Durch Ausmultiplizieren von

$$(x_i - \bar{x})^2 = x_i^2 - 2x_i\bar{x} + \bar{x}^2$$

und Verwendung von

$$\sum_{i=1}^{n} x_i = n\bar{x}$$

folgt:

$$S^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2.$$

Die unquadrierten Abweichungen sind ungeeignet, weil stets

$$\sum_{i=1}^{n}(x_i - \bar{x}) = 0$$

gilt.

4. Der Gesamtumfang beträgt:

$$n = 20 + 80 + 400 = 500.$$

Daher:

$$\bar{x} = \frac{20 \cdot 14 + 80 \cdot 10 + 400 \cdot 8}{500}\frac{4280}{500}8{,}56.$$

Der ungewichtete Wert

$$\frac{14 + 10 + 8}{3} = 10{,}67$$

behandelt alle Gruppen so, als wären sie gleich groß. Der Fehler besteht darin, Gruppenstatistiken ohne Berücksichtigung ihrer unterschiedlichen Informationsmengen zu aggregieren.

5. Für das Mittel gilt:

$$\bar{y} = 100 - 2\bar{x}80.$$

Für den Median gilt:

$$y_{\text{med}} = 100 - 2x_{\text{med}}84.$$

Für die Standardabweichung gilt:

$$S_y = |-2|S6.$$

Für den Interquartilsabstand gilt:

$$\text{IQR}_y = |-2|\,\text{IQR}\,8.$$

Die Addition von 100 verschiebt die Lage, verändert aber keine Abstände. Die Multiplikation mit -2 verdoppelt alle Abstände und spiegelt die Reihenfolge. Streuungsmaße bleiben nichtnegativ, weshalb der Betrag von -2 verwendet werden muss.