1. Das Big Picture (Chunking)

Dieses Kapitel zeigt, wie man **Zusammenhänge zwischen zwei Merkmalen sichtbar macht, beschreibt und quantitativ misst**. Je nach Skalenniveau geschieht das mit gemeinsamen und bedingten Verteilungen, Kontingenztafeln, Streudiagrammen, dem χ^2-Maß, der Kovarianz sowie der Pearson- oder Spearman-Korrelation. Entscheidend ist dabei die Grenze der deskriptiven Statistik: Ein beobachteter Zusammenhang ist noch kein Beweis dafür, dass eine Veränderung von X ursächlich eine Veränderung von Y auslöst.

2. Zentrale Definitionen

Gemeinsame Verteilung

Fachliche Definition: Die gemeinsame Verteilung zweier Merkmale X und Y beschreibt, mit welcher Häufigkeit beziehungsweise welchem Anteil die möglichen Kombinationen (a_j, b_k) auftreten. Ihre Datengrundlage sind Beobachtungspaare (x_i, y_i) derselben statistischen Einheiten.

Feynman-Übersetzung: Wir betrachten nicht nur, welchen Ausbildungsabschluss eine Person besitzt oder wie lange sie arbeitslos ist. Wir schauen für jede Person gleichzeitig: **Welcher Abschluss und welche Arbeitslosigkeitsdauer gehören zusammen?**

Die gemeinsame Verteilung enthält grundsätzlich mehr Informationen als die getrennten Verteilungen der beiden Merkmale.

Randverteilung

Fachliche Definition: Die Randverteilung von X entsteht, indem man die gemeinsamen Häufigkeiten über alle Ausprägungen von Y summiert. Analog erhält man die Randverteilung von Y durch Summation über alle Ausprägungen von X.

Feynman-Übersetzung: Man ignoriert eine Dimension der Tabelle. Für die Verteilung der Ausbildung zählt man beispielsweise alle Personen mit demselben Abschluss zusammen, unabhängig davon, wie lange sie arbeitslos sind.

Kontingenztafel

Fachliche Definition: Eine Kontingenztafel stellt die gemeinsame Häufigkeitsverteilung

zweier diskreter oder gruppierter Merkmale tabellarisch dar. Die Zellen enthalten gemeinsame Häufigkeiten, die Zeilen- und Spaltenränder die Randhäufigkeiten.

Feynman-Übersetzung: Eine Kontingenztafel ist ein Kreuzungsschema: Die Zeile sagt, welche Ausprägung von X vorliegt, die Spalte, welche Ausprägung von Y vorliegt. In der Zelle steht, wie oft genau diese Kombination vorkommt.

Absolute Häufigkeit

Fachliche Definition: Die gemeinsame absolute Häufigkeit h_{jk} ist die Anzahl der Beobachtungen, für die gleichzeitig $X = a_j$ und $Y = b_k$ gilt.

Feynman-Übersetzung: h_{jk} ist eine einfache Kopfzahl: Wie viele Fälle liegen genau in dieser Tabellenzelle?

Relative Häufigkeit

Fachliche Definition: Die gemeinsame relative Häufigkeit f_{jk} ist der Anteil der Beobachtungen, für die gleichzeitig $X = a_j$ und $Y = b_k$ gilt.

Feynman-Übersetzung: Statt zu fragen „Wie viele?“, fragt man „Welcher Anteil aller Fälle?“.

Bedingte Verteilung

Fachliche Definition: Die bedingte Verteilung von Y unter der Bedingung $X = a_j$ beschreibt die Verteilung von Y innerhalb der Teilgruppe, für die $X = a_j$ gilt.

Feynman-Übersetzung: Wir betrachten nicht mehr alle Personen. Wir wählen zunächst eine bestimmte Gruppe aus, beispielsweise nur Personen ohne Ausbildung, und untersuchen anschließend, wie sich innerhalb dieser Gruppe die Arbeitslosigkeitsdauer verteilt.

Bedingte Verteilungen entstehen durch zeilen- oder spaltenweises Normieren einer Kontingenztafel.

Statistische Unabhängigkeit

Fachliche Definition: X und Y sind unabhängig, wenn die Verteilung von Y nicht davon abhängt, welche Ausprägung von X vorliegt. Äquivalent dazu entspricht jede bedingte Verteilung von Y der Randverteilung von Y.

Feynman-Übersetzung: Die Kenntnis von X hilft überhaupt nicht dabei, etwas über Y vorherzusagen. Nachdem man X erfahren hat, weiß man über Y genauso viel wie vorher.

Erwartete Häufigkeit unter Unabhängigkeit

Fachliche Definition: Die erwartete Häufigkeit $\widetilde{h}_{jk}$ gibt an, wie viele Beobachtungen in der Zelle (j, k) liegen müssten, wenn die Randverteilungen unverändert blieben, X und Y aber unabhängig wären.

Feynman-Übersetzung: Man konstruiert eine Vergleichswelt ohne Zusammenhang: Wie voll wäre jede Zelle, wenn sich Zeilen- und Spaltenmerkmal nur zufällig miteinander kombinierten?

χ^2-Koeffizient

Fachliche Definition: Der χ^2-Koeffizient summiert die quadrierten, durch die erwarteten Häufigkeiten normierten Abweichungen zwischen beobachteten und unter Unabhängigkeit erwarteten Häufigkeiten.

Feynman-Übersetzung: Für jede Tabellenzelle wird geprüft, wie stark die Realität von der „Unabhängigkeitswelt“ abweicht. Anschließend werden alle Abweichungen zu einer Gesamtzahl zusammengefasst.

Streudiagramm

Fachliche Definition: Ein Streudiagramm stellt jedes Beobachtungspaar (x_i, y_i) als Punkt in einem Koordinatensystem dar. Es dient insbesondere zur Untersuchung zweier metrischer Merkmale.

Feynman-Übersetzung: Jeder Fall wird zu einem Punkt. Die Form der Punktwolke zeigt, ob große Werte von X tendenziell mit großen oder kleinen Werten von Y auftreten und ob die Beziehung gerade, gekrümmt oder kaum erkennbar ist.

Das Streudiagramm der Wohnfläche und Nettomiete auf Seite 25 zeigt beispielsweise einen deutlich positiven, aber nicht perfekten Zusammenhang.

Konkordante Beobachtung

Fachliche Definition: Eine Beobachtung (x_i, y_i) ist bezüglich des Datenmittelpunkts $(\bar{x}, \bar{y})$

konkordant, wenn beide Abweichungen dasselbe Vorzeichen besitzen:

$$x_i > \bar{x} \text{ und } y_i > \bar{y}$$

oder

$$x_i < \bar{x} \text{ und } y_i < \bar{y}.$$

Feynman-Übersetzung: Beide Werte liegen gemeinsam über dem Durchschnitt oder gemeinsam unter dem Durchschnitt. Sie „bewegen sich in dieselbe Richtung“.

Diskordante Beobachtung

Fachliche Definition: Eine Beobachtung (x_i, y_i) ist diskordant, wenn die Abweichungen vom jeweiligen Mittelwert unterschiedliche Vorzeichen besitzen.

Feynman-Übersetzung: Ein Wert liegt über seinem Durchschnitt, während der andere unter seinem Durchschnitt liegt. Die beiden Merkmale „bewegen sich gegeneinander“.

Kovarianz

Fachliche Definition: Die Kovarianz ist der durchschnittliche Wert der Produkte der zentrierten Beobachtungen. Sie misst Richtung und Ausprägung eines linearen Zusammenhangs.

Feynman-Übersetzung: Für jeden Punkt wird geprüft, ob X und Y gemeinsam über oder unter ihrem Durchschnitt liegen. Gleichgerichtete Punkte liefern positive Beiträge, gegengerichtete Punkte negative Beiträge.

Pearson-Korrelation

Fachliche Definition: Die Bravais-Pearson-Korrelation ist die durch die Standardabweichungen von X und Y normierte Kovarianz. Sie ist einheitenlos und liegt zwischen -1 und 1.

Feynman-Übersetzung: Die Pearson-Korrelation sagt, wie gut die Punktwolke einer steigenden oder fallenden Geraden folgt, ohne dass die verwendeten Maßeinheiten das Ergebnis beeinflussen.

Monotoner Zusammenhang

Fachliche Definition: Ein Zusammenhang ist monoton steigend, wenn größere Werte von X niemals systematisch zu kleineren Werten von Y führen. Er ist monoton fallend, wenn größere Werte von X niemals systematisch zu größeren Werten von Y führen. Der Zusammenhang muss dabei nicht linear sein.

Feynman-Übersetzung: Die Kurve darf stark gebogen sein, muss sich aber grundsätzlich immer in dieselbe Richtung bewegen.

Spearman-Rangkorrelation

Fachliche Definition: Die Spearman-Korrelation ist die Pearson-Korrelation der Ränge der Beobachtungen. Sie misst die Stärke eines monotonen Zusammenhangs und kann daher auch monotone, nichtlineare Beziehungen erkennen.

Feynman-Übersetzung: Es ist nicht wichtig, wie groß die Abstände zwischen den Werten sind. Entscheidend ist, ob die Reihenfolge bei X ungefähr mit der Reihenfolge bei Y übereinstimmt.

Die Vorlesung grenzt Pearson als Maß linearer Beziehungen von Spearman als Maß monotoner Beziehungen ab.

Bindung bei Rangdaten

Fachliche Definition: Eine Bindung liegt vor, wenn mehrere Beobachtungen denselben Merkmalswert besitzen und deshalb nicht eindeutig geordnet werden können. Üblicherweise erhalten diese Beobachtungen den Durchschnitt der betroffenen Rangplätze.

Feynman-Übersetzung: Wenn zwei Läufer exakt gleichzeitig ins Ziel kommen, kann keiner allein den dritten oder vierten Platz bekommen. Beide erhalten den Durchschnittsrang $3{,}5$.

Kausalität

Fachliche Definition: Ein kausaler Zusammenhang liegt vor, wenn eine gezielte Veränderung von X ursächlich eine Veränderung von Y bewirkt. Zur überzeugenden Identifikation sind insbesondere eine Manipulation der vermuteten Ursache und eine Kontrolle weiterer Einflussfaktoren erforderlich.

Feynman-Übersetzung: X und Y treten nicht nur gemeinsam auf. Würden wir X aktiv

verändern und sonst alles gleich halten, würde sich dadurch Y verändern.

Störvariable

Fachliche Definition: Eine Störvariable beeinflusst sowohl X als auch Y und kann dadurch einen statistischen Zusammenhang zwischen ihnen erzeugen oder verzerren.

Feynman-Übersetzung: Eine dritte Größe zieht im Hintergrund an beiden Fäden. Dadurch sieht es so aus, als ob X direkt auf Y wirkt.

Ökologischer Fehlschluss

Fachliche Definition: Ein ökologischer Fehlschluss entsteht, wenn aus einem Zusammenhang auf Gruppenebene unzulässigerweise auf einen entsprechenden Zusammenhang auf Individualebene geschlossen wird.

Feynman-Übersetzung: Nur weil Bezirke mit vielen Grünen-Wählern besonders viele EHEC-Fälle aufweisen, folgt daraus nicht, dass die Erkrankten selbst Grünen-Wähler waren.

Die Vorlesung veranschaulicht diesen Fehler anhand aggregierter Daten zu EHEC-Erkrankungen und Parteipräferenzen.

3. Formeln, Beweise & Intuition

Gemeinsame absolute Häufigkeit

Die Formel

Für die Ausprägungen $a_1, \ldots, a_J$ von X und $b_1, \ldots, b_K$ von Y gilt:

$$h_{jk} = \{i : x_i = a_j \text{ und } y_i = b_k\}\,.$$

Äquivalent kann die Häufigkeit mit einer Indikatorfunktion geschrieben werden:

$$h_{jk} = \sum_{i=1}^{n} \mathbf{1}\left[x_i = a_j,\ y_i = b_k\right].$$

Dekonstruktion

- n: Anzahl aller Beobachtungen.

- i: Index einer statistischen Einheit.
- x_i: beobachtete Ausprägung von X bei Einheit i.
- y_i: beobachtete Ausprägung von Y bei Einheit i.
- a_j: Ausprägung j von X.
- b_k: Ausprägung k von Y.
- J: Anzahl der betrachteten Ausprägungen von X.
- K: Anzahl der betrachteten Ausprägungen von Y.
- h_{jk}: Anzahl der Fälle mit der Kombination (a_j, b_k).
- $\mathbf{1}\cdot$: Funktion, die den Wert 1 annimmt, wenn die Bedingung erfüllt ist, und sonst 0.

Der Beweis / Die Herleitung

Für jede Beobachtung wird geprüft, ob sie in die Zelle (j, k) gehört:

$$\mathbf{1}\left[x_i = a_j,\ y_i = b_k\right] = \begin{cases} 1, & x_i = a_j \text{ und } y_i = b_k, \\ 0, & \text{sonst.} \end{cases}$$

Durch die Summe über alle Beobachtungen wird für jeden passenden Fall genau eine Einheit addiert:

$$\sum_{i=1}^{n} \mathbf{1}\left[x_i = a_j,\ y_i = b_k\right] = h_{jk}.$$

Da jede Beobachtung genau einer Zelle zugeordnet wird, gilt:

$$\sum_{j=1}^{J} \sum_{k=1}^{K} h_{jk} = n.$$

Die Analogie & Mechanik

Man kann sich die Kontingenztafel als Schrank mit $J \cdot K$ Fächern vorstellen. Jede Beobachtung wird genau in das Fach gelegt, das zu ihren beiden Merkmalsausprägungen passt.

Ein großes h_{jk} bedeutet lediglich, dass viele Fälle in dieser Kombination auftreten. Es beweist noch keinen Zusammenhang, weil die Zelle auch deshalb groß sein kann, weil ihre gesamte Zeile oder Spalte besonders häufig ist.

Die Definitionen der gemeinsamen und der marginalen absoluten Häufigkeiten werden in der Vorlesung über die Kontingenztafel eingeführt.

Gemeinsame relative Häufigkeit

Die Formel

$$f_{jk} = \frac{h_{jk}}{n}.$$

Dekonstruktion

- h_{jk}: absolute Häufigkeit in Zelle (j, k).
- n: Gesamtzahl der Beobachtungen.
- f_{jk}: Anteil aller Beobachtungen in Zelle (j, k).

Der Beweis / Die Herleitung

Eine relative Häufigkeit ist definitionsgemäß der Anteil einer Teilmenge an der Gesamtmenge:

$$f_{jk} = \frac{\text{Anzahl der Fälle in Zelle } (j,k)}{\text{Anzahl aller Fälle}} = \frac{h_{jk}}{n}.$$

Aus der Summeneigenschaft der absoluten Häufigkeiten folgt:

$$\sum_{j=1}^{J}\sum_{k=1}^{K} f_{jk} = \sum_{j=1}^{J}\sum_{k=1}^{K} \frac{h_{jk}}{n} \frac{1}{n} \sum_{j=1}^{J}\sum_{k=1}^{K} h_{jk} = 1.$$

Die Analogie & Mechanik

Die absoluten Häufigkeiten sind Stückzahlen. Die relativen Häufigkeiten sind die Stückzahlen als Anteil des gesamten Kuchens.

Wird h_{jk} bei unverändertem n größer, steigt f_{jk}. Wird dagegen n größer, ohne dass h_{jk} entsprechend mitwächst, sinkt der Anteil.

Randhäufigkeiten

Die Formeln

Die absolute Zeilenrandhäufigkeit lautet:

$$h_{j\bullet} = \sum_{k=1}^{K} h_{jk}.$$

Die absolute Spaltenrandhäufigkeit lautet:

$$h_{\bullet k} = \sum_{j=1}^{J} h_{jk}.$$

Für die relativen Randhäufigkeiten gilt:

$$f_{j\bullet} = \frac{h_{j\bullet}}{n} \sum_{k=1}^{K} f_{jk},$$

$$f_{\bullet k} = \frac{h_{\bullet k}}{n} \sum_{j=1}^{J} f_{jk}.$$

Dekonstruktion

- Der Punkt in $h_{j\bullet}$ bedeutet: Über den zweiten Index wird summiert.
- Der Punkt in $h_{\bullet k}$ bedeutet: Über den ersten Index wird summiert.
- $h_{j\bullet}$ zählt alle Fälle mit $X = a_j$.
- $h_{\bullet k}$ zählt alle Fälle mit $Y = b_k$.

Der Beweis / Die Herleitung

Alle Personen mit $X = a_j$ verteilen sich auf die möglichen Ausprägungen $b_1, \ldots, b_K$:

$$h_{j\bullet} = h_{j1} + h_{j2} + \cdots + h_{jK}.$$

Division durch n ergibt:

$$\frac{h_{j\bullet}}{n} = \frac{h_{j1} + \cdots + h_{jK}}{n} \frac{h_{j1}}{n} + \cdots + \frac{h_{jK}}{n} f_{j1} + \cdots + f_{jK}.$$

Die Analogie & Mechanik

Die gemeinsamen Häufigkeiten sind einzelne Räume eines Gebäudes. Die Randhäufigkeit einer Zeile ist die Anzahl aller Personen auf einer gesamten Etage.

Bei der Bildung der Randverteilung wird bewusst Information zerstört: Man weiß danach, wie oft $X = a_j$ vorkommt, aber nicht mehr, wie diese Fälle auf die Ausprägungen von Y verteilt sind.

Bedingte relative Häufigkeiten

Die Formeln

Die bedingte Häufigkeit von $Y = b_k$ gegeben $X = a_j$ lautet:

$$f_{k|j} = \frac{h_{jk}}{h_{j\bullet}} \frac{f_{jk}}{f_{j\bullet}},$$

sofern

$$h_{j\bullet} > 0.$$

Umgekehrt gilt für $X = a_j$ gegeben $Y = b_k$:

$$f_{j|k} = \frac{h_{jk}}{h_{\bullet k}} \frac{f_{jk}}{f_{\bullet k}},$$

sofern

$$h_{\bullet k} > 0.$$

Dekonstruktion

- $f_{k|j}$: Anteil der Beobachtungen mit $Y = b_k$ innerhalb der Gruppe $X = a_j$.
- Der Ausdruck links vom Strich beschreibt das interessierende Merkmal.
- Der Ausdruck rechts vom Strich beschreibt die Bedingung.
- h_{jk}: Anzahl der Fälle, die beide Bedingungen erfüllen.
- $h_{j\bullet}$: Anzahl aller Fälle in der ausgewählten Gruppe $X = a_j$.

Der Beweis / Die Herleitung

Nach der Bedingung $X = a_j$ besteht die relevante Grundgesamtheit nicht mehr aus n Beobachtungen, sondern nur noch aus $h_{j\bullet}$ Beobachtungen.

Daher lautet der gesuchte Anteil:

$$f_{k|j} = \frac{\text{Fälle mit } X = a_j \text{ und } Y = b_k}{\text{alle Fälle mit } X = a_j} = \frac{h_{jk}}{h_{j\bullet}}.$$

Die bedingten Häufigkeiten einer Zeile summieren sich zu 1:

$$\sum_{k=1}^{K} f_{k|j} = \sum_{k=1}^{K} \frac{h_{jk}}{h_{j\bullet}} \frac{\sum_{k=1}^{K} h_{jk}}{h_{j\bullet}} \frac{h_{j\bullet}}{h_{j\bullet}} 1.$$

Die Analogie & Mechanik

Man verändert beim Bedingen den Nenner. Statt alle Personen zu betrachten, zoomt man in eine bestimmte Teilgruppe hinein.

Im Vorlesungsbeispiel befinden sich unter den 123 Personen ohne Ausbildung 86 kurzzeitarbeitslose Personen. Daher gilt:

$$\frac{86}{123} \approx 0{,}699.$$

Der Wert bedeutet nicht, dass $69{,}9$ aller Arbeitslosen keine Ausbildung besitzen. Er bedeutet, dass $69{,}9$ der Arbeitslosen **ohne Ausbildung** kurzzeitarbeitslos sind. Die Richtung der Bedingung ist entscheidend.

Unabhängigkeit über bedingte Verteilungen

Die Formel

Unter Unabhängigkeit gilt für alle zulässigen Kombinationen:

$$\frac{h_{jk}}{h_{j\bullet}} = \frac{h_{\bullet k}}{n}.$$

In relativen Häufigkeiten lautet die äquivalente Bedingung:

$$f_{jk} = f_{j\bullet} f_{\bullet k}.$$

Dekonstruktion

- Die linke Seite ist die bedingte Häufigkeit von $Y = b_k$ gegeben $X = a_j$.
- Die rechte Seite ist die unbedingte Randhäufigkeit von $Y = b_k$.
- Bei Unabhängigkeit verändert die Information $X = a_j$ die Verteilung von Y nicht.

Der Beweis / Die Herleitung

Aus der Gleichheit von bedingter Verteilung und Randverteilung folgt:

$$\frac{h_{jk}}{h_{j\bullet}} = \frac{h_{\bullet k}}{n}.$$

Multiplikation mit $h_{j\bullet}$ ergibt:

$$h_{jk} = \frac{h_{j\bullet} h_{\bullet k}}{n}.$$

Division durch n liefert:

$$\frac{h_{jk}}{n} = \frac{h_{j\bullet}}{n}\frac{h_{\bullet k}}{n}.$$

Damit folgt:

$$f_{jk} = f_{j\bullet} f_{\bullet k}.$$

Umgekehrt führt dieselbe Rechnung rückwärts wieder zur Gleichheit der bedingten Verteilung mit der Randverteilung. Beide Aussagen sind daher äquivalent.

Die Analogie & Mechanik

Angenommen, insgesamt sind 10 aller Personen langzeitarbeitslos. Bei Unabhängigkeit müssten auch innerhalb jeder Ausbildungsgruppe ungefähr 10 langzeitarbeitslos sein.

Sind es in einer Gruppe dagegen 30 und in einer anderen nur 5, verändert die Kenntnis der Ausbildung unsere Einschätzung der Arbeitslosigkeitsdauer. Dann besteht ein statistischer Zusammenhang.

Erwartete Häufigkeit unter Unabhängigkeit

Die Formel

$$\widetilde{h}_{jk} = \frac{h_{j\bullet} h_{\bullet k}}{n}.$$

Äquivalent gilt:

$$\widetilde{h}_{jk} = n f_{j\bullet} f_{\bullet k}.$$

Dekonstruktion

- $\widetilde{h}_{jk}$: unter Unabhängigkeit erwartete Häufigkeit der Zelle (j, k).
- $h_{j\bullet}$: Umfang der Zeile j.
- $h_{\bullet k}$: Umfang der Spalte k.
- n: Gesamtumfang der Daten.
- Die Tilde kennzeichnet, dass es sich um einen theoretischen Vergleichswert und nicht um die beobachtete Häufigkeit handelt.

Der Beweis / Die Herleitung

Unter Unabhängigkeit entspricht der Anteil von $Y = b_k$ in jeder Zeile seinem Gesamtanteil:

$$\frac{h_{\bullet k}}{n}.$$

In Zeile j befinden sich insgesamt $h_{j\bullet}$ Beobachtungen. Der erwartete Anteil wird daher mit der Zeilengröße multipliziert:

$$\widetilde{h}_{jk} = h_{j\bullet}\frac{h_{\bullet k}}{n}.$$

Damit folgt:

$$\widetilde{h}_{jk} = \frac{h_{j\bullet}h_{\bullet k}}{n}.$$

Im Vorlesungsbeispiel ergibt sich für Personen ohne Ausbildung und Kurzzeitarbeitslosigkeit:

$$\widetilde{h}_{11} = \frac{123 \cdot 324}{447} \approx 89{,}15.$$

Beobachtet wurden dagegen 86 Fälle.

Die Analogie & Mechanik

Man kann sich die Randhäufigkeiten als feste Zutatenmengen vorstellen. Die erwartete Häufigkeit zeigt, wie diese Zutaten auf die Zellen verteilt wären, wenn sie sich rein proportional und ohne Zusammenhang mischten.

Ein großer Zeilenrand und ein großer Spaltenrand erzeugen automatisch eine große erwartete Zellhäufigkeit. Deshalb darf eine große beobachtete Häufigkeit nie isoliert beurteilt werden.

χ^2-Koeffizient

Die Formel

$$\chi^2 = \sum_{j=1}^{J}\sum_{k=1}^{K}\frac{\left(h_{jk} - \widetilde{h}_{jk}\right)^2}{\widetilde{h}_{jk}}.$$

Dekonstruktion

- h_{jk}: beobachtete Häufigkeit.
- $\widetilde{h}_{jk}$: unter Unabhängigkeit erwartete Häufigkeit.
- $h_{jk} - \widetilde{h}_{jk}$: rohe Abweichung von der Unabhängigkeitswelt.

- $\left(h_{jk} - \widetilde{h}_{jk}\right)^2$: quadrierte Abweichung.
- Division durch $\widetilde{h}_{jk}$: Normierung relativ zur erwarteten Zellgröße.
- χ^2: Summe der Abweichungsbeiträge aller Zellen.

Der Beweis / Die Herleitung

Zunächst wird für jede Zelle ein standardisierter Residuenbeitrag definiert:

$$r_{jk} = \frac{h_{jk} - \widetilde{h}_{jk}}{\sqrt{\widetilde{h}_{jk}}}.$$

Das Quadrat lautet:

$$r_{jk}^2 = \frac{\left(h_{jk} - \widetilde{h}_{jk}\right)^2}{\widetilde{h}_{jk}}.$$

Die Summe der quadrierten Residuen über alle Zellen ergibt:

$$\chi^2 = \sum_{j=1}^{J} \sum_{k=1}^{K} r_{jk}^2.$$

Da jedes r_{jk}^2 nichtnegativ ist, gilt:

$$\chi^2 \geq 0.$$

Außerdem gilt:

$$\chi^2 = 0$$

genau dann, wenn in jeder Zelle

$$h_{jk} = \widetilde{h}_{jk}$$

gilt. In diesem Fall erfüllt die empirische Tabelle exakt die Unabhängigkeitsbedingung.

Mit relativen Häufigkeiten kann die Formel umgeschrieben werden. Da

$$h_{jk} = n f_{jk}$$

und

$$\widetilde{h}_{jk} = n f_{j\bullet} f_{\bullet k}$$

gilt, folgt:

$$\chi^2 = n \sum_{j=1}^{J} \sum_{k=1}^{K} \frac{(f_{jk} - f_{j\bullet} f_{\bullet k})^2}{f_{j\bullet} f_{\bullet k}}.$$

Diese Form zeigt unmittelbar, dass χ^2 bei gleichbleibenden relativen Abweichungen proportional mit n wächst.

Die Analogie & Mechanik

Jede Zelle erhält eine Art Überraschungspunktzahl:

- Beobachtung und Erwartung nahezu gleich: kleiner Beitrag.
- Große Abweichung: großer Beitrag.
- Dieselbe rohe Abweichung ist bei einer kleinen erwarteten Häufigkeit überraschender als bei einer großen erwarteten Häufigkeit.

Beispielsweise ist eine Abweichung von 10 Fällen bei einer Erwartung von 5 viel gravierender als bei einer Erwartung von $1,000$:

$$\frac{10^2}{5} = 20,$$

während

$$\frac{10^2}{1,000} = 0{,}1.$$

Wird der Zähler extrem groß, dominiert diese Zelle den Gesamtwert. Wird der Nenner sehr klein, kann schon eine kleine absolute Abweichung einen sehr großen Beitrag erzeugen.

Der Koeffizient vergleicht in der Vorlesung ausdrücklich beobachtete und unter Unabhängigkeit erwartete Häufigkeiten.

Mittelwerte als Mittelpunkt der Daten

Die Formeln

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i,$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^{n} y_i.$$

Dekonstruktion

- $\bar{x}$: arithmetischer Mittelwert aller Werte von X.
- $\bar{y}$: arithmetischer Mittelwert aller Werte von Y.
- $(\bar{x}, \bar{y})$: Mittelpunkt der Punktwolke im Sinne der Koordinatenmittelwerte.

Der Beweis / Die Herleitung

Die zentrierten Abweichungen summieren sich stets zu null:

$$\sum_{i=1}^{n}(x_i - \bar{x}) = \sum_{i=1}^{n} x_i - n\bar{x}.$$

Da

$$n\bar{x} = \sum_{i=1}^{n} x_i$$

gilt, folgt:

$$\sum_{i=1}^{n}(x_i - \bar{x}) = 0.$$

Analog gilt:

$$\sum_{i=1}^{n}(y_i - \bar{y}) = 0.$$

Die Analogie & Mechanik

Der Mittelwert ist der Balancepunkt jeder Achse. Die Kovarianz prüft, in welchen Quadranten relativ zu diesem Balancepunkt die Beobachtungen liegen.

Kovarianz

Die Formel

$$\mathrm{Cov}(X, Y) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}).$$

Dekonstruktion

- $x_i - \bar{x}$: horizontale Abweichung eines Punkts vom Datenmittelpunkt.
- $y_i - \bar{y}$: vertikale Abweichung eines Punkts vom Datenmittelpunkt.

- Das Produkt ist positiv, wenn beide Abweichungen dasselbe Vorzeichen besitzen.
- Das Produkt ist negativ, wenn die Abweichungen unterschiedliche Vorzeichen besitzen.
- Die Division durch n bildet den Durchschnitt dieser Produkte.

Der Beweis / Die Herleitung

Für eine konkordante Beobachtung gilt entweder:

$$x_i - \bar{x} > 0 \quad \text{und} \quad y_i - \bar{y} > 0,$$

oder:

$$x_i - \bar{x} < 0 \quad \text{und} \quad y_i - \bar{y} < 0.$$

In beiden Fällen ist:

$$(x_i - \bar{x})(y_i - \bar{y}) > 0.$$

Für eine diskordante Beobachtung besitzt genau eine der beiden Abweichungen ein negatives Vorzeichen. Daher gilt:

$$(x_i - \bar{x})(y_i - \bar{y}) < 0.$$

Durch das Mitteln über alle Beobachtungen wird erkennbar, welche Art von Beiträgen überwiegt.

Die Kovarianz kann auch in einer Rechenform dargestellt werden:

$$\mathrm{Cov}(X,Y) = \frac{1}{n}\sum_{i=1}^{n} x_i y_i - \bar{x}\bar{y}.$$

Herleitung:

$$\mathrm{Cov}(X,Y) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) \quad = \frac{1}{n}\sum_{i=1}^{n}\left(x_i y_i - x_i\bar{y} - \bar{x}y_i + \bar{x}\bar{y}\right) = \frac{1}{n}\sum_{i=1}^{n} x_i y_i - \bar{y}$$

Die Analogie & Mechanik

Stelle dir vor, jeder Punkt stimmt darüber ab, ob der Zusammenhang positiv oder negativ ist:

- Rechts oben und links unten stimmen positiv.
- Links oben und rechts unten stimmen negativ.
- Punkte nahe am Mittelpunkt besitzen nur wenig Stimmgewicht.

- Punkte weit vom Mittelpunkt entfernt besitzen wegen des Produkts ein großes Stimmgewicht.

Liegt ein Punkt beispielsweise sehr weit rechts und sehr weit oben, werden zwei große positive Abweichungen multipliziert. Der positive Beitrag kann extrem groß werden. Deshalb ist die Kovarianz empfindlich gegenüber Ausreißern.

Die Vorlesung interpretiert die Kovarianz als durchschnittliche Konkordanz beziehungsweise Diskordanz.

Kovarianz als Verallgemeinerung der Varianz

Die Formel

$$\mathrm{Cov}(X, X) = \mathrm{Var}(X).$$

Der Beweis / Die Herleitung

Setzt man in der Kovarianzformel für beide Merkmale X ein, erhält man:

$$\mathrm{Cov}(X, X) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(x_i - \bar{x}) \quad = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 \; = \mathrm{Var}(X).$$

Die Analogie & Mechanik

Die Varianz fragt, wie stark X mit sich selbst gemeinsam schwankt. Da eine Abweichung mit sich selbst multipliziert wird, kann kein negativer Beitrag entstehen.

Skalierungsabhängigkeit der Kovarianz

Die Formel

Für transformierte Merkmale

$$X^* = a + bX$$

und

$$Y^* = c + dY$$

gilt:

$$\mathrm{Cov}(X^*, Y^*) = bd\,\mathrm{Cov}(X, Y).$$

Der Beweis / Die Herleitung

Die neuen Mittelwerte sind:

$$\overline{x^*} = a + b\bar{x},$$

$$\overline{y^*} = c + d\bar{y}.$$

Damit gilt:

$$x_i^* - \overline{x^*} = b(x_i - \bar{x}),$$

$$y_i^* - \overline{y^*} = d(y_i - \bar{y}).$$

Einsetzen ergibt:

$$\mathrm{Cov}(X^*, Y^*) = \frac{1}{n}\sum_{i=1}^{n} b(x_i - \bar{x})d(y_i - \bar{y}) \quad = bd\,\mathrm{Cov}(X, Y).$$

Die Analogie & Mechanik

Wird die Wohnfläche statt in Quadratmetern in Quadratzentimetern angegeben, werden alle Abweichungen massiv größer. Der inhaltliche Zusammenhang bleibt gleich, aber die Kovarianz verändert sich.

Additionen wie eine Änderung des Nullpunkts wirken sich dagegen nicht aus, weil sie bei der Zentrierung wieder verschwinden.

Pearson-Korrelation

Die Formel

$$\rho(X, Y) = \frac{\mathrm{Cov}(X, Y)}{\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}}.$$

Nach Einsetzen der empirischen Formeln ergibt sich:

$$\rho(X, Y) = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2 \sum_{i=1}^{n}(y_i - \bar{y})^2}}.$$

Dekonstruktion

- Der Zähler misst die gemeinsame lineare Schwankung.
- $\mathrm{Var}(X)$ misst die Streuung von X.

- $\mathrm{Var}(Y)$ misst die Streuung von Y.
- Der Nenner entfernt die Maßeinheiten und setzt die gemeinsame Schwankung ins Verhältnis zu den Einzelstreuungen.
- Das Vorzeichen zeigt die Richtung.
- Der Betrag zeigt die Stärke des linearen Zusammenhangs.

Der Beweis / Die Herleitung

Setzt man

$$\mathrm{Cov}(X,Y) = \frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})$$

sowie

$$\mathrm{Var}(X) = \frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2$$

und

$$\mathrm{Var}(Y) = \frac{1}{n}\sum_{i=1}^{n}(y_i-\bar{y})^2$$

ein, ergibt sich:

$$\rho(X,Y) = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})(y_i-\bar{y})}{\sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i-\bar{x})^2 \cdot \frac{1}{n}\sum_{i=1}^{n}(y_i-\bar{y})^2}}.$$

Im Nenner gilt:

$$\sqrt{\frac{1}{n}\cdot\frac{1}{n}} = \frac{1}{n}.$$

Der Faktor $\frac{1}{n}$ kürzt sich daher vollständig heraus.

Die Analogie & Mechanik

Die Kovarianz ist eine gemeinsame Bewegung in Originaleinheiten. Die Korrelation fragt dagegen: **Wie groß ist die gemeinsame Bewegung relativ zu dem, was aufgrund der Streuung beider Merkmale überhaupt möglich wäre?**

Ist der Zähler groß und positiv im Verhältnis zum Nenner, liegt $\rho(X,Y)$ nahe bei 1. Ist der Zähler groß und negativ, liegt der Wert nahe bei -1.

Ist der Nenner exakt null, besitzt mindestens eines der Merkmale keine Streuung. Dann ist die Korrelation nicht definiert. Ein Merkmal, das für alle Beobachtungen denselben Wert besitzt, kann keine Richtung des gemeinsamen Schwankens liefern.

Beschränkung der Pearson-Korrelation

Die Formel

$$-1 \leq \rho(X,Y) \leq 1.$$

Der Beweis / Die Herleitung

Definiere:

$$u_i = x_i - \bar{x}$$

und

$$v_i = y_i - \bar{y}.$$

Nach der Cauchy-Schwarz-Ungleichung gilt:

$$\left|\sum_{i=1}^{n} u_i v_i\right| \leq \sqrt{\sum_{i=1}^{n} u_i^2}\sqrt{\sum_{i=1}^{n} v_i^2}.$$

Division durch den positiven Ausdruck auf der rechten Seite ergibt:

$$\left|\frac{\sum_{i=1}^{n} u_i v_i}{\sqrt{\sum_{i=1}^{n} u_i^2 \sum_{i=1}^{n} v_i^2}}\right| \leq 1.$$

Der Bruch ist genau die Pearson-Korrelation. Daher gilt:

$$|\rho(X,Y)| \leq 1.$$

Dies ist äquivalent zu:

$$-1 \leq \rho(X,Y) \leq 1.$$

Wann gilt Gleichheit?

Gleichheit in der Cauchy-Schwarz-Ungleichung gilt genau dann, wenn die zentrierten Werte proportional sind:

$$y_i - \bar{y} = b(x_i - \bar{x})$$

für ein konstantes b und alle i.

Umgestellt folgt:

$$y_i = \bar{y} - b\bar{x} + bx_i.$$

Mit

$$a = \bar{y} - b\bar{x}$$

ergibt sich:

$$y_i = a + bx_i.$$

Alle Punkte liegen dann exakt auf einer Geraden.

- Für $b > 0$ gilt $\rho(X, Y) = 1$.
- Für $b < 0$ gilt $\rho(X, Y) = -1$.

Die Analogie & Mechanik

Die Grenzen -1 und 1 sind keine willkürliche Skalierung. Sie entstehen, weil die gemeinsame Schwankung niemals größer sein kann als das geometrische Maximum, das durch die beiden Einzelstreuungen vorgegeben ist.

Invarianz der Pearson-Korrelation gegenüber Maßeinheiten

Die Formel

Für

$$X^* = a + bX$$

und

$$Y^* = c + dY$$

mit $b \neq 0$ und $d \neq 0$ gilt:

$$\rho(X^*, Y^*) = \operatorname{sgn}(bd)\rho(X, Y).$$

Der Beweis / Die Herleitung

Für den Zähler gilt:

$$\mathrm{Cov}(X^*, Y^*) = bd\,\mathrm{Cov}(X, Y).$$

Für die Varianzen gilt:

$$\mathrm{Var}(X^*) = b^2\,\mathrm{Var}(X),$$

$$\mathrm{Var}(Y^*) = d^2\,\mathrm{Var}(Y).$$

Damit folgt:

$$\rho(X^*, Y^*) = \frac{bd\,\mathrm{Cov}(X, Y)}{\sqrt{b^2\,\mathrm{Var}(X) d^2\,\mathrm{Var}(Y)}} \quad = \frac{bd}{|b||d|}\rho(X, Y) \; = \mathrm{sgn}(bd)\rho(X, Y).$$

Die Analogie & Mechanik

Eine Umrechnung von Metern in Zentimeter verändert die Korrelation nicht, weil Zähler und Nenner im gleichen Verhältnis wachsen.

Wird jedoch die Richtung einer Skala umgekehrt, beispielsweise durch Multiplikation mit -1, kehrt sich das Vorzeichen der Korrelation um.

Spearman-Rangkorrelation

Die Formel

Seien R_i und S_i die Ränge von x_i und y_i. Dann gilt:

$$\rho_S = \rho(R, S).$$

Spearman ist also die Pearson-Korrelation der Ränge:

$$\rho_S = \frac{\sum_{i=1}^{n}(R_i - \bar{R})(S_i - \bar{S})}{\sqrt{\sum_{i=1}^{n}(R_i - \bar{R})^2 \sum_{i=1}^{n}(S_i - \bar{S})^2}}.$$

Dekonstruktion

- R_i: Rang von x_i innerhalb aller beobachteten Werte von X.
- S_i: Rang von y_i innerhalb aller beobachteten Werte von Y.
- $\bar{R}$: Mittelwert der Ränge von X.
- $\bar{S}$: Mittelwert der Ränge von Y.
- ρ_S: Spearman-Rangkorrelation.

Der Beweis / Die Herleitung

Die ursprünglichen Abstände werden zunächst durch Reihenfolgen ersetzt. Eine stark gekrümmte Transformation kann die Abstände massiv verändern, während die Reihenfolge vollständig erhalten bleibt.

Ist Y eine streng monoton steigende Funktion von X, gilt:

$$R_i = S_i$$

für alle i. Damit stimmen die beiden Rangvariablen perfekt überein und es folgt:

$$\rho_S = 1.$$

Ist Y eine streng monoton fallende Funktion von X, kehrt sich die Reihenfolge vollständig um. Dann gilt:

$$\rho_S = -1.$$

Die Analogie & Mechanik

Pearson vergleicht die tatsächlichen Laufzeiten zweier Wettkämpfe. Spearman vergleicht nur die Platzierungen.

Wenn dieselben Personen in beiden Wettkämpfen in nahezu derselben Reihenfolge abschneiden, ist Spearman hoch, selbst wenn sich die Zeitabstände stark unterscheiden.

Spearman-Kurzformel ohne Bindungen

Die Formel

Wenn keine Bindungen vorliegen, kann Spearman auch berechnet werden als:

$$\rho_S = 1 - \frac{6 \sum_{i=1}^{n} d_i^2}{n(n^2 - 1)},$$

wobei

$$d_i = R_i - S_i.$$

Der Beweis / Die Herleitung

Ohne Bindungen bestehen beide Rangfolgen aus den Zahlen $1, \ldots, n$. Daher gilt:

$$\bar{R} = \bar{S} = \frac{n+1}{2}.$$

Die Summe der quadrierten zentrierten Ränge ist:

$$A = \sum_{i=1}^{n} (R_i - \bar{R})^2 \frac{n(n^2-1)}{12}.$$

Da S_i dieselben möglichen Rangwerte besitzt, gilt auch:

$$\sum_{i=1}^{n} (S_i - \bar{S})^2 = A.$$

Nun wird die quadrierte Rangdifferenz betrachtet:

$$\sum_{i=1}^{n} d_i^2 = \sum_{i=1}^{n} (R_i - S_i)^2 \quad = \sum_{i=1}^{n} \left[(R_i - \bar{R}) - (S_i - \bar{S}) \right]^2 = 2A - 2\sum_{i=1}^{n} (R_i - \bar{R})(S_i - \bar{S}).$$

Daraus folgt:

$$\sum_{i=1}^{n} (R_i - \bar{R})(S_i - \bar{S}) = A - \frac{1}{2}\sum_{i=1}^{n} d_i^2.$$

Da beide Rangvariablen dieselbe Quadratsumme A besitzen, lautet ihre Korrelation:

$$\rho_S = \frac{A - \frac{1}{2}\sum_{i=1}^{n} d_i^2}{A} \quad = 1 - \frac{\sum_{i=1}^{n} d_i^2}{2A} = 1 - \frac{6\sum_{i=1}^{n} d_i^2}{n(n^2-1)}.$$

Die Analogie & Mechanik

Jede Abweichung zwischen den beiden Ranglisten wird als Strafpunkt gewertet. Durch das Quadrieren werden große Rangverschiebungen besonders stark bestraft.

Bei Bindungen sollte nicht unkritisch die Kurzformel verwendet werden. Stattdessen werden Durchschnittsränge vergeben und anschließend wird die Pearson-Korrelation der Rangwerte berechnet.

4. Häufige Missverständnisse & Edge Cases

Randverteilungen bestimmen die gemeinsame Verteilung nicht

Zwei Datensätze können exakt dieselbe Verteilung von X und exakt dieselbe Verteilung von Y besitzen, obwohl die Paarungen vollkommen unterschiedlich sind.

Die Randverteilungen sagen, wie viele Werte jeder Art vorkommen. Sie sagen nicht, **welche**

Werte von X mit welchen Werten von Y gekoppelt sind. Nur im Sonderfall der Unabhängigkeit kann die gemeinsame Verteilung aus den Randverteilungen rekonstruiert werden.

$f_{k|j}$ und $f_{j|k}$ sind nicht dasselbe

Im Allgemeinen gilt:

$$\frac{h_{jk}}{h_{j\bullet}} \neq \frac{h_{jk}}{h_{\bullet k}}.$$

Der Zähler ist zwar gleich, aber die Bezugsgruppe im Nenner ist verschieden.

„Anteil der Langzeitarbeitslosen unter Personen ohne Ausbildung“ ist nicht dasselbe wie „Anteil der Personen ohne Ausbildung unter Langzeitarbeitslosen“.

Gleiche absolute Häufigkeiten können unterschiedliche Bedeutungen besitzen

Eine Zellhäufigkeit von 20 kann in einer Zeile mit insgesamt 25 Fällen extrem groß, in einer Zeile mit $1,000$ Fällen dagegen sehr klein sein. Für Zusammenhangsanalysen sind deshalb häufig bedingte Anteile aussagekräftiger als rohe Häufigkeiten.

Erwartete Häufigkeiten müssen keine ganzen Zahlen sein

Ein Wert wie

$$\widetilde{h}_{11} = 89{,}15$$

ist kein tatsächlich beobachtbarer Personenzähler. Es handelt sich um einen theoretischen Vergleichswert unter Unabhängigkeit.

χ^2 ist nicht auf 1 beschränkt

Anders als eine Korrelation besitzt χ^2 keine feste Obergrenze. Ein größerer Wert bedeutet eine stärkere Gesamtabweichung von der Unabhängigkeit, ist aber nicht direkt als Prozentwert interpretierbar.

χ^2 hängt vom Stichprobenumfang ab

Aus

$$\chi^2 = n \sum_{j=1}^{J} \sum_{k=1}^{K} \frac{(f_{jk} - f_{j\bullet} f_{\bullet k})^2}{f_{j\bullet} f_{\bullet k}}$$

ist erkennbar: Verdoppelt man den Stichprobenumfang bei gleichbleibenden relativen Häufigkeiten, verdoppelt sich χ^2.

Deshalb ist der rohe χ^2-Wert nur eingeschränkt geeignet, die Stärke von Zusammenhängen über Tabellen mit unterschiedlichen Stichprobengrößen zu vergleichen.

Sehr kleine erwartete Häufigkeiten können problematisch sein

Im Term

$$\frac{\left(h_{jk} - \widetilde{h}_{jk}\right)^2}{\widetilde{h}_{jk}}$$

führt ein sehr kleiner Nenner schnell zu einem sehr großen Beitrag.

Ist

$$\widetilde{h}_{jk} = 0,$$

ist der Ausdruck nicht definiert. In inferenzstatistischen Anwendungen können außerdem sehr kleine erwartete Häufigkeiten die übliche χ^2-Approximation unzuverlässig machen.

$\mathrm{Cov}(X, Y) = 0$ bedeutet nicht Unabhängigkeit

Aus

$$\mathrm{Cov}(X, Y) = 0$$

folgt lediglich, dass kein durch die Kovarianz erfasster linearer Zusammenhang besteht. Ein starker nichtlinearer Zusammenhang kann dennoch vorhanden sein.

Bei einer symmetrischen U-förmigen Beziehung können sich positive und negative Produkte exakt aufheben. Die Folien zeigen entsprechende nichtlineare Punktwolken mit einer Korrelation nahe null.

Die Implikation

$$X \text{ und } Y \text{ unabhängig} \Rightarrow \mathrm{Cov}(X,Y) = 0$$

gilt bei existierenden Varianzen.

Die Umkehrung

$$\mathrm{Cov}(X,Y) = 0 \Rightarrow X \text{ und } Y \text{ unabhängig}$$

gilt im Allgemeinen nicht.

Eine hohe Korrelation bedeutet nicht, dass die Punkte nahe beieinander liegen

Die Korrelation bewertet die Nähe zu einer Geraden, nicht die absolute Nähe der Werte von X und Y.

Auch bei stark unterschiedlichen Größenordnungen kann gelten:

$$\rho(X,Y) = 1,$$

wenn alle Punkte exakt auf einer steigenden Geraden liegen.

Pearson erkennt nur lineare Struktur zuverlässig

Eine stark monotone, aber gekrümmte Beziehung kann bei Spearman perfekt und bei Pearson deutlich schwächer erscheinen. Im Beispiel der Vorlesung besitzt ein monotoner nichtlinearer Zusammenhang ungefähr:

$$\rho_{\text{Pearson}} = 0{,}48$$

und

$$\rho_{\text{Spearman}} = 1.$$

Spearman erkennt nicht jeden nichtlinearen Zusammenhang

Spearman erkennt monotone Beziehungen. Eine U-förmige oder periodische Beziehung ist nicht monoton: Wenn X wächst, kann Y zunächst fallen und später wieder steigen.

Daher können sowohl Pearson als auch Spearman nahe null liegen, obwohl Y stark systematisch von X abhängt.

Ausreißer können Pearson stark verzerren

Da in der Kovarianz Produkte wie

$$(x_i - \bar{x})(y_i - \bar{y})$$

auftreten, erhalten weit vom Mittelpunkt entfernte Beobachtungen besonders großes Gewicht. Ein einzelner extremer Punkt kann daher Richtung und Stärke der Pearson-Korrelation erheblich verändern.

Spearman ist häufig weniger empfindlich, weil extreme Abstände durch Rangplätze ersetzt werden. Vollständig robust ist auch Spearman nicht.

Die Korrelation ist bei fehlender Streuung nicht definiert

Gilt für alle Beobachtungen:

$$x_i = c,$$

dann ist:

$$\mathrm{Var}(X) = 0.$$

Der Nenner der Korrelation wird null:

$$\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)} = 0.$$

Eine Korrelation kann dann nicht berechnet werden.

Unterschied zwischen $\frac{1}{n}$ und $\frac{1}{n-1}$

Die Vorlesung verwendet für die deskriptive Kovarianz:

$$\mathrm{Cov}(X,Y) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}).$$

In der Inferenzstatistik wird für die Schätzung einer Populationskovarianz häufig verwendet:

$$s_{XY} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}).$$

Das sind unterschiedliche Zielsetzungen:

- $\frac{1}{n}$ beschreibt den vorliegenden Datensatz.
- $\frac{1}{n-1}$ dient typischerweise als unverzerrte Schätzung einer unbekannten Populationskovarianz.

Bei der Pearson-Korrelation kürzt sich ein einheitlich verwendeter Faktor im Zähler und Nenner heraus.

Korrelation ist keine Kausalität

Aus

$$\rho(X, Y) \neq 0$$

folgt nicht:

$$X \to Y.$$

Mögliche Erklärungen für eine Korrelation sind unter anderem:

$$X \to Y,$$

$$Y \to X,$$

$$Z \to X \quad \text{und} \quad Z \to Y,$$

oder eine Mischung dieser Mechanismen.

Die Vorlesung betont, dass kausale Aussagen typischerweise gezielte Manipulation und die Kontrolle weiterer Einflussvariablen erfordern.

Aggregierte Zusammenhänge gelten nicht automatisch individuell

Ein Zusammenhang zwischen Gruppenanteilen kann entstehen, obwohl auf Individualebene kein entsprechender Zusammenhang existiert.

Aus der Aussage „Bezirke mit einem hohen Anteil an Merkmal X besitzen einen hohen Anteil an Merkmal Y“ folgt nicht, dass Individuen mit X besonders häufig auch Y besitzen.

Ergänzender Edge Case: Simpson-Paradoxon

Ein Zusammenhang kann sich umkehren, sobald eine dritte Variable berücksichtigt wird.

Beispielsweise kann in jeder Altersgruppe eine Behandlung erfolgreicher sein, obwohl sie über alle Altersgruppen zusammen weniger erfolgreich erscheint. Ursache ist eine ungleiche Zusammensetzung der Gruppen.

Die zentrale Lektion lautet: Gemeinsame und bedingte Verteilungen müssen im Kontext möglicher Drittvariablen betrachtet werden.

5. Active Recall (Wissenstest)

1. Leite aus der Aussage, dass die bedingte Verteilung von Y gegeben $X = a_j$ für jede Zeile der Randverteilung von Y entspricht, zunächst die Formel für $\widetilde{h}_{jk}$ und anschließend die Produktregel $f_{jk} = f_{j\bullet} f_{\bullet k}$ her. Erkläre bei jedem Schritt inhaltlich, was durch die jeweilige Multiplikation oder Division geschieht.

2. Zwei Kontingenztafeln besitzen dieselben Zeilen- und Spaltenrandhäufigkeiten. In der ersten Tabelle liegen die Beobachtungen überwiegend auf einer gedachten Hauptdiagonale, in der zweiten entsprechen alle Zellen exakt den erwarteten Häufigkeiten unter Unabhängigkeit. Welche Informationen können anhand der Randverteilungen nicht unterschieden werden, und wie würden sich die beiden χ^2-Werte verhalten?

3. Konstruiere gedanklich einen starken Zusammenhang zwischen X und Y, für den sowohl die Kovarianz als auch die Pearson-Korrelation ungefähr null sind. Erkläre mithilfe der Produkte $(x_i - \bar{x})(y_i - \bar{y})$, weshalb sich die Beiträge trotz des starken Zusammenhangs gegenseitig aufheben.

4. Leite mithilfe der Cauchy-Schwarz-Ungleichung her, weshalb die Pearson-Korrelation nur Werte zwischen -1 und 1 annehmen kann. Erkläre anschließend geometrisch, welche Struktur die Punktwolke besitzen muss, damit exakt 1 oder -1 erreicht wird.

5. In mehreren Stadtbezirken korreliert der Anteil einer bestimmten Ernährungsweise stark mit einer Erkrankungsrate. Entwickle eine Argumentation, weshalb daraus weder auf das individuelle Erkrankungsrisiko der entsprechenden Personen noch unmittelbar auf einen kausalen Effekt der Ernährungsweise geschlossen werden darf. Beschreibe anschließend ein geeigneteres Untersuchungsdesign.

6. Lösungen zum Active Recall

1. Aus der Unabhängigkeit folgt:

$$\frac{h_{jk}}{h_{j\bullet}} = \frac{h_{\bullet k}}{n}.$$

Multiplikation mit $h_{j\bullet}$ ergibt:

$$\widetilde{h}_{jk} = \frac{h_{j\bullet} h_{\bullet k}}{n}.$$

Division durch n liefert:

$$f_{jk} = f_{j\bullet} f_{\bullet k}.$$

Die Zeilengröße wird mit dem allgemeinen Spaltenanteil kombiniert.

2. Die Randverteilungen enthalten keine Information darüber, wie die Ausprägungen miteinander gepaart sind. Die erste Tabelle besitzt wegen der konzentrierten Abweichungen einen positiven, möglicherweise großen χ^2-Wert. Für die zweite Tabelle gilt:

   $$h_{jk} = \widetilde{h}_{jk}$$

   in jeder Zelle und daher:

   $$\chi^2 = 0.$$

3. Ein U-förmiger Zusammenhang eignet sich. Auf einer Seite der Kurve entstehen überwiegend negative, auf der anderen überwiegend positive Produkte. Bei symmetrischer Verteilung können sich diese Beiträge aufheben, obwohl Y nahezu vollständig durch X bestimmt wird.

4. Cauchy-Schwarz liefert:

   $$\left| \sum u_i v_i \right| \le \sqrt{\sum u_i^2 \sum v_i^2}.$$

   Nach Division folgt:

   $$|\rho(X, Y)| \le 1.$$

   Exakt 1 oder -1 wird nur erreicht, wenn alle zentrierten Beobachtungen proportional sind, die Punkte also exakt auf einer steigenden oder fallenden Geraden liegen.

5. Aggregierte Bezirksdaten erlauben keinen Schluss darauf, welche Individuen gleichzeitig beide Merkmale besitzen. Zusätzlich können Störvariablen wie Alter, Einkommen oder andere Ernährungsgewohnheiten beide Bezirksanteile beeinflussen. Besser wären Individualdaten mit Kontrolle relevanter Störvariablen oder, sofern ethisch möglich, eine randomisierte Intervention mit gezielter Veränderung der

vermuteten Ursache.