1. Das Big Picture (Chunking)

Dieses Kapitel löst das Grundproblem, **zufällige Vorgänge mathematisch als Zahlenmodell darzustellen**: Eine Zufallsvariable übersetzt elementare Versuchsausgänge in Zahlen, deren Verteilung anschließend mit Wahrscheinlichkeitsfunktion, Dichte oder Verteilungsfunktion beschrieben wird. Das ist für Statistik und Data Science zentral, weil Stichproben, Schätzer und Teststatistiken später selbst als Zufallsvariablen modelliert werden; Unabhängigkeit und identische Verteilung bilden dabei die Basis vieler Inferenzverfahren.

Der Stoff lässt sich in vier gedankliche Blöcke zerlegen:

1. **Übersetzen:** Ein Zufallsexperiment mit Ergebnisraum Ω wird durch eine Funktion X in reelle Zahlen übersetzt.
2. **Verteilen:** Bei diskreten Zufallsvariablen werden Wahrscheinlichkeitsmassen addiert, bei stetigen Zufallsvariablen Dichteflächen integriert.
3. **Aufsummieren:** Die Verteilungsfunktion F vereinheitlicht beide Fälle durch $F(x) = P(X \leq x)$.
4. **Zusammenspielen:** Unabhängigkeit beschreibt, wann Wissen über eine Zufallsvariable die Verteilung einer anderen nicht verändert; die iid-Struktur verbindet dies mit wiederholten Stichproben.

Mentales Leitbild: Eine Zufallsvariable ist nicht „eine unbekannte Zahl“, sondern eine **Regel**, die jedem möglichen Weltzustand eine Zahl zuweist. Die Verteilung sagt danach, wie wahrscheinlich die verschiedenen Zahlenwerte oder Wertebereiche sind.

2. Zentrale Definitionen

Zufallsexperiment und Ergebnisraum

- **Fachliche Definition:** Ein Zufallsexperiment ist ein Vorgang mit nicht sicher vorhersagbarem Einzelergebnis. Die Menge aller möglichen elementaren Ergebnisse heißt Ergebnisraum Ω; ein einzelnes Ergebnis wird meist mit $\omega \in \Omega$ bezeichnet.
- **Feynman-Übersetzung:** Ω ist die vollständige Liste dessen, was passieren könnte. ω ist das, was in einem konkreten Durchlauf tatsächlich passiert.

Zufallsvariable

- **Fachliche Definition:** Eine Zufallsvariable X ist im Vorlesungsrahmen eine Funktion

$$X : \Omega \to \mathbb{R}, \qquad \omega \mapsto X(\omega),$$

die jedem möglichen Ergebnis $\omega \in \Omega$ eine reelle Zahl zuordnet. Vollständig maßtheoretisch verlangt man zusätzlich Messbarkeit; diese Präzisierung wird in der Vorlesung noch nicht benötigt. - **Feynman-Übersetzung:** Die reale Versuchssituation kann kompliziert sein. X ist ein Auswertungsprogramm, das aus jedem Versuchsausgang genau die Zahl herauszieht, die uns interessiert.

Träger einer Zufallsvariablen

- **Fachliche Definition:** Der Träger T enthält die Werte, die X mit positiver Wahrscheinlichkeit beziehungsweise positiver Dichte annehmen kann. Diskret gilt typischerweise

$$T = \{x_1, x_2, ...\},$$

stetig verwendet die Vorlesung

$$T = \{x \in \mathbb{R} \mid f(x) > 0\}.$$

- **Feynman-Übersetzung:** Der Träger ist der Bereich der Zahlengeraden, in dem die Zufallsvariable überhaupt „lebt“.

Diskrete Zufallsvariable

- **Fachliche Definition:** Eine Zufallsvariable X heißt diskret, wenn sie endlich oder abzählbar unendlich viele Werte $x_1, x_2, ...$ annehmen kann.
- **Feynman-Übersetzung:** Die möglichen Werte lassen sich einzeln auflisten, wenigstens theoretisch: etwa $0, 1, 2, ...$ oder die Augensummen $2, 3, ..., 12$.

Wahrscheinlichkeitsfunktion

- **Fachliche Definition:** Für eine diskrete Zufallsvariable ordnet die Wahrscheinlichkeitsfunktion jedem Trägerwert x_i die Masse

$$p_i = P(X = x_i)$$

zu, wobei $0 \leq p_i \leq 1$ und $\sum_i p_i = 1$ gelten. - **Feynman-Übersetzung:** Jeder mögliche Wert bekommt ein Stück vom gesamten Wahrscheinlichkeitskuchen. Alle Stücke zusammen ergeben genau den ganzen Kuchen.

Stetige Zufallsvariable

- **Fachliche Definition:** Eine Zufallsvariable X heißt stetig, wenn es eine nichtnegative Dichtefunktion f gibt, sodass für jedes Intervall $[a, b]$ gilt:

$$P(a \leq X \leq b) = \int_a^b f(x)\,\mathrm{d}x.$$

- **Feynman-Übersetzung:** Einzelne Punkte sind zu fein, um ihnen positive Wahrscheinlichkeit zu geben. Wahrscheinlichkeiten entstehen erst als Flächen unter einer Kurve über einem Bereich.

Dichtefunktion

- **Fachliche Definition:** Eine Funktion $f : \mathbb{R} \to [0, \infty)$ ist eine Dichte, wenn

$$\int_{-\infty}^{\infty} f(x)\,\mathrm{d}x = 1.$$

Die Wahrscheinlichkeit eines Intervalls ist die entsprechende Fläche unter f. - **Feynman-Übersetzung:** $f(x)$ zeigt, wo Wahrscheinlichkeit stark konzentriert ist. Die Höhe selbst ist noch keine Wahrscheinlichkeit; erst Breite mal Höhe, also Fläche, wird zu Wahrscheinlichkeit.

Verteilungsfunktion

- **Fachliche Definition:** Für jede Zufallsvariable X ist

$$F(x) = P(X \leq x)$$

die Verteilungsfunktion. Sie ist monoton nicht fallend, rechtsstetig und erfüllt

$$\lim_{x \to -\infty} F(x) = 0, \qquad \lim_{x \to \infty} F(x) = 1.$$

- **Feynman-Übersetzung:** $F(x)$ beantwortet immer dieselbe Frage: „Wie viel Wahrscheinlichkeit ist links von oder genau bei x bereits eingesammelt?“

Quantil

- **Fachliche Definition:** Für $0 \leq \alpha \leq 1$ heißt q_α ein α-Quantil, wenn

$$P(X \leq q_\alpha) \geq \alpha$$

und

$$P(X \geq q_\alpha) \geq 1 - \alpha.$$

Ist F streng monoton wachsend, ist das Quantil eindeutig und erfüllt

$$F(q_\alpha) = \alpha.$$

- **Feynman-Übersetzung:** Das α-Quantil ist eine Grenze, unter der mindestens der Anteil α der Verteilung liegt.

Binomialkoeffizient

- **Fachliche Definition:** Der Binomialkoeffizient

$$\binom{n}{x} = \frac{n!}{x!(n-x)!}$$

zählt, auf wie viele Arten x Objekte aus n Objekten ohne Berücksichtigung der Reihenfolge ausgewählt werden können. - **Feynman-Übersetzung:** Er zählt Gruppen, nicht Reihenfolgen. Die Auswahl „Anna, Ben, Cem“ ist dieselbe Gruppe wie „Cem, Anna, Ben“.

Hypergeometrische Verteilung

- **Fachliche Definition:** Zieht man ohne Zurücklegen n Objekte aus einer Grundgesamtheit mit N Objekten, von denen K als „Erfolge“ gelten, dann hat die Anzahl X gezogener Erfolge die Wahrscheinlichkeitsfunktion

$$P(X = x) = \frac{\binom{K}{x}\binom{N-K}{n-x}}{\binom{N}{n}}.$$

Die Vorlesung zeigt diesen Mechanismus am Lottofall mit $N = 49$, $K = 6$ und $n = 6$. - **Feynman-Übersetzung:** Zähle alle passenden Ziehungen mit genau x Treffern und teile durch die Anzahl aller möglichen Ziehungen.

Stochastische Unabhängigkeit

- **Fachliche Definition:** Zwei Zufallsvariablen X und Y heißen unabhängig, wenn für alle $x, y \in \mathbb{R}$ gilt:

$$P(X \leq x,\, Y \leq y) = P(X \leq x)P(Y \leq y).$$

Diskret ist äquivalent, für alle Trägerwerte zu fordern:

$$P(X = x,\, Y = y) = P(X = x)P(Y = y).$$

- **Feynman-Übersetzung:** Zu wissen, welchen Wert X annimmt, liefert keine Information darüber, wie Y verteilt ist.

Unabhängig und identisch verteilt

- **Fachliche Definition:** Zufallsvariablen $X_1, \ldots, X_n$ heißen unabhängig und identisch verteilt, kurz iid beziehungsweise uiv, wenn sie erstens gemeinsam stochastisch unabhängig sind und zweitens dieselbe Verteilung besitzen.
- **Feynman-Übersetzung:** Jeder Versuch folgt denselben Regeln, und die Versuche beeinflussen sich nicht gegenseitig.

3. Formeln, Beweise & Intuition

A. Zufallsvariable als Übersetzungsfunktion

- **Die Formel:**

$$X : \Omega \to \mathbb{R}, \qquad \omega \mapsto X(\omega).$$

- **Dekonstruktion:** Ω ist der Ergebnisraum, ω ein elementares Ergebnis, $\mathbb{R}$ die Menge reeller Zahlen und $X(\omega)$ die numerische Auswertung dieses Ergebnisses.
- **Der Beweis / Die Herleitung:** Hier gibt es keinen Beweis, sondern eine Modellierungsentscheidung. Beim zweifachen Würfelwurf ist

$$\Omega = \{(i, j) \mid i, j \in \{1, 2, 3, 4, 5, 6\}\}.$$

Darauf können unterschiedliche Zufallsvariablen definiert werden:

$$X(i, j) = i + j,$$

$$Y(i, j) = i - j,$$

und

$$Z(i, j) = \begin{cases} 1, & i + j \text{ ist gerade,} \\ 0, & i + j \text{ ist ungerade.} \end{cases}$$

Dasselbe Ergebnis $(2, 5)$ erzeugt damit die Werte $X(2, 5) = 7$, $Y(2, 5) = -3$ und $Z(2, 5) = 0$. Die Zufälligkeit liegt im unbekannten ω; die Regel X selbst ist fest. - **Die Analogie & Mechanik:** Ein Foto enthält sehr viele Informationen. Eine Bilderkennungsfunktion kann daraus „Anzahl Personen“, „Helligkeit“ oder „enthält ein Auto“ berechnen. Ebenso kann ein Zufallsausgang durch verschiedene Zufallsvariablen auf jeweils eine interessierende Zahl verdichtet werden.

B. Wahrscheinlichkeitsfunktion einer diskreten Zufallsvariablen

- **Die Formel:**

$$p_i = P(X = x_i), \qquad 0 \le p_i \le 1, \qquad \sum_{i \ge 1} p_i = 1.$$

- **Dekonstruktion:** x_i ist der i-te mögliche Wert von X, p_i seine Wahrscheinlichkeit und i ein Index über alle Trägerwerte.
- **Der Beweis / Die Herleitung:** Die Ereignisse $\{X = x_i\}$ sind paarweise disjunkt, weil X in einem Durchlauf nicht gleichzeitig zwei verschiedene Werte annehmen kann. Ihre Vereinigung umfasst den gesamten Ergebnisraum, sofern alle Trägerwerte berücksichtigt werden. Nach der Additivität von Wahrscheinlichkeiten folgt daher

$$P\left(\bigcup_{i \ge 1} \{X = x_i\}\right) = \sum_{i \ge 1} P(X = x_i).$$

Da die Vereinigung gleich Ω ist und $P(\Omega) = 1$ gilt, erhält man

$$\sum_{i\geq 1} p_i = 1.$$

- **Die Analogie & Mechanik:** Stelle dir Wahrscheinlichkeitsmasse als genau 1 Kilogramm Sand vor, das auf den möglichen Werten verteilt wird. Ein großes p_i bedeutet einen hohen Sandhaufen bei x_i. Wird ein Haufen größer, muss bei fester Gesamtsumme anderswo Masse fehlen.

C. Wahrscheinlichkeit eines diskreten Ereignisses

- **Die Formel:**

$$P(X \in A) = \sum_{i:x_i \in A} p_i.$$

Für ein Intervall gilt insbesondere

$$P(a \leq X \leq b) = \sum_{i:a\leq x_i \leq b} p_i.$$

- **Dekonstruktion:** $A \subseteq T$ ist eine Menge interessierender Werte, a und b sind Intervallgrenzen, und summiert werden nur die Massen der Trägerwerte innerhalb des Ereignisses.
- **Der Beweis / Die Herleitung:** Das Ereignis $\{X \in A\}$ lässt sich in disjunkte Einzelereignisse zerlegen:

$$\{X \in A\} = \bigcup_{i:x_i \in A} \{X = x_i\}.$$

Wegen Disjunktheit darf man die Einzelwahrscheinlichkeiten addieren:

$$P(X \in A) = \sum_{i:x_i \in A} P(X = x_i) = \sum_{i:x_i \in A} p_i.$$

- **Die Analogie & Mechanik:** Möchtest du wissen, wie viel Geld in mehreren markierten Fächern liegt, addierst du die Beträge genau dieser Fächer. Je mehr Trägerwerte A enthält oder je größer deren Massen sind, desto größer wird $P(X \in A)$.

D. Augensumme zweier fairer Würfel

- **Die Formel:** Für $S = X_1 + X_2$ mit zwei unabhängigen fairen Würfeln gilt

$$P(S = s) = \begin{cases} \dfrac{s-1}{36}, & 2 \leq s \leq 7, \\ \dfrac{13-s}{36}, & 8 \leq s \leq 12, \\ 0, & \text{sonst.} \end{cases}$$

- **Dekonstruktion:** X_1 und X_2 sind die beiden Augenzahlen, S ist ihre Summe, s ein möglicher Summenwert und $36 = 6 \cdot 6$ die Anzahl gleich wahrscheinlicher geordneter Würfelpaare.
- **Der Beweis / Die Herleitung:** Für $2 \leq s \leq 7$ sind die günstigen Paare

$$(1, s-1), (2, s-2), \ldots, (s-1, 1),$$

also genau $s - 1$ Paare. Für $8 \leq s \leq 12$ wird die Zahl der zulässigen Paare durch die Obergrenze 6 beschränkt; es bleiben genau $13 - s$ Paare. Da alle 36 geordneten Ergebnisse gleich wahrscheinlich sind, ist Wahrscheinlichkeit gleich günstige Fälle geteilt durch mögliche Fälle.

Für $s = 7$ erhält man beispielsweise

$$P(S = 7) = \frac{6}{36} = \frac{1}{6},$$

während

$$P(S = 2) = \frac{1}{36}.$$

- **Die Analogie & Mechanik:** Die Summe 7 hat viele „Zufahrtsstraßen“ wie $(1, 6)$, $(2, 5)$ und $(3, 4)$; die Summe 2 hat nur eine. Die Wahrscheinlichkeit hängt nicht davon ab, wie „mittig“ eine Zahl klingt, sondern davon, wie viele elementare Ergebnisse auf sie abgebildet werden.

E. Verteilungsfunktion im diskreten Fall

- **Die Formel:**

$$F(x) = P(X \leq x) = \sum_{i:x_i \leq x} p_i.$$

- **Dekonstruktion:** $F(x)$ ist die bis zur Schwelle x angesammelte Wahrscheinlichkeit. Die Summe enthält alle Massen bei Trägerwerten links von oder gleich x.
- **Der Beweis / Die Herleitung:** Setze in die allgemeine Ereignisformel die Menge

$$A = (-\infty, x] \cap T$$

ein. Dann folgt direkt

$$P(X \leq x) = \sum_{i:x_i \leq x} p_i.$$

Zwischen zwei benachbarten Trägerwerten kommt keine neue Masse hinzu, also bleibt F dort konstant. An einem Trägerwert x_i springt F um genau

$$P(X = x_i) = F(x_i) - F(x_i^-),$$

wobei

$$F(x_i^-) = \lim_{t \uparrow x_i} F(t).$$

- **Die Analogie & Mechanik:** F ist ein Kilometerzähler für Wahrscheinlichkeit. Bei diskreten Werten fährt der Zähler nicht gleichmäßig, sondern springt an jeder Stelle mit Masse nach oben. Ein großer Sprung bedeutet eine große Einzelwahrscheinlichkeit.

F. Binomialkoeffizient

- **Die Formel:**

$$\binom{n}{x} = \frac{n!}{(n-x)!x!} = \frac{n(n-1)\cdots(n-x+1)}{x(x-1)\cdots 1}.$$

- **Dekonstruktion:** n ist die Anzahl verfügbarer Objekte, x die Größe der Auswahl und $n!$ das Produkt $n(n-1)\cdots 1$.
- **Der Beweis / Die Herleitung:** Zunächst zählt

$$n(n-1)\cdots(n-x+1) = \frac{n!}{(n-x)!}$$

alle geordneten Auswahlen von x verschiedenen Objekten. Jede ungeordnete Gruppe wird dabei genau $x!$-mal gezählt, weil ihre x Mitglieder in $x!$ Reihenfolgen angeordnet werden können. Daher muss durch $x!$ geteilt werden:

$$\binom{n}{x} = \frac{n!/(n-x)!}{x!} = \frac{n!}{(n-x)!x!}.$$

- **Die Analogie & Mechanik:** Du stellst zunächst alle möglichen Sitzordnungen einer Gruppe auf und bemerkst dann, dass dieselbe Gruppe nur wegen verschiedener Reihenfolgen mehrfach erscheint. Der Nenner $x!$ entfernt diese künstlichen Mehrfachzählungen. Je größer $x!$ wird, desto stärker wird die geordnete Zahl herunterkorrigiert.

G. Lotto und hypergeometrische Wahrscheinlichkeit

- **Die Formel:** Allgemein gilt

$$P(X = x) = \frac{\binom{K}{x}\binom{N-K}{n-x}}{\binom{N}{n}}.$$

Im Lottofall der Vorlesung mit $N = 49$, $K = 6$ und $n = 6$ wird daraus

$$P(X = x) = \frac{\binom{6}{x}\binom{43}{6-x}}{\binom{49}{6}}.$$

Für genau drei Richtige gilt

$$P(X = 3) = \frac{\binom{6}{3}\binom{43}{3}}{\binom{49}{6}} \approx 0.0176504.$$

- **Dekonstruktion:** N ist die Gesamtzahl der Objekte, K die Zahl der Erfolgsobjekte, n die Ziehungsgröße und x die Zahl gezogener Erfolge. Der Faktor $\binom{K}{x}$ zählt die Auswahl der Erfolge, $\binom{N-K}{n-x}$ die Auswahl der Misserfolge und $\binom{N}{n}$ alle möglichen Stichproben.
- **Der Beweis / Die Herleitung:** Jede ungeordnete Stichprobe der Größe n ist bei fairer Ziehung ohne Zurücklegen gleich wahrscheinlich. Der Nenner zählt alle Stichproben. Für genau x Erfolge müssen unabhängig voneinander zwei Teilentscheidungen getroffen werden:

Wähle x aus K Erfolgen

und

wähle $n-x$ aus $N-K$ Misserfolgen.

Nach dem Produktprinzip beträgt die Anzahl günstiger Stichproben

$$\binom{K}{x}\binom{N-K}{n-x}.$$

Durch Division durch alle Stichproben folgt die Formel. - **Die Analogie & Mechanik:** Der Zähler zählt die „passenden Tickets“, der Nenner alle möglichen Tickets. Wird der Nenner durch eine sehr große Grundgesamtheit

riesig, während die Zahl passender Kombinationen kaum wächst, wird die Wahrscheinlichkeit klein. Wird x so extrem, dass kaum passende Kombinationen existieren, schrumpft der Zähler. Unmögliche Werte werden automatisch durch einen verschwindenden Binomialkoeffizienten ausgeschlossen.

H. Dichte und Intervallwahrscheinlichkeit

- **Die Formel:**

$$P(a \le X \le b) = \int_a^b f(x)\,\mathrm{d}x, \qquad f(x) \ge 0.$$

- **Dekonstruktion:** a und b sind Intervallgrenzen, $f(x)$ ist die Dichtehöhe an der Stelle x, und das Integral summiert unendlich viele infinitesimale Flächenstücke $f(x)\,\mathrm{d}x$.
- **Der Beweis / Die Herleitung:** Für kleine Intervallbreite Δx kann man die Wahrscheinlichkeit näherungsweise als Rechteckfläche schreiben:

$$P(x \le X \le x + \Delta x) \approx f(x)\Delta x.$$

Zerlegt man $[a, b]$ in viele kleine Teilintervalle und addiert die Rechteckflächen, entsteht eine Riemannsumme:

$$\sum_j f(\xi_j)\Delta x_j.$$

Im Grenzübergang, wenn die maximale Teilintervallbreite gegen 0 geht, wird daraus

$$\int_a^b f(x)\,\mathrm{d}x.$$

- **Die Analogie & Mechanik:** Eine Dichte ist wie Bevölkerungsdichte. „5000 Personen pro Quadratkilometer“ ist keine Personenzahl. Erst multipliziert mit einer Fläche entsteht eine Anzahl. Ebenso kann $f(x)$ größer als 1 sein, solange die Gesamtfläche 1 bleibt. Beispiel:

$$f(x) = \begin{cases} 2, & 0 \le x \le \frac{1}{2}, \\ 0, & \text{sonst} \end{cases}$$

ist eine gültige Dichte, weil

$$\int_0^{1/2} 2\,\mathrm{d}x = 1.$$

Ein extrem hoher Dichtewert bedeutet starke Konzentration in einem schmalen Bereich, nicht eine Wahrscheinlichkeit größer als 1.

I. Warum einzelne Punkte bei stetigen Zufallsvariablen Wahrscheinlichkeit null haben

- **Die Formel:** Für jedes $x \in \mathbb{R}$ gilt

$$P(X = x) = 0.$$

Daher sind die Randvarianten eines Intervalls gleich wahrscheinlich:

$$P(a \le X \le b) = P(a < X \le b) = P(a \le X < b) = P(a < X < b).$$

- **Dekonstruktion:** $P(X = x)$ ist die Wahrscheinlichkeit eines einzelnen Punktes. Die verschiedenen Intervallnotationen unterscheiden sich nur durch die Randpunkte a und b.
- **Der Beweis / Die Herleitung:** Ein einzelner Punkt kann als Intervall ohne Breite betrachtet werden:

$$P(X = x) = \int_x^x f(t)\,\mathrm{d}t = 0.$$

Alternativ folgt für einen Randpunkt

$$P(a \le X \le b) = P(a < X \le b) + P(X = a).$$

Da $P(X = a) = 0$ gilt, sind beide Intervallwahrscheinlichkeiten gleich. - **Die Analogie & Mechanik:** Ein einzelner senkrechter Strich hat keine Fläche. Eine konkrete Messzahl kann trotzdem auftreten; „Wahrscheinlichkeit null" bedeutet hier nicht logische Unmöglichkeit, sondern dass ein Punkt im kontinuierlichen Modell keine positive Fläche besitzt.

J. Normierung einer Dichte

- **Die Formel:**

$$\int_{-\infty}^{\infty} f(x)\,\mathrm{d}x = 1.$$

- **Dekonstruktion:** Das Integral über die gesamte reelle Achse erfasst alle möglichen Werte von X und muss deshalb die Gesamtwahrscheinlichkeit 1 ergeben.
- **Der Beweis / Die Herleitung:** Setzt man $a = -\infty$ und $b = \infty$ in die Intervallformel ein, erhält man

$$P(-\infty < X < \infty) = \int_{-\infty}^{\infty} f(x)\,\mathrm{d}x.$$

Da eine reellwertige Zufallsvariable sicher irgendeinen reellen Wert annimmt, ist die linke Seite gleich 1. - **Die Analogie & Mechanik:** Die gesamte Fläche unter der Dichte ist der komplette Wahrscheinlichkeitskuchen. Wird die Kurve an einer Stelle höher, muss sie bei unveränderter Normierung typischerweise schmaler sein oder anderswo niedriger werden.

K. Exponentialmodell für Anrufdauern

- **Die Formel:** Die Vorlesung verwendet

$$f(x) = \begin{cases} 0.006e^{-0.006x}, & x \ge 0, \\ 0, & x < 0. \end{cases}$$

Allgemein lautet die Exponentialdichte mit Rate $\lambda > 0$:

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \ge 0, \\ 0, & x < 0. \end{cases}$$

- **Dekonstruktion:** x ist die Dauer, e die Eulersche Zahl und λ die Rate. Im Vorlesungsbeispiel ist $\lambda = 0.006$ pro Sekunde.
- **Der Beweis / Die Herleitung der Normierung:** Wegen $f(x) = 0$ für $x < 0$ gilt

$$\int_{-\infty}^{\infty} f(x)\,\mathrm{d}x = \int_0^{\infty} \lambda e^{-\lambda x}\,\mathrm{d}x.$$

Eine Stammfunktion ist

$$-e^{-\lambda x},$$

weil

$$\frac{\mathrm{d}}{\mathrm{d}x}\left(-e^{-\lambda x}\right) = \lambda e^{-\lambda x}.$$

Damit

$$\int_0^\infty \lambda e^{-\lambda x}\,\mathrm{d}x = \left[-e^{-\lambda x}\right]_0^\infty = 0 - (-1) = 1.$$

- **Die Analogie & Mechanik:** Die Dichte startet hoch und fällt exponentiell. Eine größere Rate λ macht kurze Dauern stärker konzentriert: Die Kurve startet höher, fällt aber schneller. Eine kleinere Rate verteilt Masse weiter nach rechts. Die Rate wirkt damit gleichzeitig im Vorfaktor und im Exponenten; nur einen der beiden Effekte zu betrachten wäre irreführend.

L. Verteilungsfunktion des Exponentialmodells

- **Die Formel:** Für $x \geq 0$ gilt

$$F(x) = P(X \leq x) = \int_0^x \lambda e^{-\lambda t}\,\mathrm{d}t = 1 - e^{-\lambda x}.$$

Insgesamt:

$$F(x) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

Für die Vorlesungsrate $\lambda = 0.006$ folgt

$$F(500) = 1 - e^{-0.006 \cdot 500} = 1 - e^{-3} \approx 0.9502.$$

- **Dekonstruktion:** t ist eine Integrationsvariable, x die betrachtete Zeitschwelle und $F(x)$ die Wahrscheinlichkeit, dass die Dauer höchstens x beträgt.
- **Der Beweis / Die Herleitung:** Für $x \geq 0$ wird die Dichte von der unteren Trägergrenze 0 bis x integriert:

$$F(x) = \int_0^x \lambda e^{-\lambda t}\,\mathrm{d}t = \left[-e^{-\lambda t}\right]_0^x = -e^{-\lambda x} + 1.$$

Für $x < 0$ ist $F(x) = 0$, weil negative Anrufdauern im Modell unmöglich sind. - **Die Analogie & Mechanik:** Während die Dichte zeigt, wo neue Wahrscheinlichkeit pro zusätzlicher Zeiteinheit hinzukommt, zeigt F die bereits angesammelte Gesamtwahrscheinlichkeit. Anfangs steigt F schnell, später immer langsamer, weil die Dichte immer kleiner wird.

M. Wahrscheinlichkeiten aus der Verteilungsfunktion

- **Die Formel:**

$$P(a < X \leq b) = F(b) - F(a).$$

Bei stetigen Zufallsvariablen gilt wegen der punktweisen Wahrscheinlichkeit null auch

$$P(a \le X \le b) = F(b) - F(a).$$

- **Dekonstruktion:** $F(b)$ enthält die gesamte Wahrscheinlichkeit bis b, $F(a)$ die gesamte Wahrscheinlichkeit bis a. Die Differenz isoliert die Masse zwischen beiden Grenzen.
- **Der Beweis / Die Herleitung:** Die Ereignisse $\{X \le a\}$ und $\{a < X \le b\}$ sind disjunkt und ergeben zusammen $\{X \le b\}$. Deshalb

$$P(X \le b) = P(X \le a) + P(a < X \le b).$$

Umstellen liefert

$$P(a < X \le b) = F(b) - F(a).$$

- **Die Analogie & Mechanik:** Der Kilometerstand bei b minus der Kilometerstand bei a ergibt die Strecke zwischen a und b. Liegen $F(a)$ und $F(b)$ fast gleich, befindet sich wenig Wahrscheinlichkeit im Intervall, selbst wenn das Intervall numerisch breit ist.

N. Zusammenhang zwischen Dichte und Verteilungsfunktion

- **Die Formel:** Wenn F differenzierbar ist, gilt

$$F'(x) = f(x).$$

Umgekehrt gilt

$$F(x) = \int_{-\infty}^{x} f(t)\,\mathrm{d}t.$$

- **Dekonstruktion:** $F'(x)$ ist die lokale Steigung der Verteilungsfunktion, $f(x)$ die lokale Dichtehöhe.
- **Der Beweis / Die Herleitung:** Aus

$$F(x) = \int_{-\infty}^{x} f(t)\,\mathrm{d}t$$

folgt nach dem Hauptsatz der Differential- und Integralrechnung an geeigneten Stellen

$$\frac{\mathrm{d}}{\mathrm{d}x} F(x) = f(x).$$

Diese Beziehung ist eine Expertenbrücke, die die beiden Darstellungen aus der Vorlesung direkt verbindet. - **Die Analogie & Mechanik:** F ist der Wasserstand in einem Tank, f der momentane Zufluss. Große Dichte bedeutet steilen Anstieg von F; Dichte nahe null bedeutet eine fast waagerechte Verteilungsfunktion.

O. Quantile allgemein

- **Die Formel:**

$$P(X \le q_\alpha) \ge \alpha, \qquad P(X \ge q_\alpha) \ge 1 - \alpha.$$

Bei streng monoton wachsender Verteilungsfunktion gilt eindeutig

$$F(q_\alpha) = \alpha$$

und damit formal

$$q_\alpha = F^{-1}(\alpha).$$

- **Dekonstruktion:** α ist ein Anteil zwischen 0 und 1, q_α die zugehörige Schwelle und F^{-1} die inverse Verteilungsfunktion, sofern diese gewöhnlich invertierbar ist.
- **Der Beweis / Die Herleitung:** Ein Quantil muss so liegen, dass links mindestens α und rechts mindestens $1-\alpha$ Wahrscheinlichkeit verbleiben. Bei einer streng steigenden, stetigen Verteilungsfunktion wird jeder Wahrscheinlichkeitsstand α genau einmal erreicht, weshalb die Gleichung $F(q_\alpha) = \alpha$ eine eindeutige Lösung besitzt.

Allgemeiner und auch bei Sprüngen kann man das verallgemeinerte Inverse verwenden:

$$q_\alpha = \inf\{x \in \mathbb{R} \mid F(x) \geq \alpha\}.$$

- **Die Analogie & Mechanik:** Stelle dir vor, du schneidest eine Menschenmenge auf der Zahlengeraden so ab, dass links mindestens der Anteil α steht. Bei einer glatten, überall steigenden Verteilung gibt es genau eine passende Schnittstelle; bei Lücken oder Sprüngen können mehrere Grenzen dieselbe Bedingung erfüllen.

P. Quantil des Exponentialmodells

- **Die Formel:** Aus

$$F(q_\alpha) = 1 - e^{-\lambda q_\alpha} = \alpha$$

folgt

$$q_\alpha = -\frac{\ln(1-\alpha)}{\lambda}.$$

Für $\alpha = 0.95$ und $\lambda = 0.006$ ergibt sich

$$q_{0.95} = -\frac{\ln(0.05)}{0.006} \approx 499.29 \text{ Sekunden}.$$

- **Dekonstruktion:** ln ist der natürliche Logarithmus, $1-\alpha$ die verbleibende obere Schwanzwahrscheinlichkeit und λ die Rate.
- **Der Beweis / Die Herleitung:** Beginne mit

$$1 - e^{-\lambda q_\alpha} = \alpha.$$

Dann

$$e^{-\lambda q_\alpha} = 1 - \alpha.$$

Logarithmieren liefert

$$-\lambda q_\alpha = \ln(1-\alpha),$$

und Division durch $-\lambda$ ergibt die Quantilformel. - **Die Analogie & Mechanik:** Je näher α an 1 liegt, desto kleiner wird $1-\alpha$ und desto größer wird $-\ln(1-\alpha)$; hohe Quantile wandern daher weit nach rechts. Wird λ groß, schrumpft das Quantil proportional zu $1/\lambda$, weil die Verteilung stärker auf kurze Dauern konzentriert ist.

Q. Unabhängigkeit über die gemeinsame Verteilungsfunktion

- **Die Formel:** Zwei Zufallsvariablen X und Y sind unabhängig, wenn für alle $x, y \in \mathbb{R}$ gilt:

$$P(X \leq x,\, Y \leq y) = P(X \leq x)P(Y \leq y).$$

Für n Zufallsvariablen lautet die Bedingung

$$P(X_1 \leq x_1, \dots, X_n \leq x_n) = \prod_{j=1}^{n} P(X_j \leq x_j).$$

- **Dekonstruktion:** Die linke Seite ist eine gemeinsame Wahrscheinlichkeit. Rechts stehen die Randwahrscheinlichkeiten. $x_1, \dots, x_n$ sind beliebige Schwellen.
- **Der Beweis / Die Herleitung:** Unabhängigkeit von Zufallsvariablen bedeutet formal, dass alle durch sie erzeugten Ereignisse faktorisieren. Die Vorlesung nutzt dafür Halbgeradenereignisse $\{X \leq x\}$ und $\{Y \leq y\}$; diese reichen aus, um die Verteilungen zu charakterisieren. Die Bedingung muss für alle Schwellen gelten, nicht nur für ein ausgewähltes Wertepaar.
- **Die Analogie & Mechanik:** Die gemeinsame Chance, dass zwei voneinander unbeeinflusste Schranken gleichzeitig eingehalten werden, ist das Produkt der Einzelchancen. Sind beide Einzelwahrscheinlichkeiten klein, wird das Produkt noch kleiner. Ist eine Einzelwahrscheinlichkeit 0, ist auch die gemeinsame Wahrscheinlichkeit 0.

R. Faktorisierung im diskreten und stetigen Fall

- **Die Formel:** Diskret gilt bei Unabhängigkeit

$$P(X = x,\, Y = y) = P(X = x)P(Y = y).$$

Stetig gilt bei vorhandener gemeinsamer Dichte

$$f_{X,Y}(x, y) = f_X(x) f_Y(y).$$

Für mehrere Zufallsvariablen lautet die Dichtefaktorisierung

$$f_{X_1,\dots,X_n}(x_1, \dots, x_n) = \prod_{j=1}^{n} f_{X_j}(x_j).$$

- **Dekonstruktion:** $f_{X,Y}$ ist die gemeinsame Dichte, f_X und f_Y sind Randdichten. Im diskreten Fall stehen anstelle von Dichten Einzelwahrscheinlichkeiten.
- **Der Beweis / Die Herleitung:** Bei diskreten Variablen zerlegt man Ereignisse in einzelne Punktmassen. Wenn jede gemeinsame Punktmasse in das Produkt der Randmassen zerfällt, addieren sich diese Faktorisierungen zu den entsprechenden Ereigniswahrscheinlichkeiten. Im stetigen Fall ergibt die Produktdichte für Rechtecke $A \times B$:

$$P(X \in A, Y \in B) = \int_A \int_B f_X(x) f_Y(y)\, \mathrm{d}y\, \mathrm{d}x.$$

Wegen der Produktstruktur trennt sich das Integral:

$$P(X \in A, Y \in B) = \left(\int_A f_X(x)\, \mathrm{d}x \right) \left(\int_B f_Y(y)\, \mathrm{d}y \right).$$

Damit folgt

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B).$$

- **Die Analogie & Mechanik:** Eine gemeinsame Tabelle oder Fläche lässt sich bei Unabhängigkeit als äußeres Produkt zweier Einzelprofile aufbauen. Jede Zelle beziehungsweise jeder Flächenpunkt entsteht durch Multiplikation der beiden Randbeiträge.

S. iid-Struktur

- **Die Formel:**

$$X_1, \dots, X_n \text{ sind iid}$$

bedeutet gleichzeitig

$$P(X_1 \leq x_1, \dots, X_n \leq x_n) = \prod_{j=1}^{n} P(X_j \leq x_j)$$

und

$$F_{X_1} = F_{X_2} = \cdots = F_{X_n}.$$

- **Dekonstruktion:** Der erste Teil ist gemeinsame Unabhängigkeit, der zweite identische Verteilung. F_{X_j} bezeichnet die Verteilungsfunktion der j-ten Zufallsvariablen.
- **Der Beweis / Die Herleitung:** iid ist keine neue einzelne Gleichung, sondern die Kombination zweier Modellannahmen. Bei unabhängiger Wiederholung desselben Zufallsexperiments bleibt die Verteilungsregel in jedem Durchlauf gleich, während die Ausgänge verschiedener Durchläufe einander nicht beeinflussen. Ziehen mit Zurücklegen kann diese Struktur erzeugen; Ziehen ohne Zurücklegen im Allgemeinen nicht.
- **Die Analogie & Mechanik:** Mehrere identische Würfel werden getrennt geworfen. „Identisch verteilt“ bedeutet, dass jeder Würfel dieselben Chancen hat. „Unabhängig“ bedeutet, dass ein Würfelergebnis den anderen Wurf nicht verändert. iid bedeutet ausdrücklich nicht, dass alle Würfel dieselbe Augenzahl zeigen.

4. Häufige Missverständnisse & Edge Cases

Zufallsvariable mit Zufallsausgang verwechseln. X ist die feste Abbildungsregel; zufällig ist der realisierte Wert $X(\omega)$, weil ω unbekannt ist. Zwei verschiedene Zufallsvariablen können auf demselben Ergebnisraum definiert sein und aus demselben Ausgang unterschiedliche Informationen extrahieren.

„Zufallsvariable“ bedeutet nicht, dass die Ausprägungen beliebige Objekte sein dürfen. In der Vorlesungsdefinition müssen die Werte reell sein. Kategorien wie „rot“ und „blau“ müssen erst numerisch codiert werden, etwa durch 0 und 1.

Dichtehöhe mit Wahrscheinlichkeit verwechseln. Für stetige X ist $f(x)$ keine Punktwahrscheinlichkeit. Deshalb darf $f(x) > 1$ gelten. Nur Integrale wie $\int_a^b f(x)\,\mathrm{d}x$ müssen zwischen 0 und 1 liegen.

Aus $P(X = x) = 0$ auf Unmöglichkeit schließen. Bei stetigen Modellen hat jeder Einzelpunkt Wahrscheinlichkeit 0, obwohl bei einer Messung selbstverständlich irgendein konkreter Wert realisiert wird. Unmöglichkeit entspricht einem Ereignis außerhalb des Trägers, nicht bloß einer Punktwahrscheinlichkeit von 0.

Diskrete und stetige Regeln vermischen. Diskret werden Massen summiert; stetig werden Dichten integriert. Der Ausdruck

$$\sum_x f(x)$$

ist für eine gewöhnliche stetige Dichte keine Normierung, und

$$\int p_i \, \mathrm{d}i$$

ist keine diskrete Wahrscheinlichkeitsberechnung.

Bei der Verteilungsfunktion die Richtung verwechseln. $F(x)$ bedeutet immer $P(X \leq x)$, also Wahrscheinlichkeit links von x. Die obere Schwanzwahrscheinlichkeit ist

$$P(X > x) = 1 - F(x).$$

Für diskrete Variablen ist dagegen

$$P(X \geq x) = 1 - F(x^-)$$

zu beachten, weil bei x eine positive Masse liegen kann.

Bei Intervallen im diskreten Fall Randpunkte ignorieren. Anders als im stetigen Fall kann

$$P(a \leq X \leq b)$$

von

$$P(a < X < b)$$

abweichen, weil $P(X = a)$ und $P(X = b)$ positiv sein können.

„Stetig" garantiert nicht automatisch ein eindeutiges Quantil. Die Folien formulieren zunächst eine Eindeutigkeit für stetige Zufallsvariablen und präzisieren anschließend, dass strenge Monotonie von F entscheidend ist. Eine stetige Verteilung kann ein Intervall mit Dichte 0 besitzen; dann ist F dort konstant und eine Quantilgleichung kann nicht eindeutig invertierbar sein. Die robuste Definition verwendet

$$q_\alpha = \inf\{x \mid F(x) \geq \alpha\}.$$

Inverse Funktion und Kehrwert verwechseln. $F^{-1}(\alpha)$ ist die Umkehrfunktion beziehungsweise das verallgemeinerte Inverse, nicht der Kehrwert

$$\frac{1}{F(\alpha)}.$$

Lottoformel mit Binomialverteilung verwechseln. Beim Lotto wird ohne Zurücklegen gezogen; deshalb ändern sich die Chancen von Zug zu Zug, und das Modell ist hypergeometrisch. Eine Binomialverteilung passt zu unabhängigen Versuchen mit konstanter Erfolgswahrscheinlichkeit, etwa näherungsweise bei Ziehen mit Zurücklegen.

Die Symbolwahl im Lottofall übersehen. Die Folien verwenden $n = 6$ sowohl für die Zahl der Gewinnzahlen als auch für die Zahl der gezogenen Zahlen. In einer allgemeinen Herleitung ist es klarer, K für die Zahl der Erfolgsobjekte und n für die Stichprobengröße zu verwenden.

Unabhängigkeit mit „kein Zusammenhang im beobachteten Datensatz" verwechseln. Unabhängigkeit ist eine Aussage über die vollständige gemeinsame Verteilung. Ein Streudiagramm ohne sichtbares Muster beweist sie nicht. Umgekehrt können unabhängige Variablen in einer kleinen Stichprobe zufällig einen scheinbaren Zusammenhang zeigen.

Unkorreliertheit mit Unabhängigkeit verwechseln. Aus Unabhängigkeit folgt unter geeigneten Momentbedingungen Unkorreliertheit, aber die Umkehrung gilt im Allgemeinen nicht. Nichtlinearer Zusammenhang kann bestehen, obwohl die lineare Korrelation 0 ist.

Paarweise Unabhängigkeit mit gemeinsamer Unabhängigkeit verwechseln. Bei mehr als zwei Zufallsvariablen reicht es nicht immer, nur jedes Paar zu prüfen. Die iid-Annahme verlangt gemeinsame Unabhängigkeit der gesamten Familie.

„Identisch verteilt“ mit „identische Werte“ verwechseln. iid bedeutet gleiche Verteilungsregel, nicht gleiche Realisationen. Bei fairen Würfen können $X_1 = 2$ und $X_2 = 6$ auftreten, obwohl X_1 und X_2 identisch verteilt sind.

Ziehen ohne Zurücklegen fälschlich als iid behandeln. Die einzelnen Ziehungen können zwar symmetrisch dieselbe Randverteilung haben, sind aber abhängig: Nach einer gezogenen Zahl kann dieselbe Zahl nicht erneut erscheinen. Mit Zurücklegen kann Unabhängigkeit plausibel sein.

Modellgrenzen des Exponentialmodells übersehen. Die Exponentialverteilung setzt eine konstante Rate und Gedächtnislosigkeit voraus. Reale Anrufdauern können Mindestzeiten, mehrere Anruftypen oder Tageszeiteffekte besitzen. Dann kann die exponentielle Form trotz korrekter Normierung sachlich unangemessen sein.

Einheitenfehler im Vorlesungsbeispiel. Die Anrufdauer wird zu Beginn in Sekunden definiert. Das berechnete 95%-Quantil von ungefähr 500 ist daher in Sekunden zu interpretieren. Die spätere Formulierung „500 Minuten“ ist im Material offensichtlich ein Einheitenfehler.

Rundung mit exakter Gleichheit verwechseln. Für das Anrufbeispiel gilt

$$F(500) = 1 - e^{-3} \approx 0.9502,$$

also nicht exakt 0.95. Das exakte 95%-Quantil beträgt

$$q_{0.95} \approx 499.29 \text{ Sekunden}.$$

Die Angabe 500 ist eine sinnvolle Rundung.

5. Active Recall (Wissenstest)

1. Beim zweifachen Würfelwurf seien X die Augensumme und Y die Differenz. Erkläre präzise, warum X und Y nicht die Zufallsexperimente selbst sind, und zeige an zwei verschiedenen Ergebnissen, wie dieselbe Abbildungsregel unterschiedliche Realisationen erzeugt. Welche Information geht bei der Abbildung von ω auf $X(\omega)$ verloren?
2. Leite die Wahrscheinlichkeitsfunktion der Summe zweier fairer Würfel her, ohne eine fertige Tabelle zu verwenden. Begründe insbesondere, warum die Wahrscheinlichkeit bis zur Summe 7 steigt und danach symmetrisch fällt. Formuliere anschließend die zugehörige Verteilungsfunktion als kumulierte Summe.
3. Erkläre die hypergeometrische Lottoformel ausschließlich durch ein Zählargument. Warum werden die beiden Binomialkoeffizienten im Zähler multipliziert, und warum darf die Formel nicht ohne Weiteres durch eine Binomialverteilung ersetzt werden?
4. Für eine exponentiell verteilte Anrufdauer mit Rate λ leite aus der Dichte erst die Verteilungsfunktion und danach das α-Quantil her. Erkläre qualitativ, wie sich eine Verdopplung von λ auf die Dichte, die Verteilungsfunktion und alle Quantile auswirkt.
5. Konstruiere eine Situation mit drei Zufallsvariablen, in der jedes Paar unabhängig ist, aber die drei Variablen nicht gemeinsam unabhängig sind. Erkläre anschließend, warum paarweise Unabhängigkeit für eine iid-Annahme nicht genügt und welche zusätzliche Bedingung „identisch verteilt“ tatsächlich fordert.

6. Lösungen zum Active Recall

1. X und Y sind feste Funktionen auf demselben Ergebnisraum; zufällig ist nur das eintretende ω. Beispielsweise liefert $\omega_1 = (1,6)$ die Werte $X(\omega_1) = 7$ und $Y(\omega_1) = -5$, während $\omega_2 = (3,4)$ die Werte $X(\omega_2) = 7$ und $Y(\omega_2) = -1$ liefert. Bei X geht die Information über die Reihenfolge und die einzelnen Würfelwerte verloren, weil mehrere Ergebnisse dieselbe Summe besitzen.

2. Von 2 bis 7 existieren für die Summe s genau $s-1$ geordnete Paare; von 8 bis 12 genau $13-s$. Durch Division durch 36 entsteht

$$P(S=s) = \begin{cases} \dfrac{s-1}{36}, & 2 \le s \le 7, \\ \dfrac{13-s}{36}, & 8 \le s \le 12. \end{cases}$$

Die Verteilungsfunktion ist

$$F(x) = \sum_{s \le x} P(S=s).$$

3. $\binom{K}{x}$ zählt die gewählten Erfolge, $\binom{N-K}{n-x}$ die gewählten Misserfolge; beide Entscheidungen werden kombiniert und daher multipliziert. $\binom{N}{n}$ zählt alle gleich wahrscheinlichen Stichproben. Ohne Zurücklegen sind die Einzelziehungen abhängig und die Erfolgswahrscheinlichkeit verändert sich, weshalb die Binomialverteilung grundsätzlich nicht exakt passt.

4. Integration liefert für $x \ge 0$

$$F(x) = 1 - e^{-\lambda x}.$$

Aus $F(q_\alpha) = \alpha$ folgt

$$q_\alpha = -\frac{\ln(1-\alpha)}{\lambda}.$$

Eine Verdopplung von λ erhöht die Anfangsdichte, beschleunigt den Abfall, lässt F schneller gegen 1 steigen und halbiert jedes Quantil.

5. Seien U und V unabhängige faire Bernoulli-Zufallsvariablen mit Werten 0 und 1, und sei

$$W = (U + V) \bmod 2.$$

Dann sind U, V und W paarweise unabhängig, aber W ist durch U und V vollständig bestimmt; daher sind sie nicht gemeinsam unabhängig. iid verlangt gemeinsame Unabhängigkeit und zusätzlich dieselbe Randverteilung für alle Variablen, nicht gleiche realisierte Werte.