Lernzettel: Zufallsvariablen und ihre Eigenschaften
Statistik und Data Science I – Vorlesung 6, Sommersemester 2026

1. Das Big Picture (Chunking)

Dieses Kapitel löst das Problem, eine vollständige Wahrscheinlichkeitsverteilung auf wenige, interpretierbare Kerngrößen zu verdichten: **Wo liegt sie? Wie stark streut sie? Und wie hängen zwei Zufallsvariablen zusammen?** Im Kern geht es darum, theoretische Zufallsphänomene durch Erwartungswert, Varianz, gemeinsame und bedingte Verteilungen sowie Kovarianz und Korrelation mathematisch zu beschreiben – eine Grundlage für Schätzverfahren, Risikomessung, Regression und nahezu alle weiterführenden statistischen Modelle.

Die Inhalte lassen sich in vier gedankliche Blöcke zerlegen:

1. **Lokation:** Der Erwartungswert beschreibt den langfristigen Schwerpunkt einer Verteilung.
2. **Variation:** Varianz und Standardabweichung beschreiben die Unsicherheit um diesen Schwerpunkt.
3. **Transformationen und Rechenregeln:** Man untersucht, wie sich Lokation und Streuung verändern, wenn Zufallsvariablen addiert, skaliert oder nichtlinear transformiert werden.
4. **Gemeinsames Verhalten:** Gemeinsame, marginale und bedingte Verteilungen sowie Kovarianz und Korrelation beschreiben den Zusammenhang zwischen zwei Zufallsvariablen.

2. Zentrale Definitionen

Erwartungswert

Fachliche Definition: Der Erwartungswert einer diskreten Zufallsvariablen X mit Wahrscheinlichkeitsfunktion $p_X(x) = P(X = x)$ ist

$$E(X) = \sum_{x \in \mathcal{X}} x \, p_X(x),$$

sofern die Summe wohldefiniert und endlich ist. Für eine stetige Zufallsvariable X mit Dichte $f_X(x)$ gilt

$$E(X) = \int_{-\infty}^{\infty} x \, f_X(x) \, dx,$$

sofern das Integral existiert.

Feynman-Übersetzung: Stell dir vor, jede mögliche Zahl liegt auf einem Brett und trägt ein Gewicht, das ihrer Wahrscheinlichkeit entspricht. Der Erwartungswert ist genau der Punkt, an dem das Brett im Gleichgewicht wäre.

Gesetz der großen Zahlen

Fachliche Definition: Für unabhängig und identisch verteilte Zufallsvariablen $X_1, \ldots, X_n$ mit $E(X_i) = \mu$ konvergiert der Stichprobenmittelwert

$$\overline{X}_n = \frac{1}{n} \sum_{i=1}^{n} X_i$$

bei wachsendem n gegen μ. Die Vorlesung lässt die genaue Konvergenzart bewusst offen; eine gebräuchliche Fassung ist die Konvergenz in Wahrscheinlichkeit.

Feynman-Übersetzung: Einzelne Zufallsergebnisse können wild schwanken. Wenn du dasselbe Experiment aber sehr oft wiederholst und ständig den Durchschnitt bildest, beruhigt sich dieser Durchschnitt und nähert sich dem theoretischen Langzeitwert.

Transformation einer Zufallsvariablen

Fachliche Definition: Wird aus X durch eine Funktion g eine neue Zufallsvariable gebildet, so gilt

$$Y = g(X).$$

Der Erwartungswert der transformierten Zufallsvariablen kann direkt über die Verteilung von X berechnet werden:

$$E(Y) = E(g(X)).$$

Feynman-Übersetzung: Du beobachtest nicht mehr direkt das ursprüngliche Ergebnis, sondern rechnest jedes Ergebnis nach derselben Regel um – etwa Euro in Cent oder Temperatur in eine Kostenfunktion.

Varianz

Fachliche Definition: Die Varianz einer Zufallsvariablen X ist die erwartete quadrierte Abweichung vom Erwartungswert:

$$\mathsf{Var}(X) = E\left[(X - E(X))^2\right].$$

Sie existiert als endliche Zahl, wenn $E(X^2) < \infty$ gilt.

Feynman-Übersetzung: Die Varianz fragt: Wie weit liegen die Ergebnisse typischerweise vom Mittelpunkt entfernt? Große Abstände zählen besonders stark, weil sie quadriert werden.

Standardabweichung

Fachliche Definition: Die Standardabweichung ist die positive Quadratwurzel der Varianz:

$$\mathsf{sd}(X) = \sqrt{\mathsf{Var}(X)}.$$

Feynman-Übersetzung: Die Varianz misst Streuung in quadrierten Einheiten. Die Standardabweichung übersetzt diese Streuung zurück in die ursprüngliche Einheit von X.

Bivariate Zufallsvariable und gemeinsame Verteilung

Fachliche Definition: Eine bivariate Zufallsvariable betrachtet das Paar (X, Y). Im diskreten Fall wird das gemeinsame Verhalten durch

$$p_{X,Y}(x, y) = P(X = x, Y = y)$$

beschrieben. Im stetigen Fall wird eine gemeinsame Dichte $f_{X,Y}(x, y)$ verwendet, sodass für ein Rechteck $[a, b] \times [c, d]$ gilt:

$$P(a \le X \le b,\, c \le Y \le d) = \int_a^b \int_c^d f_{X,Y}(x, y)\, dy\, dx.$$

Feynman-Übersetzung: Statt nur eine Eigenschaft zu beobachten, beobachtest du zwei gleichzeitig. Die gemeinsame Verteilung sagt, welche Kombinationen der beiden Werte häufig und welche selten sind.

Randverteilung

Fachliche Definition: Die Randverteilung einer Komponente entsteht, indem die jeweils andere Komponente aus der gemeinsamen Verteilung herausgerechnet wird. Diskret gilt

$$p_X(x) = \sum_y p_{X,Y}(x, y),$$

und stetig gilt

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y)\, dy.$$

Feynman-Übersetzung: Du hast eine Tabelle mit Kombinationen aus zwei Merkmalen, interessierst dich aber nur noch für eines. Dann addierst du über alle Möglichkeiten des anderen Merkmals hinweg.

Bedingte Verteilung

Fachliche Definition: Die bedingte Verteilung von X unter der Information $Y = y$ lautet im diskreten Fall

$$P(X = x \mid Y = y) = \frac{P(X = x, Y = y)}{P(Y = y)},$$

sofern $P(Y = y) > 0$. Im stetigen Fall gilt

$$f_{X|Y}(x \mid y) = \frac{f_{X,Y}(x, y)}{f_Y(y)},$$

sofern $f_Y(y) > 0$.

Feynman-Übersetzung: Du verwirfst alle Fälle, in denen die bekannte Bedingung nicht erfüllt ist, und verteilst die verbleibenden Wahrscheinlichkeiten neu, sodass sie wieder zusammen 1 ergeben.

Stochastische Unabhängigkeit

Fachliche Definition: Zwei Zufallsvariablen X und Y sind unabhängig, wenn Wissen über eine Variable die Verteilung der anderen nicht verändert. Diskret ist dies äquivalent zu

$$P(X = x, Y = y) = P(X = x)P(Y = y)$$

für alle relevanten x und y. Stetig gilt entsprechend

$$f_{X,Y}(x, y) = f_X(x) f_Y(y).$$

Feynman-Übersetzung: Selbst wenn du den Wert der einen Variable kennst, weißt du dadurch nichts Neues über die andere.

Kovarianz

Fachliche Definition: Die Kovarianz zweier Zufallsvariablen X und Y ist

$$\mathrm{Cov}(X, Y) = E\left[(X - E(X))(Y - E(Y))\right].$$

Sie misst Richtung und Stärke des gemeinsamen linearen Schwankens, ist aber von den Maßeinheiten abhängig.

Feynman-Übersetzung: Die Kovarianz prüft, ob beide Variablen meist gemeinsam über ihrem Durchschnitt liegen oder gemeinsam darunter. Ist häufig eine oben und die andere unten, wird die Kovarianz negativ.

Korrelation

Fachliche Definition: Die Korrelation standardisiert die Kovarianz durch die Standardabweichungen:

$$\rho_{X,Y} = \frac{\mathsf{Cov}(X,Y)}{\mathsf{sd}(X)\,\mathsf{sd}(Y)}.$$

Sie ist nur definiert, wenn beide Standardabweichungen positiv und endlich sind, und erfüllt

$$-1 \le \rho_{X,Y} \le 1.$$

Feynman-Übersetzung: Die Korrelation ist eine einheitenfreie Kovarianz auf einer festen Skala von -1 bis 1. Dadurch lassen sich Zusammenhänge vergleichen, auch wenn die Variablen in völlig unterschiedlichen Einheiten gemessen werden.

3. Formeln, Beweise & Intuition

3.1 Erwartungswert einer diskreten Zufallsvariablen

Die Formel

$$E(X) = \sum_{x \in \mathcal{X}} x\, P(X = x).$$

Dekonstruktion

- X: die Zufallsvariable.
- x: eine mögliche Realisation von X.
- $\mathcal{X}$: die Menge aller möglichen Werte von X.
- $P(X = x)$: das Wahrscheinlichkeitsgewicht des Wertes x.
- $xP(X = x)$: der gewichtete Beitrag des Wertes x zum Schwerpunkt.

Der Beweis / Die Herleitung

Die Formel ist die theoretische Entsprechung eines gewichteten arithmetischen Mittels. Angenommen, ein Experiment wird n-mal durchgeführt. Der Wert x tritt dabei n_x-mal auf. Der empirische Mittelwert ist dann

$$\overline{x} = \frac{1}{n} \sum_{x \in \mathcal{X}} x\, n_x = \sum_{x \in \mathcal{X}} x \frac{n_x}{n}.$$

Für großes n nähert sich die relative Häufigkeit n_x/n der Wahrscheinlichkeit $P(X = x)$. Daher entsteht im Grenzfall

$$\overline{x} \approx \sum_{x \in \mathcal{X}} xP(X = x) = E(X).$$

Wichtig: Dies ist eine Motivation, keine Definition über beobachtete Daten. Der Erwartungswert gehört zur theoretischen Verteilung und existiert bereits vor jeder Datenerhebung.

Die Analogie & Mechanik

Jeder Wert x ist ein Sitzplatz auf einer Wippe; $P(X = x)$ ist das dort abgelegte Gewicht. Ein großer Wert weit rechts kann trotz kleiner Wahrscheinlichkeit den Schwerpunkt deutlich verschieben. Umgekehrt kann ein sehr wahrscheinlicher Wert nahe beim Zentrum dominieren.

Beim Lotto-Beispiel aus der Vorlesung ist die Zahl der Richtigen X meist 0 oder 1. Seltene Werte wie 5 oder 6 liegen zwar weit rechts, besitzen aber extrem kleine Wahrscheinlichkeiten. Deshalb ergibt sich nur

$$E(X) \approx 0{,}7347.$$

Das bedeutet nicht, dass man in einem einzelnen Spiel $0{,}7347$ Richtige erzielen kann. Es bedeutet, dass sich der Durchschnitt über sehr viele Spiele diesem Wert annähert.

3.2 Erwartungswert einer stetigen Zufallsvariablen

Die Formel

$$E(X) = \int_{-\infty}^{\infty} x\, f_X(x)\, dx.$$

Dekonstruktion

- $f_X(x)$: die Dichte von X am Punkt x.
- $f_X(x)\, dx$: näherungsweise die Wahrscheinlichkeit, dass X in einem winzigen Intervall um x liegt.
- $x f_X(x)\, dx$: der lokale Schwerpunktbeitrag dieses kleinen Intervalls.

Der Beweis / Die Herleitung

Zerlege die Zahlengerade in kleine Intervalle der Breite Δx. Wähle in jedem Intervall einen Repräsentanten x_k. Dann ist

$$P(X \text{ liegt im } k\text{-ten Intervall}) \approx f_X(x_k)\Delta x.$$

Ein diskret angenäherter Erwartungswert lautet deshalb

$$E(X) \approx \sum_k x_k f_X(x_k)\Delta x.$$

Wenn die Intervalle immer feiner werden, geht diese Riemann-Summe in das Integral über:

$$\lim_{\Delta x \to 0} \sum_k x_k f_X(x_k)\Delta x = \int_{-\infty}^{\infty} x f_X(x)\, dx.$$

Die Analogie & Mechanik

Bei einer stetigen Dichte ist die Wahrscheinlichkeitsmasse wie fein verteilter Sand. Das Integral summiert die unendlich vielen kleinen Sandmengen samt ihrem Abstand zum Ursprung. Eine lange, schwere rechte Verteilungsschwanz kann den Erwartungswert stark nach rechts ziehen, selbst wenn der Gipfel der Dichte deutlich weiter links liegt.

3.3 Symmetrie und Erwartungswert

Die Formel

Ist die Verteilung von X symmetrisch um a und existiert $E(X)$, dann gilt

$$E(X) = a.$$

Dekonstruktion

- a: Symmetriezentrum der Verteilung.
- Symmetrie bedeutet im stetigen Fall beispielsweise

$$f_X(a+t) = f_X(a-t)$$

für alle passenden t.

Der Beweis / Die Herleitung

Betrachte die zentrierte Variable

$$Z = X - a.$$

Durch die Symmetrie um a ist Z symmetrisch um 0. Positive und negative Abweichungen besitzen spiegelbildlich dieselbe Wahrscheinlichkeit. Daher heben sich ihre gewichteten Beiträge auf:

$$E(Z) = 0.$$

Mit der Linearität des Erwartungswerts folgt

$$E(Z) = E(X - a) = E(X) - a = 0.$$

Also

$$E(X) = a.$$

Die Analogie & Mechanik

Links und rechts vom Mittelpunkt liegt exakt gleich viel gleichartig verteilter Sand. Jeder Beitrag im Abstand t rechts wird durch einen gleich schweren Beitrag im Abstand t links ausgeglichen.

Die Existenzbedingung ist entscheidend: Symmetrie allein garantiert keinen endlichen Erwartungswert. Bei einer Cauchy-Verteilung sind die beiden Verteilungsschwänze so schwer, dass die positiven und negativen Beiträge nicht als endliche Größen existieren. Man darf nicht einfach mit „sie heben sich auf“ argumentieren, wenn beide Seiten unendlich groß sind.

3.4 Gesetz der großen Zahlen

Die Formel

Für unabhängig und identisch verteilte Zufallsvariablen $X_1, \dots, X_n$ mit

$$E(X_i) = \mu$$

lautet der Stichprobenmittelwert

$$\overline{X}_n = \frac{1}{n} \sum_{i=1}^{n} X_i,$$

und es gilt in einer gebräuchlichen Fassung

$$\overline{X}_n \xrightarrow{P} \mu.$$

Dekonstruktion

- n: Anzahl unabhängiger Wiederholungen.
- X_i: Ergebnis der i-ten Wiederholung.
- μ: gemeinsamer Erwartungswert.
- $\xrightarrow{P}$: Konvergenz in Wahrscheinlichkeit.

Der Beweis / Die Herleitung

Eine verständnisorientierte Herleitung des schwachen Gesetzes verwendet eine zusätzliche Annahme: Es existiere eine endliche gemeinsame Varianz

$$\mathsf{Var}(X_i) = \sigma^2 < \infty.$$

Zunächst gilt durch Linearität

$$E(\overline{X}_n) = E\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n}\sum_{i=1}^{n} E(X_i) = \mu.$$

Wegen der Unabhängigkeit addieren sich die Varianzen:

$$\mathsf{Var}(\overline{X}_n) = \mathsf{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right) = \frac{1}{n^2}\sum_{i=1}^{n} \mathsf{Var}(X_i) = \frac{\sigma^2}{n}.$$

Die Varianz des Mittelwerts schrumpft also gegen 0. Mit der Tschebyscheff-Ungleichung folgt für jedes $\varepsilon > 0$:

$$P\left(|\overline{X}_n - \mu| \geq \varepsilon\right) \leq \frac{\mathsf{Var}(\overline{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \longrightarrow 0.$$

Genau dies ist Konvergenz in Wahrscheinlichkeit.

Die Analogie & Mechanik

Jede einzelne Beobachtung enthält Zufallsrauschen. Beim Mitteln addieren sich die Signale vollständig, während sich unabhängige positive und negative Zufallsschwankungen teilweise gegenseitig ausgleichen. Der Nenner n wächst schneller als die Standardabweichung der Summe. Konkret gilt

$$\mathsf{sd}(\overline{X}_n) = \frac{\sigma}{\sqrt{n}}.$$

Eine Vervierfachung des Stichprobenumfangs halbiert daher die typische Schwankung des Mittelwerts. Die Grafik auf Seite 9 der Vorlesung macht genau diese Mechanik sichtbar: Der laufende Mittelwert springt anfangs stark, stabilisiert sich aber mit zunehmender Anzahl der Lottospiele in der Nähe des Erwartungswerts.

3.5 Lineare Transformation des Erwartungswerts

Die Formel

Für

$$Y = aX + b$$

gilt

$$E(Y) = aE(X) + b.$$

Dekonstruktion

- a: Skalierungsfaktor; bei negativem a zusätzlich Spiegelung.
- b: additive Verschiebung.
- Y: transformierte Zufallsvariable.

Der Beweis / Die Herleitung

Im diskreten Fall:

$$E(Y) = \sum_x (ax + b)P(X = x).$$

Verteile die Summe:

$$E(Y) = a\sum_x xP(X = x) + b\sum_x P(X = x).$$

Da sich alle Wahrscheinlichkeiten zu 1 summieren, gilt

$$\sum_x P(X = x) = 1.$$

Damit folgt

$$E(Y) = aE(X) + b.$$

Im stetigen Fall ist die Argumentation identisch mit Integralen:

$$E(Y) = \int_{-\infty}^{\infty} (ax + b)f_X(x)\,dx = aE(X) + b.$$

Die Analogie & Mechanik

Wird jeder Geldbetrag verdoppelt, verdoppelt sich auch der langfristige Durchschnitt. Wird anschließend jedem Ergebnis ein fester Bonus von 3 Euro hinzugefügt, steigt auch der Erwartungswert exakt um 3 Euro.

Ein großer Betrag von a zieht den Schwerpunkt proportional vom Ursprung weg. Der Wert b verschiebt die gesamte Verteilung, ohne ihre Form oder Breite zu verändern.

3.6 Nichtlineare Transformation und das Gesetz des unbewussten Statistikers

Die Formel

Für

$$Y = g(X)$$

gilt diskret

$$E(Y) = E(g(X)) = \sum_x g(x)P(X = x),$$

und stetig

$$E(Y) = E(g(X)) = \int_{-\infty}^{\infty} g(x)f_X(x)\,dx.$$

Im Allgemeinen gilt jedoch

$$E(g(X)) \neq g(E(X)).$$

Dekonstruktion

- g: beliebige messbare Transformation, für die der Erwartungswert existiert.
- $g(x)$: transformierter Wert einer ursprünglichen Realisation x.
- $E(g(X))$: erst transformieren, dann mitteln.
- $g(E(X))$: erst mitteln, dann genau einen Wert transformieren.

Der Beweis / Die Herleitung

Die Zufallsvariable $Y = g(X)$ nimmt die Werte $g(x)$ an, sobald $X = x$ eintritt. Daher wird jeder transformierte Wert mit der Wahrscheinlichkeit des ursprünglichen Wertes gewichtet. Man muss die Verteilung von Y nicht zuerst explizit bestimmen.

Warum sind die beiden Rechenwege im Allgemeinen verschieden? Betrachte $g(x) = x^2$ und eine Zufallsvariable mit

$$P(X = -1) = P(X = 1) = \frac{1}{2}.$$

Dann ist

$$E(X) = 0$$

und somit

$$g(E(X)) = 0^2 = 0.$$

Aber jede Realisation wird beim Quadrieren zu 1:

$$E(g(X)) = E(X^2) = 1.$$

Daher

$$E(X^2) \neq (E(X))^2.$$

Die Analogie & Mechanik

Bei einer nichtlinearen Maschine hängt das Ergebnis davon ab, ob du jede Beobachtung einzeln durch die Maschine schickst und danach mittelst oder zuerst alle Beobachtungen mittelst und nur den Mittelwert durch die Maschine schickst. Eine gekrümmte Maschine behandelt Abweichungen asymmetrisch.

Beim Quadrieren werden große positive und große negative Abweichungen beide stark positiv. Deshalb erhöht stärkere Streuung typischerweise $E(X^2)$. Für konvexe Funktionen liefert die Jensen-Ungleichung als ergänzende Einordnung

$$E(g(X)) \geq g(E(X)).$$

3.7 Linearität des Erwartungswerts

Die Formel

Für beliebige Zufallsvariablen mit existierenden Erwartungswerten gilt

$$E(X+Y) = E(X) + E(Y).$$

Allgemeiner:

$$E\left(\sum_{i=1}^{n} a_i X_i\right) = \sum_{i=1}^{n} a_i E(X_i).$$

Dekonstruktion

- a_i: feste, nicht zufällige Koeffizienten.
- X_i: Zufallsvariablen, die abhängig oder unabhängig sein dürfen.

Der Beweis / Die Herleitung

Im diskreten bivariaten Fall gilt

$$E(X+Y) = \sum_x \sum_y (x+y) P(X=x, Y=y).$$

Zerlege den Ausdruck:

$$E(X+Y) = \sum_x \sum_y x P(X=x, Y=y) + \sum_x \sum_y y P(X=x, Y=y).$$

Im ersten Summanden kann über y marginalisiert werden:

$$\sum_y P(X=x, Y=y) = P(X=x).$$

Damit wird der erste Summand zu $E(X)$; analog wird der zweite zu $E(Y)$. Also

$$E(X+Y) = E(X) + E(Y).$$

Entscheidend: **Unabhängigkeit wird hierfür nicht benötigt.**

Die Analogie & Mechanik

Wenn zwei Geschäftsbereiche zufällige Gewinne erzielen, ist der erwartete Gesamtgewinn stets die Summe der erwarteten Einzelgewinne. Ob die Bereiche gleichzeitig gute oder schlechte Jahre haben, beeinflusst das Risiko, aber nicht diese Erwartungswertaddition.

3.8 Produktregel bei Unabhängigkeit

Die Formel

Sind X und Y unabhängig, dann gilt

$$E(XY) = E(X)E(Y).$$

Dekonstruktion

- XY: Produkt der beiden Zufallsvariablen.
- Unabhängigkeit: Die gemeinsame Verteilung faktorisiert.

Der Beweis / Die Herleitung

Im diskreten Fall:

$$E(XY) = \sum_x \sum_y xyP(X = x, Y = y).$$

Bei Unabhängigkeit gilt

$$P(X = x, Y = y) = P(X = x)P(Y = y).$$

Daher

$$E(XY) = \sum_x \sum_y xyP(X = x)P(Y = y).$$

Die Faktoren lassen sich trennen:

$$E(XY) = \left(\sum_x xP(X = x)\right)\left(\sum_y yP(Y = y)\right) = E(X)E(Y).$$

Die Analogie & Mechanik

Unabhängigkeit macht aus einer zweidimensionalen Wahrscheinlichkeitslandschaft das Produkt zweier eindimensionaler Landschaften. Erst dadurch kann die doppelte Summe beziehungsweise das Doppelintegral in zwei getrennte Faktoren zerlegt werden.

Ohne Unabhängigkeit kann der Erwartungswert des Produkts größer oder kleiner sein. Genau die Differenz wird später durch die Kovarianz beschrieben:

$$E(XY) - E(X)E(Y) = \mathsf{Cov}(X, Y).$$

3.9 Varianz als erwartete quadrierte Abweichung

Die Formel

$$\mathsf{Var}(X) = E\left[(X - E(X))^2\right].$$

Diskret:

$$\mathsf{Var}(X) = \sum_x (x - E(X))^2 P(X = x).$$

Stetig:

$$\mathrm{Var}(X) = \int_{-\infty}^{\infty} (x - E(X))^2 f_X(x)\, dx.$$

Dekonstruktion

- $X - E(X)$: Abweichung vom Schwerpunkt.
- $(X - E(X))^2$: quadrierte Abweichung; negative und positive Abstände werden gleich behandelt.
- Der äußere Erwartungswert: wahrscheinlichkeitgewichteter Durchschnitt der quadrierten Abstände.

Der Beweis / Die Herleitung

Die naive mittlere Abweichung wäre

$$E(X - E(X)).$$

Durch Linearität gilt aber

$$E(X - E(X)) = E(X) - E(X) = 0.$$

Positive und negative Abweichungen löschen sich vollständig aus. Durch Quadrieren wird dieses Problem beseitigt:

$$(X - E(X))^2 \geq 0.$$

Die Varianz ist deshalb immer nichtnegativ. Sie ist genau dann 0, wenn X mit Wahrscheinlichkeit 1 konstant ist.

Die Analogie & Mechanik

Die Varianz ist wie eine Strafkostenfunktion für Entfernung vom Zielwert. Doppelte Entfernung verursacht vierfache Kosten. Deshalb reagieren Varianz und Standardabweichung empfindlich auf extreme Werte und schwere Verteilungsschwänze.

3.10 Verschiebungsregel der Varianz

Die Formel

$$\mathrm{Var}(X) = E(X^2) - (E(X))^2.$$

Dekonstruktion

- $E(X^2)$: zweites Rohmoment.
- $(E(X))^2$: Quadrat des ersten Moments.
- Die Differenz entfernt den Anteil, der nur durch die Lage der Verteilung entsteht.

Der Beweis / Die Herleitung

Aus der Definition:

$$\mathrm{Var}(X) = E\left[(X - E(X))^2\right].$$

Quadrat ausmultiplizieren:

$$(X - E(X))^2 = X^2 - 2XE(X) + (E(X))^2.$$

Erwartungswert bilden:

$$\mathsf{Var}(X) = E(X^2) - 2E(XE(X)) + E((E(X))^2).$$

Da $E(X)$ eine feste Zahl ist,

$$E(XE(X)) = E(X)E(X) = (E(X))^2$$

und

$$E((E(X))^2) = (E(X))^2.$$

Somit

$$\mathsf{Var}(X) = E(X^2) - 2(E(X))^2 + (E(X))^2 = E(X^2) - (E(X))^2.$$

Die Analogie & Mechanik

$E(X^2)$ enthält zwei Dinge zugleich: die Entfernung der Verteilung vom Ursprung und ihre innere Breite. Durch Abzug von $(E(X))^2$ wird die reine Lage entfernt; übrig bleibt die Streuung um den eigenen Mittelpunkt.

Diese Formel ist rechnerisch oft bequem, kann aber numerisch instabil sein, wenn beide Terme sehr groß und fast gleich sind. Dann ist eine direkte oder algorithmisch stabilisierte Varianzberechnung besser.

3.11 Lineare Transformation der Varianz

Die Formel

Für

$$Y = aX + b$$

gilt

$$\mathsf{Var}(Y) = a^2\,\mathsf{Var}(X)$$

und

$$\mathsf{sd}(Y) = |a|\,\mathsf{sd}(X).$$

Dekonstruktion

- b: reine Verschiebung; beeinflusst die Streuung nicht.
- a: skaliert alle Abstände vom Mittelwert.
- a^2: entsteht, weil Abstände in der Varianz quadriert werden.
- $|a|$: entsteht bei der Standardabweichung, da diese nicht negativ sein kann.

Der Beweis / Die Herleitung

Zunächst ist

$$E(Y) = aE(X) + b.$$

Damit gilt

$$Y - E(Y) = aX + b - (aE(X) + b) = a(X - E(X)).$$

Quadrieren und Erwartungswert bilden:

$$\mathsf{Var}(Y) = E\left([a(X - E(X))]^2\right) = a^2 E\left[(X - E(X))^2\right] = a^2\,\mathsf{Var}(X).$$

Für die Standardabweichung:

$$\mathsf{sd}(Y) = \sqrt{a^2\,\mathsf{Var}(X)} = |a|\,\mathsf{sd}(X).$$

Die Analogie & Mechanik

Wenn jede Länge in Zentimetern statt Metern ausgedrückt wird, werden alle Abstände mit 100 multipliziert. Die Varianz wächst daher mit 100^2, die Standardabweichung nur mit 100. Eine Verschiebung des Nullpunkts, etwa von Celsius zu einer Skala mit anderem Ursprung, verändert die Breite nicht.

3.12 Varianz einer Summe und die Rolle der Kovarianz

Die Formel

Allgemein gilt

$$\mathsf{Var}(X + Y) = \mathsf{Var}(X) + \mathsf{Var}(Y) + 2\,\mathsf{Cov}(X, Y).$$

Sind X und Y unabhängig, dann ist

$$\mathsf{Cov}(X, Y) = 0$$

und daher

$$\mathsf{Var}(X + Y) = \mathsf{Var}(X) + \mathsf{Var}(Y).$$

Für Konstanten a_1 und a_2 gilt allgemein

$$\mathsf{Var}(a_1X + a_2Y) = a_1^2\,\mathsf{Var}(X) + a_2^2\,\mathsf{Var}(Y) + 2a_1a_2\,\mathsf{Cov}(X, Y).$$

Dekonstruktion

- Die Einzelvarianzen messen das jeweilige Einzelrisiko.
- Der Kovarianzterm misst, ob beide Risiken gleichzeitig in dieselbe Richtung ausschlagen.
- Der Faktor 2 entsteht aus dem Kreuzterm beim Quadrieren.

Der Beweis / Die Herleitung

Setze

$$\mu_X = E(X) \qquad \text{und} \qquad \mu_Y = E(Y).$$

Dann gilt

$$(X+Y) - E(X+Y) = (X-\mu_X) + (Y-\mu_Y).$$

Quadrieren:

$$[(X-\mu_X) + (Y-\mu_Y)]^2 = (X-\mu_X)^2 + (Y-\mu_Y)^2 + 2(X-\mu_X)(Y-\mu_Y).$$

Erwartungswert bilden:

$$\mathsf{Var}(X+Y) = \mathsf{Var}(X) + \mathsf{Var}(Y) + 2\,\mathsf{Cov}(X,Y).$$

Bei Unabhängigkeit gilt

$$E(XY) = E(X)E(Y),$$

also

$$\mathsf{Cov}(X,Y) = 0.$$

Die Analogie & Mechanik

Zwei unabhängige Lärmquellen addieren ihre Varianzen. Zwei perfekt gleichlaufende Lärmquellen verstärken sich stärker, weil sie gleichzeitig ausschlagen. Zwei gegenläufige Quellen können sich teilweise stabilisieren; dann ist die Kovarianz negativ.

Für unabhängige, identisch verteilte Zufallsvariablen mit Varianz σ^2 gilt

$$\mathsf{Var}\left(\sum_{i=1}^{n} X_i\right) = n\sigma^2,$$

aber für den Mittelwert

$$\mathsf{Var}(\overline{X}_n) = \frac{\sigma^2}{n}.$$

Das ist die mathematische Kernmechanik hinter dem Gesetz der großen Zahlen.

3.13 Chuck-a-Luck: Erwartungswert und Risiko

Die Formel

Beim Setzen auf eine bestimmte Zahl werden drei Würfel geworfen. Für den Gewinn G gilt die Verteilung

$$P(G=3) = \frac{1}{216}, \qquad P(G=2) = \frac{15}{216},$$
$$P(G=1) = \frac{75}{216}, \qquad P(G=-1) = \frac{125}{216}.$$

Der Erwartungswert lautet

$$E(G) = 3\frac{1}{216} + 2\frac{15}{216} + 1\frac{75}{216} - 1\frac{125}{216} = -\frac{17}{216} \approx -0{,}0787.$$

Die Varianz ist

$$\mathrm{Var}(G) = E(G^2) - (E(G))^2 = \frac{269}{216} - \left(-\frac{17}{216}\right)^2 = \frac{57815}{46656} \approx 1{,}2392.$$

Dekonstruktion

- $G = -1$: kein Würfel zeigt die gesetzte Zahl; der Einsatz geht verloren.
- $G = 1, 2, 3$: genau ein, zwei oder drei Würfel zeigen die gesetzte Zahl.
- Der negative Erwartungswert entspricht einem langfristigen Verlust von etwa $7{,}87\%$ des Einsatzes pro Spiel.

Der Beweis / Die Herleitung

Die Anzahl passender Würfel folgt einer Binomialstruktur. Für genau k Treffer unter drei Würfeln gilt

$$P(K = k) = \binom{3}{k} \left(\frac{1}{6}\right)^k \left(\frac{5}{6}\right)^{3-k}.$$

Daraus folgen

$$P(K = 0) = \left(\frac{5}{6}\right)^3 = \frac{125}{216},$$

$$P(K = 1) = \binom{3}{1}\frac{1}{6}\left(\frac{5}{6}\right)^2 = \frac{75}{216},$$

$$P(K = 2) = \binom{3}{2}\left(\frac{1}{6}\right)^2\frac{5}{6} = \frac{15}{216},$$

$$P(K = 3) = \left(\frac{1}{6}\right)^3 = \frac{1}{216}.$$

Die Auszahlung ist nicht einfach $K - 1$: Bei mindestens einem Treffer erhält der Spieler seinen Einsatz zurück und zusätzlich den angegebenen Gewinn. Deshalb nimmt die in der Vorlesung definierte Gewinnvariable die Werte $-1, 1, 2, 3$ an.

Die Analogie & Mechanik

Der Erwartungswert ist der durchschnittliche Preis des Spiels auf lange Sicht; die Varianz beschreibt dagegen, wie unruhig die einzelnen Spielausgänge sind. Zwei Strategien können denselben erwarteten Verlust besitzen und dennoch völlig unterschiedliche Verlustwahrscheinlichkeiten und Schwankungen haben.

Die drei Strategien der Vorlesung besitzen denselben Erwartungswert:

$$E(2X_6) = E(X_1 + X_6) = E(X_6 + Y_6) = -\frac{34}{216}.$$

Ihre Varianzen unterscheiden sich jedoch:

$$\mathrm{Var}(2X_6) = 4\,\mathrm{Var}(X_6) \approx 4{,}9567,$$

$$\mathrm{Var}(X_6 + Y_6) = 2\,\mathrm{Var}(X_6) \approx 2{,}4784,$$

weil X_6 und Y_6 verschiedene Würfe betreffen und unabhängig sind. Für die Einsätze X_1 und X_6 im selben Wurf gilt dagegen

$$\mathrm{Var}(X_1 + X_6) \approx 2{,}0030.$$

Daraus kann ergänzend die Kovarianz erschlossen werden:

$$\mathrm{Cov}(X_1, X_6) = \frac{\mathrm{Var}(X_1 + X_6) - 2\,\mathrm{Var}(X_6)}{2} \approx -0{,}2377.$$

Die negative Kovarianz ist anschaulich: Ein einzelner Würfel kann nicht zugleich eine 1 und eine 6 zeigen. Gewinne auf beide Zahlen im selben Wurf stabilisieren sich daher teilweise gegenseitig.

3.14 Gemeinsame Wahrscheinlichkeitsfunktion und Dichte

Die Formel

Diskret:

$$p_{X,Y}(x, y) = P(X = x, Y = y).$$

Die Gesamtwahrscheinlichkeit muss 1 ergeben:

$$\sum_x \sum_y p_{X,Y}(x, y) = 1.$$

Stetig:

$$f_{X,Y}(x, y) \geq 0$$

und

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x, y)\, dy\, dx = 1.$$

Dekonstruktion

- (x, y): konkrete Wertekombination.
- $p_{X,Y}(x, y)$: Wahrscheinlichkeit genau dieser Kombination im diskreten Fall.
- $f_{X,Y}(x, y)$: Dichtehöhe im stetigen Fall; keine Punktwahrscheinlichkeit.

Der Beweis / Die Herleitung

Eine gemeinsame Verteilung muss alle möglichen Paare vollständig abdecken. Im diskreten Fall werden alle Zellwahrscheinlichkeiten einer Kontingenztafel summiert. Im stetigen Fall wird das gesamte Volumen unter der Dichtefläche integriert.

Für ein Gebiet $A \subseteq \mathbb{R}^2$ gilt

$$P((X,Y) \in A) = \iint_A f_{X,Y}(x,y)\, d(x,y).$$

Die dreidimensionale Dichtegrafik auf Seite 33 der Vorlesung ist wie eine Landschaft: Wahrscheinlichkeit entspricht nicht der Höhe an einem Punkt, sondern dem Volumen über einer Fläche in der Grundebene.

Die Analogie & Mechanik

Eine gemeinsame diskrete Verteilung ist wie eine Landkarte aus Feldern, in denen jedes Feld ein Wahrscheinlichkeitsgewicht trägt. Eine gemeinsame stetige Dichte ist wie eine hügelige Landschaft; die Wahrscheinlichkeit eines Gebiets entspricht dem Erdvolumen über diesem Gebiet.

Ein sehr hoher, aber extrem schmaler Gipfel kann weniger Wahrscheinlichkeit enthalten als ein niedriger, breiter Hügel. Höhe allein ist keine Wahrscheinlichkeit.

3.15 Randverteilungen

Die Formel

Diskret:

$$P(X = x) = \sum_y P(X = x, Y = y).$$

Stetig:

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)\, dy.$$

Analog gilt

$$P(Y = y) = \sum_x P(X = x, Y = y)$$

beziehungsweise

$$f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)\, dx.$$

Dekonstruktion

- Die nicht interessierende Variable wird über ihren gesamten Wertebereich aufsummiert oder ausintegriert.
- Das Ergebnis ist wieder eine gültige eindimensionale Verteilung.

Der Beweis / Die Herleitung

Die Ereignisse

$$\{X = x, Y = y_1\}, \{X = x, Y = y_2\}, ...$$

sind disjunkt. Ihre Vereinigung ist das Ereignis $\{X = x\}$. Nach Additivität der Wahrscheinlichkeit folgt

$$P(X = x) = \sum_y P(X = x, Y = y).$$

Im stetigen Fall übernimmt das Integral dieselbe Summationsrolle.

Die Analogie & Mechanik

In einer Kreuztabelle entspricht die Randverteilung der Summe einer ganzen Zeile oder Spalte. Du „klappst“ eine zweidimensionale Tabelle zu einer eindimensionalen Liste zusammen.

Die gemeinsame Verteilung legt die Randverteilungen eindeutig fest. Umgekehrt reichen zwei Randverteilungen im Allgemeinen nicht aus, um die gemeinsame Verteilung zu rekonstruieren. Es fehlt die Information darüber, wie die beiden Variablen gekoppelt sind.

3.16 Bedingte Verteilungen

Die Formel

Diskret:

$$P(X = x \mid Y = y) = \frac{P(X = x, Y = y)}{P(Y = y)}.$$

Stetig:

$$f_{X|Y}(x \mid y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}.$$

Dekonstruktion

- Zähler: gemeinsame Masse beziehungsweise Dichte für die Kombination (x, y).
- Nenner: gesamte Masse beziehungsweise Dichte des festgehaltenen Wertes y.
- Division: Renormierung innerhalb der ausgewählten Teilpopulation.

Der Beweis / Die Herleitung

Die diskrete Formel folgt unmittelbar aus der Definition bedingter Wahrscheinlichkeit:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}.$$

Setze

$$A = \{X = x\} \qquad \text{und} \qquad B = \{Y = y\}.$$

Dann ist

$$A \cap B = \{X = x, Y = y\}.$$

Damit folgt die Formel.

Dass die bedingten Wahrscheinlichkeiten wieder zu 1 summieren, sieht man an

$$\sum_x P(X = x \mid Y = y) = \frac{\sum_x P(X = x, Y = y)}{P(Y = y)} = \frac{P(Y = y)}{P(Y = y)} = 1.$$

Die Analogie & Mechanik

Bei der Roulette-Tabelle der Vorlesung wird für die Bedingung „Farbe ist rot“ nur die rote Zeile betrachtet. Die ursprünglichen Zellwahrscheinlichkeiten werden anschließend durch die Zeilensumme $18/37$ geteilt. Aus $8/37$ und $10/37$ werden dadurch $8/18$ und $10/18$.

Ein kleiner Nenner $P(Y = y)$ vergrößert die bedingten Gewichte stark. Das ist kein Fehler: Man betrachtet dann eine seltene Teilgruppe und verteilt innerhalb dieser kleinen Gruppe die Gesamtwahrscheinlichkeit neu.

3.17 Unabhängigkeit als Faktorisation

Die Formel

Diskret:

$$X \perp Y \quad \Longleftrightarrow \quad P(X = x, Y = y) = P(X = x)P(Y = y)$$

für alle relevanten x und y.

Stetig:

$$X \perp Y \quad \Longleftrightarrow \quad f_{X,Y}(x, y) = f_X(x)f_Y(y).$$

Äquivalent gilt für zulässige y:

$$P(X = x \mid Y = y) = P(X = x)$$

beziehungsweise

$$f_{X|Y}(x \mid y) = f_X(x).$$

Dekonstruktion

- $X \perp Y$: Kurznotation für Unabhängigkeit.
- Faktorisation: Die gemeinsame Verteilung enthält keine zusätzliche Kopplungsstruktur.
- Bedingte Gleichheit: Die Information $Y = y$ verändert die Verteilung von X nicht.

Der Beweis / Die Herleitung

Aus der Definition der bedingten Wahrscheinlichkeit folgt bei Unabhängigkeit

$$P(X = x \mid Y = y) = \frac{P(X = x)P(Y = y)}{P(Y = y)} = P(X = x).$$

Umgekehrt gilt, falls die bedingte Verteilung gleich der Randverteilung ist,

$$P(X = x, Y = y) = P(X = x \mid Y = y)P(Y = y) = P(X = x)P(Y = y).$$

Die Analogie & Mechanik

Bei unabhängigen Variablen sieht jede Zeile einer bedingten Wahrscheinlichkeitstabelle gleich aus wie die Randverteilung. Keine Zeile enthält neue Information über die andere Variable.

In der Roulette-Tabelle sind Farbe und Zahlentyp nicht unabhängig: Unter der Bedingung „rot“ sind ungerade Zahlen mit $10/18$ wahrscheinlicher als gerade Zahlen mit $8/18$, während die unbedingten Wahrscheinlichkeiten beider Zahlentypen jeweils $18/37$ betragen.

3.18 Kovarianz und Verschiebungssatz

Die Formel

Definition:

$$\mathsf{Cov}(X,Y) = E\left[(X - E(X))(Y - E(Y))\right].$$

Verschiebungssatz:

$$\mathsf{Cov}(X,Y) = E(XY) - E(X)E(Y).$$

Dekonstruktion

- $X - E(X)$ und $Y - E(Y)$: zentrierte Abweichungen.
- Das Produkt ist positiv, wenn beide Abweichungen dasselbe Vorzeichen haben.
- Das Produkt ist negativ, wenn die Abweichungen entgegengesetzte Vorzeichen haben.

Der Beweis / Die Herleitung

Multipliziere aus:

$$(X - E(X))(Y - E(Y)) = XY - XE(Y) - YE(X) + E(X)E(Y).$$

Bilde den Erwartungswert:

$$\mathsf{Cov}(X,Y) = E(XY) - E(X)E(Y) - E(Y)E(X) + E(X)E(Y).$$

Damit folgt

$$\mathsf{Cov}(X,Y) = E(XY) - E(X)E(Y).$$

Sind X und Y unabhängig, gilt $E(XY) = E(X)E(Y)$ und somit

$$\mathsf{Cov}(X,Y) = 0.$$

Die Analogie & Mechanik

Stell dir zwei Unternehmen vor. Erzielen beide besonders hohe Gewinne in denselben Jahren und niedrige Gewinne in denselben Jahren, ist die Kovarianz positiv. Läuft eines typischerweise gut, wenn das andere schlecht läuft, ist sie negativ. Gibt es kein systematisches lineares gemeinsames Schwanken, liegt sie nahe bei 0.

Die Größe hängt von den Einheiten ab. Wird X mit 100 multipliziert, wird auch die Kovarianz mit 100 multipliziert. Deshalb ist sie für Vergleiche zwischen unterschiedlich skalierten Variablen ungeeignet.

3.19 Korrelation und ihre Schranken

Die Formel

$$\rho_{X,Y} = \frac{\mathsf{Cov}(X,Y)}{\mathsf{sd}(X)\,\mathsf{sd}(Y)}.$$

Es gilt

$$-1 \le \rho_{X,Y} \le 1.$$

Dekonstruktion

- Zähler: gemeinsames lineares Schwanken.
- Nenner: maximal mögliche Skala dieses gemeinsamen Schwankens, gemessen durch die Einzelstreuungen.
- $\rho_{X,Y} > 0$: tendenziell gleichgerichteter linearer Zusammenhang.
- $\rho_{X,Y} < 0$: tendenziell gegenläufiger linearer Zusammenhang.
- $\rho_{X,Y} = 0$: kein linearer Zusammenhang; ein nichtlinearer Zusammenhang kann trotzdem stark sein.

Der Beweis / Die Herleitung

Standardisiere beide Variablen:

$$U = \frac{X - E(X)}{\mathsf{sd}(X)}, \qquad V = \frac{Y - E(Y)}{\mathsf{sd}(Y)}.$$

Dann gilt

$$E(U^2) = E(V^2) = 1$$

und

$$E(UV) = \rho_{X,Y}.$$

Nach der Cauchy-Schwarz-Ungleichung gilt

$$|E(UV)| \leq \sqrt{E(U^2)E(V^2)} = 1.$$

Daher

$$|\rho_{X,Y}| \leq 1.$$

Gleichheit tritt genau dann ein, wenn die standardisierten Variablen fast sicher linear abhängig sind. Daraus folgt bei positiven, endlichen Standardabweichungen eine Beziehung der Form

$$Y = aX + b$$

mit Wahrscheinlichkeit 1. Für $a > 0$ gilt $\rho_{X,Y} = 1$, für $a < 0$ gilt $\rho_{X,Y} = -1$.

Die Analogie & Mechanik

Die Korrelation misst, wie gut die Punkte in einem Streudiagramm auf einer steigenden oder fallenden Geraden liegen. Eine perfekte Kurve kann trotzdem Korrelation 0 besitzen, wenn sie nicht linear ist. Beispielsweise kann für eine symmetrische Zufallsvariable X und $Y = X^2$ gelten

$$\mathsf{Cov}(X, Y) = 0,$$

obwohl Y vollständig durch X bestimmt ist.

4. Häufige Missverständnisse & Edge Cases

Erwartungswert ist kein „wahrscheinlichster Wert“

Der Erwartungswert muss weder tatsächlich annehmbar noch besonders wahrscheinlich sein. Bei einem fairen Würfel gilt

$$E(X) = 3{,}5,$$

obwohl niemals $3{,}5$ Augen fallen. Erwartungswert, Median und Modus beantworten verschiedene Fragen.

Langfristiger Durchschnitt bedeutet keine kurzfristige Garantie

Das Gesetz der großen Zahlen sagt nicht, dass nach wenigen Versuchen ein Ausgleich „fällig“ ist. Nach zehn roten Roulette-Ergebnissen wird Schwarz im nächsten Spiel nicht wahrscheinlicher, sofern die Spiele unabhängig sind. Das Gesetz betrifft den Durchschnitt vieler Wiederholungen, nicht eine kompensierende Kraft im nächsten Versuch.

Symmetrie reicht nur bei existierendem Erwartungswert

Eine symmetrische Verteilung kann keinen Erwartungswert besitzen. Das scheinbare Argument „links und rechts heben sich auf“ ist ungültig, wenn beide Beiträge divergieren.

Erwartungswerte brauchen keine Unabhängigkeit für Summen

Die Formel

$$E(X + Y) = E(X) + E(Y)$$

gilt auch bei Abhängigkeit. Unabhängigkeit wird erst für spezielle Produkt- und Varianzregeln benötigt.

Nichtlineare Transformationen dürfen nicht durch den Erwartungswert gezogen werden

Im Allgemeinen ist

$$E(g(X)) \neq g(E(X)).$$

Das Gleichheitszeichen ist bei linearem g korrekt, bei gekrümmtem g aber typischerweise falsch. Besonders häufig wird fälschlich

$$E(X^2) = (E(X))^2$$

gesetzt. Tatsächlich gilt

$$E(X^2) = (E(X))^2 + \mathsf{Var}(X).$$

Verschiebung verändert die Varianz nicht

Ein additives b in

$$Y = aX + b$$

verändert zwar den Erwartungswert, nicht aber die Streuung. Nur der Skalierungsfaktor a wirkt auf Varianz und Standardabweichung.

Bei Summen darf der Kovarianzterm nicht vergessen werden

Ohne Unabhängigkeit gilt nicht automatisch

$$\mathsf{Var}(X+Y) = \mathsf{Var}(X) + \mathsf{Var}(Y).$$

Korrekt ist

$$\mathsf{Var}(X+Y) = \mathsf{Var}(X) + \mathsf{Var}(Y) + 2\,\mathsf{Cov}(X,Y).$$

Das Chuck-a-Luck-Beispiel zeigt den Unterschied: Einsätze auf zwei Zahlen im selben Wurf sind abhängig und besitzen negative Kovarianz.

Unabhängigkeit ist stärker als Unkorreliertheit

Aus Unabhängigkeit folgt bei existierenden zweiten Momenten

$$\mathsf{Cov}(X,Y) = 0.$$

Die Umkehrung gilt im Allgemeinen nicht. Eine Kovarianz von 0 beseitigt nur lineares gemeinsames Schwanken. Nichtlineare Abhängigkeiten bleiben möglich.

Korrelation ist keine Kausalität

Eine hohe Korrelation sagt nicht, dass Änderungen in X Änderungen in Y verursachen. Eine dritte Variable, gemeinsame Trends, Auswahlmechanismen oder Zufall können den Zusammenhang erzeugen.

Korrelation kann undefiniert sein

Ist eine Variable konstant, gilt

$$\mathsf{sd}(X) = 0.$$

Dann enthält die Korrelationsformel eine Division durch 0 und ist nicht definiert. Auch bei nicht existierenden oder unendlichen zweiten Momenten sind Varianz, Kovarianz oder Korrelation nicht als endliche Größen verfügbar.

Eine Dichtehöhe ist keine Wahrscheinlichkeit

Für stetige Zufallsvariablen gilt typischerweise

$$P(X = x) = 0.$$

Wahrscheinlichkeiten entstehen durch Integration über Intervalle oder Flächen. Eine Dichte kann sogar größer als 1 sein, solange ihre gesamte Fläche beziehungsweise ihr gesamtes Volumen 1 ergibt.

Bedingte stetige Dichten sind subtil

Die Formel

$$f_{X|Y}(x \mid y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$$

setzt $f_Y(y) > 0$ voraus. Obwohl bei stetigen Variablen $P(Y = y) = 0$ gilt, kann eine bedingte Dichte dennoch sinnvoll über Dichten beziehungsweise reguläre bedingte Verteilungen definiert werden. Man darf die diskrete Punktwahrscheinlichkeitslogik nicht wörtlich übertragen.

Randverteilungen bestimmen die gemeinsame Verteilung nicht

Zwei Paare von Zufallsvariablen können dieselben Randverteilungen besitzen, aber völlig verschiedene Abhängigkeitsstrukturen. Erst bei Unabhängigkeit ist die gemeinsame Verteilung durch das Produkt der Ränder festgelegt.

Perfekte Korrelation verlangt eine fast sichere lineare Beziehung

Die Aussage

$$|\rho_{X,Y}| = 1$$

bedeutet nicht bloß „ungefähr sehr linear“, sondern eine exakte affine Beziehung mit Wahrscheinlichkeit 1, sofern beide Varianzen positiv und endlich sind.

Hinweis zu einer Formel im Foliensatz

In der allgemeinen Summenformel auf Seite 20 erscheint in der ausgeschriebenen Summe offenbar zweimal $\mathrm{Var}(X_1)$. Mathematisch korrekt lautet die Regel für unabhängige Zufallsvariablen

$$\mathrm{Var}(X_1 + \cdots + X_n) = \mathrm{Var}(X_1) + \mathrm{Var}(X_2) + \cdots + \mathrm{Var}(X_n).$$

5. Active Recall (Wissenstest)

1. Eine Zufallsvariable X besitzt den Erwartungswert $E(X) = 4$ und die Varianz $\mathrm{Var}(X) = 9$. Definiere $Y = -2X + 7$. Leite Erwartungswert, Varianz und Standardabweichung von Y her und erkläre anschaulich, welche Rolle Spiegelung, Skalierung und Verschiebung jeweils spielen.
2. Zwei Spielstrategien besitzen denselben erwarteten Gewinn, aber unterschiedliche Varianzen. Erkläre, warum daraus keine widersprüchlichen Aussagen folgen. Nutze das Chuck-a-Luck-Beispiel, um zu begründen, weshalb eine Verdopplung desselben Einsatzes riskanter sein kann als derselbe Gesamteinsatz über zwei unabhängige Spiele.
3. Leite die allgemeine Formel für $\mathrm{Var}(X + Y)$ aus der Varianzdefinition her. Erkläre anschließend, warum die vereinfachte Additionsregel bei Unabhängigkeit gilt und weshalb Unkorreliertheit dafür bereits ausreicht, obwohl sie nicht dasselbe wie Unabhängigkeit ist.
4. Gegeben sei eine gemeinsame diskrete Wahrscheinlichkeitsfunktion $p_{X,Y}(x,y)$. Beschreibe Schritt für Schritt, wie du daraus eine Randverteilung, eine bedingte Verteilung und einen Unabhängigkeitstest konstruierst. Erkläre bei jedem Schritt, welche Information verloren geht oder neu fokussiert wird.
5. Konstruiere oder erläutere ein Beispiel, in dem X und Y stark abhängig sind, aber $\rho_{X,Y} = 0$ gilt. Zeige rechnerisch oder symmetriegestützt, warum die Kovarianz verschwindet, und erkläre, was dieses Beispiel über die Grenzen der Korrelation aussagt.

6. Lösungen zum Active Recall

1. Aus der Linearität folgt

$$E(Y) = -2E(X) + 7 = -1.$$

Für die Varianz gilt

$$\mathsf{Var}(Y) = (-2)^2 \,\mathsf{Var}(X) = 36,$$

und damit

$$\mathsf{sd}(Y) = |-2|\,\mathsf{sd}(X) = 6.$$

Das Minus spiegelt, der Betrag 2 verdoppelt alle Abstände, und 7 verschiebt nur die Lage.

2. Der Erwartungswert beschreibt die langfristige Durchschnittslage, die Varianz die Schwankung. Bei $2X_6$ wird dieselbe Zufallsschwankung verdoppelt, daher vervierfacht sich die Varianz. Bei $X_6 + Y_6$ stammen die Schwankungen aus unabhängigen Spielen und die Varianzen addieren sich nur, sodass das Risiko geringer ist.

3. Durch Ausmultiplizieren der zentrierten Summe erhält man

$$\mathsf{Var}(X + Y) = \mathsf{Var}(X) + \mathsf{Var}(Y) + 2\,\mathsf{Cov}(X, Y).$$

Unabhängigkeit impliziert Kovarianz 0. Für die Varianzaddition genügt bereits $\mathsf{Cov}(X, Y) = 0$; vollständige Unabhängigkeit ist stärker als nötig.

4. Randverteilung: über die andere Variable summieren. Bedingte Verteilung: die relevante gemeinsame Zellwahrscheinlichkeit durch die passende Randsumme teilen. Unabhängigkeit: prüfen, ob für alle Zellen

$$p_{X,Y}(x, y) = p_X(x)p_Y(y)$$

gilt. Marginalisierung entfernt Kopplungsinformation; Konditionierung fokussiert auf eine Teilgruppe; der Unabhängigkeitstest prüft, ob diese Fokussierung die Verteilung verändert.

5. Wähle eine um 0 symmetrische Zufallsvariable X und setze

$$Y = X^2.$$

Dann ist Y vollständig durch X bestimmt. Wegen der Symmetrie ist jedoch typischerweise $E(X) = 0$ und $E(X^3) = 0$, sodass

$$\mathsf{Cov}(X, Y) = E(X^3) - E(X)E(X^2) = 0.$$

Korrelation erkennt nur lineare, nicht beliebige funktionale Abhängigkeit.