1. Das Big Picture (Chunking)

Dieses Kapitel löst das Grundproblem der statistischen Inferenz: Aus einer endlichen, zufälligen Stichprobe sollen plausible Aussagen über eine unbekannte Grundgesamtheit beziehungsweise über die Parameter eines statistischen Modells gewonnen werden. Statt jede einzelne Häufigkeit der Grundgesamtheit zu schätzen, wird die Verteilung durch wenige Parameter beschrieben und anschließend so angepasst, dass die tatsächlich beobachteten Daten unter dem Modell möglichst plausibel sind. Die Maximum-Likelihood-Methode ist deshalb zentral, weil sie für viele Verteilungen ein einheitliches Rezept zur Konstruktion von Schätzern liefert und die Grundlage für spätere Konfidenzintervalle und Tests bildet.

2. Zentrale Definitionen

Grundgesamtheit

- **Fachliche Definition:** Die Grundgesamtheit ist die Menge aller Einheiten oder theoretisch möglichen Wiederholungen eines Vorgangs, über die eine statistische Aussage getroffen werden soll. Ihr Umfang wird häufig mit N bezeichnet.
- **Feynman-Übersetzung:** Das ist die komplette Welt, über die du etwas wissen willst. Die Stichprobe ist nur das kleine Fenster, durch das du auf diese Welt schaust.

Stichprobe

- **Fachliche Definition:** Eine Stichprobe besteht aus n beobachteten Einheiten beziehungsweise Realisationen $x_1, \dots, x_n$, die nach einem festgelegten Auswahlmechanismus aus der Grundgesamtheit oder aus einem statistischen Modell stammen.
- **Feynman-Übersetzung:** Weil du nicht alle untersuchen kannst, schaust du dir nur einige Fälle an und hoffst, dass sie das Ganze ausreichend gut widerspiegeln.

Merkmalsausprägung, absolute Häufigkeit und relative Häufigkeit

- **Fachliche Definition:** Nimmt ein Merkmal die Ausprägungen $a_1, \dots, a_J$ an, dann bezeichnet h_j die Anzahl der Einheiten mit Ausprägung a_j. Die relative Häufigkeit lautet $f_j = h_j/N$.
- **Feynman-Übersetzung:** h_j sagt, wie viele Fälle zu einer Kategorie gehören. f_j sagt, welcher Anteil aller Fälle das ist.

Statistische Inferenz

- **Fachliche Definition:** Statistische Inferenz bezeichnet das probabilistisch abgesicherte Schließen von beobachteten Stichprobendaten auf unbekannte Eigenschaften der zugrunde liegenden Grundgesamtheit oder eines statistischen Modells.
- **Feynman-Übersetzung:** Du siehst nur einen Ausschnitt und versuchst daraus begründet auf das unsichtbare Ganze zu schließen, ohne so zu tun, als wärst du dir völlig sicher.

Statistisches Modell

- **Fachliche Definition:** Ein statistisches Modell ist eine Menge von Wahrscheinlichkeitsverteilungen $\{P_\theta : \theta \in \Theta\}$, die als mögliche datenerzeugende Mechanismen betrachtet werden. Der Parameter θ bestimmt, welche konkrete Verteilung aus der Modellfamilie gilt.
- **Feynman-Übersetzung:** Ein Modell ist eine vereinfachte Schablone für die Wirklichkeit. Der Parameter ist der Regler, mit dem du die Schablone an die Daten anpasst.

Parametrisches Modell

- **Fachliche Definition:** Ein Modell heißt parametrisch, wenn jede Verteilung durch einen endlichdimensionalen Parameter θ beschrieben wird, beispielsweise durch $\theta = (\mu, \sigma^2)$ bei einer Normalverteilung.

- **Feynman-Übersetzung:** Statt tausende Einzelheiten zu speichern, beschreibst du die Form der Verteilung mit wenigen Zahlen, etwa Lage und Streuung.

Parameter, Schätzer und Schätzwert

- **Fachliche Definition:** Ein Parameter θ ist eine feste, aber unbekannte Eigenschaft des Modells. Ein Schätzer $\hat{\theta} = T(X_1, \dots, X_n)$ ist eine Zufallsvariable, weil er von der zufälligen Stichprobe abhängt. Nach Einsetzen der beobachteten Daten entsteht der konkrete Schätzwert $T(x_1, \dots, x_n)$.
- **Feynman-Übersetzung:** Der Parameter ist die unbekannte Zielzahl. Der Schätzer ist das Rechenrezept. Der Schätzwert ist das Ergebnis, das dieses Rezept für deine konkreten Daten ausgibt.

Unabhängig und identisch verteilt

- **Fachliche Definition:** $X_1, \dots, X_n$ sind unabhängig und identisch verteilt, kurz iid, wenn jede Zufallsvariable dieselbe Verteilung besitzt und keine Beobachtung zusätzliche Information über eine andere liefert.
- **Feynman-Übersetzung:** Jede Beobachtung folgt denselben Spielregeln, und das Ergebnis eines Falls verändert die Chancen der anderen Fälle nicht.

Approximationsfehler

- **Fachliche Definition:** Der Approximationsfehler entsteht, weil die wahre Verteilung der Grundgesamtheit in der Regel nicht exakt zu der gewählten Modellfamilie gehört. Er misst konzeptionell die Abweichung zwischen Realität und Modellschablone.
- **Feynman-Übersetzung:** Selbst mit perfekten Daten kann deine Schablone falsch geformt sein. Dann passt sie nie vollständig zur Wirklichkeit.

Schätzfehler

- **Fachliche Definition:** Der Schätzfehler entsteht, weil $\hat{\theta}$ aus einer endlichen Zufallsstichprobe berechnet wird und deshalb von Stichprobe zu Stichprobe schwankt.
- **Feynman-Übersetzung:** Auch mit einer guten Schablone stellst du die Regler nicht exakt ein, weil du nur wenige zufällige Beobachtungen gesehen hast.

Wahrscheinlichkeitsfunktion und Dichte

- **Fachliche Definition:** Bei diskreten Verteilungen gibt $P_\theta(X = x)$ die Wahrscheinlichkeit eines einzelnen Werts an. Bei stetigen Verteilungen beschreibt $f_\theta(x)$ eine Dichte; für einen einzelnen Punkt gilt $P_\theta(X = x) = 0$, während Intervallwahrscheinlichkeiten durch Integration der Dichte entstehen.
- **Feynman-Übersetzung:** Bei diskreten Daten kann ein einzelner Wert echte Wahrscheinlichkeit besitzen. Bei stetigen Daten zählt nur die Fläche über einem Bereich, nicht die Höhe an einem einzigen Punkt.

Likelihood

- **Fachliche Definition:** Nach Beobachtung von $x_1, \dots, x_n$ ist die Likelihood $L(\theta)$ die gemeinsame Wahrscheinlichkeitsfunktion beziehungsweise gemeinsame Dichte der beobachteten Daten, aufgefasst als Funktion des unbekannten Parameters θ.
- **Feynman-Übersetzung:** Du hältst die Daten fest und drehst am Parameterregler. Die Likelihood zeigt, bei welcher Reglereinstellung die beobachteten Daten am besten zum Modell passen.

Log-Likelihood

- **Fachliche Definition:** Die Log-Likelihood ist $\ell(\theta) = \log L(\theta)$. Da der Logarithmus streng monoton wächst, besitzt sie dieselben Maximierer wie $L(\theta)$, verwandelt aber Produkte in Summen.

- **Feynman-Übersetzung:** Die Log-Likelihood ist dieselbe Rangliste der Parameter, nur in einer Rechenform, die viel leichter abzuleiten und numerisch stabiler ist.

Maximum-Likelihood-Schätzer

- **Fachliche Definition:** Ein Maximum-Likelihood-Schätzer ist ein Parameterwert $\hat{\theta}_{\mathrm{ML}}$, der die Likelihood beziehungsweise Log-Likelihood über dem zulässigen Parameterraum Θ maximiert.
- **Feynman-Übersetzung:** Wähle die Reglereinstellung, unter der das, was du tatsächlich gesehen hast, am wenigsten überraschend erscheint.

3. Formeln, Beweise & Intuition

3.1 Grundgesamtheit: Von absoluten zu relativen Häufigkeiten

Die Formel

$$f_j = \frac{h_j}{N}, \qquad j = 1, \dots, J.$$

Zusätzlich gelten

$$\sum_{j=1}^{J} h_j = N \qquad \text{und} \qquad \sum_{j=1}^{J} f_j = 1.$$

Dekonstruktion

- N: Anzahl aller Einheiten in der Grundgesamtheit.
- J: Anzahl der möglichen Merkmalsausprägungen.
- a_j: die j-te Merkmalsausprägung.
- h_j: absolute Häufigkeit der Ausprägung a_j.
- f_j: relativer Anteil beziehungsweise Auswahlwahrscheinlichkeit für a_j.

Der Beweis / Die Herleitung

Die N Einheiten werden vollständig auf die J Kategorien verteilt. Deshalb ist die Summe der absoluten Häufigkeiten gleich N:

$$\sum_{j=1}^{J} h_j = N.$$

Teilt man jede Kategoriehäufigkeit durch die Gesamtzahl N, erhält man ihren Anteil:

$$f_j = \frac{h_j}{N}.$$

Durch Summieren folgt

$$\sum_{j=1}^{J} f_j = \sum_{j=1}^{J} \frac{h_j}{N} = \frac{1}{N} \sum_{j=1}^{J} h_j = \frac{N}{N} = 1.$$

Für das Obstbeispiel der Vorlesung ergibt sich etwa

$$f_{\text{Apfel}} = \frac{500}{1000} = 0{,}5.$$

Die Analogie & Mechanik

Stelle dir eine Urne mit N Kugeln vor. h_j Kugeln tragen die Farbe a_j. Der Anteil f_j ist genau die Chance, bei einem zufälligen Zug eine Kugel dieser Farbe zu erhalten. Wird h_j bei festem N größer, steigt f_j proportional. Wird N bei festem h_j größer, sinkt f_j, weil dieselbe Kategorie in einer größeren Gesamtmenge verdünnt wird.

3.2 Erwartete Stichprobenhäufigkeit einer Kategorie

Die Formel

Definiere die Stichprobenhäufigkeit der Kategorie a_j durch

$$H_j = \sum_{i=1}^{n} \mathbf{1}\{X_i = a_j\}.$$

Dann gilt bei identischen Auswahlwahrscheinlichkeiten

$$\mathbb{E}[H_j] = nf_j.$$

Dekonstruktion

- n: Stichprobenumfang.
- X_i: Merkmalswert der i-ten gezogenen Einheit.
- $\mathbf{1}\{X_i = a_j\}$: Indikator, der den Wert 1 annimmt, wenn $X_i = a_j$ gilt, und sonst 0.
- H_j: Anzahl der Beobachtungen mit Ausprägung a_j in der Stichprobe.
- f_j: Wahrscheinlichkeit der Ausprägung a_j bei einer einzelnen Ziehung.

Der Beweis / Die Herleitung

Für jeden Indikator gilt

$$\mathbb{E}\left[\mathbf{1}\{X_i = a_j\}\right] = 1 \cdot P(X_i = a_j) + 0 \cdot P(X_i \neq a_j) = f_j.$$

Mit der Linearität des Erwartungswerts folgt

$$\mathbb{E}[H_j] = \mathbb{E}\left[\sum_{i=1}^{n} \mathbf{1}\{X_i = a_j\}\right] = \sum_{i=1}^{n} \mathbb{E}\left[\mathbf{1}\{X_i = a_j\}\right] = \sum_{i=1}^{n} f_j = nf_j.$$

Für $n = 50$ und $f_{\text{Apfel}} = 0{,}5$ erhält man

$$\mathbb{E}[H_{\text{Apfel}}] = 50 \cdot 0{,}5 = 25.$$

Die Analogie & Mechanik

Wenn eine Münze bei jedem Wurf mit Wahrscheinlichkeit 0,5 Kopf zeigt, erwartest du bei 50 Würfen ungefähr 25 Köpfe. Das ist kein Versprechen für exakt 25, sondern der langfristige Schwerpunkt

vieler wiederholter Stichproben. Ein größeres n vergrößert die erwartete absolute Zahl, während der erwartete Anteil bei f_j bleibt.

3.3 Parametrisches Modell und die Informationskompression

Die Formel

Ein Beispielmodell lautet

$$X \sim \mathcal{N}(\mu, \sigma^2).$$

Für eine Stichprobe wird häufig angenommen

$$X_1, \dots, X_n \overset{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2).$$

Allgemeiner schreibt man

$$X_1, \dots, X_n \overset{\text{iid}}{\sim} P_\theta, \qquad \theta \in \Theta.$$

Dekonstruktion

- X: Zufallsvariable für das interessierende Merkmal.
- $\mathcal{N}(\mu, \sigma^2)$: Normalverteilung.
- μ: Lageparameter beziehungsweise Erwartungswert.
- σ^2: Varianz als Maß der Streuung.
- P_θ: Verteilung aus einer parametrischen Modellfamilie.
- θ: unbekannter Parameter oder Parametervektor.
- Θ: Menge aller zulässigen Parameterwerte.

Der Beweis / Die Herleitung

Hier gibt es keinen mathematischen Beweis, weil die Modellwahl eine Annahme ist. Die Logik lautet:

1. Die wahre Grundgesamtheit kann durch sehr viele Einzelhäufigkeiten beschrieben werden.
2. Eine parametrische Modellfamilie ersetzt diese hochdimensionale Beschreibung durch wenige Parameter.
3. Bei einer Normalverteilung werden beispielsweise nur μ und σ^2 geschätzt.
4. Der Preis dieser Kompression ist ein möglicher Approximationsfehler.

Man kann den gedanklichen Ablauf so darstellen:

$$\text{wahre Grundgesamtheit} \longrightarrow \text{gewählte Modellfamilie } \{P_\theta : \theta \in \Theta\} \longrightarrow \text{Schätzung } \hat{\theta}.$$

Die Analogie & Mechanik

Eine Landkarte enthält nicht jedes Blatt und jeden Stein, sondern wenige Strukturen, die für den Zweck wichtig sind. Eine einfachere Karte ist leichter zu lesen und aus wenigen Beobachtungen zu erstellen, kann aber relevante Details verschlucken. Ein komplexeres Modell kann die Realität genauer nachzeichnen, braucht jedoch mehr Daten, weil mehr Regler eingestellt werden müssen.

3.4 Warum Unabhängigkeit ein Produkt erzeugt

Die Formel

Für unabhängige Beobachtungen gilt bei diskreten Daten

$$P_\theta(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^{n} P_\theta(X_i = x_i).$$

Bei stetigen Daten gilt entsprechend für die gemeinsame Dichte

$$f_\theta(x_1, \dots, x_n) = \prod_{i=1}^{n} f_\theta(x_i).$$

Dekonstruktion

- x_i: beobachteter Wert der i-ten Zufallsvariable.
- $P_\theta(X_i = x_i)$: Einzelwahrscheinlichkeit bei diskreten Daten.
- $f_\theta(x_i)$: Einzeldichte bei stetigen Daten.
- $\prod_{i=1}^{n}$: Produkt über alle Beobachtungen.

Der Beweis / Die Herleitung

Für zwei unabhängige Zufallsvariablen ist Unabhängigkeit definiert durch

$$P_\theta(X_1 = x_1, X_2 = x_2) = P_\theta(X_1 = x_1) P_\theta(X_2 = x_2).$$

Wendet man dieselbe Eigenschaft schrittweise auf n Beobachtungen an, entsteht das Produkt aller Einzelbeiträge. Die Annahme identischer Verteilung sorgt zusätzlich dafür, dass jeder Beitrag aus derselben Wahrscheinlichkeitsfunktion oder Dichte stammt.

Die Analogie & Mechanik

Stelle dir mehrere unabhängige Zugangskontrollen vor. Damit die gesamte Ereigniskette eintritt, muss jede einzelne Kontrolle das beobachtete Ergebnis liefern. Die Gesamtplausibilität ist daher das Produkt der Einzelplausibilitäten. Ein einziger extrem kleiner Faktor zieht das gesamte Produkt stark nach unten; genau deshalb bestrafen Likelihoods Parameterwerte, unter denen auch nur einige Beobachtungen sehr untypisch wären.

3.5 Wahrscheinlichkeitsrechnung und statistische Inferenz: dieselbe Formel, andere Blickrichtung

Die Formel

In der Wahrscheinlichkeitsrechnung ist θ fest und die Zufallsvariable ist ungewiss:

$$P_\theta(X \in A).$$

In der statistischen Inferenz sind die Daten $x_1, \dots, x_n$ beobachtet und damit fest; variiert wird der Parameter:

$$L(\theta; x_1, \dots, x_n).$$

Dekonstruktion

- A: interessierendes Ereignis oder Werteintervall.
- θ: gegebener Parameter in der Wahrscheinlichkeitsrechnung, unbekannter Parameter in der Inferenz.
- $x_1, \dots, x_n$: festgehaltene Beobachtungen.
- $L(\theta; x_1, \dots, x_n)$: Plausibilität der festen Daten als Funktion von θ.

Der Beweis / Die Herleitung

Die zugrunde liegende Wahrscheinlichkeitsfunktion oder Dichte ändert sich nicht. Es ändert sich nur, welches Argument als fest und welches als variabel betrachtet wird:

- Vor der Beobachtung sind $X_1, \dots, X_n$ zufällig und θ ist ein fester Modellwert.
- Nach der Beobachtung werden $x_1, \dots, x_n$ eingesetzt. Nun vergleicht man verschiedene Werte von θ.

Die Likelihood ist daher keine neue Datenverteilung, sondern eine Umdeutung derselben mathematischen Modellfunktion für eine andere Fragestellung.

Die Analogie & Mechanik

Vor einem Fußballspiel fragst du: Wie wahrscheinlich ist dieses Ergebnis, wenn die Teamstärke bekannt ist? Nach dem Spiel fragst du umgekehrt: Welche Teamstärke würde das beobachtete Ergebnis plausibel machen? Das Spiel ist nun fest; der unbekannte Regler wird rückwärts erschlossen.

3.6 Allgemeine Likelihood für diskrete und stetige Daten

Die Formel

Für unabhängige diskrete Beobachtungen lautet die Likelihood

$$L(\theta) = \prod_{i=1}^{n} P_\theta(X_i = x_i).$$

Für unabhängige stetige Beobachtungen lautet sie

$$L(\theta) = \prod_{i=1}^{n} f_\theta(x_i).$$

Dekonstruktion

- $L(\theta)$: Likelihood als Funktion des unbekannten Parameters.
- $P_\theta(X_i = x_i)$: Wahrscheinlichkeit des beobachteten diskreten Werts.
- $f_\theta(x_i)$: Dichtehöhe am beobachteten stetigen Wert.
- n: Anzahl der Beobachtungen.

Der Beweis / Die Herleitung

Die Formeln folgen direkt aus der Produktzerlegung unabhängiger Beobachtungen. Bei stetigen Verteilungen darf nicht $P_\theta(X_i = x_i)$ verwendet werden, denn

$$P_\theta(X_i = x_i) = 0$$

für jeden einzelnen Punkt. Relevant ist stattdessen, wie viel Dichte das Modell in der unmittelbaren Umgebung des beobachteten Werts platziert. Formal lässt sich die lokale Intervallwahrscheinlichkeit für kleines $\Delta > 0$ approximieren durch

$$P_\theta(x_i \le X_i \le x_i + \Delta) \approx f_\theta(x_i)\Delta.$$

Für n unabhängige Beobachtungen wäre der gemeinsame Faktor näherungsweise

$$\prod_{i=1}^{n} f_\theta(x_i)\Delta^n.$$

Da Δ^n nicht von θ abhängt, maximiert derselbe Parameter das Produkt der Dichten.

Die Analogie & Mechanik

Bei stetigen Daten ist die Dichte wie die Bevölkerungsdichte auf einer Landkarte: Die Dichte an einem exakten Punkt ist keine Einwohnerzahl, aber eine hohe Dichte bedeutet, dass in einer kleinen Umgebung viele Fälle zu erwarten sind. Eine Dichte darf sogar größer als 1 sein; nur die gesamte Fläche unter der Dichte muss 1 ergeben.

3.7 Definition des Maximum-Likelihood-Schätzers

Die Formel

Allgemein gilt

$$\hat{\theta}_{\mathrm{ML}} \in \arg\max_{\theta \in \Theta} L(\theta).$$

Äquivalent gilt

$$\hat{\theta}_{\mathrm{ML}} \in \arg\max_{\theta \in \Theta} \ell(\theta).$$

Bei einem eindeutigen Maximum kann statt $\in$ auch $=$ geschrieben werden.

Dekonstruktion

- $\hat{\theta}_{\mathrm{ML}}$: Maximum-Likelihood-Schätzer.
- $\arg\max$: der Parameterwert, an dem die Funktion maximal wird.
- Θ: zulässiger Parameterraum.
- $L(\theta)$: Likelihood.
- $\ell(\theta)$: Log-Likelihood.

Der Beweis / Die Herleitung

Die Maximum-Likelihood-Idee ist kein Satz, sondern ein Schätzprinzip: Unter allen zulässigen Modellen wird dasjenige ausgewählt, das den beobachteten Daten die größte gemeinsame Wahrscheinlichkeitsmasse beziehungsweise Dichte zuweist. Für differenzierbare eindimensionale Probleme sucht man zunächst innere Kandidaten über

$$\frac{\partial}{\partial\theta}\ell(\theta) = 0.$$

Danach muss geprüft werden, ob tatsächlich ein Maximum vorliegt, beispielsweise durch

$$\frac{\partial^2}{\partial\theta^2}\ell(\theta) < 0$$

am Kandidaten sowie durch einen Vergleich mit möglichen Randpunkten des Parameterraums.

Die Analogie & Mechanik

Du besitzt mehrere Kamerafokus-Einstellungen und ein bereits aufgenommenes Bild. Die beste Einstellung ist jene, unter der das beobachtete Bild am schärfsten erklärt wird. Das Nullsetzen der Ableitung findet nur Stellen ohne momentane Steigung; es garantiert noch nicht, dass du auf einem Gipfel statt in einem Tal oder auf einem flachen Plateau stehst.

3.8 Warum die Log-Likelihood denselben Maximierer besitzt

Die Formel

$$\ell(\theta) = \log L(\theta)$$

und für $L(\theta) > 0$

$$\arg\max_{\theta \in \Theta} L(\theta) = \arg\max_{\theta \in \Theta} \ell(\theta).$$

Für unabhängige Daten wird aus dem Produkt eine Summe:

$$\ell(\theta) = \log \left(\prod_{i=1}^{n} p_\theta(x_i) \right) = \sum_{i=1}^{n} \log p_\theta(x_i),$$

wobei p_θ je nach Datentyp für eine Wahrscheinlichkeitsfunktion oder Dichte steht.

Dekonstruktion

- log: natürlicher Logarithmus.
- $p_\theta(x_i)$: Einzelbeitrag der i-ten Beobachtung.
- $\ell(\theta)$: Log-Likelihood.

Der Beweis / Die Herleitung

Der Logarithmus ist streng monoton wachsend. Für zwei positive Zahlen u und v gilt daher

$$u > v \iff \log u > \log v.$$

Wenn ein Parameterwert θ_1 eine größere Likelihood als θ_2 besitzt, hat er also auch die größere Log-Likelihood. Die Rangfolge aller Parameterwerte bleibt unverändert, weshalb der Maximierer derselbe ist.

Die Rechenvereinfachung folgt aus der Logarithmusregel

$$\log(ab) = \log a + \log b.$$

Deshalb wird die Ableitung einer Summe benötigt, nicht die Produktregel für ein langes Produkt.

Die Analogie & Mechanik

Eine logarithmische Skala verändert Abstände, aber nicht die Reihenfolge. Wie bei der Umrechnung von Geldbeträgen in eine andere streng steigende Skala bleibt der reichste Wert derselbe. Zusätzlich verhindert die Logarithmierung, dass das Produkt vieler kleiner Zahlen numerisch auf 0 abrutscht.

3.9 Münzwurf: Likelihood und Maximum-Likelihood-Schätzer

Sei $Y_i = 1$ für Wappen und $Y_i = 0$ für Zahl. Es gelte

$$Y_1, \dots, Y_n \overset{\text{iid}}{\sim} \text{Bernoulli}(\pi),$$

wobei

$$P_\pi(Y_i = 1) = \pi \qquad \text{und} \qquad P_\pi(Y_i = 0) = 1 - \pi.$$

Definiere die Zahl der Wappen durch

$$k = \sum_{i=1}^{n} y_i.$$

Die Formel

Für die konkret beobachtete Reihenfolge lautet die Likelihood

$$L(\pi) = \prod_{i=1}^{n} \pi^{y_i}(1-\pi)^{1-y_i} = \pi^k(1-\pi)^{n-k}.$$

Wenn nur die Anzahl k und nicht die Reihenfolge als Beobachtung betrachtet wird, lautet die Binomialwahrscheinlichkeit

$$L_{\text{Anzahl}}(\pi) = \binom{n}{k}\pi^k(1-\pi)^{n-k}.$$

Beide führen zum selben Maximum-Likelihood-Schätzer:

$$\hat{\pi}_{\text{ML}} = \frac{k}{n}.$$

Für $n = 20$ und $k = 6$ folgt

$$\hat{\pi}_{\text{ML}} = \frac{6}{20} = 0{,}3.$$

Dekonstruktion

- π: unbekannte Wahrscheinlichkeit für Wappen.
- $1 - \pi$: Wahrscheinlichkeit für Zahl.
- n: Anzahl der Würfe.
- k: beobachtete Anzahl der Wappen.
- $n - k$: beobachtete Anzahl der Zahlen.
- $\binom{n}{k}$: Anzahl der möglichen Reihenfolgen mit genau k Wappen.

Der Beweis / Die Herleitung

Jede Beobachtung trägt den Faktor

$$\pi^{y_i}(1-\pi)^{1-y_i}$$

bei. Für $y_i = 1$ bleibt π, für $y_i = 0$ bleibt $1-\pi$. Da insgesamt k Einsen und $n-k$ Nullen beobachtet wurden, entsteht

$$L(\pi) = \pi^k(1-\pi)^{n-k}.$$

Die Log-Likelihood ist bis auf eine von π unabhängige Konstante

$$\ell(\pi) = k\log\pi + (n-k)\log(1-\pi) + C.$$

Ableiten ergibt

$$\ell'(\pi) = \frac{k}{\pi} - \frac{n-k}{1-\pi}.$$

Nullsetzen:

$$\frac{k}{\pi} = \frac{n-k}{1-\pi}.$$

Kreuzmultiplikation:

$$k(1-\pi) = \pi(n-k).$$

Ausmultiplizieren und Kürzen:

$$k - k\pi = n\pi - k\pi \Longrightarrow k = n\pi.$$

Damit

$$\hat{\pi}_{\mathrm{ML}} = \frac{k}{n}.$$

Für $0 < k < n$ ist

$$\ell''(\pi) = -\frac{k}{\pi^2} - \frac{n-k}{(1-\pi)^2} < 0,$$

also liegt ein eindeutiges inneres Maximum vor.

Der Faktor $\binom{n}{k}$ hängt nicht von π ab. Daher verschiebt er die Höhe der Likelihood, aber nicht die Stelle ihres Maximums.

Die Analogie & Mechanik

Der Schätzer spiegelt die beobachtete Erfolgsquote direkt zurück. Werden bei gleicher Zahl von Würfen mehr Wappen beobachtet, steigt der Zähler k und damit $\hat{\pi}_{\mathrm{ML}}$. Wird bei festem k die Zahl der Würfe n größer, sinkt die geschätzte Wappenwahrscheinlichkeit. Ein Parameter nahe 0 wird durch jedes beobachtete Wappen stark bestraft; ein Parameter nahe 1 wird durch jede beobachtete Zahl stark bestraft.

3.10 Poissonverteilung: Likelihood und Maximum-Likelihood-Schätzer der Rate

Es gelte

$$X_1, \dots, X_n \overset{\text{iid}}{\sim} \text{Poisson}(\lambda), \qquad \lambda \geq 0.$$

Die Wahrscheinlichkeitsfunktion einer Beobachtung ist

$$P_\lambda(X_i = x_i) = \frac{\lambda^{x_i}}{x_i!} e^{-\lambda}, \qquad x_i \in \{0, 1, 2, \dots\}.$$

Die Formel

Die Likelihood ist

$$L(\lambda) = \prod_{i=1}^{n} \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \left(\prod_{i=1}^{n} \frac{1}{x_i!} \right) \lambda^{\sum_{i=1}^{n} x_i} e^{-n\lambda}.$$

Die Log-Likelihood lautet

$$\ell(\lambda) = -\sum_{i=1}^{n} \log(x_i!) + \left(\sum_{i=1}^{n} x_i \right) \log \lambda - n\lambda.$$

Der Maximum-Likelihood-Schätzer ist

$$\hat{\lambda}_{\text{ML}} = \frac{1}{n} \sum_{i=1}^{n} x_i = \overline{x}.$$

Dekonstruktion

- λ: mittlere Ereigniszahl pro beobachteter Einheit oder Zeitspanne.
- x_i: beobachtete Ereigniszahl im i-ten Intervall.
- $x_i!$: Fakultät von x_i.
- $e^{-\lambda}$: Faktor, der sehr große Raten bestraft, wenn die beobachteten Zählwerte nicht entsprechend groß sind.
- $\overline{x}$: arithmetisches Mittel der beobachteten Zählwerte.

Der Beweis / Die Herleitung

Aus der Unabhängigkeit folgt

$$L(\lambda) = \prod_{i=1}^{n} \frac{\lambda^{x_i}}{x_i!} e^{-\lambda}.$$

Gleichartige Faktoren werden zusammengefasst:

$$\prod_{i=1}^{n} \lambda^{x_i} = \lambda^{\sum_{i=1}^{n} x_i}$$

und

$$\prod_{i=1}^{n} e^{-\lambda} = e^{-n\lambda}.$$

Logarithmieren ergibt

$$\ell(\lambda) = \sum_{i=1}^{n} \left[x_i \log \lambda - \log(x_i!) - \lambda \right].$$

Nach Sortieren der Summen folgt die oben angegebene Form. Die erste Ableitung ist

$$\ell'(\lambda) = \frac{1}{\lambda} \sum_{i=1}^{n} x_i - n.$$

Nullsetzen:

$$\frac{1}{\lambda} \sum_{i=1}^{n} x_i = n.$$

Multiplikation mit λ und Division durch n liefert

$$\hat{\lambda}_{\mathrm{ML}} = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

Falls $\sum_{i=1}^{n} x_i > 0$, gilt

$$\ell''(\lambda) = -\frac{1}{\lambda^2} \sum_{i=1}^{n} x_i < 0,$$

sodass der stationäre Punkt ein Maximum ist.

Die Analogie & Mechanik

λ ist die durchschnittliche Taktzahl eines Ereignisprozesses, etwa Anrufe pro Minute. Der Maximum-Likelihood-Schätzer sagt: Stelle den Modelltakt auf die tatsächlich beobachtete Durchschnittsrate ein. Wird die Summe $\sum x_i$ bei festem n größer, steigt $\hat{\lambda}_{\mathrm{ML}}$. Wird dieselbe Gesamtereigniszahl auf mehr Intervalle verteilt, wächst der Nenner n und die geschätzte Rate pro Intervall sinkt. Eine einzelne sehr große Beobachtung erhöht den Mittelwert unmittelbar und kann den Schätzer deutlich verschieben.

3.11 Normalverteilung mit bekannter Varianz: Likelihood für den Mittelwert

Es gelte

$$X_1, \ldots, X_n \overset{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2),$$

wobei σ^2 bekannt und μ unbekannt ist.

Die Formel

Die Dichte einer Beobachtung lautet

$$f(x_i \mid \mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right).$$

Die Likelihood lautet

$$L(\mu) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^n \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2\right).$$

Die Log-Likelihood lautet

$$\ell(\mu) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2.$$

Der Maximum-Likelihood-Schätzer ist

$$\hat{\mu}_{\mathrm{ML}} = \frac{1}{n}\sum_{i=1}^{n} x_i = \overline{x}.$$

Dekonstruktion

- μ: unbekannter Mittelwert und Lageparameter.
- σ^2: bekannte Varianz.
- $x_i - \mu$: Abweichung der Beobachtung vom angenommenen Zentrum.
- $(x_i-\mu)^2$: quadrierter Fehler.
- $\sum_{i=1}^{n}(x_i-\mu)^2$: gesamte quadratische Fehlersumme.
- $\overline{x}$: Stichprobenmittel.

Der Beweis / Die Herleitung über die Ableitung

Da der erste Term der Log-Likelihood nicht von μ abhängt, ist für die Maximierung nur

$$-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2$$

relevant. Ableiten ergibt

$$\frac{\partial}{\partial\mu}\ell(\mu) = -\frac{1}{2\sigma^2}\sum_{i=1}^{n}2(x_i-\mu)(-1).$$

Damit

$$\frac{\partial}{\partial\mu}\ell(\mu) = \frac{1}{\sigma^2}\sum_{i=1}^{n}(x_i-\mu).$$

Nullsetzen:

$$\sum_{i=1}^{n}(x_i-\mu) = 0.$$

Ausmultiplizieren:

$$\sum_{i=1}^{n} x_i - n\mu = 0.$$

Daraus folgt

$$\hat{\mu}_{\mathrm{ML}} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Die zweite Ableitung ist

$$\frac{\partial^2}{\partial \mu^2}\ell(\mu) = -\frac{n}{\sigma^2} < 0,$$

also ist das Maximum eindeutig.

Alternative Herleitung über quadratische Abstände

Da alle übrigen Terme konstant sind, ist die Maximierung von $\ell(\mu)$ gleichbedeutend mit der Minimierung von

$$Q(\mu) = \sum_{i=1}^{n}(x_i - \mu)^2.$$

Mit $\overline{x} = n^{-1}\sum_{i=1}^{n} x_i$ gilt die Zerlegung

$$\sum_{i=1}^{n}(x_i - \mu)^2 = \sum_{i=1}^{n}(x_i - \overline{x})^2 + n(\mu - \overline{x})^2.$$

Zur Herleitung schreibe

$$x_i - \mu = (x_i - \overline{x}) + (\overline{x} - \mu).$$

Nach Quadrieren und Summieren entsteht

$$\sum_{i=1}^{n}(x_i - \mu)^2 = \sum_{i=1}^{n}(x_i - \overline{x})^2 + 2(\overline{x} - \mu)\sum_{i=1}^{n}(x_i - \overline{x}) + n(\overline{x} - \mu)^2.$$

Der mittlere Term verschwindet, weil

$$\sum_{i=1}^{n}(x_i - \overline{x}) = 0.$$

Der erste Term hängt nicht von μ ab, und der zweite verbleibende Term ist genau dann minimal, wenn

$$\mu = \overline{x}.$$

Die Analogie & Mechanik

Das Stichprobenmittel ist der Balancepunkt der Daten auf einer Zahlengeraden. Verschiebst du das Modellzentrum nach links oder rechts, wächst die Summe der quadrierten Abstände. Ein kleiner Wert

von σ^2 macht die Log-Likelihood in μ steiler, weil Abweichungen durch den kleinen Nenner stärker bestraft werden; der Ort des Maximums bleibt aber $\overline{x}$. Ein großer Wert von σ^2 macht die Kurve flacher und signalisiert weniger präzise Information über μ. Wegen des Quadrierens erhalten weit entfernte Beobachtungen überproportional großes Gewicht.

3.12 Approximationsfehler und Schätzfehler als zwei getrennte Unsicherheitsquellen

Die zentrale Mechanik

Die Vorlesung trennt zwei Probleme:

1. **Modellschritt:** Passt die gewählte Familie $\{P_\theta : \theta \in \Theta\}$ überhaupt ausreichend gut zur Grundgesamtheit?
2. **Schätzschritt:** Wie genau kann der passende Parameter mit nur n Beobachtungen bestimmt werden?

Ein komplexeres Modell besitzt mehr Freiheitsgrade und kann den Approximationsfehler häufig reduzieren. Gleichzeitig verteilt sich die Stichprobeninformation auf mehr Parameter, wodurch der Schätzfehler tendenziell wachsen kann. Ein einfaches Modell hat den umgekehrten Vorteil und Nachteil.

Die Analogie & Mechanik

Du willst eine gekrümmte Strecke mit Linealsegmenten nachzeichnen. Mit sehr wenigen Segmenten ist die Form zu grob: hoher Approximationsfehler. Mit sehr vielen Segmenten könntest du die Form genau treffen, aber wenn deine Messpunkte verrauscht sind, reagiert jedes Segment stark auf Zufallsschwankungen: hoher Schätzfehler. Gute Modellierung sucht nicht maximale Komplexität, sondern ein angemessenes Gleichgewicht.

3.13 Das allgemeine Rezept der Maximum-Likelihood-Schätzung

Die Formelmechanik

1. Modell festlegen:

$$X_1, \dots, X_n \overset{\text{iid}}{\sim} P_\theta.$$

2. Likelihood aufstellen:

$$L(\theta) = \prod_{i=1}^{n} p_\theta(x_i).$$

3. Logarithmieren:

$$\ell(\theta) = \sum_{i=1}^{n} \log p_\theta(x_i).$$

4. Innere Kandidaten bestimmen:

$$\nabla_\theta \ell(\theta) = 0.$$

5. Maximum prüfen und Rand des Parameterraums untersuchen.
6. Gefundenen Parameterwert als Funktion der Daten schreiben:

$$\hat{\theta}_{\mathrm{ML}} = T(X_1, \ldots, X_n).$$

Dekonstruktion

- p_θ: Wahrscheinlichkeitsfunktion oder Dichte.
- ∇_θ: Gradient nach allen Komponenten eines Parametervektors.
- T: aus der Optimierung resultierende Schätzfunktion.

Der Beweis / Die Herleitung

Das Rezept kombiniert drei Prinzipien:

- Unabhängigkeit erzeugt ein Produkt der Einzelbeiträge.
- Der Logarithmus macht daraus eine Summe, ohne den Maximierer zu verändern.
- Differentialrechnung findet Kandidaten für Extremstellen.

Die Optimierung ist erst vollständig, wenn Zulässigkeitsbedingungen, Randpunkte und die Art der Extremstelle geprüft wurden.

Die Analogie & Mechanik

Das Verfahren ist wie das Abstimmen eines Radios: Zuerst wählst du das richtige Frequenzband, dann definierst du ein Maß für Signalqualität, anschließend drehst du den Regler bis zum stärksten Signal. Ein mathematisch stationärer Punkt ist nur eine Stelle, an der du den Regler kurzfristig nicht verbessern kannst; Randlösungen und mehrere Gipfel müssen weiterhin berücksichtigt werden.

4. Häufige Missverständnisse & Edge Cases

Likelihood ist nicht dasselbe wie Wahrscheinlichkeit des Parameters.

In der klassischen Maximum-Likelihood-Sicht ist θ kein Zufallsereignis. $L(\theta)$ muss sich daher über θ weder zu 1 summieren noch zu 1 integrieren. Die Likelihood vergleicht Parameterwerte relativ zueinander, nachdem die Daten feststehen.

Bei stetigen Daten ist eine Dichtehöhe keine Punktwahrscheinlichkeit.

Für stetige X gilt $P(X = x) = 0$. Eine Dichte $f_\theta(x) > 1$ ist dennoch möglich, solange die gesamte Fläche unter der Dichte 1 beträgt. Der Vergleich von Dichtewerten ist für die Likelihood zulässig, aber die Dichte selbst darf nicht als Wahrscheinlichkeit eines exakten Messwerts interpretiert werden.

Das Nullsetzen der Ableitung reicht nicht aus.

Die Gleichung $\ell'(\theta) = 0$ liefert nur innere Kandidaten. Der Punkt kann ein Minimum, ein Sattelpunkt oder Teil eines Plateaus sein. Zusätzlich müssen zweite Ableitungen, globale Funktionswerte und die Ränder von Θ geprüft werden.

Das Maximum kann am Rand liegen.

Bei $k = 0$ Wappen lautet der Bernoulli-Schätzer $\hat{\pi}_{\mathrm{ML}} = 0$; bei $k = n$ gilt $\hat{\pi}_{\mathrm{ML}} = 1$. In beiden Fällen gibt es keinen inneren stationären Punkt. Bei Poisson-Daten mit $x_1 = \cdots = x_n = 0$ liegt das Maximum bei $\hat{\lambda}_{\mathrm{ML}} = 0$, sofern 0 zum Parameterraum gehört.

Eine beobachtete Reihenfolge und eine beobachtete Anzahl sind nicht exakt dasselbe Ereignis.

Für eine konkrete Münzwurfreihenfolge fehlt der Faktor $\binom{n}{k}$; für das Ereignis „genau k Wappen in beliebiger Reihenfolge“ gehört er dazu. Da der Faktor nicht von π abhängt, ist der Maximum-Likelihood-Schätzer in beiden Fällen identisch. Die Wahrscheinlichkeitswerte selbst sind jedoch verschieden.

Unabhängigkeit ist eine starke Modellannahme.

Zeitreihen, räumliche Daten, Haushaltsdaten oder wiederholte Messungen derselben Person sind oft abhängig. Dann ist das Produkt der marginalen Einzelverteilungen im Allgemeinen nicht die korrekte gemeinsame Likelihood. Eine naive iid-Analyse kann insbesondere die tatsächliche Unsicherheit unterschätzen.

Identische Verteilung kann ebenfalls verletzt sein.

Wenn sich Messbedingungen, Gruppen oder Zeitpunkte unterscheiden, können die X_i verschiedene Verteilungen besitzen. Dann muss das Modell diese Unterschiede, beispielsweise durch gruppenspezifische Parameter oder erklärende Variablen, abbilden.

Ziehen ohne Zurücklegen aus einer endlichen Grundgesamtheit erzeugt Abhängigkeit.

Nach einer Ziehung verändert sich die Zusammensetzung der verbleibenden Grundgesamtheit. Die iid-Annahme ist dann nicht exakt. Bei einer sehr großen Grundgesamtheit und kleinem Stichprobenanteil kann sie jedoch eine brauchbare Approximation sein.

Ein gutes Maximum kann in einem schlechten Modell liegen.

Maximum Likelihood findet den bestpassenden Parameter innerhalb der gewählten Modellfamilie. Wenn die Normalverteilung die Datenform schlecht approximiert, macht ein exakt berechnetes $\widehat{\mu}_{\mathrm{ML}}$ das Modell nicht automatisch angemessen. Modellkontrolle und inhaltliche Plausibilität bleiben notwendig.

Approximationsfehler und Schätzfehler dürfen nicht verwechselt werden.

Mehr Daten reduzieren typischerweise den Schätzfehler, beheben aber keinen systematischen Modellfehler. Wenn die Modellfamilie falsch ist, kann eine riesige Stichprobe lediglich sehr präzise den bestmöglichen, aber weiterhin unpassenden Parameter innerhalb dieses falschen Modells bestimmen.

Maximum-Likelihood-Schätzer sind nicht automatisch unverzerrt.

Die Beispiele der Vorlesung liefern für π, λ und μ jeweils das Stichprobenmittel beziehungsweise eine Stichprobenquote. Daraus darf nicht geschlossen werden, dass jeder Maximum-Likelihood-Schätzer in kleinen Stichproben erwartungstreu ist. Maximum Likelihood optimiert die Datenplausibilität, nicht direkt die Unverzerrtheit.

Ausreißer können Mittelwert-Schätzer stark beeinflussen.

Sowohl beim Poisson-Modell als auch beim Normalmodell mit bekannter Varianz ist der Maximum-Likelihood-Schätzer ein arithmetisches Mittel. Eine extreme Beobachtung verändert die Summe im Zähler direkt. Beim Normalmodell verstärkt die quadratische Fehlerfunktion den Einfluss weit entfernter Werte.

Sehr kleine Likelihoodwerte verursachen numerische Probleme.

Das Produkt vieler Zahlen zwischen 0 und 1 kann im Computer numerisch zu 0 werden, obwohl es mathematisch positiv ist. Die Log-Likelihood ersetzt das Produkt durch eine Summe und ist daher nicht nur algebraisch, sondern auch numerisch günstiger.

Der Logarithmus benötigt positive Likelihoodbeiträge.

Wenn ein Parameterwert einer beobachteten Ausprägung Wahrscheinlichkeit oder Dichte 0 zuweist, gilt $L(\theta) = 0$ und formal $\ell(\theta) = -\infty$. Dieser Parameterwert ist gegenüber jedem Wert mit positiver Likelihood ausgeschlossen, muss aber bei Randanalysen sorgfältig behandelt werden.

Nicht identifizierbare Parameter können nicht eindeutig geschätzt werden.

Wenn verschiedene Parameterwerte exakt dieselbe Verteilung der Daten erzeugen, besitzt die Likelihood mehrere gleich hohe Maxima. Dann ist der Parameter durch die Daten und das Modell nicht eindeutig bestimmt; mehr Rechenaufwand löst dieses Strukturproblem nicht.

Einheiten und Beobachtungsintervalle verändern Poisson-Raten.

Eine Rate von λ Ereignissen pro Minute entspricht nicht demselben Zahlenwert pro Stunde. Wird die Intervalllänge mit dem Faktor c skaliert, skaliert der Erwartungswert bei homogener Rate ebenfalls mit c. Daten und Parameter müssen deshalb auf dieselbe Einheit bezogen sein.

5. Active Recall (Wissenstest)

Frage 1

Erkläre präzise, warum $L(\theta)$ keine Wahrscheinlichkeitsverteilung über θ ist. Beschreibe dabei, welche Größen vor und nach Beobachtung der Daten als variabel beziehungsweise fest betrachtet werden und warum eine Dichte bei stetigen Daten trotzdem für die Likelihood verwendet werden kann.

Frage 2

Bei n unabhängigen Münzwürfen werden k Wappen beobachtet. Leite $\hat{\pi}_{\mathrm{ML}}$ vollständig aus der Log-Likelihood her. Erkläre zusätzlich, warum der Faktor $\binom{n}{k}$ den Schätzer nicht verändert und was bei $k = 0$ beziehungsweise $k = n$ mit der üblichen Ableitungsstrategie passiert.

Frage 3

Für fünf gleich lange Zeitintervalle werden die Poisson-Zählwerte $0, 2, 1, 4, 3$ beobachtet. Bestimme den Maximum-Likelihood-Schätzer für λ durch Herleitung aus der Likelihood. Erkläre anschließend, wie sich der Schätzer verändert, wenn der gesamte Datensatz exakt verdoppelt wird, und wie er sich verändert, wenn stattdessen eine zusätzliche Beobachtung mit dem Wert 20 hinzukommt.

Frage 4

Zeige auf zwei unterschiedlichen Wegen, warum bei einer Normalverteilung mit bekannter Varianz der Maximum-Likelihood-Schätzer für μ das Stichprobenmittel ist: einmal über die Ableitung der Log-Likelihood und einmal über die Zerlegung der quadratischen Fehlersumme. Erkläre außerdem, warum eine Änderung von σ^2 die Lage des Maximums nicht verändert, aber die Krümmung der Log-Likelihood beeinflusst.

Frage 5

Eine sehr große Stichprobe von Körpergrößen ist deutlich rechtsschief, wird aber mit einer Normalverteilung modelliert. Unterscheide in diesem Beispiel Approximationsfehler und Schätzfehler. Begründe, welcher Fehler durch eine noch größere Stichprobe kleiner wird, welcher bestehen bleiben kann und warum ein hochpräziser Maximum-Likelihood-Schätzer dennoch zu irreführenden Schlussfolgerungen führen kann.

6. Lösungen zum Active Recall

Lösung 1

Vor der Beobachtung sind $X_1, \dots, X_n$ zufällig und θ ist im klassischen Modell fest. Nach Einsetzen von $x_1, \dots, x_n$ werden die Daten festgehalten und dieselbe gemeinsame Wahrscheinlichkeitsfunktion beziehungsweise Dichte als Funktion von θ gelesen. Deshalb muss $L(\theta)$ über θ nicht normiert sein. Bei stetigen Daten sind Punktwahrscheinlichkeiten 0; Dichtewerte vergleichen stattdessen die lokale Datenplausibilität und führen über kleine Intervalle zur Likelihood.

Lösung 2

$$\ell(\pi) = k \log \pi + (n-k) \log(1-\pi) + C,$$

$$\ell'(\pi) = \frac{k}{\pi} - \frac{n-k}{1-\pi} = 0 \Longrightarrow \hat{\pi}_{\mathrm{ML}} = \frac{k}{n}.$$

$\binom{n}{k}$ ist unabhängig von π und ändert daher den Maximierer nicht. Bei $k = 0$ beziehungsweise $k = n$ liegt das Maximum am Rand bei 0 beziehungsweise 1; ein inneres Nullsetzen ist dann nicht anwendbar.

Lösung 3

Für Poisson-Daten gilt

$$\hat{\lambda}_{\mathrm{ML}} = \overline{x} = \frac{0+2+1+4+3}{5} = 2.$$

Die exakte Verdopplung des gesamten Datensatzes verdoppelt Zähler und Nenner, sodass der Mittelwert 2 bleibt. Mit einer zusätzlichen Beobachtung 20 ergibt sich

$$\hat{\lambda}_{\mathrm{ML}} = \frac{10+20}{6} = 5,$$

wodurch der starke Einfluss eines Extremwerts sichtbar wird.

Lösung 4

Aus

$$\ell'(\mu) = \frac{1}{\sigma^2} \sum_{i=1}^{n} (x_i - \mu) = 0$$

folgt $\hat{\mu}_{\mathrm{ML}} = \overline{x}$. Alternativ gilt

$$\sum_{i=1}^{n} (x_i - \mu)^2 = \sum_{i=1}^{n} (x_i - \overline{x})^2 + n(\mu - \overline{x})^2,$$

also ist die Fehlersumme bei $\mu = \overline{x}$ minimal. σ^2 ist ein positiver Skalierungsfaktor: Es ändert den Maximierer nicht, aber über

$$\ell''(\mu) = -\frac{n}{\sigma^2}$$

die Steilheit und damit die Konzentration der Likelihood.

Lösung 5

Die Rechtsschiefe gegenüber der symmetrischen Normalverteilung ist Approximationsfehler. Die zufällige Abweichung von $\hat{\mu}$ zwischen verschiedenen Stichproben ist Schätzfehler. Mehr Daten reduzieren typischerweise den Schätzfehler, beseitigen aber die falsche Verteilungsform nicht. Dadurch kann $\hat{\mu}$ sehr präzise sein, während normalverteilungsbasierte Aussagen über Randbereiche, Wahrscheinlichkeiten, Intervalle oder Tests systematisch unpassend bleiben.