1. Das Big Picture (Chunking)

Dieses Kapitel beantwortet zwei zusammenhängende Fragen: Wie erkennt man, ob ein statistischer Schätzer gut ist, und wie kann man eine unbekannte Verteilung schätzen, ohne vorab eine feste Verteilungsfamilie anzunehmen? Im Kern geht es um den Ausgleich zwischen systematischem Fehler, zufälliger Schwankung und Modellkomplexität: Ein Modell soll flexibel genug sein, um die Realität abzubilden, aber nicht so flexibel, dass es vor allem Stichprobenzufall nachzeichnet. Das ist fundamental für Statistik und Data Science, weil nahezu jede Inferenzentscheidung davon abhängt, wie zuverlässig ein aus endlichen Daten berechneter Schätzwert die unbekannte Grundgesamtheit repräsentiert.

2. Zentrale Definitionen

Schätzer

Fachliche Definition: Ein Schätzer $\hat{\theta} = T(X_1, \ldots, X_n)$ ist eine Funktion der Zufallsvariablen einer Stichprobe. Vor der Datenerhebung ist $\hat{\theta}$ selbst eine Zufallsvariable; nach Einsetzen der beobachteten Daten erhält man einen konkreten Schätzwert.

Feynman-Übersetzung: Ein Schätzer ist eine Rechenregel. Solange die Daten noch nicht erhoben sind, ist auch ihr Ergebnis ungewiss. Erst wenn die Zahlen vorliegen, spuckt die Regel einen festen Wert aus.

Stichprobenverteilung eines Schätzers

Fachliche Definition: Die Stichprobenverteilung ist die Wahrscheinlichkeitsverteilung von $\hat{\theta}$, die sich aus gedanklich wiederholten Stichprobenziehungen unter demselben Datenentstehungsprozess ergibt.

Feynman-Übersetzung: Ziehe sehr oft neue Stichproben und berechne jedes Mal denselben Schätzer. Die Verteilung aller erhaltenen Ergebnisse zeigt, wie der Schätzer typischerweise funktioniert.

Bias beziehungsweise Verzerrung

Fachliche Definition: Der Bias eines Schätzers ist

$$\text{Bias}(\hat{\theta}) = \text{E}(\hat{\theta}) - \theta.$$

Er misst die systematische Abweichung des durchschnittlichen Schätzergebnisses vom wahren Parameter θ.

Feynman-Übersetzung: Der Bias fragt: Liegt die Rechenregel im Durchschnitt dauerhaft zu hoch oder zu niedrig?

Unverzerrtheit

Fachliche Definition: Ein Schätzer ist unverzerrt beziehungsweise erwartungstreu, wenn

$$\text{E}(\hat{\theta}) = \theta$$

und damit $\text{Bias}(\hat{\theta}) = 0$ gilt.

Feynman-Übersetzung: Der Schätzer kann in einzelnen Stichproben danebenliegen, aber Über- und Unterschätzungen gleichen sich langfristig aus.

Varianz eines Schätzers

Fachliche Definition: Die Varianz ist

$$\mathrm{Var}(\hat{\theta}) = \mathrm{E}\left[\left(\hat{\theta} - \mathrm{E}(\hat{\theta})\right)^2\right].$$

Sie misst die Streuung der Schätzergebnisse um ihren eigenen Erwartungswert.

Feynman-Übersetzung: Die Varianz sagt, wie nervös der Schätzer auf neue Stichproben reagiert. Kleine Datenänderungen führen bei hoher Varianz zu stark unterschiedlichen Ergebnissen.

Mittlerer quadratischer Fehler

Fachliche Definition: Der Mean Squared Error ist

$$\mathrm{MSE}(\hat{\theta}) = \mathrm{E}\left[\left(\hat{\theta} - \theta\right)^2\right].$$

Er misst die mittlere quadrierte Abweichung vom wahren Parameter und berücksichtigt sowohl Bias als auch Varianz.

Feynman-Übersetzung: Der MSE fragt nicht nur, ob der Schätzer schwankt, sondern ob seine Ergebnisse tatsächlich nahe an der Wahrheit liegen.

Konsistenz im quadratischen Mittel

Fachliche Definition: Eine Folge von Schätzern $\hat{\theta}_n$ ist im quadratischen Mittel konsistent, wenn

$$\mathrm{MSE}(\hat{\theta}_n) \longrightarrow 0 \quad \text{für} \quad n \longrightarrow \infty.$$

Feynman-Übersetzung: Mit immer mehr Daten wird der Schätzer im Mittel beliebig genau.

Asymptotische Erwartungstreue

Fachliche Definition: Ein Schätzer ist asymptotisch erwartungstreu, wenn

$$\mathrm{Bias}(\hat{\theta}_n) \longrightarrow 0 \quad \text{für} \quad n \longrightarrow \infty.$$

Feynman-Übersetzung: Bei kleinen Stichproben darf eine systematische Abweichung bestehen, aber sie verschwindet, wenn genügend Daten vorliegen.

Parametrisches Verteilungsmodell

Fachliche Definition: Bei einem parametrischen Modell wird die Form der Verteilung festgelegt; unbekannt ist nur ein endlichdimensionaler Parametervektor θ.

Feynman-Übersetzung: Man entscheidet sich vorab für eine Schablone, etwa eine Normal- oder Poissonverteilung, und schätzt nur noch die passenden Stellschrauben dieser Schablone.

Nichtparametrische Verteilungsschätzung

Fachliche Definition: Eine nichtparametrische Schätzung legt keine feste endlichdimensionale Verteilungsfamilie fest. Die Form der Verteilung wird flexibel aus den Daten rekonstruiert, etwa durch ein Histogramm oder einen Kerndichteschätzer.

Feynman-Übersetzung: Statt eine fertige Schablone auszuwählen, lässt man die Daten die Form der Verteilung weitgehend selbst zeichnen.

Histogramm als Dichteschätzer

Fachliche Definition: Der Wertebereich wird in Klassen zerlegt. In jeder Klasse wird die Dichtehöhe als relative Häufigkeit geteilt durch Klassenbreite definiert, sodass die Rechteckfläche der relativen Häufigkeit entspricht und die Gesamtfläche 1 beträgt.

Feynman-Übersetzung: Jede Klasse erhält ein Rechteck. Wie viel Wahrscheinlichkeit in der Klasse liegt, wird als Fläche dargestellt, nicht bloß als Höhe.

Approximationsfehler

Fachliche Definition: Der Approximationsfehler entsteht, weil eine möglicherweise komplexe wahre Verteilung durch eine eingeschränkte Modellklasse angenähert wird, beispielsweise durch eine stückweise konstante Histogrammfunktion.

Feynman-Übersetzung: Selbst mit unendlich vielen Daten kann eine zu grobe Schablone die wahre Form nicht exakt nachzeichnen.

Schätzfehler

Fachliche Definition: Der Schätzfehler entsteht, weil die unbekannten Modellgrößen aus einer endlichen Zufallsstichprobe geschätzt werden. Er beschreibt die Abweichung des stichprobenbasierten Modells von dem Modell, das man bei vollständiger Kenntnis der Grundgesamtheit innerhalb derselben Modellklasse erhalten würde.

Feynman-Übersetzung: Wir sehen nur einen kleinen Ausschnitt der Bevölkerung. Deshalb können die geschätzten Balken oder Kurven zufällig zu hoch oder zu niedrig sein.

Gesamtfehler und Komplexitätsausgleich

Fachliche Definition: Der Gesamtfehler verbindet Approximations- und Schätzfehler. Mehr Modellparameter verringern typischerweise den Approximationsfehler, erhöhen aber bei festem Stichprobenumfang den Schätzfehler.

Feynman-Übersetzung: Ein zu simples Modell übersieht echte Struktur. Ein zu kompliziertes Modell hält Zufallsrauschen für echte Struktur. Gesucht ist die Mitte.

Fließendes Histogramm

Fachliche Definition: Für jede Stelle x wird gezählt, welcher Anteil der Beobachtungen im gleitenden Intervall $(x-b, x+b]$ liegt. Dieser Anteil wird durch die Intervallbreite $2b$ geteilt.

Feynman-Übersetzung: Man schiebt ein Fenster über die Zahlengerade und fragt an jeder Position, wie dicht die Daten dort liegen.

Kernfunktion

Fachliche Definition: Im Material ist eine Kernfunktion K eine um 0 symmetrische Dichtefunktion. Sie verteilt das Gewicht eines Datenpunkts auf seine Umgebung.

Feynman-Übersetzung: Jeder Datenpunkt bekommt einen kleinen Hügel. Die Form des Hügels wird durch den Kern bestimmt.

Kerndichteschätzer

Fachliche Definition: Der Kerndichteschätzer ist

$$\hat{f}_b(x) = \frac{1}{nb} \sum_{i=1}^{n} K\left(\frac{x - X_i}{b}\right).$$

Er mittelt skalierte und verschobene Kernfunktionen über alle Beobachtungen.

Feynman-Übersetzung: Über jeden Messwert wird ein kleiner Hügel gelegt. Alle Hügel zusammen ergeben eine glatte Schätzung der Dichte.

Bandweite

Fachliche Definition: Die Bandweite $b > 0$ bestimmt die horizontale Skalierung der Kerne und damit den Glättungsgrad der Dichteschätzung.

Feynman-Übersetzung: Die Bandweite ist der Schärferegler: kleines b zeigt viele Zacken, großes b bügelt Details glatt.

3. Formeln, Beweise & Intuition

3.1 Der Schätzer ist eine Zufallsvariable

Die Formel

$$\hat{\theta} = T(X_1, \dots, X_n).$$

Nach Beobachtung der Stichprobe $x_1, \dots, x_n$ ergibt sich der Schätzwert

$$\hat{\theta}_{\text{obs}} = T(x_1, \dots, x_n).$$

Dekonstruktion

- $X_1, \dots, X_n$: Zufallsvariablen vor der Datenerhebung.
- $x_1, \dots, x_n$: konkret beobachtete Realisationen.
- T: feste Rechenregel.
- $\hat{\theta}$: zufälliges Ergebnis der Rechenregel vor der Beobachtung.
- $\hat{\theta}_{\text{obs}}$: konkreter numerischer Schätzwert nach der Beobachtung.

Der Beweis / Die Herleitung

1. Die Stichprobe kann bei einer Wiederholung andere Werte annehmen.
2. T wird auf diese zufälligen Eingaben angewendet.
3. Eine Funktion von Zufallsvariablen ist wieder eine Zufallsvariable.
4. Daher besitzt $\hat{\theta}$ eine Verteilung sowie Größen wie Erwartungswert und Varianz.

Die Analogie & Mechanik

Stelle dir T als Küchenmaschine vor. Das Rezept bleibt gleich, aber die Zutatenchargen $X_1, \dots, X_n$ unterscheiden sich. Deshalb variiert auch das Endprodukt $\hat{\theta}$. Die zentrale Einsicht lautet: Ein einzelner beobachteter Wert verrät nicht vollständig, wie zuverlässig die Maschine über viele Chargen arbeitet.

3.2 Bias

Die Formel

$$\text{Bias}(\hat{\theta}) = \text{E}(\hat{\theta}) - \theta.$$

Dekonstruktion

- θ: wahrer, unbekannter Parameter.
- $\hat{\theta}$: Schätzer.

- $\mathrm{E}(\hat{\theta})$: durchschnittliches Ergebnis über gedanklich unendlich viele Wiederholungen.
- $\mathrm{Bias}(\hat{\theta})$: gerichteter systematischer Fehler.

Der Beweis / Die Herleitung

Der Bias ist eine Definition. Seine Vorzeichenlogik folgt unmittelbar:

- Falls $\mathrm{E}(\hat{\theta}) > \theta$, dann ist $\mathrm{Bias}(\hat{\theta}) > 0$: systematische Überschätzung.
- Falls $\mathrm{E}(\hat{\theta}) < \theta$, dann ist $\mathrm{Bias}(\hat{\theta}) < 0$: systematische Unterschätzung.
- Falls $\mathrm{E}(\hat{\theta}) = \theta$, dann ist $\mathrm{Bias}(\hat{\theta}) = 0$: Unverzerrtheit.

Die Analogie & Mechanik

Eine Waage, die immer 2 Kilogramm zu viel anzeigt, hat positiven Bias. Sie kann extrem präzise sein und jedes Mal fast denselben Wert liefern, aber dieser Wert liegt systematisch falsch. Ein großer positiver Term $\mathrm{E}(\hat{\theta})$ relativ zu θ erzeugt großen positiven Bias; ein stark zu kleiner Erwartungswert erzeugt negativen Bias.

3.3 Varianz eines Schätzers

Die Formel

$$\mathrm{Var}(\hat{\theta}) = \mathrm{E}\left[\left(\hat{\theta} - \mathrm{E}(\hat{\theta})\right)^2\right].$$

Äquivalent gilt

$$\mathrm{Var}(\hat{\theta}) = \mathrm{E}(\hat{\theta}^2) - \left[\mathrm{E}(\hat{\theta})\right]^2.$$

Dekonstruktion

- $\hat{\theta} - \mathrm{E}(\hat{\theta})$: Abweichung vom eigenen Zentrum.
- Das Quadrat verhindert Vorzeichenaufhebung und bestraft große Abweichungen überproportional.
- Der Erwartungswert mittelt diese quadrierten Abweichungen über alle möglichen Stichproben.

Der Beweis / Die Herleitung

Ausmultiplizieren liefert

$$\begin{aligned}\mathrm{Var}(\hat{\theta}) &= \mathrm{E}\left[\hat{\theta}^2 - 2\hat{\theta}\,\mathrm{E}(\hat{\theta}) + \left(\mathrm{E}(\hat{\theta})\right)^2\right] \\ &= \mathrm{E}(\hat{\theta}^2) - 2\,\mathrm{E}(\hat{\theta})\,\mathrm{E}(\hat{\theta}) + \left(\mathrm{E}(\hat{\theta})\right)^2 \\ &= \mathrm{E}(\hat{\theta}^2) - \left[\mathrm{E}(\hat{\theta})\right]^2.\end{aligned}$$

Die Analogie & Mechanik

Zwei Bogenschützen können dasselbe mittlere Trefferzentrum haben. Der eine schießt eng gebündelt, der andere weit verstreut. Die Varianz misst die Größe der Streuung, nicht die Entfernung zur Zielmitte. Ein Schätzer mit winziger Varianz kann dennoch schlecht sein, wenn sein gesamtes Trefferbündel wegen hohen Bias weit neben der Wahrheit liegt.

3.4 MSE und Bias-Varianz-Zerlegung

Die Formel

$$\mathrm{MSE}(\hat{\theta}) = \mathrm{E}\left[\left(\hat{\theta} - \theta\right)^2\right] = \mathrm{Var}(\hat{\theta}) + \left[\mathrm{Bias}(\hat{\theta})\right]^2.$$

Dekonstruktion

- $\hat{\theta} - \theta$: tatsächlicher Schätzfehler relativ zur Wahrheit.
- $\mathrm{Var}(\hat{\theta})$: zufällige Schwankung.
- $[\mathrm{Bias}(\hat{\theta})]^2$: quadrierter systematischer Fehler.
- Das Quadrat macht positiven und negativen Bias gleicher Größe gleich kostspielig.

Der Beweis / Die Herleitung

Füge den Erwartungswert des Schätzers geschickt hinzu und ziehe ihn wieder ab:

$$\hat{\theta} - \theta = \left(\hat{\theta} - \mathrm{E}(\hat{\theta})\right) + \left(\mathrm{E}(\hat{\theta}) - \theta\right).$$

Quadrieren und Erwartungswert bilden:

$$\begin{aligned}
\mathrm{MSE}(\hat{\theta}) &= \mathrm{E}\left[\left(\hat{\theta} - \mathrm{E}(\hat{\theta}) + \mathrm{E}(\hat{\theta}) - \theta\right)^2\right] \\
&= \mathrm{E}\left[\left(\hat{\theta} - \mathrm{E}(\hat{\theta})\right)^2\right] \\
&\quad + 2\left(\mathrm{E}(\hat{\theta}) - \theta\right)\mathrm{E}\left[\hat{\theta} - \mathrm{E}(\hat{\theta})\right] \\
&\quad + \left(\mathrm{E}(\hat{\theta}) - \theta\right)^2.
\end{aligned}$$

Der Kreuzterm verschwindet, weil

$$\mathrm{E}\left[\hat{\theta} - \mathrm{E}(\hat{\theta})\right] = \mathrm{E}(\hat{\theta}) - \mathrm{E}(\hat{\theta}) = 0.$$

Somit folgt

$$\mathrm{MSE}(\hat{\theta}) = \mathrm{Var}(\hat{\theta}) + \left[\mathrm{Bias}(\hat{\theta})\right]^2.$$

Für einen unverzerrten Schätzer gilt speziell

$$\mathrm{MSE}(\hat{\theta}) = \mathrm{Var}(\hat{\theta}).$$

Die Analogie & Mechanik

Der Gesamtfehler eines Dartspielers hat zwei Quellen: Das Trefferbündel kann neben dem Bullseye liegen, und die einzelnen Würfe können stark streuen. Der MSE addiert beide Probleme auf einer gemeinsamen Skala. Wegen des Quadrats kann eine Verdopplung des Bias seinen Beitrag zum MSE vervierfachen.

3.5 Bernoulli-Modell: Maximum-Likelihood-Schätzer

Die Formel

Für

$$X_1, \ldots, X_n \overset{\text{iid}}{\sim} \mathrm{Bernoulli}(p)$$

ist der Maximum-Likelihood-Schätzer

$$\hat{p}_{\mathrm{ML}} = \bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

Dekonstruktion

- $X_i \in \{0,1\}$: Ergebnis des i-ten Bernoulli-Versuchs.
- $p = \mathrm{P}(X_i = 1)$: unbekannte Erfolgswahrscheinlichkeit.
- n: Stichprobenumfang.
- $\sum_{i=1}^{n} X_i$: Anzahl der Erfolge.
- $\bar{X}$: relative Erfolgshäufigkeit.

Der Beweis / Die Herleitung

Die Likelihood lautet

$$L(p) = \prod_{i=1}^{n} p^{X_i}(1-p)^{1-X_i} = p^{\sum_{i=1}^{n} X_i}(1-p)^{n-\sum_{i=1}^{n} X_i}.$$

Die Log-Likelihood ist

$$\ell(p) = \left(\sum_{i=1}^{n} X_i\right)\log p + \left(n - \sum_{i=1}^{n} X_i\right)\log(1-p).$$

Ableiten:

$$\ell'(p) = \frac{\sum_{i=1}^{n} X_i}{p} - \frac{n - \sum_{i=1}^{n} X_i}{1-p}.$$

Setze $\ell'(p) = 0$:

$$\frac{\sum_{i=1}^{n} X_i}{p} = \frac{n - \sum_{i=1}^{n} X_i}{1-p}.$$

Kreuzmultiplikation ergibt

$$(1-p)\sum_{i=1}^{n} X_i = p\left(n - \sum_{i=1}^{n} X_i\right).$$

Nach Kürzen folgt

$$\sum_{i=1}^{n} X_i = np$$

und damit

$$\hat{p}_{\mathrm{ML}} = \frac{1}{n}\sum_{i=1}^{n} X_i.$$

An den Randfällen mit ausschließlich Misserfolgen oder ausschließlich Erfolgen liegt das Maximum entsprechend bei $\hat{p}_{\mathrm{ML}} = 0$ beziehungsweise $\hat{p}_{\mathrm{ML}} = 1$.

Bias

$$\begin{aligned}\mathrm{E}(\hat{p}_{\mathrm{ML}}) &= \mathrm{E}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right)\\ &= \frac{1}{n}\sum_{i=1}^{n}\mathrm{E}(X_i)\\ &= \frac{1}{n}\cdot n\cdot p\\ &= p.\end{aligned}$$

Also

$$\mathrm{Bias}(\hat{p}_{\mathrm{ML}}) = 0.$$

Varianz

Wegen der Unabhängigkeit gilt

$$\mathrm{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n}\mathrm{Var}(X_i).$$

Daher

$$\begin{aligned}\mathrm{Var}(\hat{p}_{\mathrm{ML}}) &= \mathrm{Var}\left(\frac{1}{n}\sum_{i=1}^{n} X_i\right)\\ &= \frac{1}{n^2}\sum_{i=1}^{n}\mathrm{Var}(X_i)\\ &= \frac{1}{n^2}\cdot n\cdot p(1-p)\\ &= \frac{p(1-p)}{n}.\end{aligned}$$

MSE und Konsistenz

Da der Schätzer unverzerrt ist,

$$\mathrm{MSE}(\hat{p}_{\mathrm{ML}}) = \frac{p(1-p)}{n}.$$

Weil $0 \le p(1-p) \le \frac{1}{4}$ gilt,

$$0 \le \mathrm{MSE}(\hat{p}_{\mathrm{ML}}) \le \frac{1}{4n} \longrightarrow 0.$$

Damit ist $\hat{p}_{\mathrm{ML}}$ im quadratischen Mittel konsistent.

Die Analogie & Mechanik

Die relative Häufigkeit ist wie das Mischen vieler kleiner Ja-Nein-Signale. Der Zähler zählt Erfolge; der Nenner n verteilt diese Anzahl auf alle Versuche. Bei festem Erfolgsanteil stabilisiert ein größeres n den Schätzer, weil die Varianz mit $1/n$ sinkt. Die Unsicherheit ist bei $p = 1/2$ am größten und bei $p = 0$ oder $p = 1$ gleich 0, weil dann alle Beobachtungen deterministisch gleich sind.

3.6 Poisson-Beispiel: guter und absichtlich schlechter Schätzer

Die Formeln

Für

$$X_1, \dots, X_n \overset{\text{iid}}{\sim} \text{Poisson}(\lambda)$$

ist der Maximum-Likelihood-Schätzer

$$\hat{\lambda}_{\text{ML}} = \bar{X}.$$

Das Material vergleicht ihn mit

$$\hat{\lambda}_0 = 2\bar{X}.$$

Dekonstruktion

- λ: erwartete Ereignisanzahl pro Beobachtungseinheit.
- $\bar{X}$: mittlere beobachtete Ereignisanzahl.
- Der Faktor 2 im zweiten Schätzer verdoppelt jedes Ergebnis künstlich.

Der Beweis / Die Herleitung

Für eine Poissonvariable gilt

$$\text{E}(X_i) = \lambda \quad \text{und} \quad \text{Var}(X_i) = \lambda.$$

Daher

$$\text{E}(\hat{\lambda}_{\text{ML}}) = \lambda, \qquad \text{Var}(\hat{\lambda}_{\text{ML}}) = \frac{\lambda}{n},$$

und somit

$$\text{MSE}(\hat{\lambda}_{\text{ML}}) = \frac{\lambda}{n}.$$

Für den ungeeigneten Schätzer gilt

$$\text{E}(\hat{\lambda}_0) = 2\,\text{E}(\bar{X}) = 2\lambda,$$

also

$$\text{Bias}(\hat{\lambda}_0) = \lambda.$$

Seine Varianz ist

$$\text{Var}(\hat{\lambda}_0) = 4\,\text{Var}(\bar{X}) = \frac{4\lambda}{n}.$$

Damit folgt

$$\mathrm{MSE}(\hat{\lambda}_0) = \lambda^2 + \frac{4\lambda}{n}.$$

Selbst für $n \longrightarrow \infty$ bleibt

$$\mathrm{MSE}(\hat{\lambda}_0) \longrightarrow \lambda^2,$$

also ist $\hat{\lambda}_0$ für $\lambda > 0$ nicht konsistent.

Die Analogie & Mechanik

Wenn ein Tachometer jede Geschwindigkeit verdoppelt, helfen auch immer mehr Messungen nicht: Die zufällige Schwankung kann kleiner werden, aber der eingebaute systematische Fehler bleibt. Genau deshalb reicht geringe Varianz allein nicht als Qualitätskriterium.

3.7 Allgemeine asymptotische Eigenschaften von Maximum-Likelihood-Schätzern

Die Formeln

Das Material nennt unter geeigneten Zusatzannahmen:

$$\mathrm{Bias}(\hat{\theta}_{\mathrm{ML}}) \longrightarrow 0,$$

$$\hat{\theta}_{\mathrm{ML}} \longrightarrow \theta,$$

und asymptotische Normalität.

Eine übliche präzisere Form der letzten Aussage lautet als ergänzendes Expertenwissen:

$$\sqrt{n}\left(\hat{\theta}_{\mathrm{ML}} - \theta\right) \xrightarrow{d} \mathcal{N}\left(0, I(\theta)^{-1}\right),$$

wobei $I(\theta)$ die Fisher-Information pro Beobachtung bezeichnet.

Dekonstruktion

- $\xrightarrow{d}$: Konvergenz in Verteilung.
- $\sqrt{n}$: typische Geschwindigkeit, mit der der Schätzfehler schrumpft.
- $I(\theta)$: Informationsmenge über θ in einer Beobachtung.
- $I(\theta)^{-1}$: asymptotische Varianz auf der $\sqrt{n}$-Skala.

Der Beweis / Die Herleitung

Das Skript beweist diese allgemeinen Aussagen nicht. Die Grundmechanik ist:

1. Der ML-Schätzer maximiert die Log-Likelihood, also gilt näherungsweise $\ell_n'(\hat{\theta}_{\mathrm{ML}}) = 0$.
2. Entwickle die Score-Funktion um den wahren Wert θ:

$$0 \approx \ell_n'(\theta) + \ell_n''(\theta)\left(\hat{\theta}_{\mathrm{ML}} - \theta\right).$$

3. Auflösen liefert

$$\hat{\theta}_{\mathrm{ML}} - \theta \approx -\frac{\ell_n'(\theta)}{\ell_n''(\theta)}.$$

4. Der Score $\ell_n'(\theta)$ ist eine Summe vieler Beiträge und wird nach geeigneter Skalierung durch einen zentralen Grenzwertsatz näherungsweise normalverteilt.
5. Die negative normierte zweite Ableitung nähert sich der Fisher-Information.

Diese Herleitung benötigt Regularitätsbedingungen; sie ist keine bedingungslose Eigenschaft jedes ML-Problems.

Die Analogie & Mechanik

Die Likelihood ist eine Landschaft. Mit mehr Daten wird ihr Gipfel typischerweise steiler und konzentrierter um den wahren Wert. Hohe Information bedeutet einen schmalen Gipfel und damit eine kleine Schätzunsicherheit. Problematisch sind flache, mehrgipflige oder am Rand liegende Maxima.

3.8 Histogramm als Dichteschätzer

Die Formel

Zerlege den Wertebereich in Klassen

$$(c_0, c_1], \dots, (c_{J-1}, c_J].$$

Die relative Häufigkeit der j-ten Klasse ist

$$f_j = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}\{c_{j-1} < X_i \leq c_j\}.$$

Die zugehörige Höhe ist

$$\hat{\theta}_j = \frac{f_j}{c_j - c_{j-1}}.$$

Der Histogrammschätzer lautet

$$\hat{f}(x) = \begin{cases} \hat{\theta}_1, & c_0 < x \leq c_1, \\ \hat{\theta}_2, & c_1 < x \leq c_2, \\ \vdots & \\ \hat{\theta}_J, & c_{J-1} < x \leq c_J, \\ 0, & \text{sonst.} \end{cases}$$

Dekonstruktion

- J: Anzahl der Klassen.
- c_{j-1} und c_j: linke und rechte Klassengrenze.
- $c_j - c_{j-1}$: Klassenbreite.
- f_j: Anteil der Daten in Klasse j.
- $\hat{\theta}_j$: Dichtehöhe der Klasse.
- $\mathbf{1}\{\cdot\}$: Indikator, der 1 annimmt, wenn die Bedingung erfüllt ist, sonst 0.

Der Beweis / Die Herleitung

Die Fläche des j-ten Rechtecks ist

$$F_j = \hat{\theta}_j(c_j - c_{j-1}) = \frac{f_j}{c_j - c_{j-1}}(c_j - c_{j-1}) = f_j.$$

Die Gesamtfläche ist daher

$$\int_{-\infty}^{\infty} \hat{f}(x)\,dx = \sum_{j=1}^{J} F_j = \sum_{j=1}^{J} f_j = 1.$$

Außerdem gilt $\hat{f}(x) \geq 0$. Damit erfüllt das Histogramm die beiden Grundeigenschaften einer Dichtefunktion.

Warum nur $J-1$ Parameter frei sind

Die Normierungsbedingung lautet

$$\sum_{j=1}^{J} \hat{\theta}_j(c_j - c_{j-1}) = 1.$$

Sind $\hat{\theta}_1, \ldots, \hat{\theta}_{J-1}$ festgelegt, ist der letzte Wert durch

$$\hat{\theta}_J = \frac{1 - \sum_{j=1}^{J-1} \hat{\theta}_j(c_j - c_{j-1})}{c_J - c_{J-1}}$$

bestimmt. Deshalb besitzt ein Histogramm mit J Klassen nur $J-1$ frei wählbare Höhenparameter.

Die Analogie & Mechanik

Stelle dir Wahrscheinlichkeit als Wasser vor. Jede Klasse ist ein Behälter mit bestimmter Breite. Die Wassermenge entspricht f_j, die Wasserhöhe entspricht $\hat{\theta}_j$. Bei gleicher Wassermenge wird ein schmaler Behälter höher gefüllt als ein breiter. Deshalb dürfen bei ungleichen Klassenbreiten nicht bloß relative Häufigkeiten als Balkenhöhen verwendet werden.

Wenn der Zähler f_j groß ist, wird der Balken hoch. Wenn der Nenner $c_j - c_{j-1}$ sehr klein wird, kann die Höhe ebenfalls sehr groß werden, obwohl die Fläche weiterhin nur f_j beträgt. Eine Dichtehöhe darf daher größer als 1 sein.

3.9 Approximationsfehler, Schätzfehler und Gesamtfehler

Die Formel

Das Material erklärt die Zerlegung konzeptionell. Eine hilfreiche formale Darstellung als ergänzendes Expertenwissen ist

$$f - \hat{f}_J = (f - f_J^\star) + \left(f_J^\star - \hat{f}_J\right).$$

Dekonstruktion

- f: wahre Dichte.
- $f_J^\star$: bestmögliche Darstellung der wahren Dichte innerhalb einer Histogrammklasse mit J Klassen, gedacht bei vollständiger Kenntnis der Grundgesamtheit.
- $\hat{f}_J$: aus der Stichprobe geschätztes Histogramm.
- $f - f_J^\star$: Approximationsfehler.
- $f_J^\star - \hat{f}_J$: Schätzfehler.

Der Beweis / Die Herleitung

Die Gleichung entsteht durch Addieren und Subtrahieren derselben Größe $f_J^\star$:

$$\begin{aligned} f - \hat{f}_J &= f - f_J^\star + f_J^\star - \hat{f}_J \\ &= (f - f_J^\star) + \left(f_J^\star - \hat{f}_J\right). \end{aligned}$$

Für eine Norm $\|\cdot\|$ folgt aus der Dreiecksungleichung

$$\|f - \hat{f}_J\| \leq \|f - f_J^\star\| + \|f_J^\star - \hat{f}_J\|.$$

Die Vorlesungsmechanik lautet:

- Größeres J: flexiblere stückweise konstante Funktion, daher typischerweise kleinerer Approximationsfehler.
- Größeres J bei festem n: weniger Beobachtungen pro Klasse, daher typischerweise größerer Schätzfehler.
- Größeres n bei festem J: mehr Information pro Parameter, daher kleinerer Schätzfehler.
- Der Approximationsfehler hängt bei festgelegter Modellklasse nicht vom Stichprobenumfang n ab.

Die Analogie & Mechanik

Eine Landkarte kann auf zwei Arten falsch sein. Erstens kann ihr Maßstab zu grob sein: kleine Straßen fehlen unabhängig davon, wie sorgfältig gemessen wurde. Das ist Approximationsfehler. Zweitens können einzelne eingezeichnete Punkte wegen weniger Messungen ungenau sein. Das ist Schätzfehler. Mehr Details auf der Karte verringern den ersten Fehler, verlangen aber mehr Daten, damit der zweite Fehler nicht explodiert.

3.10 Fließendes Histogramm

Die Formel

$$\hat{f}(x) = \frac{1}{2b} \cdot \frac{\#\{i : x - b < X_i \leq x + b\}}{n}.$$

Mit Indikatoren:

$$\hat{f}(x) = \frac{1}{2bn} \sum_{i=1}^{n} \mathbf{1}\{x - b < X_i \leq x + b\}.$$

Dekonstruktion

- x: Position, an der die Dichte geschätzt wird.
- $b > 0$: Bandweite beziehungsweise halbe Fensterbreite.
- $(x - b, x + b]$: gleitendes Intervall mit Breite $2b$.
- $\#\{\cdot\}$: Anzahl der Beobachtungen im Fenster.
- Division durch n: relative Häufigkeit im Fenster.
- Division durch $2b$: Umrechnung der Wahrscheinlichkeit in Dichtehöhe.

Der Beweis / Die Herleitung

Die Wahrscheinlichkeit in einem kleinen Intervall lässt sich heuristisch durch

$$\mathrm{P}(x - b < X \leq x + b) \approx 2b\, f(x)$$

annähern. Ersetze die unbekannte Wahrscheinlichkeit durch die relative Häufigkeit:

$$\mathrm{P}(x-b < X \le x+b) \approx \frac{\#\{i : x-b < X_i \le x+b\}}{n}.$$

Auflösen nach $f(x)$ liefert den Schätzer.

Nachweis der Gesamtfläche

Für jeden Datenpunkt X_i ist

$$\mathbf{1}\{x-b < X_i \le x+b\} = \mathbf{1}\{X_i - b \le x < X_i + b\}.$$

Als Funktion von x ist dieser Indikator auf einem Intervall der Länge $2b$ gleich 1. Daher

$$\begin{aligned}\int_{-\infty}^{\infty} \hat{f}(x)\,dx &= \frac{1}{2bn}\sum_{i=1}^{n}\int_{-\infty}^{\infty}\mathbf{1}\{X_i - b \le x < X_i + b\}\,dx \\ &= \frac{1}{2bn}\sum_{i=1}^{n} 2b \\ &= 1.\end{aligned}$$

Die Analogie & Mechanik

Das Fenster ist wie ein Suchscheinwerfer, der über die Zahlengerade fährt. Viele Datenpunkte im Lichtkegel erzeugen eine hohe Dichte. Ein kleines b macht den Lichtkegel schmal: lokale Details werden sichtbar, aber die Zählung schwankt stark. Ein großes b sammelt viele Punkte und stabilisiert die Zählung, verwischt aber lokale Struktur.

3.11 Äquivalenz zum Rechteckskern

Die Formel

Der Rechteckskern ist

$$K(u) = \begin{cases} \frac{1}{2}, & -1 \le u < 1, \\ 0, & \text{sonst.} \end{cases}$$

Damit gilt

$$\hat{f}(x) = \frac{1}{nb}\sum_{i=1}^{n} K\left(\frac{x - X_i}{b}\right).$$

Dekonstruktion

- $u = (x - X_i)/b$: standardisierter Abstand zwischen Auswertungsstelle und Datenpunkt.
- $K(u) = 1/2$: der Punkt zählt mit konstantem Gewicht, wenn sein Abstand kleiner als b ist.
- $1/b$: vertikale Normierung nach horizontaler Skalierung.

Der Beweis / Die Herleitung

Es gilt

$$K\left(\frac{x - X_i}{b}\right) = \frac{1}{2}\mathbf{1}\left\{-1 \le \frac{x - X_i}{b} < 1\right\}.$$

Da $b > 0$,

$$-1 \leq \frac{x - X_i}{b} < 1$$

ist äquivalent zu

$$-b \leq x - X_i < b,$$

also zu

$$x - b < X_i \leq x + b.$$

Somit

$$\begin{aligned}\frac{1}{nb}\sum_{i=1}^{n} K\left(\frac{x - X_i}{b}\right) &= \frac{1}{nb}\sum_{i=1}^{n}\frac{1}{2}\mathbf{1}\{x - b < X_i \leq x + b\} \\ &= \frac{1}{2bn}\sum_{i=1}^{n}\mathbf{1}\{x - b < X_i \leq x + b\}.\end{aligned}$$

Das ist genau das fließende Histogramm.

Die Analogie & Mechanik

Jeder Datenpunkt trägt ein flaches Rechteck der Breite $2b$ und Höhe $1/(2b)$ bei. Der Schätzer ist der Durchschnitt dieser Rechtecke. Wo viele Rechtecke überlappen, ist die geschätzte Dichte hoch.

3.12 Allgemeiner Kerndichteschätzer

Die Formel

$$\hat{f}_b(x) = \frac{1}{nb}\sum_{i=1}^{n} K\left(\frac{x - X_i}{b}\right).$$

Dekonstruktion

- K: Kernfunktion mit $K(u) \geq 0$ und $\int_{-\infty}^{\infty} K(u)\,du = 1$.
- X_i: Zentrum des i-ten Kernhügels.
- b: horizontale Skalierung.
- $1/b$: notwendige vertikale Gegen-Skalierung, damit jeder Hügel Fläche 1 behält.
- $1/n$: Mittelung über alle n Datenpunkte.

Der Beweis / Die Herleitung der Normierung

Zunächst ist $\hat{f}_b(x) \geq 0$, sofern $K(u) \geq 0$. Für die Gesamtfläche gilt

$$\int_{-\infty}^{\infty} \hat{f}_b(x)\,dx = \frac{1}{nb}\sum_{i=1}^{n}\int_{-\infty}^{\infty} K\left(\frac{x - X_i}{b}\right)\,dx.$$

Substitution

$$u = \frac{x - X_i}{b}, \qquad dx = b\,du$$

liefert

$$\begin{aligned}\int_{-\infty}^{\infty} \hat{f}_b(x)\,dx &= \frac{1}{nb}\sum_{i=1}^{n} b \int_{-\infty}^{\infty} K(u)\,du \\ &= \frac{1}{n}\sum_{i=1}^{n} 1 \\ &= 1.\end{aligned}$$

Die Analogie & Mechanik

Ein Kern ist ein fester Klecks Farbe mit Fläche 1. Wird er horizontal auf die Breite b zusammengedrückt, muss er vertikal um den Faktor $1/b$ höher werden, damit die Farbmenge gleich bleibt. Ohne den Faktor $1/b$ wäre die Gesamtfläche keine Dichte mehr.

Wenn b sehr klein wird, wird jeder Kern schmal und hoch. Der Nenner nb wird klein, wodurch lokale Spitzen stark anwachsen. Wenn b sehr groß wird, werden die Kerne breit und flach; lokale Unterschiede verschwinden.

3.13 Kernfunktionen aus dem Material

Rechteckskern

$$K(u) = \begin{cases} \frac{1}{2}, & -1 \le u < 1, \\ 0, & \text{sonst.} \end{cases}$$

Normierung:

$$\int_{-1}^{1} \frac{1}{2}\,du = 1.$$

Epanechnikov-Kern

$$K(u) = \begin{cases} \frac{3}{4}(1-u^2), & -1 \le u < 1, \\ 0, & \text{sonst.} \end{cases}$$

Normierung:

$$\begin{aligned}\int_{-1}^{1} \frac{3}{4}(1-u^2)\,du &= \frac{3}{4}\left[u - \frac{u^3}{3}\right]_{-1}^{1} \\ &= \frac{3}{4}\cdot\frac{4}{3} \\ &= 1.\end{aligned}$$

Bisquare- beziehungsweise Biweight-Kern

$$K(u) = \begin{cases} \frac{15}{16}(1-u^2)^2, & -1 \le u < 1, \\ 0, & \text{sonst.} \end{cases}$$

Normierung:

$$\begin{aligned}\int_{-1}^{1} \frac{15}{16}(1-u^2)^2\,du &= \frac{15}{16}\int_{-1}^{1}(1-2u^2+u^4)\,du \\ &= \frac{15}{16}\left(2-\frac{4}{3}+\frac{2}{5}\right) \\ &= \frac{15}{16}\cdot\frac{16}{15} \\ &= 1.\end{aligned}$$

Gauß-Kern

$$K(u) = \frac{1}{\sqrt{2\pi}}\exp\left(-\frac{u^2}{2}\right).$$

Er ist die Dichte der Standardnormalverteilung und erfüllt daher

$$\int_{-\infty}^{\infty} K(u)\,du = 1.$$

Die Analogie & Mechanik

Alle Kerne verteilen pro Datenpunkt dieselbe Gesamtmasse, aber unterschiedlich geformt. Der Rechteckskern gewichtet alle Punkte innerhalb der Bandweite gleich und erzeugt eher kantige Verläufe. Glattere Kerne lassen das Gewicht kontinuierlich mit der Entfernung sinken. Im Temperaturbeispiel des Materials liefern bei gleicher Bandweite Rechteck-, Epanechnikov-, Biweight- und Gauß-Kern sehr ähnliche globale Formen; die Bandweite beeinflusst die Glättung meist stärker als die genaue Kernwahl.

3.14 Wirkung der Bandweite

Die Formel

Der einzelne Beitrag eines Datenpunkts lautet

$$K_b(x-X_i) = \frac{1}{b}K\left(\frac{x-X_i}{b}\right).$$

Dekonstruktion

- b im Argument steuert die horizontale Breite.
- $1/b$ steuert die Höhe so, dass die Fläche 1 bleibt.
- Die Gesamtschätzung ist der Mittelwert aller $K_b(x-X_i)$.

Der Beweis / Die Herleitung der Grenzmechanik

- Für kleines b wird $|x-X_i|/b$ schnell groß. Nur sehr nahe Beobachtungen tragen deutlich bei. Die Schätzung reagiert stark auf einzelne Datenpunkte und hat typischerweise kleinen Glättungsbias, aber hohe Varianz.
- Für großes b wird $|x-X_i|/b$ klein. Viele Beobachtungen tragen an vielen Stellen bei. Die Schätzung wird stabiler, aber echte lokale Strukturen werden geglättet; der Bias steigt typischerweise.

Als konzeptionelle Zusammenfassung:

$$\text{kleines } b \quad \Rightarrow \quad \text{geringerer Approximationsbias, höhere Schätzvarianz,}$$

$$\text{großes } b \quad \Rightarrow \quad \text{höherer Approximationsbias, geringere Schätzvarianz.}$$

Die Analogie & Mechanik

Bei einem Foto entspricht kleines b einer sehr hohen Schärfung: Details und Bildrauschen werden beide sichtbar. Großes b entspricht einem starken Weichzeichner: Rauschen verschwindet, aber Konturen gehen verloren. Die optimale Bandweite minimiert nicht einen der beiden Fehler isoliert, sondern ihren Gesamtbeitrag.

4. Häufige Missverständnisse & Edge Cases

Schätzer und Schätzwert werden verwechselt

$\hat{\theta}$ bezeichnet die zufällige Rechenregel beziehungsweise ihre Zufallsvariable; ein konkretes Ergebnis nach Datenerhebung ist nur eine Realisation. Aus einem einzigen Schätzwert kann man Bias oder Varianz nicht direkt ablesen.

Unverzerrt bedeutet nicht immer richtig

Aus $\text{Bias}(\hat{\theta}) = 0$ folgt nicht $\hat{\theta} = \theta$ in jeder Stichprobe. Ein unverzerrter Schätzer kann eine sehr große Varianz besitzen und häufig weit danebenliegen.

Kleine Varianz bedeutet nicht automatisch guter Schätzer

Ein konstant falscher Schätzer kann Varianz 0 besitzen. Entscheidend ist die Abweichung von θ, weshalb für den Vergleich verzerrter Schätzer der MSE geeigneter ist.

Das Quadrat im MSE verändert die Einheit

Wenn θ in Euro gemessen wird, liegt $\text{MSE}(\hat{\theta})$ in Quadrat-Euro. Für eine Fehlergröße in der ursprünglichen Einheit verwendet man häufig die Wurzel

$$\text{RMSE}(\hat{\theta}) = \sqrt{\text{MSE}(\hat{\theta})}.$$

Der RMSE wird im Material nicht eingeführt, ist aber eine nützliche Interpretationsergänzung.

Konsistenz ist eine asymptotische, keine finite Garantie

Aus Konsistenz folgt nicht, dass ein Schätzer bei kleinem n gut ist. Zwei konsistente Schätzer können bei realistischen Stichprobengrößen sehr unterschiedliche Bias- und Varianzeigenschaften haben.

Asymptotische Erwartungstreue allein garantiert keine Konsistenz

Ein verschwindender Bias reicht nicht, wenn die Varianz nicht ebenfalls gegen 0 geht. Aus der Zerlegung

$$\text{MSE}(\hat{\theta}_n) = \text{Var}(\hat{\theta}_n) + \left[\text{Bias}(\hat{\theta}_n)\right]^2$$

wird sichtbar, dass beide Komponenten verschwinden müssen, um quadratische Konsistenz zu erhalten.

In der Bernoulli-Varianzherleitung ist Unabhängigkeit entscheidend

Ohne Unabhängigkeit gilt allgemein

$$\text{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \text{Var}(X_i) + 2\sum_{i<j} \text{Cov}(X_i, X_j).$$

Positive Abhängigkeit kann die Varianz des Mittelwerts deutlich erhöhen.

Maximum-Likelihood-Eigenschaften gelten nicht bedingungslos

Konsistenz und asymptotische Normalität können scheitern, wenn das Modell nicht identifizierbar ist, Parameter am Rand liegen, die Likelihood nicht hinreichend glatt ist, das Modell falsch spezifiziert ist oder das globale Maximum nicht regulär existiert. Die Formulierung im Material enthält deshalb ausdrücklich Zusatzannahmen.

Nichtparametrisch bedeutet nicht ohne Stellschrauben

Histogramme benötigen Klassengrenzen und Klassenanzahl; Kerndichteschätzer benötigen Kern und Bandweite. Nichtparametrisch bedeutet, dass keine feste endlichdimensionale Verteilungsfamilie vorgegeben wird, nicht dass keinerlei Modellentscheidungen getroffen werden.

Histogrammhöhen sind bei ungleichen Klassenbreiten keine relativen Häufigkeiten

Die korrekte Höhe ist

$$\hat{\theta}_j = \frac{f_j}{c_j - c_{j-1}}.$$

Nur die Fläche des Balkens entspricht f_j. Werden ungleiche Klassenbreiten verwendet und trotzdem Häufigkeiten als Höhen gezeichnet, wird die Verteilung visuell verzerrt.

Eine Dichte darf größer als 1 sein

Nur die Gesamtfläche muss 1 sein. Bei einer sehr schmalen Klasse oder kleinen Bandweite kann die Dichtehöhe deutlich über 1 liegen, ohne eine Wahrscheinlichkeit größer als 1 darzustellen.

Mehr Klassen oder kleinere Bandweite sind nicht automatisch besser

Sehr viele Klassen oder sehr kleines b reduzieren zwar grobe Approximation, können aber Stichprobenrauschen verstärken. Leere oder fast leere Klassen führen zu instabilen Höhen; die Dichtekurve wird zackig.

Sehr wenige Klassen oder große Bandweite können echte Struktur vernichten

Mehrgipfligkeit, Schiefe oder lokale Häufungen können verschwinden. Im Extrem dominiert beim fließenden Histogramm die Form des eingesetzten Kerns stärker als die feine Datenstruktur.

Klassengrenzen beeinflussen Histogramme

Selbst bei gleicher Klassenbreite kann eine Verschiebung des Startpunkts c_0 die sichtbare Form verändern. Kerndichteschätzer vermeiden diese starre Bindung an feste Klassengrenzen, lösen aber nicht das Bandweitenproblem.

Randverzerrung bei Kerndichteschätzern

Liegt die wahre Verteilung nur auf einem beschränkten Bereich, etwa $x \geq 0$, verteilt ein symmetrischer Kern nahe dem Rand Masse in den unmöglichen Bereich $x < 0$. Dadurch kann die Dichte am Rand systematisch unterschätzt werden. Das Material behandelt diesen Edge Case nicht; in fortgeschrittenen Verfahren nutzt man Randkorrekturen, Transformationen oder geeignete asymmetrische Kerne.

Kompakter und unbeschränkter Träger unterscheiden sich

Rechteck-, Epanechnikov- und Bisquare-Kern sind außerhalb von $[-1, 1]$ gleich 0. Der Gauß-Kern ist überall positiv. Daher beeinflusst beim Gauß-Kern theoretisch jeder Datenpunkt jede Stelle x, wenn auch bei großer Entfernung nur extrem schwach.

Randfälle im Bernoulli-Modell

Für $p = 0$ oder $p = 1$ gilt

$$\mathrm{Var}(\hat{p}) = 0.$$

Dann enthält jede Stichprobe ausschließlich Nullen beziehungsweise Einsen. Übliche asymptotische Normalapproximationen sind an diesen Randpunkten nicht regulär.

5. Active Recall (Wissenstest)

1. Zwei Schätzer $\hat{\theta}_A$ und $\hat{\theta}_B$ besitzen dieselbe Varianz. $\hat{\theta}_A$ ist unverzerrt, während $\hat{\theta}_B$ einen Bias von $c \neq 0$ hat. Leite den Unterschied ihrer MSE-Werte her und erkläre, warum die Varianz allein hier zu einer falschen Qualitätsbewertung führen würde.
2. Erkläre für den Bernoulli-Schätzer $\hat{p} = n^{-1} \sum_{i=1}^{n} X_i$ jeden Schritt von der Unabhängigkeit der Beobachtungen bis zur Konsistenz im quadratischen Mittel. Welche Stelle der Herleitung würde sich bei positiv korrelierten Beobachtungen ändern?
3. Ein Histogramm verwendet sehr unterschiedlich breite Klassen. Begründe mathematisch, warum die Balkenhöhe nicht einfach der relativen Häufigkeit entsprechen darf. Zeige außerdem, wie eine Dichtehöhe größer als 1 mit einer gültigen Wahrscheinlichkeit vereinbar ist.
4. Formuliere die Zerlegung des Fehlers einer nichtparametrischen Dichteschätzung in Approximations- und Schätzfehler. Erkläre anschließend, warum eine Erhöhung der Klassenanzahl bei festem Stichprobenumfang beide Komponenten in entgegengesetzte Richtungen bewegt.
5. Leite das fließende Histogramm aus dem Rechteckskern her und erkläre anhand der Formel, warum $b \longrightarrow 0$ zu einer rauen Schätzung und ein sehr großes b zu Überglättung führt. Welche Rolle spielt dabei der Faktor $1/b$?

6. Lösungen zum Active Recall

1. Wegen

$$\mathrm{MSE}(\hat{\theta}) = \mathrm{Var}(\hat{\theta}) + \left[\mathrm{Bias}(\hat{\theta})\right]^2$$

ist

$$\mathrm{MSE}(\hat{\theta}_B) - \mathrm{MSE}(\hat{\theta}_A) = c^2.$$

Gleiche Varianz bedeutet nur gleiche Streuung um das jeweilige eigene Zentrum; $\hat{\theta}_B$ liegt zusätzlich systematisch neben θ.

2. Unabhängigkeit erlaubt das Addieren der Einzelvarianzen:

$$\mathrm{Var}(\hat{p}) = \frac{1}{n^2} \sum_{i=1}^{n} p(1-p) = \frac{p(1-p)}{n}.$$

Da $\hat{p}$ unverzerrt ist, entspricht dies dem MSE und konvergiert gegen 0. Bei positiver Korrelation treten positive Kovarianzterme auf; die Varianz sinkt dann langsamer oder möglicherweise gar nicht gegen 0.

3. Wahrscheinlichkeit wird durch Fläche dargestellt:

$$f_j = \hat{\theta}_j(c_j - c_{j-1}),$$

also

$$\hat{\theta}_j = \frac{f_j}{c_j - c_{j-1}}.$$

Ist die Klassenbreite kleiner als die enthaltene Wahrscheinlichkeit, kann $\hat{\theta}_j > 1$ sein; entscheidend bleibt, dass die Rechteckfläche höchstens 1 ist und alle Flächen zusammen 1 ergeben.

4. Die formale Zerlegung ist

$$f - \hat{f}_J = (f - f_J^\star) + (f_J^\star - \hat{f}_J).$$

Mehr Klassen erhöhen die Modellflexibilität und verringern typischerweise $f - f_J^\star$. Gleichzeitig müssen mehr Höhen aus denselben n Daten geschätzt werden; pro Parameter steht weniger Information zur Verfügung, sodass $f_J^\star - \hat{f}_J$ stärker schwankt.

5. Für den Rechteckskern gilt

$$K\left(\frac{x - X_i}{b}\right) = \frac{1}{2}\mathbf{1}\{x - b < X_i \leq x + b\}.$$

Einsetzen in den allgemeinen Kerndichteschätzer ergibt

$$\hat{f}(x) = \frac{1}{2bn}\sum_{i=1}^{n}\mathbf{1}\{x - b < X_i \leq x + b\}.$$

Kleines b berücksichtigt nur sehr nahe Punkte und erzeugt schmale, hohe Beiträge; großes b mittelt über breite Umgebungen und verwischt lokale Struktur. Der Faktor $1/b$ erhält trotz horizontaler Skalierung die Fläche jedes Kerns.