1. Das Big Picture (Chunking)

Statistische Hypothesentests lösen das Problem, aus einer endlichen, zufälligen Stichprobe eine kontrollierte Entscheidung über unbekannte Eigenschaften einer Grundgesamtheit zu treffen. Im Kern wird geprüft, ob die beobachteten Daten unter einer Nullhypothese noch plausibel sind oder so stark gegen sie sprechen, dass sie bei einem vorher festgelegten Fehlerrisiko verworfen wird. Das ist für Statistik und Wirtschaftswissenschaften zentral, weil empirische Aussagen über Wirkungen, Unterschiede, Zusammenhänge oder Erfolgswahrscheinlichkeiten fast immer unter Unsicherheit getroffen werden müssen.

2. Zentrale Definitionen

Zufallsstichprobe und Unabhängigkeit

- **Fachliche Definition:** Eine Zufallsstichprobe besteht aus Zufallsvariablen $X_1, \dots, X_n$, die häufig unabhängig und identisch verteilt sind. Dies wird als $X_1, \dots, X_n \overset{\text{iid}}{\sim} F_\theta$ geschrieben, wobei F_θ eine durch den unbekannten Parameter θ bestimmte Verteilung bezeichnet.
- **Feynman-Übersetzung:** Wir beobachten dasselbe Zufallsexperiment mehrfach. Jeder Versuch folgt denselben Regeln und beeinflusst die anderen Versuche nicht.

Bernoulli-Verteilung

- **Fachliche Definition:** Eine Zufallsvariable X ist bernoulliverteilt mit Erfolgswahrscheinlichkeit π, wenn $X \in \{0, 1\}$ gilt und

$$P_\pi(X = 1) = \pi, \qquad P_\pi(X = 0) = 1 - \pi.$$

- **Feynman-Übersetzung:** Es gibt pro Versuch nur zwei Ergebnisse: Erfolg oder Misserfolg. Der Wert π sagt, wie wahrscheinlich ein Erfolg ist.

Statistische Hypothese

- **Fachliche Definition:** Eine statistische Hypothese ist eine Aussage über die Verteilung der Daten oder über einen unbekannten Parameter θ. Eine Punkthypothese legt genau einen Wert fest, etwa $\theta = \theta_0$; eine zusammengesetzte Hypothese erlaubt mehrere Werte, etwa $\theta \leq \theta_0$.
- **Feynman-Übersetzung:** Eine Hypothese ist eine überprüfbare Behauptung darüber, wie der Zufallsprozess hinter den Daten funktioniert.

Nullhypothese

- **Fachliche Definition:** Die Nullhypothese H_0 ist die Hypothese, deren fälschliche Verwerfung kontrolliert wird. Im Binomialbeispiel lautet sie

$$H_0 : \pi \leq 0{,}25.$$

- **Feynman-Übersetzung:** H_0 ist die Ausgangsposition. Wir geben sie erst auf, wenn die Daten ungewöhnlich stark gegen sie sprechen.

Alternativhypothese

- **Fachliche Definition:** Die Alternativhypothese H_1 umfasst die Parameterwerte, die nicht zu H_0 gehören. Im Binomialbeispiel gilt

$$H_1 : \pi > 0{,}25.$$

- **Feynman-Übersetzung:** H_1 beschreibt die Erklärung, für die wir statistische Evidenz suchen.

Einseitiger und zweiseitiger Test

- **Fachliche Definition:** Ein Test ist einseitig, wenn nur Abweichungen in einer Richtung gegen H_0 sprechen, etwa $H_1 : \mu > \mu_0$. Er ist zweiseitig, wenn Abweichungen in beide Richtungen relevant sind, etwa $H_1 : \mu \neq \mu_0$.
- **Feynman-Übersetzung:** Beim einseitigen Test suchen wir nur nach „größer“ oder nur nach „kleiner“. Beim zweiseitigen Test suchen wir nach jeder deutlichen Abweichung.

Teststatistik

- **Fachliche Definition:** Eine Teststatistik ist eine Funktion der Stichprobe,

$$Z = Z(X_1, \dots, X_n),$$

deren Wert misst, wie stark die Daten mit H_0 vereinbar sind oder ihr widersprechen. Im Binomialtest wird häufig die Erfolgszahl

$$Z = \sum_{i=1}^{n} X_i$$

verwendet. - **Feynman-Übersetzung:** Die Teststatistik verdichtet viele Einzelbeobachtungen zu einer einzigen Prüfzahl.

Ablehnbereich

- **Fachliche Definition:** Der Ablehnbereich A ist die Menge von Werten der Teststatistik, bei denen H_0 verworfen wird. Für einen rechtsseitigen Binomialtest hat er die Form

$$A = \{a, a+1, \dots, n\}.$$

- **Feynman-Übersetzung:** Der Ablehnbereich ist die Alarmzone. Landet die Prüfzahl dort, ist das Ergebnis unter H_0 zu ungewöhnlich.

Kritischer Wert

- **Fachliche Definition:** Ein kritischer Wert ist die Grenze zwischen Beibehaltungs- und Ablehnbereich. Beim rechtsseitigen Test ist a der kleinste Wert, ab dem H_0 verworfen wird.
- **Feynman-Übersetzung:** Der kritische Wert ist die eingestellte Empfindlichkeit des Alarms.

Fehler 1. Art

- **Fachliche Definition:** Ein Fehler 1. Art liegt vor, wenn H_0 verworfen wird, obwohl H_0 wahr ist. Seine Wahrscheinlichkeit bei einem konkreten Parameterwert $\theta \in \Theta_0$ ist

$$\alpha(\theta) = P_\theta(Z \in A).$$

- **Feynman-Übersetzung:** Der Alarm geht los, obwohl nichts Ungewöhnliches passiert ist.

Fehler 2. Art

- **Fachliche Definition:** Ein Fehler 2. Art liegt vor, wenn H_0 nicht verworfen wird, obwohl H_1 wahr ist. Seine Wahrscheinlichkeit bei $\theta \in \Theta_1$ ist

$$\beta(\theta) = P_\theta(Z \notin A).$$

- **Feynman-Übersetzung:** Es gibt tatsächlich einen Effekt, aber der Test übersieht ihn.

Signifikanzniveau

- **Fachliche Definition:** Das Signifikanzniveau α ist eine vor der Datenanalyse festgelegte Obergrenze für die größtmögliche Wahrscheinlichkeit eines Fehlers 1. Art:

$$\sup_{\theta \in \Theta_0} P_\theta(Z \in A) \leq \alpha.$$

Typische Werte sind $0{,}05$, $0{,}01$ oder $0{,}001$. - **Feynman-Übersetzung:** Wir legen vorher fest, wie häufig wir höchstens einen falschen Alarm akzeptieren.

Gütefunktion und Teststärke

- **Fachliche Definition:** Die Gütefunktion eines Tests ist

$$g(\theta) = P_\theta(Z \in A).$$

Für $\theta \in \Theta_1$ ist $g(\theta) = 1 - \beta(\theta)$ die Teststärke oder Power. - **Feynman-Übersetzung:** Die Power sagt, wie wahrscheinlich der Test einen tatsächlich vorhandenen Effekt entdeckt.

p-Wert

- **Fachliche Definition:** Der p-Wert ist unter H_0 die Wahrscheinlichkeit, einen mindestens so stark gegen H_0 sprechenden Wert der Teststatistik zu erhalten wie den beobachteten Wert z_{obs}. Bei einer zusammengesetzten Nullhypothese wird die ungünstigste Verteilung innerhalb von H_0 verwendet.
- **Feynman-Übersetzung:** Der p-Wert fragt: Wie überraschend wären Daten wie diese oder noch extremere Daten, wenn H_0 gelten würde?

Konfidenzintervall

- **Fachliche Definition:** Ein Konfidenzintervall $C_{1-\alpha}(X)$ ist ein datenabhängiger Bereich, der den wahren Parameter bei wiederholter Stichprobenziehung mit Wahrscheinlichkeit mindestens $1-\alpha$ überdeckt. Bei passend aufeinander abgestimmten zweiseitigen Tests und Intervallen gilt

$$H_0 : \theta = \theta_0 \text{ wird verworfen } \iff \theta_0 \notin C_{1-\alpha}(X).$$

- **Feynman-Übersetzung:** Das Intervall enthält die Parameterwerte, die mit den Daten noch hinreichend vereinbar sind.

3. Formeln, Beweise & Intuition

Chunk 1: Von einzelnen Bernoulli-Versuchen zur Binomialverteilung

Die Formel

Aus

$$X_1, \dots, X_n \overset{\text{iid}}{\sim} \text{Bernoulli}(\pi)$$

und

$$Z = \sum_{i=1}^{n} X_i$$

folgt

$$Z \sim \text{Bin}(n, \pi)$$

mit

$$P_\pi(Z = z) = \binom{n}{z} \pi^z (1-\pi)^{n-z}, \qquad z \in \{0, 1, \dots, n\}.$$

Außerdem gilt

$$E_\pi[Z] = n\pi,$$

und

$$\text{Var}_\pi(Z) = n\pi(1-\pi).$$

Dekonstruktion

- n: Anzahl der unabhängigen Versuche.
- X_i: Indikator des Erfolgs im Versuch i; bei Erfolg gilt $X_i = 1$, sonst $X_i = 0$.
- π: unbekannte Erfolgswahrscheinlichkeit pro Versuch.
- Z: Gesamtzahl der Erfolge.
- z: ein möglicher beobachtbarer Wert von Z.
- $\binom{n}{z}$: Anzahl der Möglichkeiten, genau z Erfolge auf n Positionen zu verteilen.

Der Beweis / Die Herleitung

Für eine konkrete Reihenfolge mit genau z Erfolgen und $n-z$ Misserfolgen gilt wegen der Unabhängigkeit

$$P_\pi(\text{konkrete Reihenfolge}) = \pi^z (1-\pi)^{n-z}.$$

Es existieren

$$\binom{n}{z} = \frac{n!}{z!(n-z)!}$$

verschiedene Reihenfolgen mit genau z Erfolgen. Da diese Ereignisse disjunkt sind, werden ihre Wahrscheinlichkeiten addiert:

$$P_\pi(Z = z) = \binom{n}{z}\pi^z(1-\pi)^{n-z}.$$

Für den Erwartungswert wird die Linearität des Erwartungswerts genutzt:

$$E_\pi[Z] = E_\pi\left[\sum_{i=1}^{n} X_i\right] = \sum_{i=1}^{n} E_\pi[X_i] = \sum_{i=1}^{n} \pi = n\pi.$$

Wegen der Unabhängigkeit addieren sich auch die Varianzen:

$$\mathrm{Var}_\pi(Z) = \sum_{i=1}^{n} \mathrm{Var}_\pi(X_i) = n\pi(1-\pi).$$

Die Analogie & Mechanik

Stelle dir n gleichartige Qualitätsprüfungen vor. Z zählt, wie viele Produkte einen Test bestehen. Wenn π steigt, wandert die gesamte Verteilung von Z nach rechts; große Erfolgszahlen werden wahrscheinlicher. Wenn n wächst, wächst der Erwartungswert proportional zu n, während die typische relative Schwankung der Erfolgsquote $\widehat{\pi} = Z/n$ ungefähr mit $1/\sqrt{n}$ schrumpft.

Chunk 2: Wie aus einer inhaltlichen Behauptung eine Testentscheidung wird

Für das Vorlesungsbeispiel gilt

$$H_0 : \pi \le \pi_0 \qquad \text{gegen} \qquad H_1 : \pi > \pi_0,$$

wobei

$$\pi_0 = 0{,}25.$$

Da große Werte von Z gegen H_0 sprechen, wird ein rechtsseitiger Ablehnbereich gewählt:

$$A = \{a, a+1, \dots, n\}.$$

Die Entscheidungsregel lautet

$$Z \in A \iff Z \ge a \implies H_0 \text{ verwerfen,}$$

und

$$Z \notin A \iff Z < a \implies H_0 \text{ nicht verwerfen.}$$

Dekonstruktion

- π_0: Grenzwert, der H_0 und H_1 trennt.
- a: kritische Erfolgszahl.
- A: Menge aller Ergebnisse, die als zu extrem für H_0 gelten.
- z_{obs}: tatsächlich beobachtete Erfolgszahl.

Der Beweis / Die Herleitung

Unter dem Randfall $\pi = \pi_0$ werden im Mittel

$$E_{\pi_0}[Z] = n\pi_0$$

Erfolge erwartet. Unter $\pi < \pi_0$ liegt der Erwartungswert noch niedriger. Deshalb widersprechen besonders große Werte von Z der gesamten Nullhypothese $\pi \leq \pi_0$. Die Richtung des Ablehnbereichs folgt somit aus der Richtung von H_1.

Die Analogie & Mechanik

H_0 behauptet, eine Produktionsanlage erzeuge höchstens 25% Premiumprodukte. Werden in einer Stichprobe ungewöhnlich viele Premiumprodukte gefunden, spricht dies gegen diese Obergrenze. Ein höheres a macht den Alarm schwerer auslösbar; ein niedrigeres a macht ihn empfindlicher.

Chunk 3: Fehlerwahrscheinlichkeiten als Funktionen des wahren Parameters

Die Wahrscheinlichkeit, H_0 zu verwerfen, ist

$$g(\pi) = P_\pi(Z \in A) = P_\pi(Z \geq a) = \sum_{z=a}^{n} \binom{n}{z} \pi^z (1-\pi)^{n-z}.$$

Damit gilt für $\pi \leq \pi_0$

$$\alpha(\pi) = P_\pi(\text{Fehler 1. Art}) = g(\pi),$$

und für $\pi > \pi_0$

$$\beta(\pi) = P_\pi(\text{Fehler 2. Art}) = 1 - g(\pi) = P_\pi(Z < a).$$

Die Power ist für $\pi > \pi_0$

$$1 - \beta(\pi) = g(\pi).$$

Dekonstruktion

- $g(\pi)$: Wahrscheinlichkeit einer Verwerfung bei wahrem Parameter π.
- $\alpha(\pi)$: Falschalarmwahrscheinlichkeit bei einem konkreten Wert innerhalb von H_0.
- $\beta(\pi)$: Übersehenswahrscheinlichkeit bei einem konkreten Wert innerhalb von H_1.
- $1 - \beta(\pi)$: Entdeckungswahrscheinlichkeit eines tatsächlich vorhandenen Effekts.

Der Beweis / Die Herleitung

Es gibt nur zwei Testentscheidungen: $Z \in A$ oder $Z \notin A$. Daher gilt immer

$$P_\pi(Z \in A) + P_\pi(Z \notin A) = 1.$$

Welche Bedeutung die beiden Wahrscheinlichkeiten haben, hängt davon ab, ob der wahre Parameter in H_0 oder H_1 liegt. Unter H_0 ist eine Verwerfung falsch; unter H_1 ist dieselbe Verwerfung richtig.

Die Analogie & Mechanik

Ein Rauchmelder hat ebenfalls zwei Fehlerarten. Wird seine Schwelle sehr niedrig eingestellt, erkennt er schwachen Rauch zuverlässig, produziert aber viele Fehlalarme. Wird die Schwelle hoch eingestellt, gibt es wenige Fehlalarme, aber kleine Brände werden häufiger übersehen.

Chunk 4: Warum der ungünstigste Fall von H_0 am Rand liegt

Für den rechtsseitigen Binomialtest ist

$$P_\pi(Z \geq a)$$

monoton wachsend in π. Daher gilt

$$\alpha_{\max} = \sup_{\pi \leq \pi_0} P_\pi(Z \geq a) = P_{\pi_0}(Z \geq a).$$

Für den Fehler 2. Art gilt entsprechend

$$\sup_{\pi > \pi_0} P_\pi(Z < a) = \lim_{\pi \downarrow \pi_0} P_\pi(Z < a) = P_{\pi_0}(Z < a).$$

Da $\{Z \geq a\}$ und $\{Z < a\}$ komplementär sind, folgt

$$\alpha_{\max} + \sup_{\pi > \pi_0} \beta(\pi) = 1.$$

Der Beweis / Die Herleitung

Eine besonders anschauliche Kopplung verwendet unabhängige Zufallsvariablen

$$U_1, \dots, U_n \overset{\text{iid}}{\sim} \text{Uniform}(0,1)$$

und definiert

$$X_i(\pi) = \mathbf{1}\{U_i \leq \pi\}.$$

Gilt $\pi_1 \leq \pi_2$, dann gilt für jedes i

$$X_i(\pi_1) \leq X_i(\pi_2).$$

Somit gilt auch

$$Z(\pi_1) = \sum_{i=1}^{n} X_i(\pi_1) \leq \sum_{i=1}^{n} X_i(\pi_2) = Z(\pi_2).$$

Das Ereignis $Z \geq a$ wird daher bei größerem π wahrscheinlicher. Innerhalb von $H_0 : \pi \leq \pi_0$ ist der gefährlichste Wert folglich π_0.

Wichtige Präzisierung

Da $H_1 : \pi > \pi_0$ offen ist, muss der größte Fehler 2. Art nicht als echtes Maximum angenommen werden. Formal korrekt ist häufig ein Supremum. Die Folienaussage $\alpha_{\max} + \beta_{\max} = 1$ ist inhaltlich als Grenzwertaussage zu verstehen.

Die Analogie & Mechanik

Wer behauptet, ein Motor verbrauche höchstens π_0 Einheiten, macht die Behauptung am schwersten prüfbar, wenn der wahre Verbrauch genau an dieser Obergrenze liegt. Liegt er deutlich darunter, sind extreme hohe Beobachtungen noch unwahrscheinlicher.

Chunk 5: Konstruktion eines Tests zum Signifikanzniveau α

Der kritische Wert eines rechtsseitigen exakten Binomialtests kann gewählt werden als

$$a^* = \min\left\{a \in \{0,1,\dots,n\} : P_{\pi_0}(Z \geq a) \leq \alpha\right\}.$$

Dann gilt

$$\sup_{\pi \leq \pi_0} P_\pi(Z \geq a^*) = P_{\pi_0}(Z \geq a^*) \leq \alpha.$$

Für $n = 100$, $\pi_0 = 0{,}25$ und $\alpha = 0{,}01$ ist

$$P_{0,25}(Z \geq 36) \approx 0{,}009407,$$

während

$$P_{0,25}(Z \geq 35) \approx 0{,}016427.$$

Somit lautet der kleinste zulässige kritische Wert

$$a^* = 36.$$

Der Beweis / Die Herleitung

Der Test soll möglichst empfindlich sein, ohne die Fehlergrenze zu verletzen. Ein kleinerer kritischer Wert vergrößert den Ablehnbereich und damit sowohl die Power als auch die Wahrscheinlichkeit eines Fehlers 1. Art. Deshalb wählt man den kleinsten Wert a, dessen obere Binomialwahrscheinlichkeit noch höchstens α beträgt.

Die Analogie & Mechanik

Eine Alarmgrenze von $a^* = 36$ bedeutet: Ab 36 Erfolgen wird die Behauptung $\pi \leq 0{,}25$ verworfen. Würde die Grenze auf 35 gesenkt, würde der Test häufiger echte Erhöhungen entdecken, aber die erlaubte Falschalarmrate von 1% überschreiten.

Diskretheitsfolge

Da Z nur ganzzahlige Werte annimmt, kann die tatsächliche Fehlerwahrscheinlichkeit meist nicht exakt auf α eingestellt werden. Daher gilt häufig streng

$$P_{\pi_0}(Z \geq a^*) < \alpha.$$

Ein solcher Test ist konservativ.

Chunk 6: Der p-Wert und seine Verbindung zum Ablehnbereich

Für den rechtsseitigen Test

$$H_0 : \pi \leq \pi_0 \qquad \text{gegen} \qquad H_1 : \pi > \pi_0$$

lautet der exakte p-Wert

$$p(z_{\text{obs}}) = \sup_{\pi \leq \pi_0} P_\pi(Z \geq z_{\text{obs}}).$$

Wegen der Monotonie ist das Supremum am Rand π_0:

$$p(z_{\text{obs}}) = P_{\pi_0}(Z \geq z_{\text{obs}}) = \sum_{z=z_{\text{obs}}}^{n} \binom{n}{z} \pi_0^z (1-\pi_0)^{n-z}.$$

Für $n = 100$, $\pi_0 = 0{,}25$ und $z_{\text{obs}} = 50$ ergibt sich

$$p = \sum_{z=50}^{100} \binom{100}{z} 0{,}25^z 0{,}75^{100-z} \approx 6{,}64 \cdot 10^{-8}.$$

Da

$$p \leq 0{,}01,$$

wird H_0 zum Signifikanzniveau $\alpha = 0{,}01$ verworfen.

Warum gilt die Entscheidungsregel $p \leq \alpha$?

Der p-Wert ist das kleinste Signifikanzniveau, bei dem der beobachtete Wert gerade noch in den Ablehnbereich fällt. Formal gilt bei einem monotonen rechtsseitigen Test

$$p(z_{\text{obs}}) \leq \alpha \iff z_{\text{obs}} \geq a^* \iff z_{\text{obs}} \in A.$$

Die Analogie & Mechanik

Der p-Wert misst nicht, wie wahrscheinlich H_0 ist. Er misst, wie weit die Beobachtung im „ungewöhnlichen Rand“ der unter H_0 erwarteten Verteilung liegt. Ein extrem kleiner p-Wert bedeutet: Selbst der für H_0 günstigste zulässige Parameterwert erzeugt solche oder extremere Daten nur sehr selten.

Chunk 7: Zweiseitiger Binomialtest und Aufteilung des Signifikanzniveaus

Für

$$H_0 : \pi = \pi_0 \qquad \text{gegen} \qquad H_1 : \pi \neq \pi_0$$

sprechen sowohl sehr kleine als auch sehr große Werte von Z gegen H_0. Bei einer gleichmäßigen Aufteilung der Fehlerwahrscheinlichkeit werden kritische Werte a_L und a_U so gewählt, dass

$$P_{\pi_0}(Z \leq a_L) \leq \frac{\alpha}{2}$$

und

$$P_{\pi_0}(Z \geq a_U) \leq \frac{\alpha}{2}.$$

Der Ablehnbereich ist

$$A = \{0, 1, \ldots, a_L\} \cup \{a_U, a_U + 1, \ldots, n\}.$$

Für das Impfstoffbeispiel mit

$$n = 20, \qquad \pi_0 = 0{,}5, \qquad \alpha = 0{,}05$$

gilt

$$P_{0,5}(Z \leq 5) = P_{0,5}(Z \geq 15) \approx 0{,}020695 \leq 0{,}025.$$

Damit ist ein korrekter gleichseitiger Ablehnbereich

$$A = \{0, 1, \ldots, 5\} \cup \{15, 16, \ldots, 20\}.$$

Die tatsächliche Größe des Tests ist

$$P_{0,5}(Z \in A) = 2 \cdot 0{,}020695 \approx 0{,}041389 < 0{,}05.$$

Für $z_{\text{obs}} = 15$ ist die einseitige obere Randwahrscheinlichkeit

$$P_{0,5}(Z \geq 15) \approx 0{,}020695.$$

Wegen der Symmetrie der Verteilung bei $\pi_0 = 0{,}5$ ist der entsprechend verdoppelte zweiseitige p-Wert

$$p_{\text{zweiseitig}} = 2P_{0,5}(Z \geq 15) \approx 0{,}041389.$$

Somit gilt

$$p_{\text{zweiseitig}} < 0{,}05,$$

und H_0 wird verworfen.

Die Analogie & Mechanik

Bei einem zweiseitigen Test steht der Fehlerrisiko-„Topf“ von insgesamt α für zwei Alarmzonen zur Verfügung. Wird er symmetrisch aufgeteilt, erhält jede Seite höchstens $\alpha/2$. Ein Ergebnis kann also sowohl „ungewöhnlich niedrig“ als auch „ungewöhnlich hoch“ sein.

Chunk 8: Dualität von zweiseitigem Test und Konfidenzintervall

Ein zum Test passendes Konfidenzintervall kann als Menge aller Parameterwerte konstruiert werden, die durch den zugehörigen Test nicht verworfen werden:

$$C_{1-\alpha}(x) = \{\theta_0 : H_0 : \theta = \theta_0 \text{ wird bei Daten } x \text{ nicht verworfen}\}.$$

Daraus folgt unmittelbar

$$H_0 : \theta = \theta_0 \text{ wird verworfen } \iff \theta_0 \notin C_{1-\alpha}(x).$$

Der Beweis / Die Herleitung

Das Intervall wird gerade durch Umkehrung einer Familie von Tests erzeugt. Jeder Kandidat θ_0 wird einzeln getestet. Alle nicht verworfenen Kandidaten bleiben im Intervall; alle verworfenen Kandidaten liegen außerhalb. Die Äquivalenz ist daher keine zufällige Beobachtung, sondern eine Folge der Konstruktion.

Asymptotisches Intervall für eine Erfolgswahrscheinlichkeit

Mit

$$\widehat{\pi} = \frac{Z}{n}$$

liefert der zentrale Grenzwertsatz näherungsweise

$$\frac{\widehat{\pi} - \pi}{\sqrt{\pi(1-\pi)/n}} \approx \mathcal{N}(0,1).$$

Ersetzt man im Standardfehler den unbekannten Wert π durch $\widehat{\pi}$, erhält man das Wald-Konfidenzintervall

$$\widehat{\pi} \pm z_{1-\alpha/2}\sqrt{\frac{\widehat{\pi}(1-\widehat{\pi})}{n}}.$$

Hier ist $z_{1-\alpha/2}$ das entsprechende Quantil der Standardnormalverteilung. Für $\alpha = 0{,}05$ gilt

$$z_{0{,}975} \approx 1{,}96.$$

Im Impfstoffbeispiel ist

$$\widehat{\pi} = \frac{15}{20} = 0{,}75.$$

Der geschätzte Standardfehler ist

$$\widehat{\mathrm{SE}}(\widehat{\pi}) = \sqrt{\frac{0{,}75(1-0{,}75)}{20}} \approx 0{,}096825.$$

Daraus folgt

$$0{,}75 \pm 1{,}96 \cdot 0{,}096825 \approx [0{,}5602;\, 0{,}9398].$$

Da

$$0{,}5 \notin [0{,}5602;\, 0{,}9398],$$

wird $H_0 : \pi = 0{,}5$ verworfen.

Die Analogie & Mechanik

Das Intervall ist wie eine Menge plausibler Verdächtiger. Liegt π_0 außerhalb, ist dieser Wert mit den Daten zu schlecht vereinbar. Der Nenner des standardisierten Abstands enthält den Standardfehler: Wird n sehr groß, wird der Standardfehler klein und schon eine moderate Abweichung $\widehat{\pi} - \pi_0$ kann statistisch deutlich werden. Wird $\widehat{\pi}$ nahe 0 oder 1, wird der Wald-Standardfehler klein; genau dort kann die Normalapproximation jedoch besonders unzuverlässig sein.

Chunk 9: Was Stichprobengröße, Effektgröße und kritischer Wert mechanisch bewirken

Eine asymptotische standardisierte Teststatistik für eine Punkthypothese $H_0 : \pi = \pi_0$ ist

$$T = \frac{\widehat{\pi} - \pi_0}{\sqrt{\pi_0(1-\pi_0)/n}}.$$

Dekonstruktion

- Der Zähler $\widehat{\pi} - \pi_0$ ist die beobachtete Effektgröße relativ zur Nullhypothese.
- Der Nenner $\sqrt{\pi_0(1-\pi_0)/n}$ ist die unter H_0 erwartete zufällige Streuung der Stichprobenquote.
- T misst die Abweichung in Einheiten des Standardfehlers.

Mechanik extremer Werte

- Wird der Betrag des Zählers sehr groß, wird $|T|$ groß: Die Daten liegen weit von H_0 entfernt.
- Wird der Nenner durch ein großes n sehr klein, wird $|T|$ ebenfalls groß: Die Schätzung ist präzise, sodass selbst kleine Abweichungen statistisch auffallen.
- Wird der Ablehnbereich vergrößert, steigt die Power, aber auch das Risiko eines Fehlers 1. Art.
- Wird der Ablehnbereich verkleinert, sinkt das Risiko eines Fehlers 1. Art, aber der Fehler 2. Art steigt.

Die fundamentale Trennung lautet daher:

$$\text{statistische Evidenz} = \frac{\text{beobachtete Abweichung}}{\text{zufällige Unsicherheit}}.$$

Eine wirtschaftlich große Abweichung kann wegen hoher Unsicherheit statistisch nicht signifikant sein. Umgekehrt kann eine wirtschaftlich winzige Abweichung bei sehr großem n statistisch signifikant werden.

4. Häufige Missverständnisse & Edge Cases

1. „H_0 nicht verwerfen“ bedeutet nicht „H_0 beweisen“.

Ein nicht signifikantes Ergebnis kann entstehen, weil H_0 tatsächlich gut passt, aber auch weil n zu klein, die Daten zu variabel oder der Test zu schwach ist. Die korrekte Formulierung lautet: H_0 kann nicht verworfen werden.

2. Ein p-Wert ist nicht $P(H_0 \mid \textbf{Daten})$.

Der p-Wert hat die Richtung

$$P(\text{Daten oder extremere Daten} \mid H_0),$$

nicht

$$P(H_0 \mid \text{Daten}).$$

Die zweite Größe wäre eine posteriore Wahrscheinlichkeit und erfordert zusätzliche Annahmen, etwa eine Priorverteilung.

3. Das Signifikanzniveau ist nicht die Fehlerwahrscheinlichkeit nach einer konkreten Beobachtung.

α beschreibt die langfristige Falschalarmrate eines vorher festgelegten Testverfahrens unter H_0. Nach Beobachtung der Daten ist die Entscheidung bereits gefallen; α ist dann keine bedingte Wahrscheinlichkeit dafür, dass genau diese Entscheidung falsch ist.

4. Der Fehler 2. Art ist keine einzelne feste Zahl.

$\beta(\theta)$ hängt vom tatsächlich wahren Parameterwert ab. Alternativen sehr nahe an der Grenze von H_0 sind schwer zu erkennen; weit entfernte Alternativen besitzen meist höhere Power.

5. Die Richtung des Tests muss vor der Datenanalyse feststehen.

Erst nach Sichtung der Daten einen einseitigen Test in die beobachtete Richtung zu wählen, vergrößert die tatsächliche Fehlerwahrscheinlichkeit. Die Forschungsfrage bestimmt H_1, nicht das Ergebnis.

6. Bei einer zusammengesetzten Nullhypothese muss der ungünstigste Fall betrachtet werden.

Für $H_0 : \pi \leq \pi_0$ ist nicht irgendein willkürlicher Wert aus H_0 maßgeblich. Beim rechtsseitigen Binomialtest ist der Randwert π_0 der ungünstigste Fall, weil die obere Schwanzwahrscheinlichkeit mit π wächst.

7. Diskrete Tests treffen das nominale Signifikanzniveau oft nicht exakt.

Weil Z nur ganzzahlige Werte annimmt, springt die Fehlerwahrscheinlichkeit beim Verschieben des kritischen Werts. Ein exakter nicht randomisierter Test ist daher häufig konservativ:

$$\alpha_{\text{tatsächlich}} < \alpha_{\text{nominal}}.$$

8. Zweiseitige p-Werte sind bei diskreten, unsymmetrischen Verteilungen nicht immer einfach „zweimal die kleinere Randwahrscheinlichkeit“.

Im symmetrischen Beispiel mit $\pi_0 = 0{,}5$ funktioniert die Verdopplung. Allgemein existieren mehrere Definitionen von „mindestens so extrem“, etwa gleichseitige Randbereiche oder Wahrscheinlichkeitsordnung. Softwarepakete können deshalb leicht unterschiedliche exakte p-Werte liefern.

9. Test und Konfidenzintervall sind nur bei methodischer Abstimmung exakt äquivalent.

Ein exakter Binomialtest und ein approximatives Wald-Intervall müssen nicht für jede Stichprobe dieselbe Entscheidung liefern. Exakte Test-Intervall-Dualität entsteht, wenn das Intervall tatsächlich durch Invertieren genau dieses Tests konstruiert wird.

10. Das Wald-Konfidenzintervall kann bei kleinem n oder extremem $\widehat{\pi}$ versagen.

Es kann schlechte Überdeckungswahrscheinlichkeiten besitzen und sogar Grenzen außerhalb von $[0, 1]$ erzeugen. Robustere Alternativen sind etwa Wilson-, Agresti-Coull- oder exakte Clopper-Pearson-Intervalle.

11. Die Modellannahmen sind Teil der Schlussfolgerung.

Der Binomialtest setzt insbesondere identische Erfolgswahrscheinlichkeiten und Unabhängigkeit voraus. Bei Clusterung, zeitlicher Abhängigkeit, wechselnden Erfolgswahrscheinlichkeiten oder selektiver Stichprobenziehung kann die angenommene Binomialverteilung falsch sein.

12. Statistische Signifikanz ist nicht wirtschaftliche oder praktische Relevanz.

Ein sehr großes n kann einen winzigen Effekt signifikant machen. Für wirtschaftswissenschaftliche Entscheidungen müssen zusätzlich Effektgröße, Konfidenzintervall, Kosten, Nutzen und Kausalitätsannahmen betrachtet werden.

13. Mehrfaches Testen erhöht die Wahrscheinlichkeit mindestens eines Fehlers 1. Art.

Wer viele Hypothesen prüft und nur die signifikanten Ergebnisse berichtet, überschreitet ohne Korrektur die nominelle Gesamtfehlerwahrscheinlichkeit. Typische Gegenmaßnahmen sind Bonferroni-Korrektur oder Verfahren zur Kontrolle der False Discovery Rate.

14. Optionales Stoppen verändert die Fehlerkontrolle.

Wird die Datenerhebung immer dann beendet, wenn der p-Wert erstmals unter α fällt, gilt die ursprüngliche Fehlergarantie im Allgemeinen nicht mehr. Stichprobengröße und Auswertungsregel müssen vorab festgelegt oder mit sequenziellen Verfahren korrekt berücksichtigt werden.

15. Recheninkonsistenz im Vorlesungsmaterial beim Impfstoffbeispiel.

Die Folien geben für $n = 20$, $\pi_0 = 0{,}5$ und die obere Grenze teilweise $a_2 = 14$ mit

$$P_{0,5}(Z \geq 14) \approx 0{,}02$$

an. Tatsächlich gilt

$$P_{0,5}(Z \geq 14) \approx 0{,}057659 > 0{,}025.$$

Korrekt ist

$$a_U = 15,$$

weil

$$P_{0,5}(Z \geq 15) \approx 0{,}020695.$$

Ebenso ist der auf der Folie angegebene Wert

$$3{,}8 \cdot 10^{-6}$$

für

$$P_{0,5}(Z \geq 15)$$

nicht korrekt. Die richtige einseitige Randwahrscheinlichkeit beträgt ungefähr

$$0{,}020695,$$

und der symmetrisch verdoppelte zweiseitige p-Wert beträgt ungefähr

$$0{,}041389.$$

Die Testentscheidung bleibt dennoch dieselbe: H_0 wird bei $\alpha = 0{,}05$ verworfen.

5. Active Recall (Wissenstest)

1. Begründe ohne bloß auf eine Grafik zu verweisen, warum beim rechtsseitigen Binomialtest für $H_0 : \pi \le \pi_0$ die maximale Wahrscheinlichkeit eines Fehlers 1. Art am Rand $\pi = \pi_0$ liegt. Leite anschließend her, warum die Summe aus dieser maximalen Fehlerwahrscheinlichkeit und dem Supremum des Fehlers 2. Art über $\pi > \pi_0$ gleich 1 ist.
2. Konstruiere für $n = 20$, $\pi_0 = 0{,}5$ und $\alpha = 0{,}05$ einen zweiseitigen gleichseitigen Binomialtest. Bestimme beide kritischen Grenzen, den Ablehnbereich und die tatsächliche Größe des Tests. Erkläre außerdem, weshalb die obere Grenze 14 unzulässig ist.
3. Für $n = 100$, $\pi_0 = 0{,}25$ und $z_{\text{obs}} = 50$ soll $H_0 : \pi \le 0{,}25$ gegen $H_1 : \pi > 0{,}25$ getestet werden. Formuliere den exakten p-Wert, begründe die Verwendung des Randwerts π_0 und interpretiere das Ergebnis inhaltlich, ohne den p-Wert als Wahrscheinlichkeit von H_0 zu deuten.
4. Erkläre die Test-Konfidenzintervall-Dualität durch Invertierung einer Familie zweiseitiger Tests. Begründe anschließend, warum ein exakter Binomialtest und ein Wald-Konfidenzintervall trotz gleicher nomineller Irrtumswahrscheinlichkeit in einzelnen Stichproben zu unterschiedlichen Entscheidungen kommen können.
5. Zwei Studien beobachten dieselbe Abweichung $\widehat{\pi} - \pi_0$, aber Studie B besitzt die vierfache Stichprobengröße von Studie A. Analysiere, wie sich der Standardfehler, der Betrag einer asymptotischen standardisierten Teststatistik, der p-Wert und die Power typischerweise verändern. Erkläre, warum daraus noch keine Aussage über die wirtschaftliche Relevanz des Effekts folgt.

6. Lösungen zum Active Recall

1. Mit der Kopplung $X_i(\pi) = \mathbf{1}\{U_i \le \pi\}$ folgt aus $\pi_1 \le \pi_2$ punktweise $Z(\pi_1) \le Z(\pi_2)$. Daher ist $P_\pi(Z \ge a)$ wachsend und unter H_0 bei π_0 maximal. Außerdem ist $P_{\pi_0}(Z \ge a) + P_{\pi_0}(Z < a) = 1$; wegen der offenen Alternative ist der zweite Term das Supremum von $\beta(\pi)$ für $\pi \downarrow \pi_0$.
2. Es gilt $a_L = 5$ und $a_U = 15$. Damit ist

$$A = \{0, \dots, 5\} \cup \{15, \dots, 20\},$$

und die tatsächliche Größe beträgt

$$2P_{0,5}(Z \le 5) \approx 0{,}041389.$$

Die Grenze 14 ist unzulässig, weil

$$P_{0,5}(Z \ge 14) \approx 0{,}057659 > 0{,}025.$$

3. Der p-Wert ist

$$\sup_{\pi \le 0{,}25} P_\pi(Z \ge 50) = P_{0{,}25}(Z \ge 50) \approx 6{,}64 \cdot 10^{-8}.$$

Der Randwert wird wegen der Monotonie der oberen Schwanzwahrscheinlichkeit verwendet. Solche oder extremere Daten wären unter der gesamten Nullhypothese äußerst selten; daher wird H_0 verworfen.

4. Das Intervall enthält genau die Werte θ_0, deren Punkthypothesen $H_0 : \theta = \theta_0$ nicht verworfen werden. Deshalb gilt Verwerfung genau dann, wenn θ_0 außerhalb liegt. Ein Wald-Intervall ist jedoch eine Normalapproximation und nicht zwingend die Inversion des exakten Binomialtests; Diskretheit und Approximationsfehler können daher unterschiedliche Entscheidungen erzeugen.

5. Bei vierfachem n halbiert sich der Standardfehler ungefähr, weil er proportional zu $1/\sqrt{n}$ ist. Bei unverändertem Zähler verdoppelt sich der Betrag der standardisierten Teststatistik, der p-Wert wird typischerweise kleiner und die Power größer. Die Effektgröße selbst bleibt jedoch gleich; wirtschaftliche Relevanz hängt von ihrer sachlichen Bedeutung, Kosten und Nutzen ab, nicht allein von der statistischen Präzision.