Lernzettel – Statistik und Data Science I, Vorlesung 12: Spezielle Testprobleme

1. Das Big Picture (Chunking)

Dieses Kapitel löst die Frage, wie man das allgemeine Testprinzip an sehr unterschiedliche Zielgrößen anpasst: Erwartungswert, Varianz, Median, Unabhängigkeit und Verteilungsform. Im Kern wird immer dieselbe Maschine gebaut: Hypothesen formulieren, eine unter der Nullhypothese bekannte Teststatistik konstruieren, unwahrscheinliche Werte als Ablehnbereich festlegen und die beobachteten Daten daran messen. Relevant ist das, weil die Wahl des Tests nicht vom gewünschten Ergebnis, sondern von Datentyp, Zielparameter und tragfähigen Modellannahmen abhängt.

2. Zentrale Definitionen

Statistischer Test

- **Fachliche Definition:** Ein statistischer Test ist eine Entscheidungsregel, die eine Stichprobe über eine Teststatistik und einen Ablehnbereich in die Entscheidungen „Nullhypothese verwerfen“ oder „Nullhypothese nicht verwerfen“ übersetzt.
- **Feynman-Übersetzung:** Wir legen vor dem Blick auf das Ergebnis fest, welche Daten unter einer Ausgangsbehauptung so ungewöhnlich wären, dass wir diese Behauptung fallen lassen.

Nullhypothese und Alternative

- **Fachliche Definition:** Die Nullhypothese H_0 beschreibt die Menge der Parameterwerte oder Verteilungen, gegen die getestet wird. Die Alternative H_1 beschreibt die konkurrierenden Werte oder Modelle.
- **Feynman-Übersetzung:** H_0 ist die Ausgangsposition. H_1 ist die Richtung, für die wir Belege suchen.

Signifikanzniveau

- **Fachliche Definition:** Das Signifikanzniveau α ist eine vorab festgelegte obere Schranke für die Wahrscheinlichkeit, H_0 zu verwerfen, obwohl H_0 gilt.
- **Feynman-Übersetzung:** α ist das maximal akzeptierte Risiko für einen Fehlalarm.

Fehler erster und zweiter Art

- **Fachliche Definition:** Ein Fehler erster Art liegt vor, wenn H_0 verworfen wird, obwohl H_0 wahr ist. Ein Fehler zweiter Art liegt vor, wenn H_0 nicht verworfen wird, obwohl H_1 wahr ist. Die zugehörigen Wahrscheinlichkeiten werden häufig mit α und β bezeichnet.
- **Feynman-Übersetzung:** Fehler erster Art: Alarm ohne echtes Problem. Fehler zweiter Art: Ein echtes Problem wird übersehen.

Teststatistik

- **Fachliche Definition:** Eine Teststatistik $T = T(X_1, \dots, X_n)$ ist eine Funktion der Stichprobe, deren Verteilung unter H_0 bekannt oder approximierbar ist und die Abweichungen von H_0 quantifiziert.
- **Feynman-Übersetzung:** Die Teststatistik komprimiert alle Daten zu einer einzigen Zahl, die sagt, wie schlecht die Daten zur Ausgangsbehauptung passen.

Ablehnbereich

- **Fachliche Definition:** Der Ablehnbereich A enthält diejenigen Werte der Teststatistik, bei deren Beobachtung H_0 verworfen wird. Er wird so gewählt, dass unter H_0 die Wahrscheinlichkeit $P_{H_0}(T \in A)$ höchstens α beträgt.
- **Feynman-Übersetzung:** Das ist die rote Zone: Landet unsere Kennzahl dort, sind die Daten unter H_0 zu ungewöhnlich.

Kritischer Wert

- **Fachliche Definition:** Ein kritischer Wert ist ein Quantil der Nullverteilung, das die Grenze zwischen Ablehnungs- und Nichtablehnungsbereich festlegt.
- **Feynman-Übersetzung:** Er ist die vorher festgelegte Grenzmarke, die die Teststatistik überschreiten muss.

p-Wert

- **Fachliche Definition:** Der p-Wert ist unter H_0 die Wahrscheinlichkeit, eine mindestens so stark gegen H_0 sprechende Teststatistik wie die beobachtete zu erhalten. Die genaue Definition von „mindestens so stark“ richtet sich nach der Alternative.
- **Feynman-Übersetzung:** Der p-Wert fragt: Wie oft würden unter H_0 Daten auftreten, die mindestens so extrem sind wie unsere?

Konfidenzintervall-Test-Dualität

- **Fachliche Definition:** Bei vielen regulären Tests wird eine punktförmige Nullhypothese $H_0 : \theta = \theta_0$ auf Niveau α genau dann nicht verworfen, wenn θ_0 im zugehörigen Konfidenzintervall mit Konfidenzniveau $1 - \alpha$ liegt.
- **Feynman-Übersetzung:** Test und Konfidenzintervall erzählen dieselbe Geschichte aus zwei Blickwinkeln: Der Test prüft einen Kandidatenwert, das Intervall zeigt alle Kandidatenwerte, die den Test bestehen würden.

Standardfehler

- **Fachliche Definition:** Der Standardfehler ist die Standardabweichung der Stichprobenverteilung eines Schätzers. Für den Stichprobenmittelwert bei unabhängigen, identisch verteilten Beobachtungen mit Varianz σ^2 ist er $\sigma/\sqrt{n}$.
- **Feynman-Übersetzung:** Er beschreibt, wie stark ein Schätzwert von Stichprobe zu Stichprobe typischerweise wackelt.

Freiheitsgrade

- **Fachliche Definition:** Freiheitsgrade zählen die Anzahl unabhängig variierbarer Informationsanteile, nachdem Nebenbedingungen und geschätzte Parameter berücksichtigt wurden.
- **Feynman-Übersetzung:** Freiheitsgrade sagen, wie viele Zahlen sich noch frei bewegen dürfen, wenn bestimmte Summen oder Parameter bereits feststehen.

Parametrischer Test

- **Fachliche Definition:** Ein parametrischer Test setzt eine Verteilungsfamilie mit endlich vielen Parametern voraus, etwa eine Normalverteilung mit Erwartungswert μ und Varianz σ^2.
- **Feynman-Übersetzung:** Wir nehmen an, dass die Daten aus einer bekannten Formfamilie stammen und prüfen nur deren Stellschrauben.

Vorzeichentest

- **Fachliche Definition:** Der Vorzeichentest ist ein verteilungsfreier Test für einen Median. Unter einem stetigen Modell wird gezählt, wie viele Beobachtungen auf einer Seite des hypothetischen Medians liegen; unter H_0 folgt diese Anzahl einer Binomialverteilung mit Erfolgswahrscheinlichkeit $0{,}5$.
- **Feynman-Übersetzung:** Statt Abstände zu messen, zählen wir nur, wie viele Werte links und rechts vom behaupteten Mittelpunkt liegen.

χ^2-Unabhängigkeitstest

- **Fachliche Definition:** Der χ^2-Unabhängigkeitstest prüft in einer Kontingenztafel, ob die gemeinsame Verteilung zweier kategorialer Merkmale in das Produkt ihrer Randverteilungen zerfällt.
- **Feynman-Übersetzung:** Wir prüfen, ob die Häufigkeiten in den Zellen so aussehen, wie sie bei völlig getrennten Merkmalen aussehen müssten.

χ^2-Anpassungstest

- **Fachliche Definition:** Der χ^2-Anpassungstest vergleicht beobachtete Kategorienhäufigkeiten mit den unter einer vorgegebenen Verteilung erwarteten Häufigkeiten.
- **Feynman-Übersetzung:** Wir prüfen, ob die beobachtete Verteilung zu einem vorgegebenen Bauplan passt.

Konsistenz eines Tests

- **Fachliche Definition:** In der Formulierung der Vorlesung heißt ein Test konsistent, wenn bei wachsendem Stichprobenumfang die Wahrscheinlichkeiten beider Fehlentscheidungen gegen 0 gehen. In einer häufig verwendeten engeren Definition bedeutet Konsistenz vor allem, dass für jede feste Alternative die Teststärke gegen 1 geht.
- **Feynman-Übersetzung:** Mit immer mehr Daten soll der Test die Wahrheit immer zuverlässiger erkennen.

3. Formeln, Beweise & Intuition

3.1 Die universelle Testlogik

Die Formel

Ein Test auf Niveau α basiert auf einer Teststatistik T und einem Ablehnbereich A mit

$$\sup_{\theta \in \Theta_0} P_\theta(T \in A) \leq \alpha.$$

Die Entscheidungsregel lautet

$$T_{\text{obs}} \in A \Rightarrow H_0 \text{ verwerfen},$$

$$T_{\text{obs}} \notin A \Rightarrow H_0 \text{ nicht verwerfen}.$$

Dekonstruktion

- Θ_0: Menge aller unter H_0 zulässigen Parameterwerte.
- P_θ: Wahrscheinlichkeitsmodell bei Parameterwert θ.
- T: Teststatistik.
- A: Ablehnbereich.
- α: maximal tolerierte Wahrscheinlichkeit eines Fehlers erster Art.
- T_{obs}: aus den beobachteten Daten berechneter Wert.

Der Beweis / Die Herleitung

1. Ein Test darf nicht erst nach Betrachtung der Daten seine Grenze festlegen, sonst wäre die Fehlerwahrscheinlichkeit unbekannt.
2. Deshalb wird die Nullverteilung von T bestimmt: Wie verhält sich T, wenn H_0 gilt?
3. Aus dieser Verteilung wird eine Menge A ausgewählt, die unter H_0 höchstens Wahrscheinlichkeit α besitzt.
4. Liegt T_{obs} in dieser seltenen Menge, ist entweder ein seltenes Ereignis unter H_0 eingetreten oder H_0 ist falsch.
5. Der Test entscheidet sich kontrolliert für die zweite Interpretation, wobei das Risiko der ersten Interpretation durch α begrenzt bleibt.

Die Analogie & Mechanik

Ein Rauchmelder wird so kalibriert, dass gewöhnlicher Kochdampf nur selten Alarm auslöst. A ist der Alarmbereich. Ein kleineres α verschiebt die Alarmgrenze weiter nach außen: Es gibt weniger Fehlalarme, aber echte Brände können leichter übersehen werden.

3.2 Test für den Erwartungswert bei bekannter Varianz

Modell und Hypothesen

Es gelten unabhängige Beobachtungen

$$X_1, \dots, X_n \overset{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2),$$

wobei σ^2 bekannt ist. Die drei Grundformen sind

$$H_0 : \mu = \mu_0 \quad \text{gegen} \quad H_1 : \mu \neq \mu_0,$$

$$H_0 : \mu \geq \mu_0 \quad \text{gegen} \quad H_1 : \mu < \mu_0,$$

$$H_0 : \mu \leq \mu_0 \quad \text{gegen} \quad H_1 : \mu > \mu_0.$$

Die Formel

$$Z = \frac{\overline{X} - \mu_0}{\sigma/\sqrt{n}}.$$

Unter der Randnullhypothese $\mu = \mu_0$ gilt

$$Z \sim \mathcal{N}(0,1).$$

Dekonstruktion

- X_i: Beobachtung i.
- n: Stichprobenumfang.
- $\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$: Stichprobenmittelwert.
- μ: unbekannter Erwartungswert der Grundgesamtheit.
- μ_0: unter H_0 behaupteter Grenz- oder Punktwert.
- σ: bekannte Standardabweichung der Einzelbeobachtungen.
- $\sigma/\sqrt{n}$: Standardfehler von $\overline{X}$.
- Z: standardisierte Distanz zwischen Beobachtung und Nullwert.

Der Beweis / Die Herleitung

Aus der Stabilität der Normalverteilung folgt

$$\overline{X} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$

Subtraktion des Erwartungswerts und Division durch die Standardabweichung liefern

$$\frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1).$$

Unter $H_0 : \mu = \mu_0$ darf μ durch μ_0 ersetzt werden:

$$\frac{\overline{X} - \mu_0}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1).$$

Damit ist die Nullverteilung vollständig bekannt und ihre Quantile können als kritische Werte dienen.

Ablehnbereiche

Für den zweiseitigen Test:

$$A = \left(-\infty, -z_{1-\alpha/2}\right) \cup \left(z_{1-\alpha/2}, \infty\right).$$

Äquivalent:

$$|Z| > z_{1-\alpha/2}.$$

Für den linksseitigen Test:

$$A = \left(-\infty, -z_{1-\alpha}\right).$$

Für den rechtsseitigen Test:

$$A = (z_{1-\alpha}, \infty)\,.$$

Dabei ist z_q das q-Quantil der Standardnormalverteilung:

$$P(Z \leq z_q) = q.$$

Warum wird beim zweiseitigen Test α halbiert?

1. Unter $H_1 : \mu \neq \mu_0$ sprechen sowohl sehr kleine als auch sehr große Mittelwerte gegen H_0.
2. Die gesamte erlaubte Fehlalarmwahrscheinlichkeit beträgt α.
3. Wegen der Symmetrie der Standardnormalverteilung wird diese Wahrscheinlichkeit gleich auf beide Enden verteilt.
4. Jede Seite erhält daher Wahrscheinlichkeit $\alpha/2$.

Die Analogie & Mechanik

Z misst die Abweichung in Einheiten typischer Mittelwertschwankungen. Ein Wert $Z = 2$ bedeutet: Der beobachtete Mittelwert liegt zwei Standardfehler vom Nullwert entfernt.

- Wird der Zähler $|\overline{X} - \mu_0|$ groß, wächst der Widerspruch zu H_0.
- Wird der Nenner $\sigma/\sqrt{n}$ klein, wird dieselbe absolute Abweichung überzeugender.
- Wenn n wächst, sinkt der Standardfehler mit $1/\sqrt{n}$. Viermal so viele Beobachtungen halbieren ihn.
- Wenn σ groß ist, sind starke Stichprobenschwankungen normal; derselbe Abstand wird weniger auffällig.

p-Werte

Zweiseitig:

$$p = 2P\left(Z \geq |z_{\text{obs}}|\right) = 2\left[1 - \Phi\left(|z_{\text{obs}}|\right)\right].$$

Linksseitig:

$$p = P(Z \leq z_{\text{obs}}) = \Phi(z_{\text{obs}}).$$

Rechtsseitig:

$$p = P(Z \geq z_{\text{obs}}) = 1 - \Phi(z_{\text{obs}}).$$

Hier bezeichnet Φ die Verteilungsfunktion der Standardnormalverteilung.

Die Entscheidungsregel ist

$$p \leq \alpha \Rightarrow H_0 \text{ verwerfen.}$$

Konfidenzintervall und Dualität

Das zweiseitige Konfidenzintervall mit Konfidenzniveau $1-\alpha$ lautet

$$\left[\overline{X} - z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}, \overline{X} + z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\right].$$

Herleitung aus dem Pivot:

$$P\left(-z_{1-\alpha/2} \leq \frac{\overline{X}-\mu}{\sigma/\sqrt{n}} \leq z_{1-\alpha/2}\right) = 1-\alpha.$$

Multiplikation mit $\sigma/\sqrt{n}$ ergibt

$$P\left(-z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}} \leq \overline{X}-\mu \leq z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\right) = 1-\alpha.$$

Nach μ umgestellt:

$$P\left(\overline{X} - z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}} \leq \mu \leq \overline{X} + z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\right) = 1-\alpha.$$

Der Punkt μ_0 liegt genau dann außerhalb dieses Intervalls, wenn

$$\left|\frac{\overline{X}-\mu_0}{\sigma/\sqrt{n}}\right| > z_{1-\alpha/2}.$$

Das ist exakt die Ablehnungsbedingung des zweiseitigen Tests.

Beispiel Bleistiftlänge bei bekannter Varianz

Gegeben sind

$$\mu_0 = 17, \qquad \sigma = 1{,}5, \qquad n = 5, \qquad \overline{x} = 18{,}1.$$

Die Teststatistik ist

$$z_{\text{obs}} = \frac{18{,}1-17}{1{,}5/\sqrt{5}} \approx 1{,}64.$$

Für $\alpha = 0{,}01$ und einen zweiseitigen Test ist

$$z_{1-\alpha/2} = z_{0{,}995} \approx 2{,}579.$$

Da

$$|1{,}64| < 2{,}579,$$

wird H_0 nicht verworfen. Der zugehörige p-Wert ist ungefähr

$$p = 2\left[1-\Phi(1{,}64)\right] \approx 0{,}10.$$

Das 99%-Konfidenzintervall ist

$$18{,}1 \pm 2{,}579\frac{1{,}5}{\sqrt{5}}$$

und damit ungefähr

$$[16{,}37; 19{,}83].$$

Da 17 im Intervall liegt, ergibt sich dieselbe Entscheidung.

3.3 Test für den Erwartungswert bei unbekannter Varianz

Die Formel für die Varianzschätzung

$$S_*^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2.$$

Die Teststatistik lautet

$$T = \frac{\overline{X} - \mu_0}{S_*/\sqrt{n}}.$$

Unter $H_0 : \mu = \mu_0$ und bei normalverteilten Daten gilt

$$T \sim t_{n-1}.$$

Dekonstruktion

- S_*^2: unverzerrte Stichprobenvarianz.
- $S_* = \sqrt{S_*^2}$: Stichprobenstandardabweichung.
- $n-1$: Freiheitsgrade der Varianzschätzung.
- t_{n-1}: Student-t-Verteilung mit $n-1$ Freiheitsgraden.
- T: standardisierte Mittelwertabweichung mit geschätztem Standardfehler.

Warum steht im Nenner $n-1$?

Die Abweichungen erfüllen zwangsläufig

$$\sum_{i=1}^{n}(X_i - \overline{X}) = 0.$$

Sind $n-1$ Abweichungen bekannt, ist die letzte bereits festgelegt. Es existieren daher nur $n-1$ frei variierbare Abweichungen. Für normalverteilte Daten gilt außerdem

$$E\left[\sum_{i=1}^{n}(X_i - \overline{X})^2\right] = (n-1)\sigma^2.$$

Division durch $n-1$ liefert deshalb

$$E(S_*^2) = \sigma^2.$$

Der Beweis / Die Herleitung der t-Verteilung

Für eine Normalstichprobe gelten zwei zentrale Resultate:

$$U = \frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1),$$

$$V = \frac{(n-1)S_*^2}{\sigma^2} \sim \chi^2_{n-1}.$$

Außerdem sind U und V unabhängig. Nun gilt

$$\frac{S_*}{\sigma} = \sqrt{\frac{V}{n-1}}.$$

Daher folgt

$$\frac{\overline{X} - \mu}{S_*/\sqrt{n}} = \frac{U}{\sqrt{V/(n-1)}} \sim t_{n-1}.$$

Unter H_0 wird μ durch μ_0 ersetzt.

Ablehnbereiche

Zweiseitig:

$$|T| > t_{1-\alpha/2,n-1}.$$

Linksseitig:

$$T < -t_{1-\alpha,n-1}.$$

Rechtsseitig:

$$T > t_{1-\alpha,n-1}.$$

Die Analogie & Mechanik

Beim z-Test kennen wir die Geräuschstärke σ. Beim t-Test müssen wir sie aus denselben Daten schätzen. Diese zusätzliche Unsicherheit macht die t-Verteilung breiter und ihre kritischen Werte größer.

- Kleines n: S_* ist unsicher, die Verteilung hat schwere Ränder, starke Evidenz ist schwerer zu erreichen.
- Großes n: t_{n-1} nähert sich $\mathcal{N}(0,1)$; die Zusatzunsicherheit verschwindet.
- Sehr kleines S_* macht $|T|$ groß. Das ist nur überzeugend, wenn die geringe Streuung realistisch und nicht durch Messrundung, Ausreißerbereinigung oder Datenabhängigkeit künstlich erzeugt wurde.

Beispiel Bleistiftlänge bei unbekannter Varianz

Für die fünf Beobachtungen ergibt sich

$$\overline{x} = 18{,}1, \qquad s_*^2 = 1{,}265, \qquad s_* \approx 1{,}125.$$

Damit

$$t_{\text{obs}} = \frac{18{,}1 - 17}{\sqrt{1{,}265}/\sqrt{5}} \approx 2{,}187.$$

Für $\alpha = 0{,}01$ und $n - 1 = 4$ Freiheitsgrade ist

$$t_{0{,}995,4} \approx 4{,}604.$$

Da

$$|2{,}187| < 4{,}604,$$

wird H_0 nicht verworfen. Der große Unterschied zwischen $2{,}579$ beim z-Test und $4{,}604$ beim t-Test zeigt den Preis der unbekannten Varianz bei sehr kleinem n.

3.4 Test für die Varianz einer Normalverteilung

Modell und Hypothesen

Es gilt

$$X_1, \ldots, X_n \overset{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2),$$

wobei μ und σ^2 unbekannt sind. Typische Hypothesen lauten

$$H_0 : \sigma^2 = \sigma_0^2 \quad \text{gegen} \quad H_1 : \sigma^2 \neq \sigma_0^2,$$

$$H_0 : \sigma^2 \geq \sigma_0^2 \quad \text{gegen} \quad H_1 : \sigma^2 < \sigma_0^2,$$

$$H_0 : \sigma^2 \leq \sigma_0^2 \quad \text{gegen} \quad H_1 : \sigma^2 > \sigma_0^2.$$

Die Formel

$$Q = \frac{(n-1)S_*^2}{\sigma_0^2}.$$

Unter $H_0 : \sigma^2 = \sigma_0^2$ gilt

$$Q \sim \chi^2_{n-1}.$$

Dekonstruktion

- S_*^2: beobachtete Stichprobenvarianz.
- σ_0^2: unter H_0 behauptete Varianz.
- Q: Verhältnis der beobachteten gesamten quadrierten Streuung zur unter H_0 erwarteten Skala.
- $n-1$: Freiheitsgrade, weil der unbekannte Mittelwert durch $\overline{X}$ geschätzt wurde.

Der Beweis / Die Herleitung

Standardisiere jede Beobachtung:

$$Y_i = \frac{X_i - \mu}{\sigma} \sim \mathcal{N}(0,1).$$

Die gesamte Streuung um den geschätzten Mittelwert erfüllt für eine Normalstichprobe

$$\frac{1}{\sigma^2}\sum_{i=1}^{n}(X_i - \overline{X})^2 \sim \chi^2_{n-1}.$$

Da

$$(n-1)S_*^2 = \sum_{i=1}^{n}(X_i - \overline{X})^2,$$

folgt

$$\frac{(n-1)S_*^2}{\sigma^2} \sim \chi^2_{n-1}.$$

Unter H_0 gilt $\sigma^2 = \sigma_0^2$, womit die Teststatistik entsteht.

Ablehnbereiche

Zweiseitig:

$$A = \left[0, \chi^2_{\alpha/2,n-1}\right) \cup \left(\chi^2_{1-\alpha/2,n-1}, \infty\right).$$

Linksseitig:

$$A = \left[0, \chi^2_{\alpha,n-1}\right).$$

Rechtsseitig:

$$A = \left(\chi^2_{1-\alpha,n-1}, \infty\right).$$

Warum ist der zweiseitige Bereich nicht symmetrisch?

Die χ^2-Verteilung nimmt nur nichtnegative Werte an und ist besonders bei wenigen Freiheitsgraden rechtsschief. Deshalb liegen die beiden kritischen Werte nicht gleich weit von einem Mittelpunkt entfernt. Gleich verteilt wird die Wahrscheinlichkeit, nicht die geometrische Distanz:

$$P\left(Q < \chi^2_{\alpha/2,n-1}\right) = \frac{\alpha}{2},$$

$$P\left(Q > \chi^2_{1-\alpha/2,n-1}\right) = \frac{\alpha}{2}.$$

Die Analogie & Mechanik

Stelle dir σ_0^2 als erlaubtes Vibrationsniveau einer Maschine vor. S_*^2 misst die beobachtete Vibration.

- Sehr großes S_*^2 macht Q groß: Die Maschine streut stärker als behauptet.
- Sehr kleines S_*^2 macht Q klein: Die Streuung ist ungewöhnlich gering.
- Sehr kleines σ_0^2 im Nenner macht dieselbe beobachtete Streuung extrem groß relativ zur Behauptung.
- Der Test reagiert auf quadrierte Abweichungen und ist daher besonders empfindlich gegenüber Ausreißern und Verletzungen der Normalverteilung.

3.5 Vorzeichentest für den Median

Modell und Hypothesen

Die Daten $X_1, \dots, X_n$ seien unabhängig und identisch verteilt mit stetiger Verteilungsfunktion. Für einen hypothetischen Median m_0 werden etwa die Hypothesen

$$H_0 : m = m_0 \quad \text{gegen} \quad H_1 : m \neq m_0$$

geprüft.

Die Formel

Definiere

$$Z = \sum_{i=1}^{n} \mathbf{1}\{X_i \leq m_0\}.$$

Unter H_0 gilt wegen der Stetigkeit

$$P(X_i \leq m_0) = 0{,}5$$

und damit

$$Z \sim \text{Bin}(n, 0{,}5).$$

Dekonstruktion

- m: wahrer Median.
- m_0: unter H_0 behaupteter Median.
- $\mathbf{1}\{X_i \leq m_0\}$: Indikator, der den Wert 1 annimmt, wenn X_i links von oder auf m_0 liegt, sonst 0.
- Z: Anzahl der Beobachtungen auf dieser Seite.
- Bin$(n, 0{,}5)$: Binomialverteilung mit n Versuchen und Erfolgswahrscheinlichkeit $0{,}5$.

Der Beweis / Die Herleitung

1. Ein Median m_0 teilt die Verteilung so, dass mindestens die Hälfte der Wahrscheinlichkeit links und mindestens die Hälfte rechts liegt.
2. Bei einer stetigen Verteilung ist $P(X_i = m_0) = 0$. Daher gilt exakt

$$P(X_i < m_0) = P(X_i > m_0) = 0{,}5.$$

3. Jeder Indikator ist somit eine Bernoulli-Zufallsvariable:

$$\mathbf{1}\{X_i \leq m_0\} \sim \text{Bernoulli}(0{,}5).$$

4. Wegen der Unabhängigkeit ist die Summe der n Indikatoren binomialverteilt.

Zweiseitiger p-Wert

Bei einer symmetrischen Binomialverteilung und beobachtetem Wert z_{obs} kann man die mindestens ebenso extremen Randbereiche zusammenfassen. Für $z_{\text{obs}} > n/2$ lautet die symmetrische Form

$$p = P\left(Z \leq n - z_{\text{obs}}\right) + P\left(Z \geq z_{\text{obs}}\right).$$

Wegen der Symmetrie bei Erfolgswahrscheinlichkeit $0{,}5$ gilt

$$p = 2P\left(Z \geq z_{\text{obs}}\right)$$

sofern die Verdopplung nicht größer als 1 wird.

Die Analogie & Mechanik

Der Vorzeichentest ignoriert, wie weit ein Wert von m_0 entfernt ist. Ein Wert knapp oberhalb und ein extremer Wert weit oberhalb zählen beide nur als „rechts“.

- Vorteil: Extreme Ausreißer können die Teststatistik kaum dominieren.
- Preis: Viele metrische Informationen werden weggeworfen; bei tatsächlich normalverteilten Daten ist ein passender parametrischer Test häufig teststärker.
- Wenn fast alle Werte auf einer Seite liegen, wird Z extrem und H_0 unplausibel.

Beispiel Genesungsdauer

Von $n = 10$ Beobachtungen liegen 7 bei höchstens 200 Wochen. Daher

$$z_{\text{obs}} = 7.$$

Unter $H_0 : m = 200$ gilt

$$Z \sim \text{Bin}(10, 0{,}5).$$

Die symmetrisch ebenso extremen Werte sind $Z \leq 3$ und $Z \geq 7$. Daher

$$p = P(Z \leq 3) + P(Z \geq 7) \approx 0{,}3439.$$

Bei $\alpha = 0{,}05$ wird H_0 nicht verworfen.

3.6 χ^2-Unabhängigkeitstest

Datenstruktur und Hypothese

Zwei kategoriale Merkmale X und Y besitzen die Ausprägungen

$$a_1, \ldots, a_J$$

und

$$b_1, \ldots, b_K.$$

Die beobachtete Zellenhäufigkeit wird mit h_{jk} bezeichnet. Die Randhäufigkeiten sind

$$h_{j\bullet} = \sum_{k=1}^{K} h_{jk},$$

$$h_{\bullet k} = \sum_{j=1}^{J} h_{jk},$$

und

$$n = \sum_{j=1}^{J} \sum_{k=1}^{K} h_{jk}.$$

Geprüft wird

$$H_0 : X \text{ und } Y \text{ sind stochastisch unabhängig}$$

gegen

$$H_1 : X \text{ und } Y \text{ sind nicht stochastisch unabhängig.}$$

Die Formel für Unabhängigkeit

Unter H_0 gilt

$$\pi_{jk} = P(X = a_j, Y = b_k) = P(X = a_j)P(Y = b_k) = \pi_{j\bullet}\pi_{\bullet k}.$$

Die Randwahrscheinlichkeiten werden durch relative Randhäufigkeiten geschätzt:

$$\hat{\pi}_{j\bullet} = \frac{h_{j\bullet}}{n},$$

$$\hat{\pi}_{\bullet k} = \frac{h_{\bullet k}}{n}.$$

Damit ergibt sich die erwartete Zellenhäufigkeit

$$\tilde{h}_{jk} = n\hat{\pi}_{j\bullet}\hat{\pi}_{\bullet k}.$$

Einsetzen liefert die zentrale Rechenformel

$$\tilde{h}_{jk} = n\frac{h_{j\bullet}}{n}\frac{h_{\bullet k}}{n} = \frac{h_{j\bullet}h_{\bullet k}}{n}.$$

Warum ist „Zeilensumme mal Spaltensumme durch Gesamtzahl“ logisch?

Angenommen, der Anteil einer Zeile beträgt $h_{j\bullet}/n$ und der Anteil einer Spalte beträgt $h_{\bullet k}/n$. Bei Unabhängigkeit ist der erwartete gemeinsame Anteil das Produkt dieser Anteile. Multipliziert man diesen Anteil wieder mit n, erhält man die erwartete Anzahl in der Zelle.

Die Teststatistik

$$Q = \sum_{j=1}^{J}\sum_{k=1}^{K}\frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}}.$$

Unter H_0 gilt approximativ

$$Q \overset{a}{\sim} \chi^2_{(J-1)(K-1)},$$

sofern die erwarteten Häufigkeiten nicht zu klein sind.

Der Ablehnbereich ist

$$A = \left(\chi^2_{1-\alpha,(J-1)(K-1)}, \infty\right).$$

Dekonstruktion

- h_{jk}: beobachtete Anzahl in Zelle (j, k).
- $\tilde{h}_{jk}$: unter Unabhängigkeit erwartete Anzahl.
- $h_{jk} - \tilde{h}_{jk}$: rohe Abweichung.
- $(h_{jk} - \tilde{h}_{jk})^2$: verhindert Aufhebung positiver und negativer Abweichungen.
- Division durch $\tilde{h}_{jk}$: skaliert die Abweichung relativ zur erwarteten Zellgröße.
- Q: Summe aller standardisierten Zellabweichungen.

Warum wird durch die erwartete Häufigkeit geteilt?

Eine Abweichung um 5 ist in einer Zelle mit Erwartungswert 10 gravierender als in einer Zelle mit Erwartungswert 1000. Für Zählvariablen ist die Varianz grob proportional zur erwarteten Häufigkeit. Der Quotient

$$\frac{(h_{jk} - \tilde{h}_{jk})^2}{\tilde{h}_{jk}}$$

misst daher näherungsweise eine quadrierte Abweichung in Einheiten ihrer typischen Zufallsschwankung.

Herleitung der Freiheitsgrade

Eine allgemeine $J \times K$-Tabelle besitzt JK Zellwahrscheinlichkeiten. Wegen

$$\sum_{j=1}^{J} \sum_{k=1}^{K} \pi_{jk} = 1$$

sind davon $JK - 1$ frei.

Unter Unabhängigkeit werden nur die Randverteilungen benötigt:

- Für X sind $J - 1$ Wahrscheinlichkeiten frei.
- Für Y sind $K - 1$ Wahrscheinlichkeiten frei.

Das Unabhängigkeitsmodell besitzt somit

$$(J - 1) + (K - 1)$$

freie Parameter. Die Differenz zum allgemeinen Modell ist

$$(JK - 1) - [(J - 1) + (K - 1)] = (J - 1)(K - 1).$$

Die Analogie & Mechanik

Stelle dir eine Tabelle als Schachbrett vor. Die Randhäufigkeiten geben vor, wie viel Masse jede Zeile und Spalte insgesamt tragen muss. Unabhängigkeit verteilt diese Masse proportional über die Zellen. Q misst, wie stark das tatsächliche Muster von diesem proportionalen Muster abweicht.

- Große Zellenabweichungen vergrößern Q quadratisch.
- Kleine erwartete Häufigkeiten stehen im Nenner und können einzelne Beiträge stark aufblasen.
- Ein großes Q zeigt irgendeinen Zusammenhang, aber nicht automatisch Richtung, Stärke oder praktische Bedeutung.

Beispiel Sonntagsfrage

Für $J = 2$ Geschlechtskategorien und $K = 7$ Parteikategorien gelten

$$(J-1)(K-1) = 1 \cdot 6 = 6$$

Freiheitsgrade. Die Vorlesung erhält

$$q_{\text{obs}} = 3{,}832.$$

Für $\alpha = 0{,}05$ ist der kritische Wert

$$\chi^2_{0{,}95,6} \approx 12{,}59.$$

Da

$$3{,}832 < 12{,}59,$$

wird H_0 nicht verworfen. Aus diesen Daten kann kein statistisch signifikanter Zusammenhang nachgewiesen werden.

3.7 χ^2-Anpassungstest

Diskretes Modell und Hypothesen

Die Zufallsvariable X kann die Werte $a_1, \dots, a_J$ annehmen. Vorgegeben sind Wahrscheinlichkeiten $\pi_1, \dots, \pi_J$ mit

$$\sum_{j=1}^{J} \pi_j = 1.$$

Geprüft wird

$$H_0 : P(X = a_j) = \pi_j \quad \text{für alle } j$$

gegen

$$H_1 : P(X = a_j) \neq \pi_j \quad \text{für mindestens ein } j.$$

Erwartete Häufigkeiten

Unter H_0 ist die erwartete Häufigkeit in Kategorie j

$$\tilde{h}_j = n\pi_j.$$

Die Teststatistik

$$Q = \sum_{j=1}^{J} \frac{(h_j - n\pi_j)^2}{n\pi_j}.$$

Unter H_0 gilt approximativ

$$Q \overset{a}{\sim} \chi^2_{J-1}.$$

Der Ablehnbereich ist

$$A = \left(\chi^2_{1-\alpha,J-1}, \infty\right).$$

Dekonstruktion

- h_j: beobachtete Häufigkeit in Kategorie j.
- $n\pi_j$: unter H_0 erwartete Häufigkeit.
- Q: gesamter standardisierter Abstand zwischen beobachteter und vorgegebener Verteilung.
- $J-1$: Freiheitsgrade wegen der festen Gesamtsumme $\sum_{j=1}^{J} h_j = n$.

Herleitung der Freiheitsgrade

Die J Kategorienhäufigkeiten summieren sich zu n. Sind $J-1$ Häufigkeiten bekannt, folgt die letzte aus

$$h_J = n - \sum_{j=1}^{J-1} h_j.$$

Daher können nur $J-1$ Kategorien unabhängig variieren.

Wenn r Parameter der Nullverteilung aus denselben Daten geschätzt werden, lautet die übliche Anpassung

$$\text{df} = J - 1 - r.$$

Jeder geschätzte Parameter verbraucht einen unabhängigen Informationsanteil, weil das Modell gezielt näher an die beobachteten Daten angepasst wird.

Stetige Verteilungen durch Klassierung

Für eine stetige Zufallsvariable wird der Wertebereich in Intervalle zerlegt:

$$c_0 < c_1 < \cdots < c_J.$$

Unter einer vorgegebenen Verteilung mit Verteilungsfunktion F gilt

$$\pi_j = P(c_{j-1} \leq X \leq c_j) = F(c_j) - F(c_{j-1}).$$

Danach wird mit den Intervallhäufigkeiten derselbe χ^2-Anpassungstest durchgeführt.

Die Analogie & Mechanik

Der Anpassungstest ist eine Qualitätskontrolle für einen Verteilungsbauplan. Jede Kategorie hat ein Sollgewicht $n\pi_j$. Die Teststatistik addiert die relativ skalierten Soll-Ist-Abweichungen.

- Große Differenzen erhöhen Q quadratisch.
- Seltene Kategorien mit kleinem $n\pi_j$ können starke Beiträge liefern.
- Durch zu grobe Intervalle können relevante Abweichungen verborgen werden.
- Durch zu feine Intervalle entstehen kleine erwartete Häufigkeiten und die χ^2-Approximation wird unzuverlässig.

Beispiel Absolvent*innenstudie

Beobachtet werden

$$(h_1, h_2, h_3) = (4, 12, 18)$$

bei

$$n = 34.$$

Unter Gleichverteilung gilt

$$\pi_1 = \pi_2 = \pi_3 = \frac{1}{3}$$

und damit für jede Kategorie

$$n\pi_j = \frac{34}{3} \approx 11{,}33.$$

Die Teststatistik ist

$$Q = \frac{(4-11{,}33)^2}{11{,}33} + \frac{(12-11{,}33)^2}{11{,}33} + \frac{(18-11{,}33)^2}{11{,}33} \approx 8{,}706.$$

Mit

$$J - 1 = 2$$

Freiheitsgraden und $\alpha = 0{,}05$ gilt

$$\chi^2_{0{,}95,2} \approx 5{,}99.$$

Da

$$8{,}706 > 5{,}99,$$

wird H_0 verworfen. Mindestens eine Kategorienwahrscheinlichkeit unterscheidet sich von $1/3$. Der globale Test sagt allein noch nicht, welche Kategorie die Abweichung hauptsächlich verursacht.

3.8 Gemeinsame Mechanik der Teststatistiken

Viele Teststatistiken folgen demselben Grundmuster:

$$\text{Testsignal} = \frac{\text{beobachtete Abweichung von } H_0}{\text{typische Zufallsschwankung unter } H_0}.$$

Beim Mittelwerttest:

$$\frac{\overline{X} - \mu_0}{\mathrm{SE}(\overline{X})}.$$

Beim χ^2-Test zellweise:

$$\frac{(\text{beobachtet} - \text{erwartet})^2}{\text{erwartet}}.$$

Die Logik ist immer relativ, nicht absolut. Eine Abweichung ist nur dann überzeugend, wenn sie groß im Verhältnis zu dem ist, was Zufall allein gewöhnlich erzeugt.

Zähler extrem groß

Ist der Zähler groß, liegen Daten und Nullhypothese weit auseinander. Die Teststatistik bewegt sich typischerweise in Richtung Ablehnbereich.

Nenner extrem klein

Ist der Nenner klein, wird bereits eine moderate Abweichung statistisch auffällig. Das kann durch große Stichproben entstehen, aber auch durch unrealistisch kleine Streuung, winzige erwartete Zellen oder Modellfehler. Ein kleiner Nenner erhöht daher sowohl Sensitivität als auch Anfälligkeit.

Stichprobenumfang extrem groß

Mit wachsendem n werden Standardfehler kleiner. Dann können auch praktisch unbedeutende Effekte statistisch signifikant werden. Deshalb sollte Signifikanz mit Effektgröße und fachlicher Relevanz verbunden werden.

4. Häufige Missverständnisse & Edge Cases

„H_0 nicht verwerfen“ bedeutet nicht „H_0 ist bewiesen“

Ein nicht signifikantes Ergebnis kann entstehen, weil H_0 plausibel ist, aber auch weil die Stichprobe klein, die Streuung groß oder der Test unpassend ist. Die korrekte Aussage lautet: Die Daten liefern auf dem gewählten Niveau nicht genügend Evidenz gegen H_0.

Der p-Wert ist nicht die Wahrscheinlichkeit, dass H_0 wahr ist

Der p-Wert ist eine Wahrscheinlichkeit über mögliche Daten unter angenommener Gültigkeit von H_0. Er berechnet nicht $P(H_0 \mid \text{Daten})$.

Einseitig oder zweiseitig wird vor der Datenanalyse entschieden

Nach einem positiven Ergebnis spontan einen rechtsseitigen Test zu wählen, halbiert den p-Wert opportunistisch und zerstört die Kontrolle des Fehlers erster Art. Die Richtung muss sachlich vorab begründet sein.

Statistische Signifikanz ist nicht praktische Relevanz

Bei sehr großem n kann ein winziger, fachlich bedeutungsloser Effekt signifikant werden. Umgekehrt kann ein fachlich großer Effekt bei kleinem n nicht signifikant sein. Berichte daher zusätzlich Schätzer, Konfidenzintervalle und geeignete Effektgrößen.

Der z-Test mit bekannter Varianz ist ein Spezialfall

In realen Anwendungen ist σ^2 selten wirklich bekannt. Wird eine aus derselben kleinen Stichprobe geschätzte Standardabweichung wie eine bekannte Konstante behandelt, sind die kritischen Werte zu klein und der Test wird zu liberal.

Der exakte t-Test braucht Normalität

Die exakte t-Verteilung folgt aus Normalität und der Unabhängigkeit von $\overline{X}$ und S_*^2. Bei starken Ausreißern, Schiefe oder Abhängigkeit kann die Kalibrierung besonders bei kleinem n scheitern. Bei moderaten Abweichungen und größerem n ist der Mittelwerttest oft robust, aber nicht automatisch.

Der Varianztest ist besonders normalitätssensitiv

Die χ^2-Verteilung von $(n-1)S_*^2/\sigma^2$ gilt exakt nur für normalverteilte Daten. Schwere Verteilungsränder oder Ausreißer können die Fehlerwahrscheinlichkeit stark verfälschen.

Ties beim Vorzeichentest

Die Vorlesungsherleitung nimmt eine stetige Verteilung an, sodass $P(X_i = m_0) = 0$ gilt. In realen gerundeten Daten können Gleichstände auftreten. Üblicherweise werden Beobachtungen mit $X_i = m_0$ entfernt und der effektive Stichprobenumfang entsprechend reduziert; eine andere Behandlung verändert die Nullverteilung.

Der Vorzeichentest prüft den Median, nicht den Mittelwert

Ein symmetrisches Datenset kann ähnlichen Median und Mittelwert besitzen, aber bei Schiefe sind beide Zielgrößen verschieden. Die Wahl des Vorzeichentests darf nicht stillschweigend als Mittelwerttest interpretiert werden.

Diskrete p-Werte treffen α oft nicht exakt

Beim Binomialtest kann kein Ablehnbereich exakt Wahrscheinlichkeit α besitzen, weil nur diskrete Sprünge möglich sind. Exakte Tests sind deshalb häufig konservativ: Die tatsächliche Fehlerwahrscheinlichkeit liegt unter α.

Kleine erwartete Häufigkeiten gefährden χ^2-Approximationen

Die χ^2-Verteilung ist asymptotisch. Sind erwartete Häufigkeiten sehr klein, können die zellweisen Abweichungen nicht gut durch die Approximation beschrieben werden. Kategorien sollten fachlich sinnvoll zusammengelegt oder exakte beziehungsweise simulationsbasierte Verfahren erwogen werden.

Beim Unabhängigkeitstest sind Beobachtungen, nicht Zellen, unabhängig

Die Testherleitung setzt unabhängige Untersuchungseinheiten voraus. Wiederholte Messungen derselben Person, Clusterstichproben oder gepaarte Daten verletzen diese Annahme, selbst wenn die Kontingenztafel formal korrekt aussieht.

Ein signifikanter Unabhängigkeitstest lokalisiert den Zusammenhang nicht

Ein großes globales Q zeigt, dass mindestens eine Zelle vom Unabhängigkeitsmodell abweicht. Zur Interpretation müssen Zellbeiträge, standardisierte Residuen und eine fachlich passende Effektgröße untersucht werden. Post-hoc-Vergleiche erzeugen zusätzlich ein multiples Testproblem.

Beim Anpassungstest darf die Klassierung nicht nach dem Ergebnis optimiert werden

Wer Intervallgrenzen so lange verändert, bis ein gewünschtes Ergebnis entsteht, verändert die tatsächliche Fehlerwahrscheinlichkeit. Grenzen sollten vorab oder nach einer transparenten, datenunabhängigen Regel festgelegt werden.

Geschätzte Parameter reduzieren Freiheitsgrade

Wird beispielsweise eine Normalverteilung angepasst und werden μ und σ^2 aus denselben Daten geschätzt, gehen zwei Freiheitsgrade verloren. Die Verwendung von $J-1$ statt $J-1-2$ würde die Nullverteilung falsch kalibrieren.

Nullhypothesen am Rand zusammengesetzter Hypothesen

Bei einseitigen Mittelwerttests wie $H_0 : \mu \leq \mu_0$ wird der Ablehnbereich anhand des Randfalls $\mu = \mu_0$ kalibriert. Für kleinere Werte von μ ist ein großer positiver Testwert noch unwahrscheinlicher. Der Randfall maximiert daher die Fehlerwahrscheinlichkeit innerhalb von H_0.

Konsistenz ist keine Garantie für kleine Stichproben

Ein konsistenter Test kann bei kleinem oder mittlerem n geringe Teststärke besitzen. Asymptotische Sicherheit beantwortet nicht, ob das aktuelle Studiendesign genügend Information enthält.

5. Active Recall (Wissenstest)

1. Leite aus der Verteilung von $\overline{X}$ die Teststatistik des Mittelwerttests bei bekannter Varianz her. Erkläre dabei, warum der Standardfehler $\sigma/\sqrt{n}$ und nicht σ/n lautet und weshalb beim zweiseitigen Test das Signifikanzniveau auf zwei Ränder verteilt wird.
2. Erkläre präzise, warum das Ersetzen von σ durch S_* nicht einfach wieder zu einer Standardnormalverteilung führt. Rekonstruiere, welche zwei Zufallsgrößen zur t-Verteilung kombiniert werden und welche Rolle die Normalverteilungsannahme spielt.
3. Eine Kontingenztafel besitzt J Zeilen und K Spalten. Leite die erwartete Häufigkeit $\tilde{h}_{jk}$ aus der Unabhängigkeitsannahme her und begründe anschließend die Freiheitsgrade $(J-1)(K-1)$ ohne die Formel nur auswendig zu nennen.
4. Vergleiche Vorzeichentest und Ein-Stichproben-t-Test als Tests einer Lage. Welche Information nutzt jeder Test, gegen welche Datenprobleme ist er robust, und weshalb kann Robustheit mit einem Verlust an Teststärke bezahlt werden?
5. Beim χ^2-Anpassungstest wird ein sehr großer Wert der Teststatistik beobachtet. Erkläre, welche Schlussfolgerung zulässig ist, welche nicht zulässig ist und wie kleine erwartete Häufigkeiten, datenabhängige Klassengrenzen sowie aus den Daten geschätzte Parameter die Interpretation verändern.

6. Lösungen zum Active Recall

1. Wegen $\overline{X} \sim \mathcal{N}(\mu, \sigma^2/n)$ besitzt $\overline{X}$ die Standardabweichung $\sigma/\sqrt{n}$. Standardisierung unter $H_0 : \mu = \mu_0$ ergibt $Z = (\overline{X} - \mu_0)/(\sigma/\sqrt{n}) \sim \mathcal{N}(0,1)$. Beim zweiseitigen Test sprechen beide Ränder gegen H_0; deshalb wird die gesamte Fehlerwahrscheinlichkeit α als $\alpha/2$ auf jeden Rand verteilt.
2. S_* ist selbst zufällig, sodass der Nenner zusätzliche Unsicherheit enthält. Für Normaldaten sind $U = (\overline{X} - \mu)/(\sigma/\sqrt{n}) \sim \mathcal{N}(0,1)$ und $V = (n-1)S_*^2/\sigma^2 \sim \chi^2_{n-1}$ unabhängig. Der Quotient $U/\sqrt{V/(n-1)}$ folgt daher einer t-Verteilung. Ohne Normalität gilt diese exakte Struktur im Allgemeinen nicht.
3. Unter Unabhängigkeit gilt $\pi_{jk} = \pi_{j\bullet}\pi_{\bullet k}$. Mit $\hat{\pi}_{j\bullet} = h_{j\bullet}/n$ und $\hat{\pi}_{\bullet k} = h_{\bullet k}/n$ folgt $\tilde{h}_{jk} = n\hat{\pi}_{j\bullet}\hat{\pi}_{\bullet k} = h_{j\bullet}h_{\bullet k}/n$. Das allgemeine Tabellenmodell hat $JK - 1$ freie Wahrscheinlichkeiten, das Unabhängigkeitsmodell $(J-1) + (K-1)$; die Differenz ist $(J-1)(K-1)$.
4. Der t-Test nutzt Größe und Richtung aller Abstände zum hypothetischen Mittelwert und ist bei passender Normalannahme effizient. Der Vorzeichentest nutzt nur die Seite relativ zum hypothetischen Median und ist dadurch robust gegen Ausreißer und Verteilungsform. Weil er die Abstandsgrößen verwirft, enthält seine Teststatistik weniger Information und kann bei gut erfülltem parametrischem Modell geringere Teststärke besitzen.
5. Ein großes Q liefert Evidenz, dass mindestens eine beobachtete Kategorienwahrscheinlichkeit von der unter H_0 vorgegebenen abweicht. Es zeigt nicht automatisch, welche Kategorie verantwortlich ist oder ob die Abweichung praktisch wichtig ist. Kleine erwartete Häufigkeiten gefährden die χ^2-Approximation, datenabhängig gewählte Klassen verfälschen die Testkalibrierung und jeder aus denselben Daten geschätzte Modellparameter reduziert die Freiheitsgrade um eins.