# Deskriptive Statistik zur Beschreibung von Merkmalen

Prof. Dr. Thomas Kneib

Professur für Statistik

Wintersemester 2026/27






# Voraussetzungen

- Summenzeichen und mathematische Notation ($\Rightarrow$ M-V03, Vorkurs B1)
- Skalenniveaus ($\Rightarrow$ SDS1-V01)

# Lernziele

- Wie lässt sich die Verteilung eines Merkmals in einem gegebenen Datensatz beschreiben?
- Welche Maßzahlen beschreiben verschiedene Aspekte dieser Verteilung?
- Wie können Verteilungen grafisch dargestellt und typisiert werden?

# Häufigkeiten und Häufigkeitsverteilungen

- Gegeben seien Beobachtungen $x_1, \ldots, x_n$ zu einem Merkmal $X$, wobei $n$ den Stichprobenumfang bezeichne.
- Seien $a_1, \ldots, a_J$, $J \leq n$ die möglichen Ausprägungen des Merkmals $X$.
- Für mindestens ordinale Merkmale seien diese Werte darüberhinaus geordnet, also $a_1 < \ldots < a_J$.

- Absolute und relative Häufigkeiten der Merkmalsausprägungen:

$$h(a_j) = h_j \quad \text{absolute Häufigkeit der Ausprägung } a_j, \text{ d.h. Anzahl der } x_i \text{ aus } x_1, \ldots, x_n \text{ mit } x_i = a_j$$
$$f(a_j) = f_j = h_j/n \quad \text{relative Häufigkeit von } a_j$$

- Verteilung der absoluten Häufigkeiten:

$$h_1, \ldots, h_J$$

- Verteilung der relativen Häufigkeiten:

$$f_1, \ldots, f_J$$

- Bei stetigen Daten mit vielen möglichen Ausprägungen werden die Häufigkeiten in der Regel basierend auf einer Zerlegung des Datenbereichs in $J$ Intervalle/Klassen

$$[c_0, c_1], \ldots, (c_{j-1}, c_j], \ldots, (c_{J-1}, c_J]$$

bestimmt.

# Beispiel: Landwirtschaftliche Flächen

- Daten zur landwirtschaftlich genutzten Fläche von $n = 1.565$ Landwirten in der Wesermarsch
- Eine auf neun Klassen reduzierte Häufigkeitsverteilung aller Beobachtungen ergibt folgende absoluten Häufigkeiten:

| **Anbaufläche in ha** | **Absolute Häufigkeit** |
|---|---|
| $0 < x \leq 10$ | 421 |
| $10 < x \leq 20$ | 127 |
| $20 < x \leq 30$ | 134 |
| $30 < x \leq 50$ | 302 |
| $50 < x \leq 75$ | 365 |
| $75 < x \leq 100$ | 159 |
| $100 < x \leq 125$ | 38 |
| $125 < x \leq 150$ | 14 |
| $150 < x \leq 200$ | 5 |
| **Summe** | **1565** |

- Für die relativen Häufigkeiten ergibt sich folgende Verteilung für den Datensatz:

| **Anbaufläche in ha** | **Relative Häufigkeit** |
|---|---|
| $0 < x \leq 10$ | 0.2690 |
| $10 < x \leq 20$ | 0.0812 |
| $20 < x \leq 30$ | 0.0856 |
| $30 < x \leq 50$ | 0.1930 |
| $50 < x \leq 75$ | 0.2332 |
| $75 < x \leq 100$ | 0.1016 |
| $100 < x \leq 125$ | 0.0243 |
| $125 < x \leq 150$ | 0.0089 |
| $150 < x \leq 200$ | 0.0032 |
| **Summe** | **1.0000** |

# Säulendiagramm

- Die Häufigkeiten werden jeweils über ein zur $x$-Achse senkrechtes Rechteck dargestellt, wobei die **Höhen** $\mathcal{H}_j$ der Rechtecke proportional sind zu den absoluten bzw. relativen Häufigkeiten, d.h.

$$\mathcal{H}_1 \propto h_1, \ldots, \mathcal{H}_J \propto h_J$$

bzw.

$$\mathcal{H}_1 \propto f_1, \ldots, \mathcal{H}_J \propto f_J.$$

# Histogramm

- Die Häufigkeiten werden jeweils über ein zur $x$-Achse senkrechtes Rechteck dargestellt, wobei die **Flächen** $\mathcal{F}_j$ der Rechtecke proportional sind zu den relativen Häufigkeiten, d.h.

$$\mathcal{F}_1 \propto f_1, \ldots, \mathcal{F}_J \propto f_J.$$

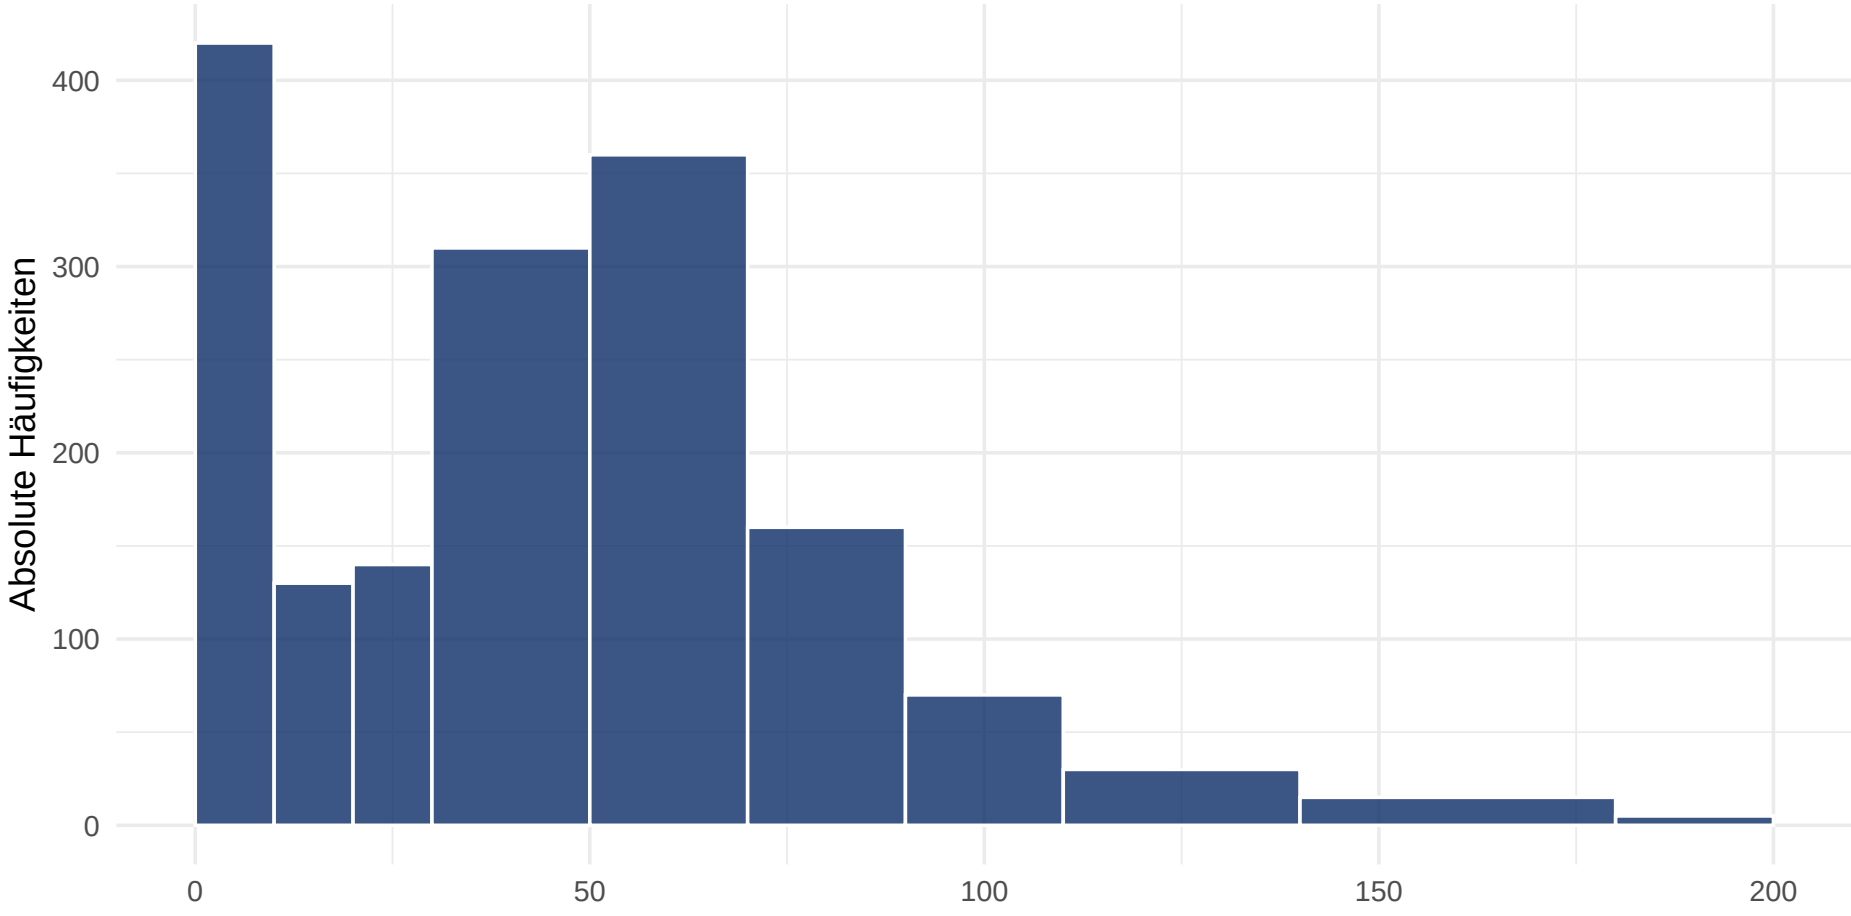
- Das Histogramm ist eine flächenproportionale Darstellung der Häufigkeitsverteilung.
- Die Höhen der Rechtecke sind entsprechend proportional zur

$$\text{Dichte:} \quad \frac{\text{relative Häufigkeit}}{\text{Breite des Rechtecks}}.$$

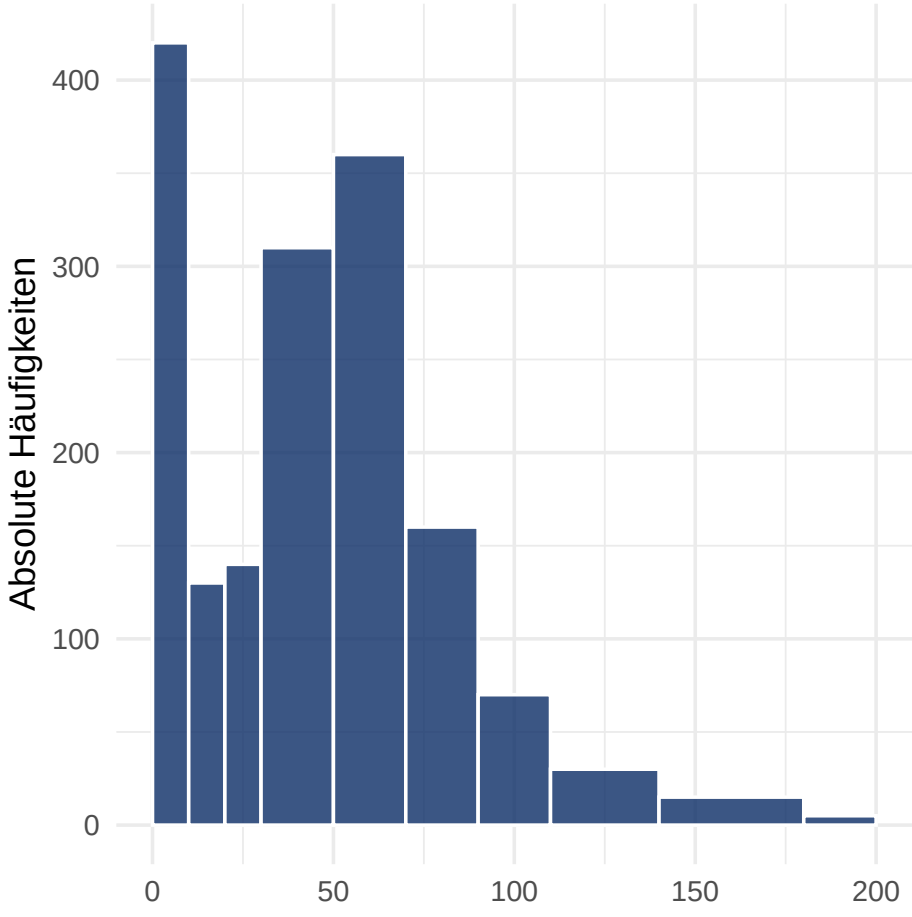
- Der Begriff **Dichte** wird in SDS1-V05 formal eingeführt. Hier reicht das Verständnis, dass Flächen unter der Dichte relativen Häufigkeiten entsprechen.
- In der Literatur werden auch Histogramme basierend auf absoluten Häufigkeiten verwendet. In dieser Veranstaltung betrachten wir nur Histogramme basierend auf relativen Häufigkeiten.

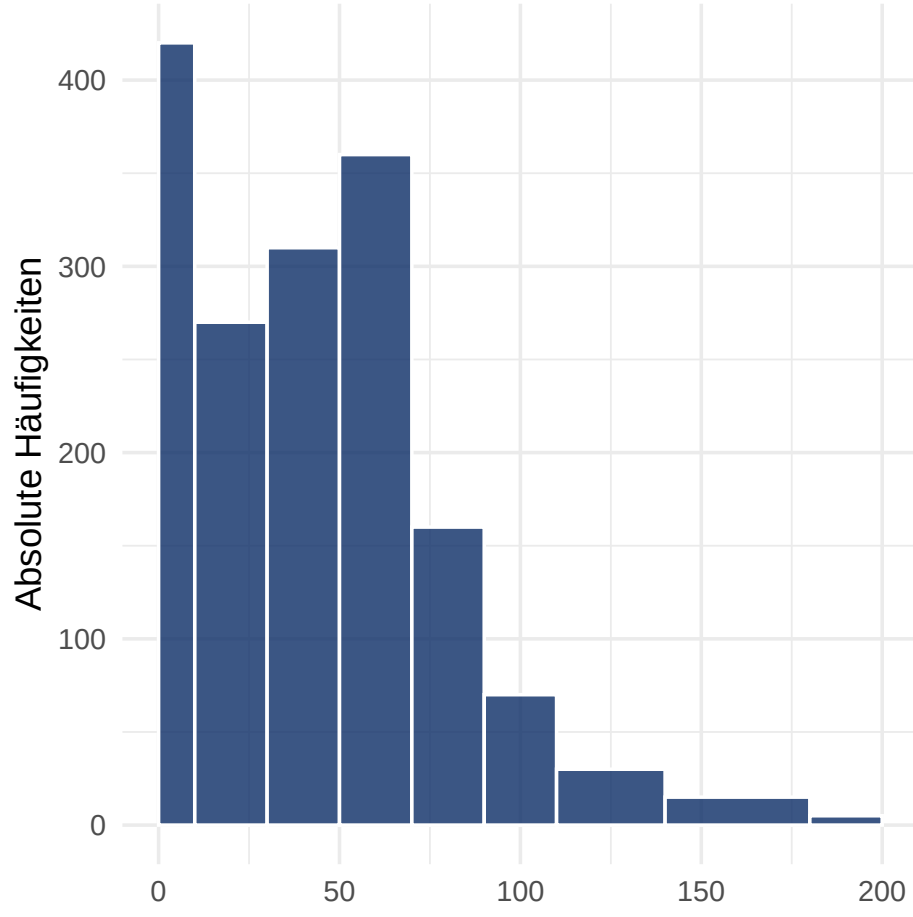
# Säulendiagramme und Histogramme

- Darstellung der Größe der landwirtschaftlicher Anbauflächen als Säulendiagramm:

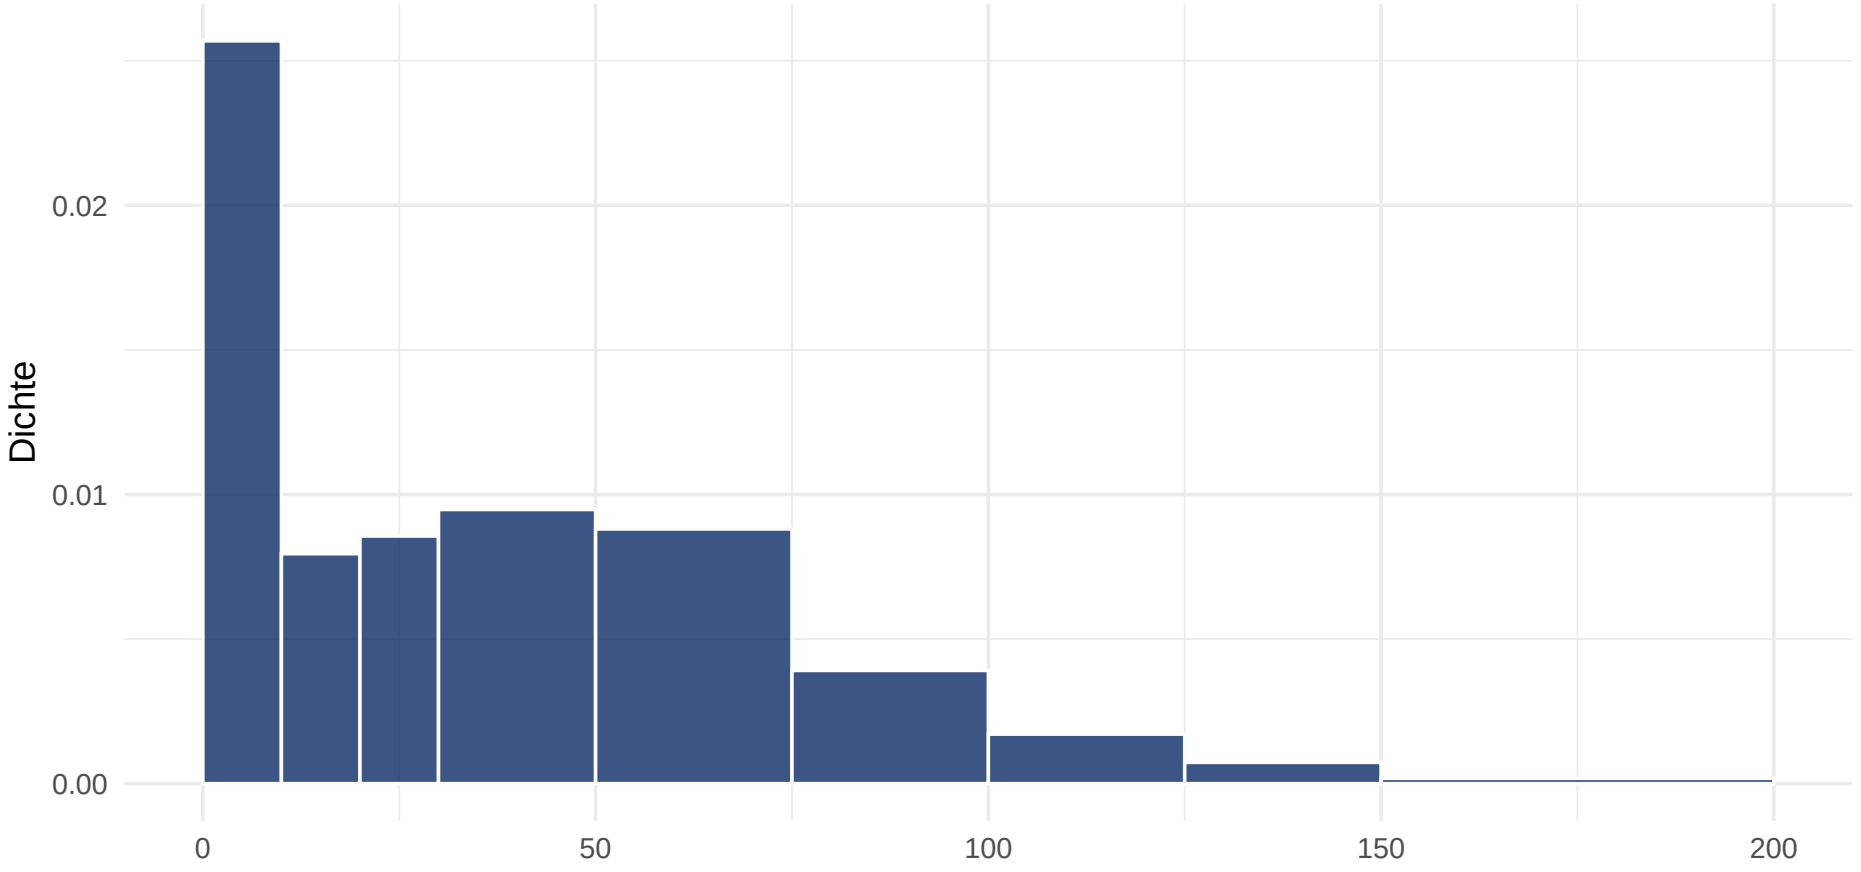


- Beim Säulendiagramm ist die visuelle Darstellung abhängig von der gewählten Breite der Klassen:

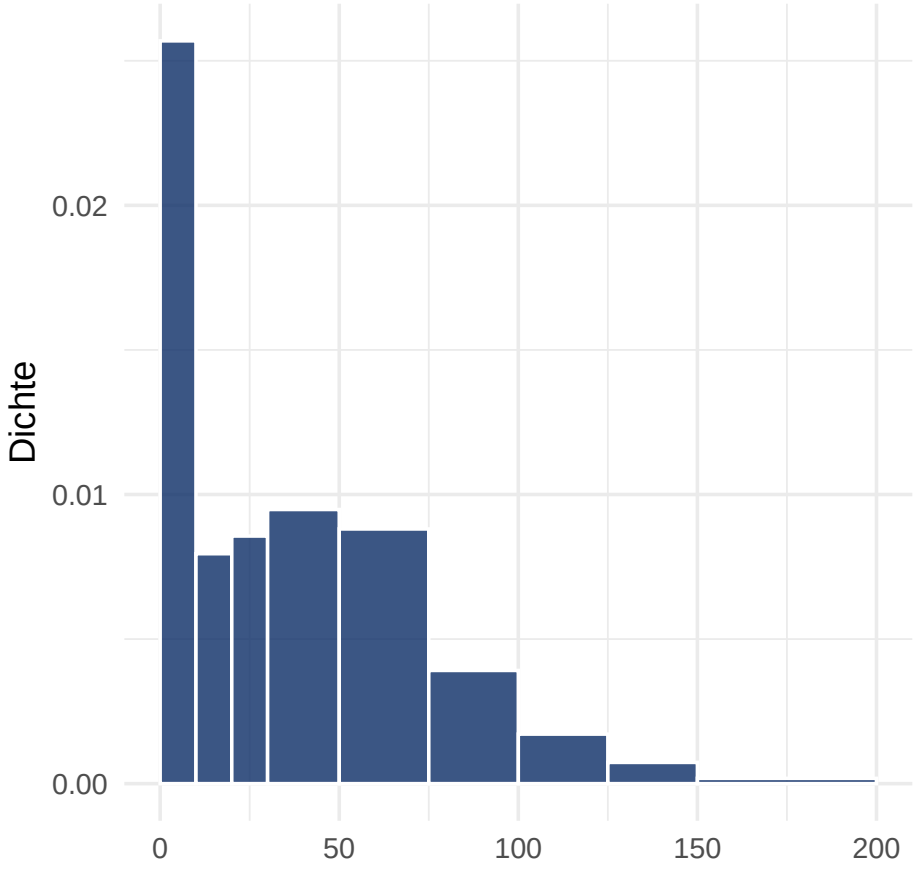


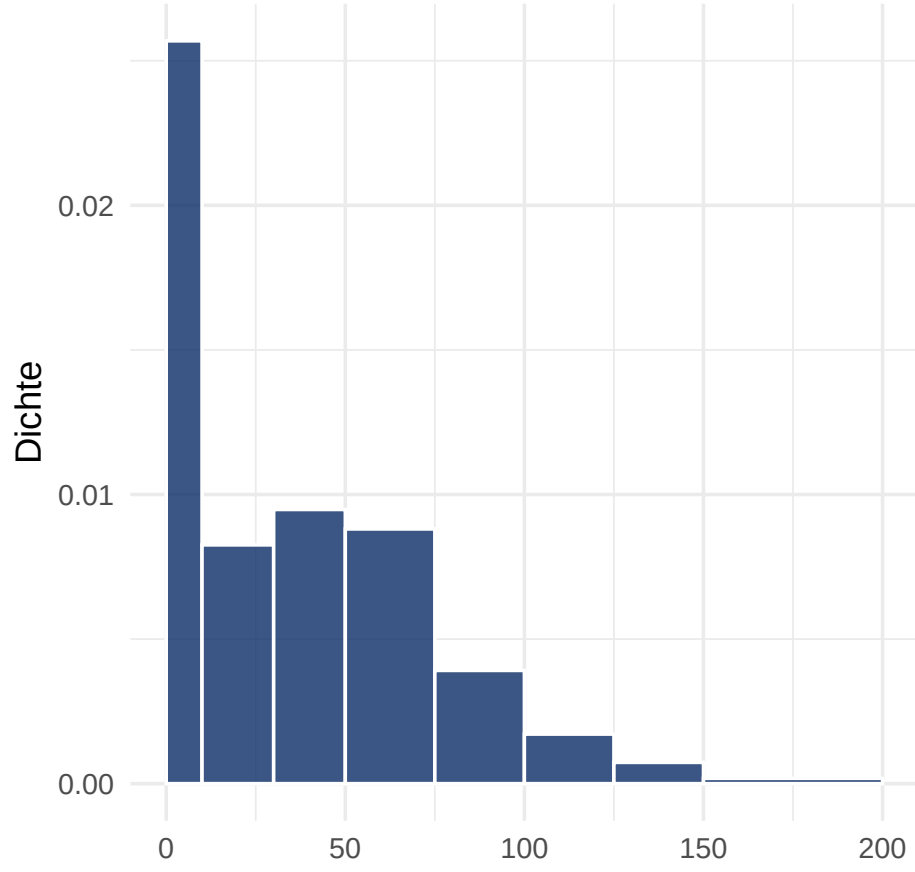



- Darstellung der Größe landwirtschaftlicher Anbauflächen als Histogramm:



- Beim Histogramm ist die visuelle Darstellung weitaus weniger abhängig von der gewählten Breite der Klassen:

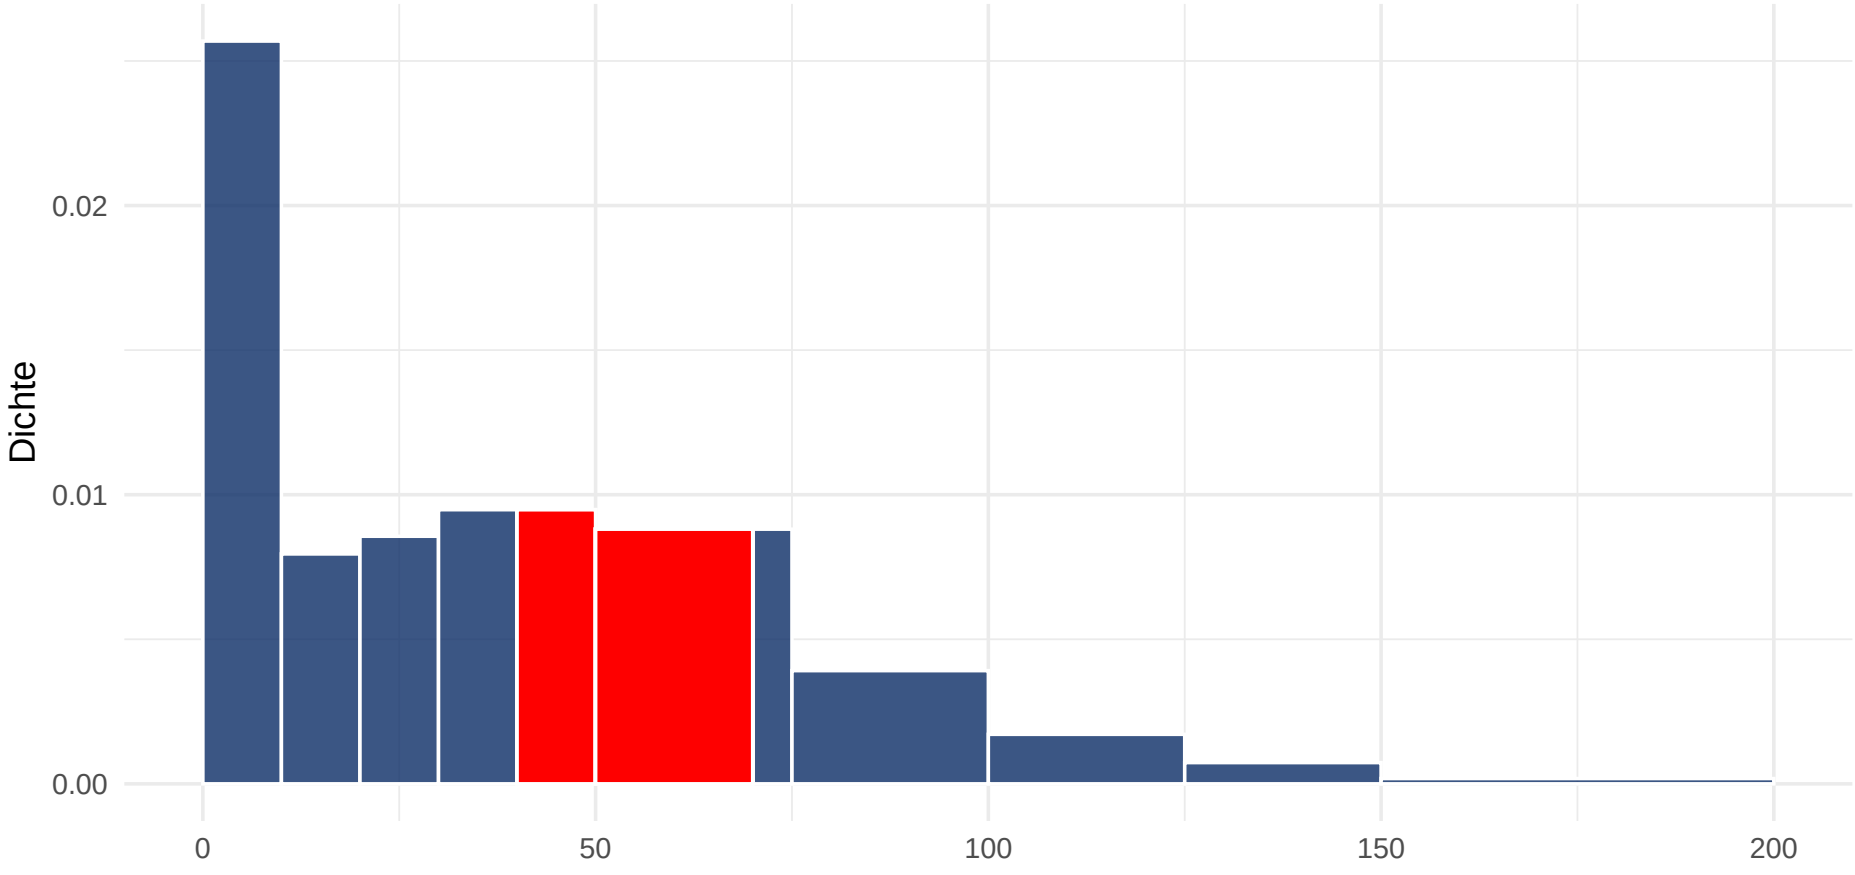


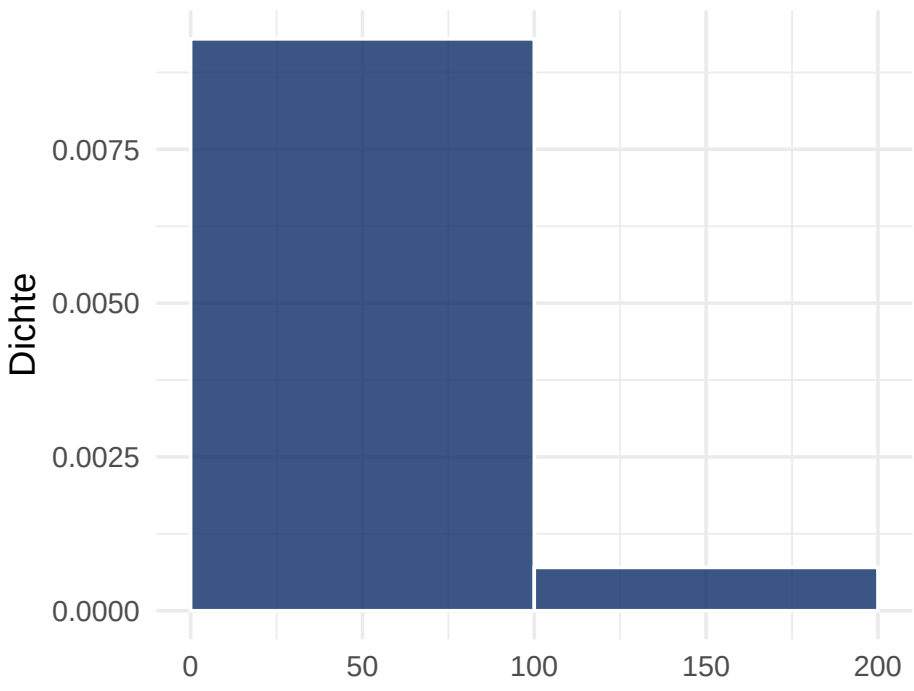
# Histogramme

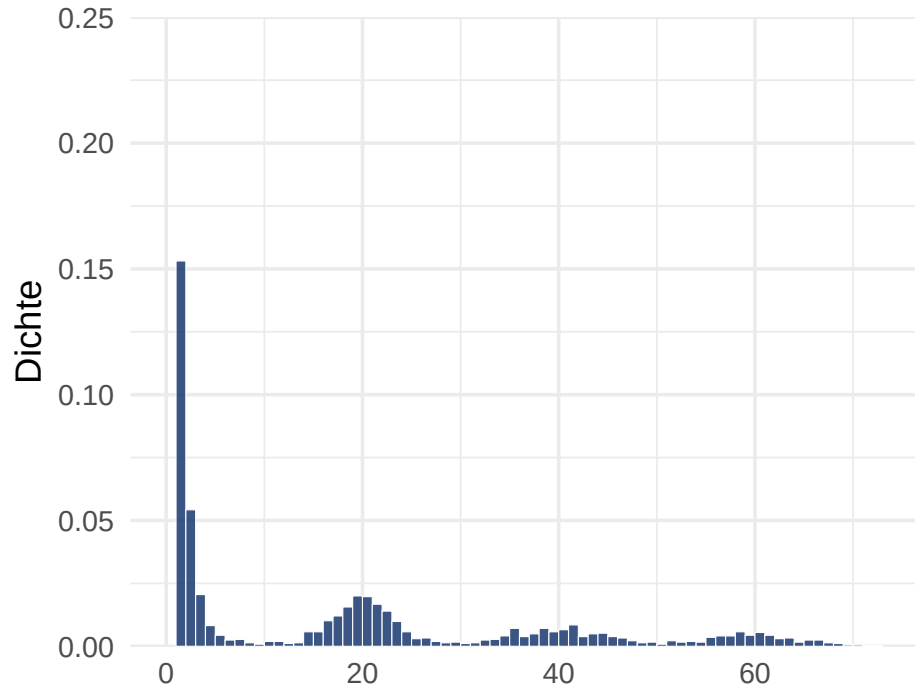
- Histogramme werden in dieser Veranstaltung als Goldstandard für die Visualisierung von Häufigkeiten stetiger Merkmale betrachtet.
- Die Gesamtfläche des Histogramms ist Eins, da die Flächen den Anteilen entsprechen, und alle Anteile zusammen eins ergeben.
- Entsprechend können Teile der Fläche zur Schätzung von Häufigkeiten beliebiger Klassen benutzt werden.
- Der geschätzte Anteil der landwirtschaftlichen Anbauflächen zwischen $a$ und $b$ ergibt sich aus $\int_a^b \mathcal{H}_x dx$, wobei $\mathcal{H}_x$ die Höhe des Histogramms an der Stelle $x$ ist.
- Diese Erkenntnis ist im Speziellen relevant für die Behandlung stetiger Verteilungen in der Veranstaltung SDS1-V05.

- Beispiel: Anteil der Landwirte mit landwirtschaftlich genutzter Fläche zwischen 40 und 70 ha:



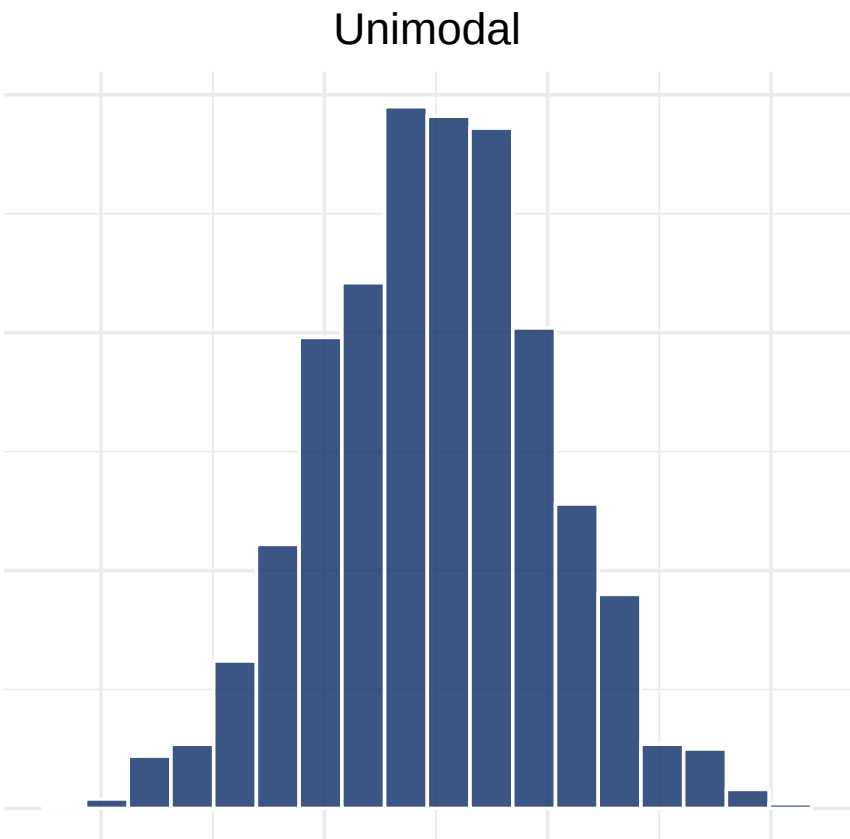
- Üblicherweise werden für Histogramme $J$ äquidistante Klassen verwendet.
- Bei der Wahl der Anzahl $J$ sollte grundsätzlich mit Bedacht vorgegangen werden $\Longrightarrow$ **Bias-Variance-Trade Off**.

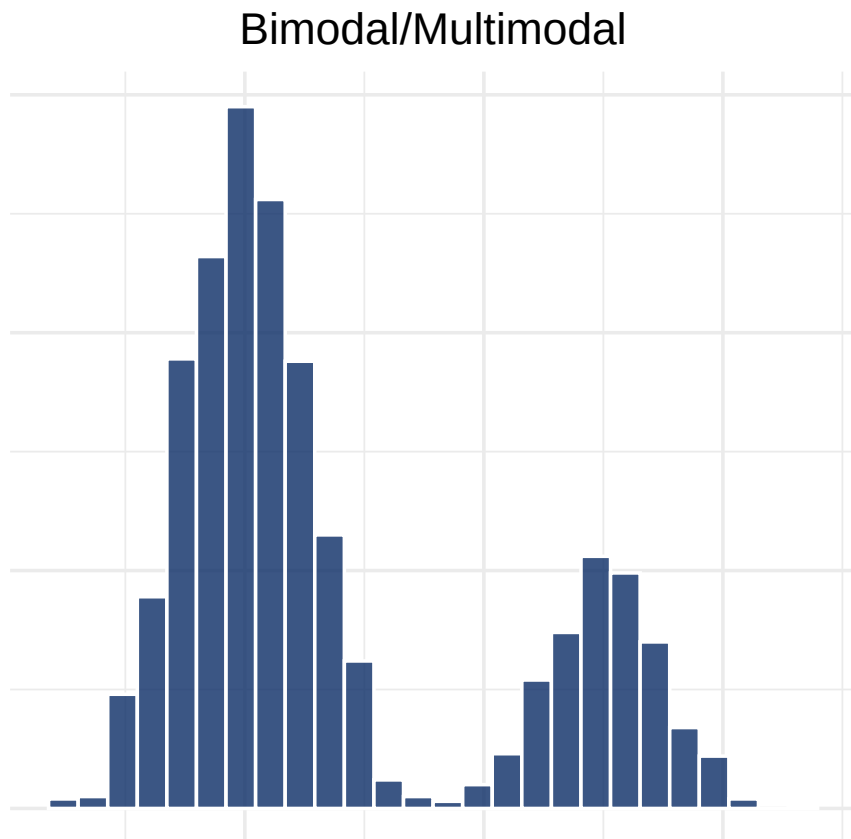


# Typisierung von Häufigkeitsverteilungen

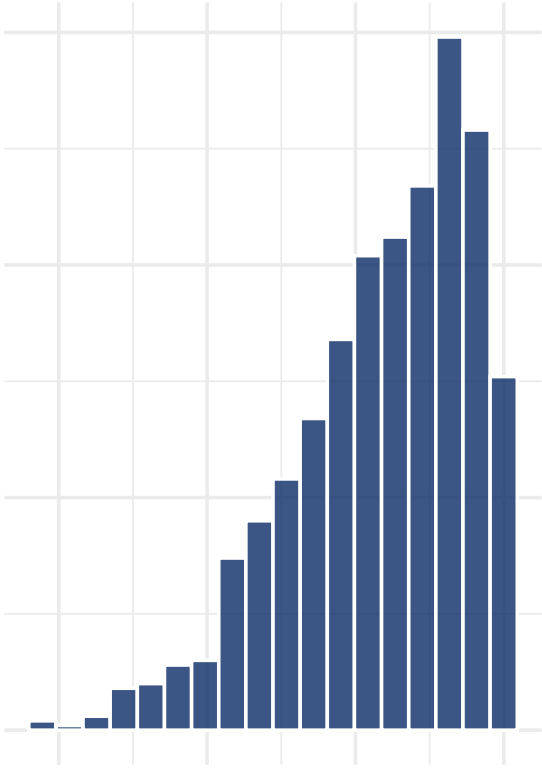
- Anhand ihrer Histogramme können Häufigkeitsverteilungen in verschiedene Typen eingeteilt werden.
- Modalität der Verteilung:



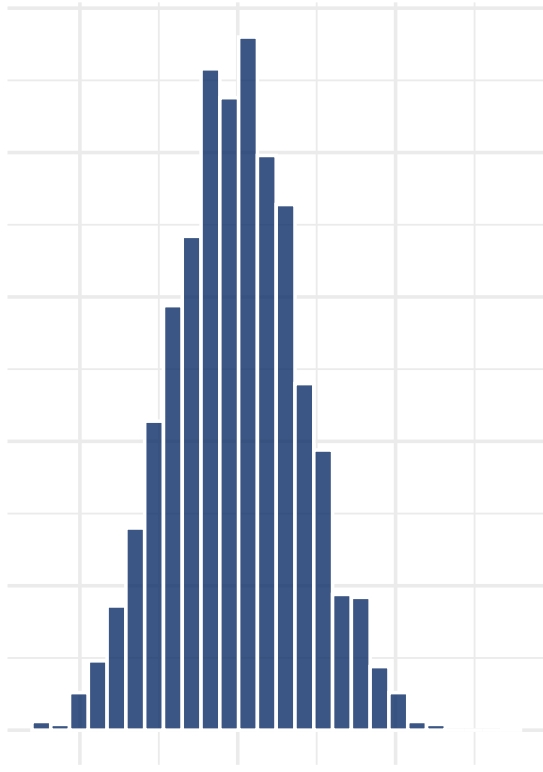



- Symmetrie bzw. Schiefe der Verteilung:

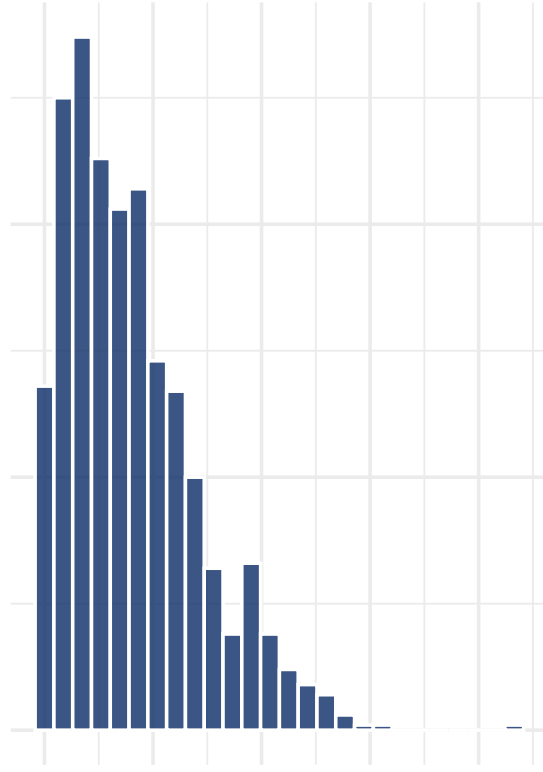
linksschief/rechtssteil



symmetrisch



rechtsschief/linkssteil



# Lagemaße

- Lagemaße beschreiben das Zentrum/die zentrale Tendenz der Daten.
- Das arithmetisches Mittel ist die durchschnittliche Ausprägung eines Merkmals:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \sum_{j=1}^{J} a_j f_j$$

- Der Median teilt die Beobachtungen eines Merkmals in 50% große und 50% kleine Beobachtungen ein:

$$x_{med} = \begin{cases} x_{(\frac{n+1}{2})} & n \text{ ungerade} \\ \in [x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}] & n \text{ gerade} \end{cases}$$

mit den geordneten Beobachtungen $x_{(1)} \leq x_{(2)} \leq \ldots \leq x_{(n)}$.

- Der Modus ist die am häufigsten beobachtete Ausprägung eines Merkmals: $x_{mod}$ = häufigste Merkmalsausprägung
- Die Lagemaße beschreiben die zentrale Tendenz der Daten:
  - Für das arithmetische Mittel gilt: $\sum_{i=1}^{n}(x_i - \bar{x}) = 0$,

    d.h. die Differenzen nach links und rechts heben sich gegenseitig auf.
  - Für den Median liegen mindestens 50 % der Beobachtungen links und mindestens 50 % der Beobachtungen rechts des Medians.

# Beispiel: Mietspiegel

- Beobachtungen zur Nettomiete pro Quadratmeter zu $n = 2051$ Wohnungen in München
- Gegliedert nach Baualter und Wohnflächenkategorien (klein, mittel, groß)

| Nettomiete/qm | | | | |
|---|---|---|---|---|
| | Wohnfläche | | | |
| Baualter | bis 38 qm | 39 bis 80 qm | 81 qm und mehr | |
| bis 1918 | 10.96 (20) | 7.86 (189) | 7.46 (190) | 7.82 (399) |
| 1919 bis 48 | 8.00 (5) | 7.07 (128) | 6.71 (53) | 7.00 (186) |
| 1949 bis 65 | 10.32 (64) | 8.10 (321) | 7.68 (68) | 8.35 (453) |
| 1966 bis 77 | 10.43 (112) | 8.10 (364) | 7.67 (151) | 8.42 (627) |
| 1987 bis 89 | 11.00 (10) | 9.41 (115) | 8.95 (42) | 9.39 (167) |
| ab 1990 | 11.40 (6) | 10.19 (154) | 9.80 (59) | 10.12 (219) |
| | 10.44 (217) | 8.33 (1271) | 7.83 (563) | 8.42 (2051) |

- In Klammern ist jeweils die Anzahl der einbezogenen Wohnungen angegeben.

- Arithmetisches Mittel bei Schichtenbildung:

$$\bar{x} = \frac{1}{n}(n_1\bar{x}_1 + \cdots + n_r\bar{x}_r) = \frac{1}{n}\sum_{j=1}^{r} n_j\bar{x}_j$$

- Das Gesamtmittel entspricht dem gewichteten Durchschnit der arithmetischen Mittel in den Schichten.

# Voraussetzung für die Lagemaße

- Arithmetisches Mittel:
  - Anwendbar für kardinale Merkmale
  - Auch sinnvoll für binäre, als 0/1 kodierte Merkmale
  - Wird manchmal auch für ordinale Merkmale verwendet.
- Median:
  - Anwendbar ab Ordinalskala
- Modus:
  - Anwendbar für beliebiges Skalenniveau
  - Bei metrischen Merkmalen (mit vielen verschiedenen Ausprägungen) häufig nicht sinnvoll interpretierbar
  - Im Folgenden weniger relevant

# Lagemaße und Form der Verteilung

- Symmetrische, unimodale Verteilung:

$$\bar{x} \approx x_{med} \approx x_{mod}$$

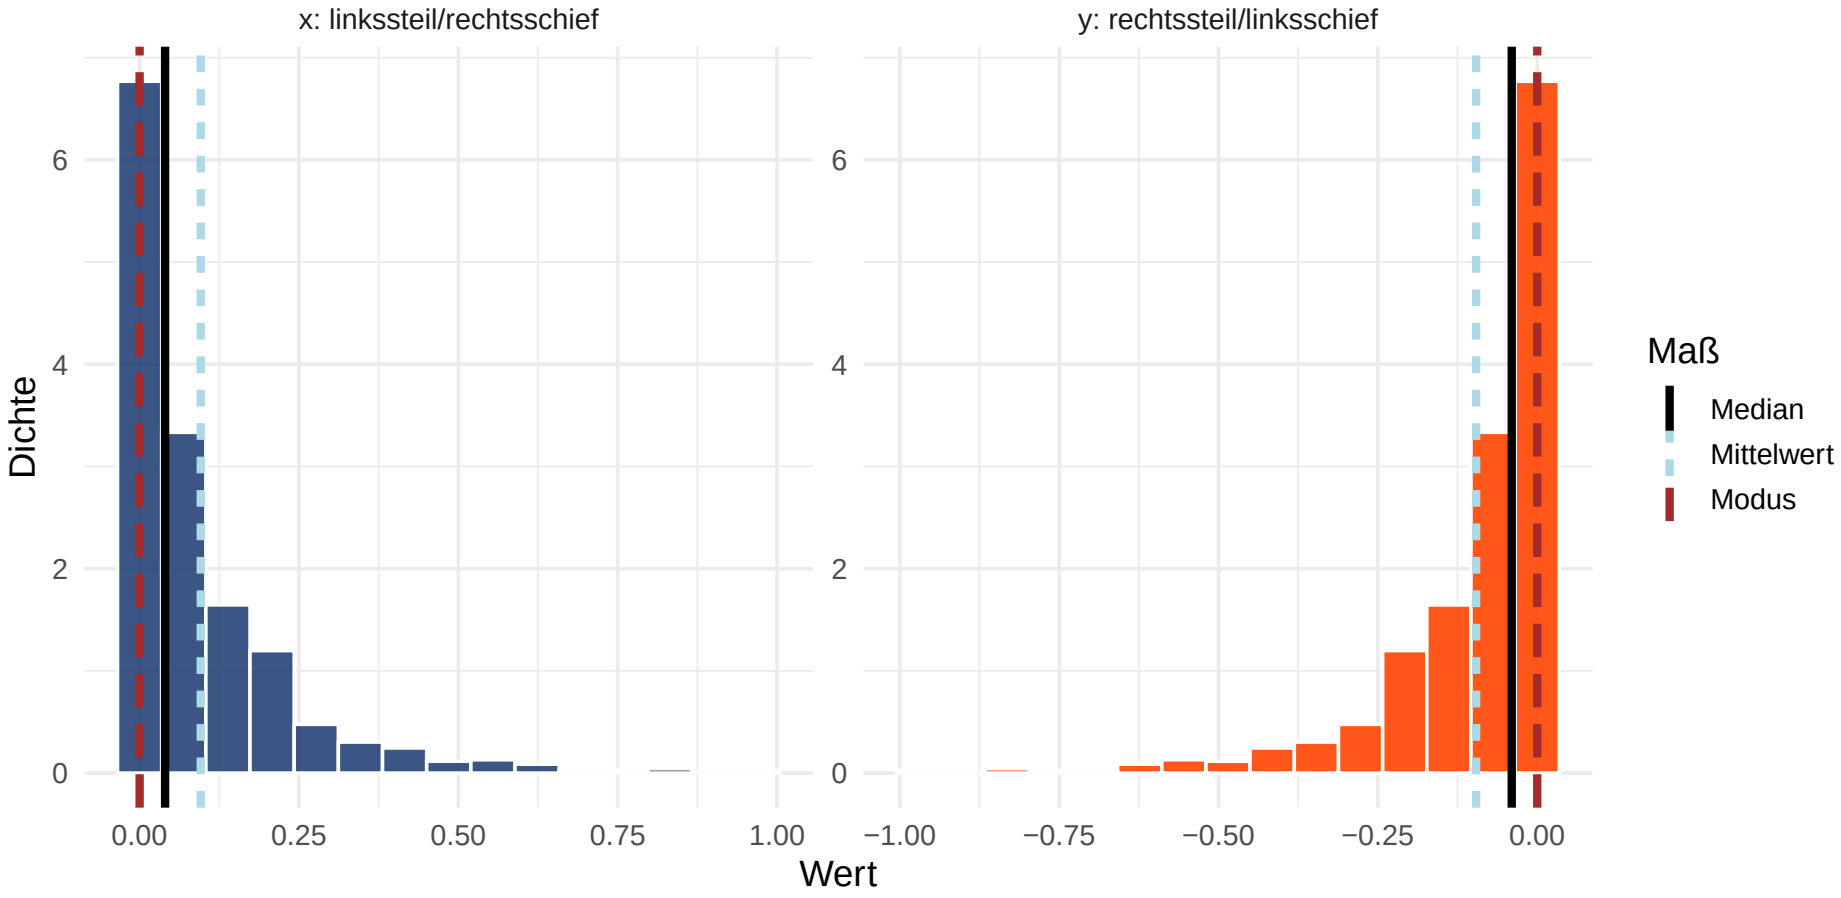
- rechtsschiefe/linkssteile Verteilung:

$$\bar{x} > x_{med} > x_{mod}$$

- linksschiefe/rechtssteile Verteilung:

$$\bar{x} < x_{med} < x_{mod}$$

# Beispiel: Schiefe Verteilungen



# Verhalten bei Transformation

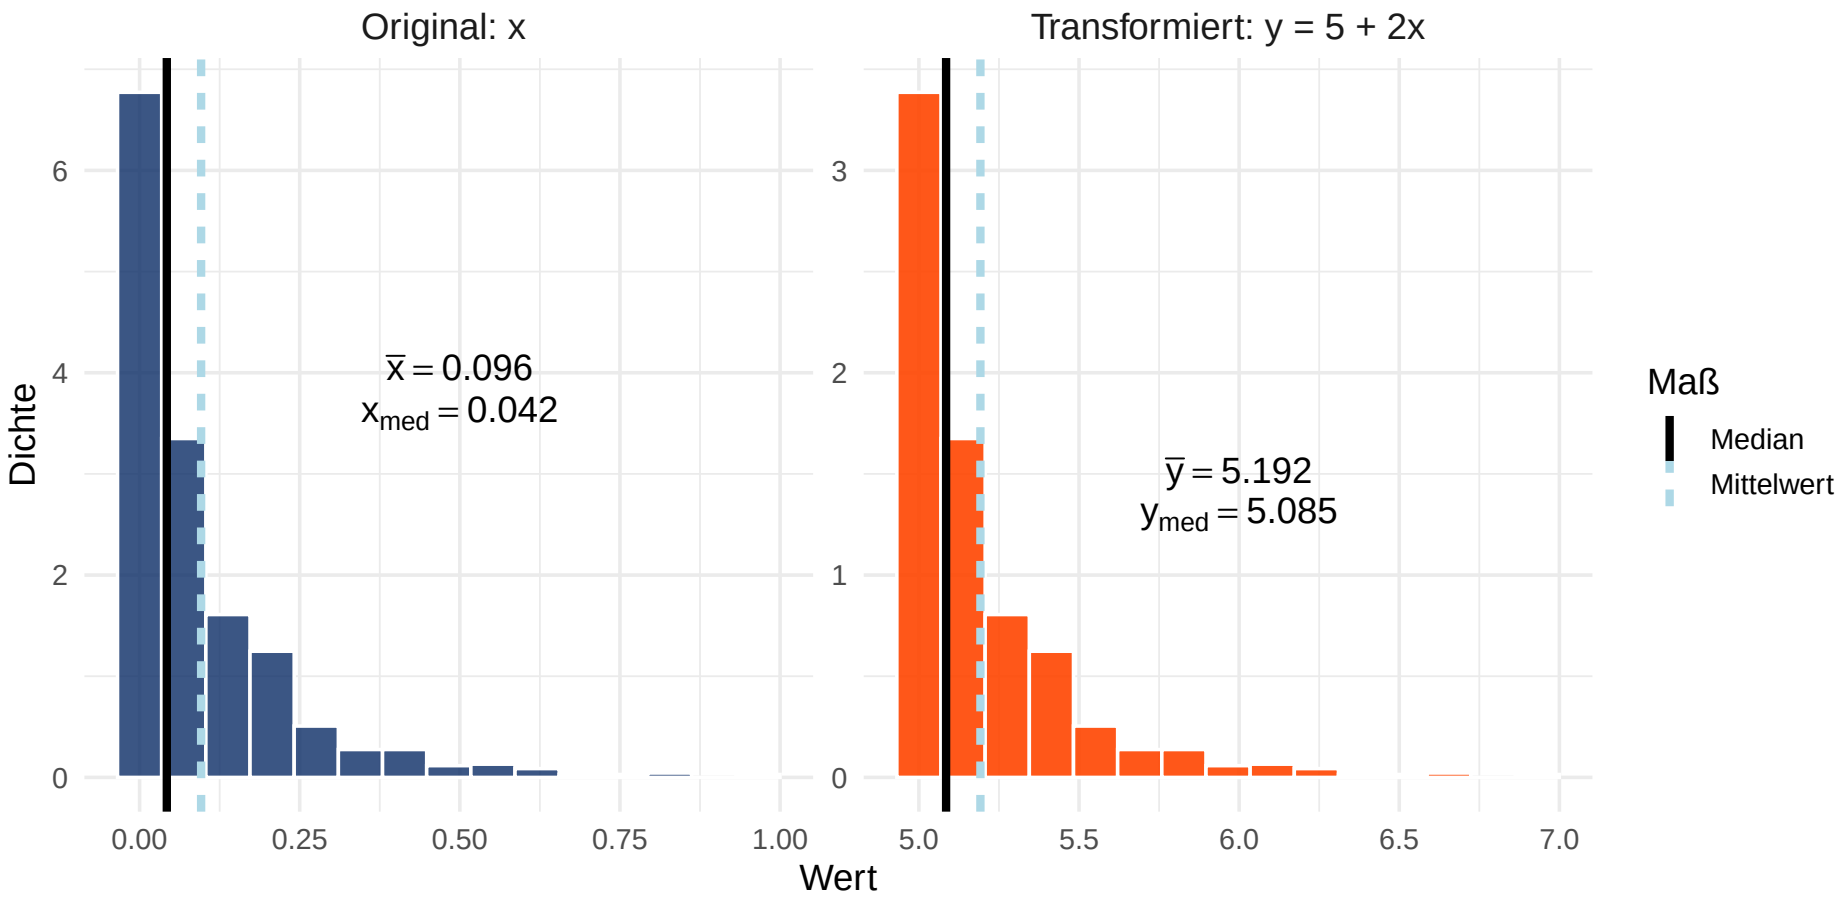
- Bei linearer Transformation der Daten wird das arithmetische Mittel entsprechend mittransformiert:

$$y_i = a + bx_i \implies \bar{y} = a + b\bar{x}.$$

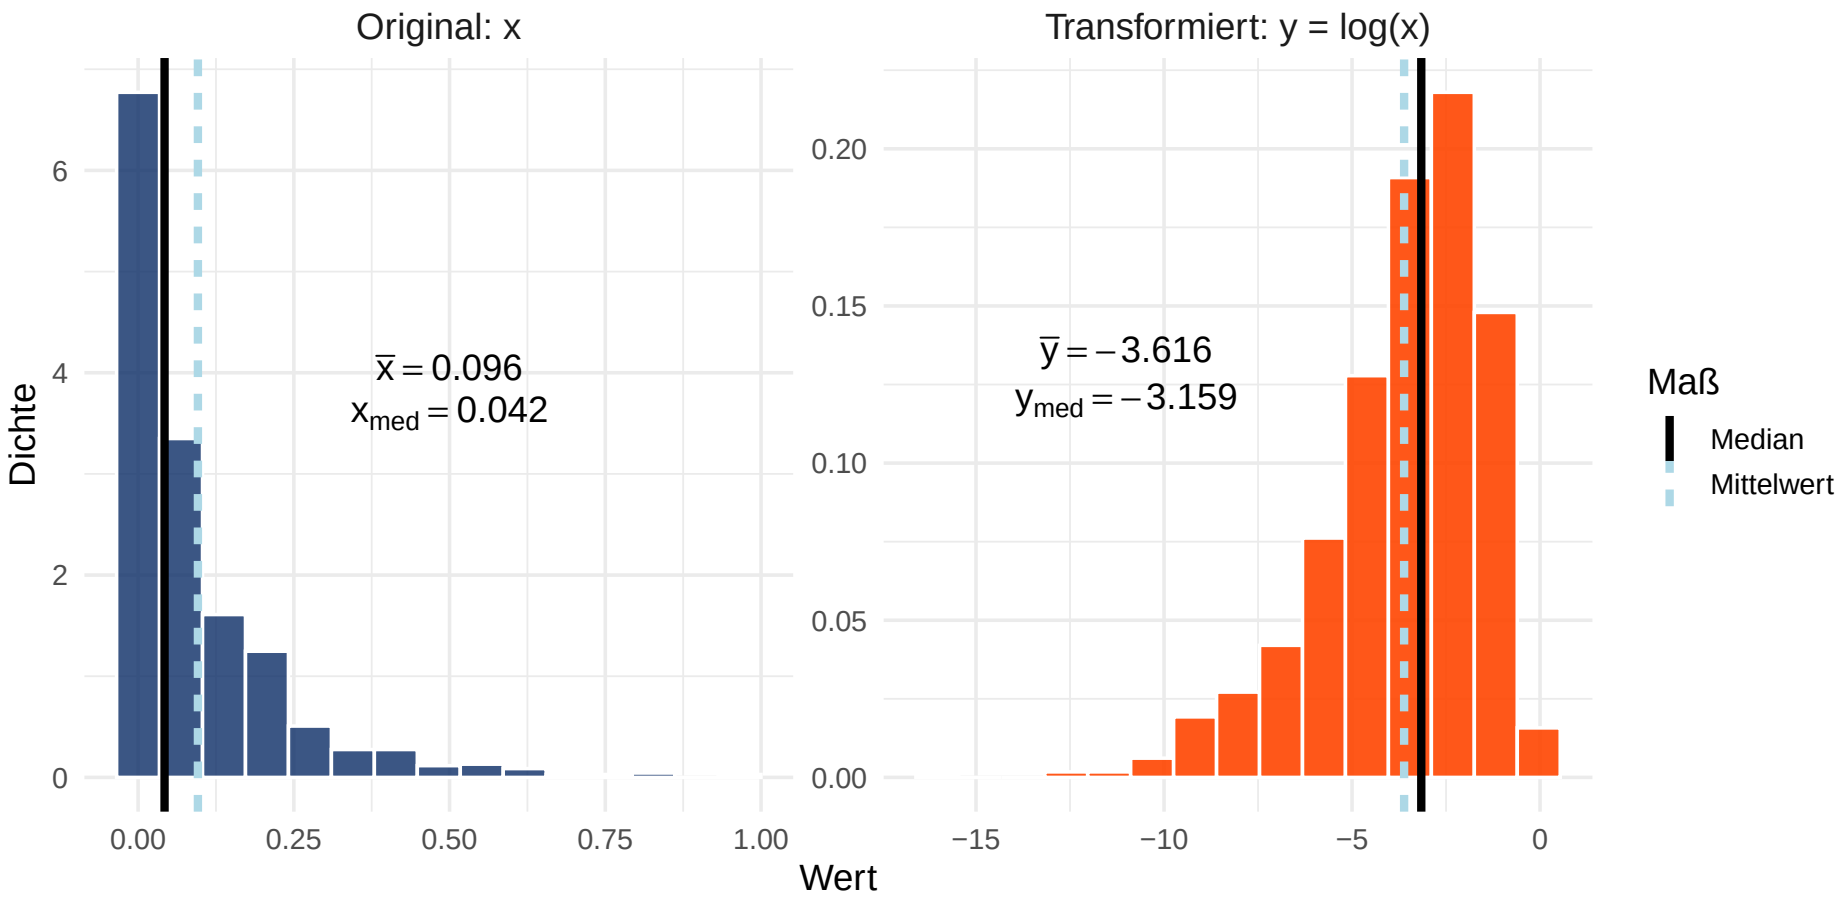
- Für monotone Transformationen $g$ wird der Median mittransformiert:

$$y_i = g(x_i) \implies y_{med} = g(x_{med}).$$

# Beispiel: Lineare Transformation



# Beispiel: Monotone Transformation



# Quantile

- Verallgemeinerung des Median: Das $\alpha$-Quantil ist jene Zahl bzw. sind jene Zahlen für welche mindestens $\alpha \cdot 100$ % der Daten kleiner oder gleich sind und für $(1-\alpha) \cdot 100$ % größer oder gleich sind, wobei $0 \leq \alpha \leq 1$ gilt, d.h.

$$x_\alpha \begin{cases} = x_{([n\alpha]+1)} & n\alpha \notin \mathbb{N}, \\ \in [x_{(n\alpha)}, x_{(n\alpha+1)}] & n\alpha \in \mathbb{N}. \end{cases}$$

- Dabei ist $[n\alpha]$ die zu $n\alpha$ nächstkleinere ganze Zahl.
- Voraussetzung: Mindestens ordinalskaliertes Merkmal

## Häufig verwendete Quantile

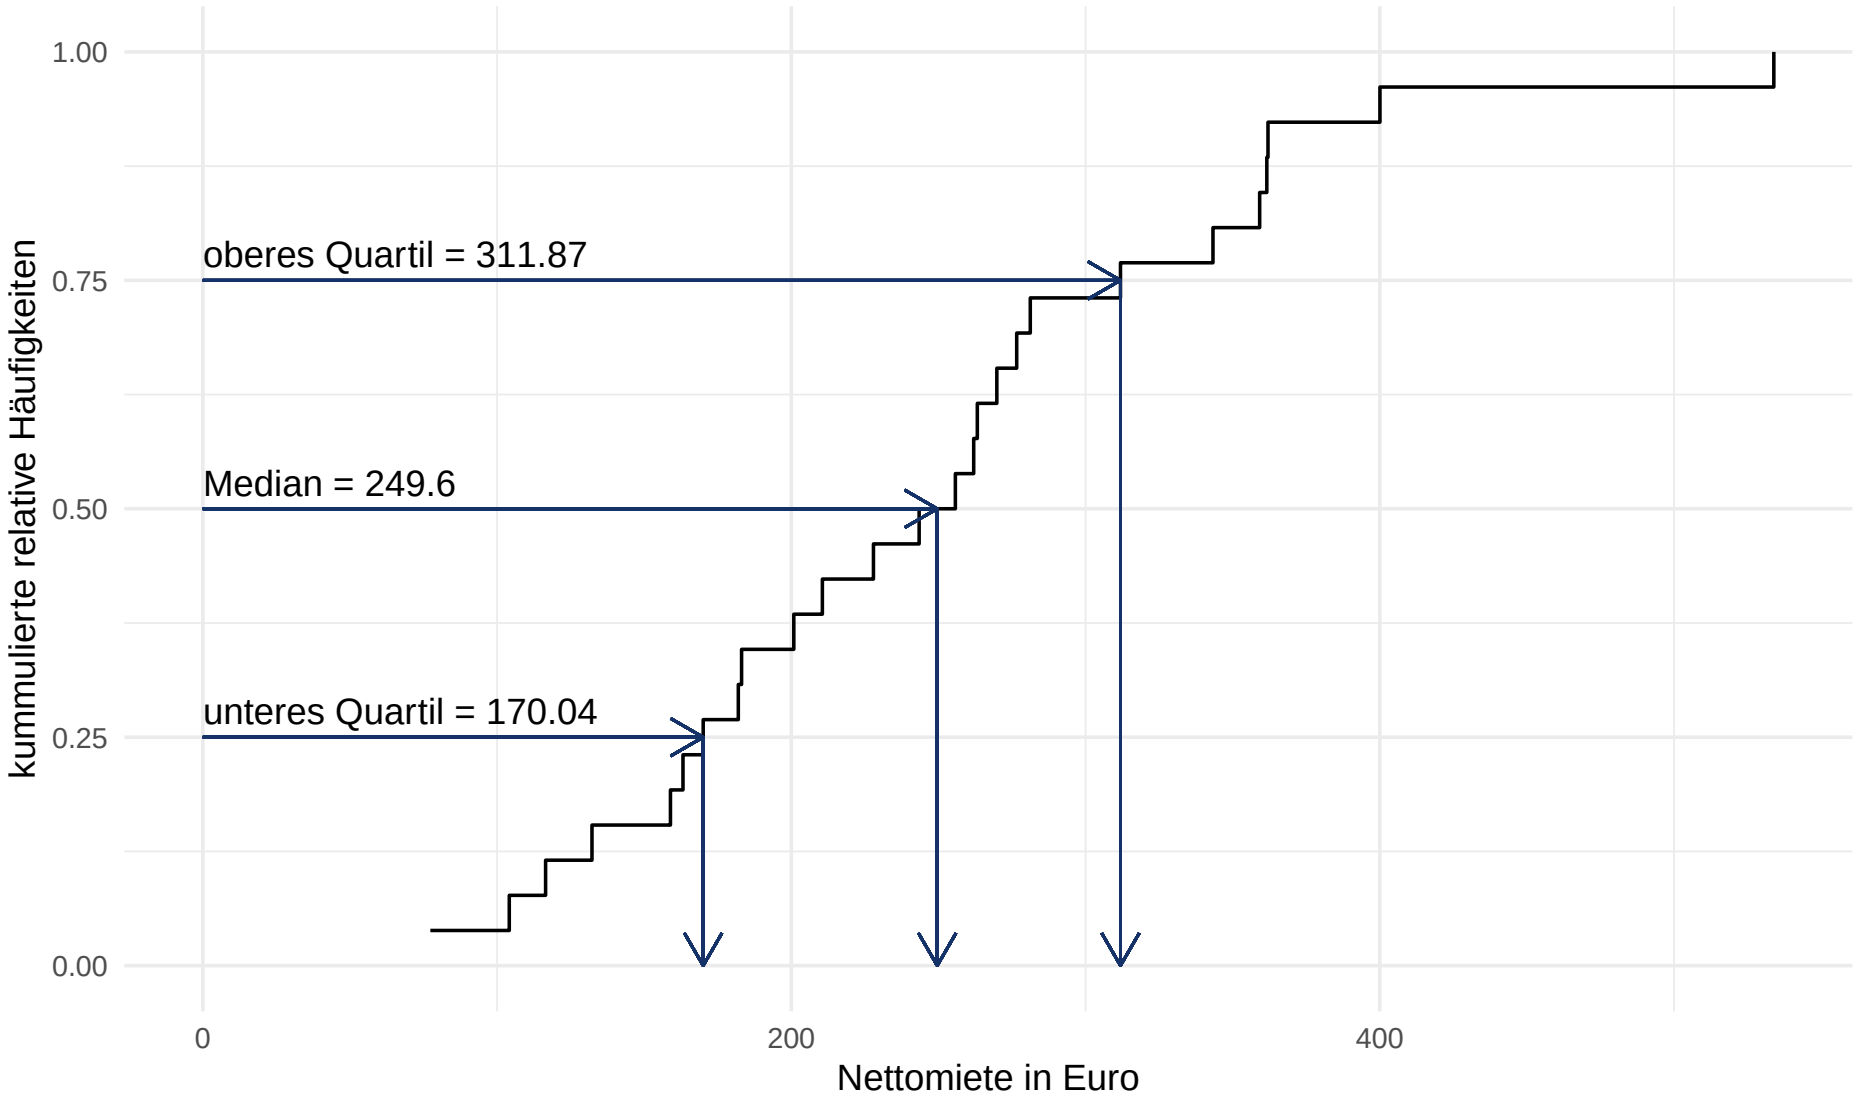
- Median: $x_{med} = x_{0.5}$
- Quartile: $x_{0.25}, x_{0.5}, x_{0.75}$
- Dezile: $x_{0.1}, x_{0.2}, \ldots, x_{0.8}, x_{0.9}$
- Vingtile: $x_{0.05}$ und $x_{0.95}$

# Beispiel: Mietspiegel

- Stichprobe von 26 Wohnungen, Nettomieten nach Größe geordnet:

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| 77.31 | 104.14 | 116.48 | 132.24 | 158.91 | 163.17 | 170.04 | 181.98 |
| 183.09 | 200.84 | 210.55 | 227.91 | 243.44 | 255.75 | 261.98 | 263.21 |
| 269.84 | 276.60 | 281.21 | 311.87 | 343.30 | 359.17 | 361.60 | 362.00 |
| 400.05 | 533.92 | | | | | | |

- Ziel: Bestimmung des 25%-, 50%- und des 75%-Quantils.


1.00
0.75
0.50
0.25
0.00
kummulierte relative Häufigkeiten
oberes Quartil = 311.87
Median = 249.6
unteres Quartil = 170.04
0
200
400
Nettomiete in Euro

- Für die Quartile ergibt sich:
  - $x_{0.25}$: $0.25 \cdot 26 = 6.5 \rightarrow$ aufrunden auf 7

    $x_{0.25} = x_{(7)} = 170.04$
  - $x_{0.50}$: Jeder Wert auf der Treppenstufe zwischen 243.44 und 255.57 teilt die Stichprobe in zwei gleichgroße Hälften.
  - Um einen eindeutigen Wert zu erhalten, bilden wir hier den Mittelwert der beiden Beobachtungen:

    $x_{0.50} = \frac{243.44+255.75}{2} = 249.6$
  - $x_{0.75}$: $0.75 \cdot 26 = 19.5 \rightarrow$ aufrunden auf 20

    $x_{0.75} = x_{(20)} = 311.87$

# Streuungsmaße

- Ziel: Beschreibe nicht nur die zentrale Tendenz, sondern auch die Streuung oder Variabilität eines Merkmals.
- Varianz:
  - Definition: $S^2 = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})^2$ (mittlere quadratische Abweichung vom Mittelwert)
  - Verschiebungssatz zur einfacheren Berechnung: $S^2 = \frac{1}{n} \sum_{i=1}^{n} x_i^2 - \bar{x}^2$
- Standardabweichung:

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})^2}$$

- Vorteil: $S$ hat die gleiche Einheit wie das betrachtete Merkmal.

- Variante:

$$S_*^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2$$

- Vorteil: $S_*^2$ hat bessere theoretische Eigenschaften (mehr dazu in SDS1-V09).

# Beispiel: Mietspiegel

- Für die Stichprobe aus 26 Wohnungen erhält man

$$\frac{1}{n}\sum_{i=1}^{n} x_i^2 = 72616.82$$

und

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = 250.02$$

- Nach dem Verschiebungssatz für die Varianz ergibt sich also

$$S^2 = 72616.82 - \ (250.02)^2 = 10106.82$$

und

$$S = \sqrt{\tilde{S}^2} = \sqrt{10106.82} = 100.53.$$

- Für die Nettomieten pro Quadratmeter der gesamten Stichprobe ist die Standardabweichung gegeben durch

$$S_{\text{ges}} = 2.45$$

und für die Schichten der kleinen, mittleren und großen Wohnungen erhält man

$$S_{\text{kl}} = 2.31, \quad S_{\text{mi}} = 2.36, \quad S_{\text{gr}} = 2.28.$$

- In Bezug auf die Streuung der Nettomiete pro Quadratmeter sind sich kleine, mittlere und große Wohnungen also relativ ähnlich.

- Für die absoluten Nettomieten der gesamten Stichprobe ist die Standardabweichung gegeben durch

$$S_{\text{ges}} = 241.92$$

und für die Schichten der kleinen, mittleren und großen Wohnungen erhält man

$$S_{\text{kl}} = 67.53, \quad S_{\text{mi}} = 166.20, \quad S_{\text{gr}} = 262.76.$$

- Die kleinen Wohnungen sind also in Bezug auf die absolute Nettomiete homogener (weisen eine kleinere Varianz / Standardabweichung auf) als große Wohnungen.

# Interquartilsabstand

- Anstelle der Varianz und der Standardabweichung wird auch ein auf Quartilen beruhendes Streuungsmaß verwendet.
- Die Distanz

$$d_{Qn} = x_{0.75} - x_{0.25}$$

heißt Interquartilsabstand (IQR).

# Eigenschaften der Streuungsmaße bei linearer Transformation:

- Für lineare Transformation der Varianz gilt

$$x_i \mapsto a + bx_i \implies s^2 \mapsto b^2 s^2 \quad \text{bzw. } s_*^2 \mapsto b^2 s_*^2.$$

- Für lineare Transformation der Standardabweichung gilt

$$x_i \mapsto a + bx_i \implies s \mapsto bs \quad \text{bzw. } s_* \mapsto bs_*.$$

- Für lineare Transformationen des Interquartilsabstands gilt

$$x_i \mapsto a + bx_i \implies IQR \mapsto b\, IQR.$$

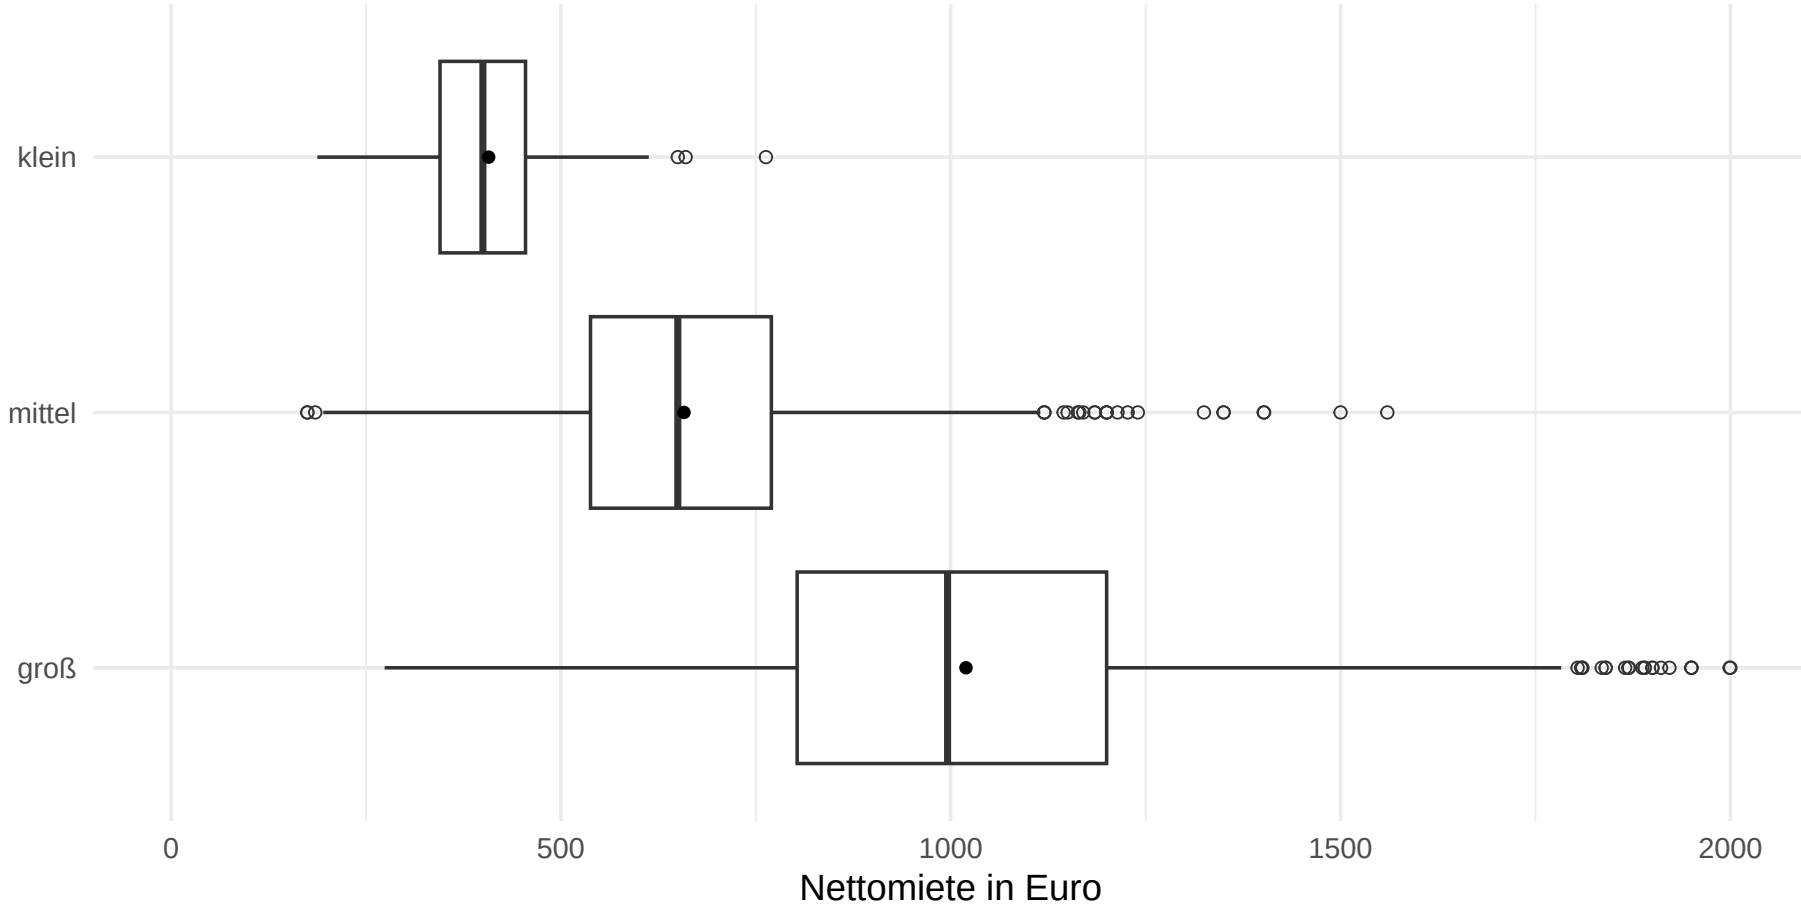
# Boxplots

- Boxplots sind eine grafische Fünf-Punkte-Zusammenfassung einer Verteilung bestehend aus:
  - dem minimalen Wert $x_{min}$,
  - dem unteren Quartil $x_{0.25}$,
  - dem Median $x_{med}$,
  - dem oberen Quartil $x_{0.75}$ und
  - dem maximalen Wert $x_{max}$.

- Häufig werden zusätzlich Ausreißer (also außergewöhnlich kleine oder große Beobachtungen) separat eingezeichnet.
- Übliche Ausreißerregel: mehr als 1.5 $IQR$ Abstand zu $x_{0.25}$ bzw. $x_{0.75}$
- Der Boxplot gibt einen schnellen Überblick über die Form der Verteilung (Zentrale Tendenz, Variabilität, Schiefe, Extreme Werte).

# Beispiel: Mietspiegel

- Box-Plots für die Nettomieten geschichtet nach Wohnungsgröße



- Der Median wird mit wachsender Wohnungsgröße erwartungsgemäß größer.
- Ausreißer – gekennzeichnet durch runde Kreise – gibt es in allen drei Kategorien, aber die Spannweite der Daten wächst zusammen mit der Wohnungsgröße.
- Bei den großen Wohnungen ist zu erkennen, dass die Verteilung linkssteil (rechtsschief) ist.

# Take Home Messages

- Für diskrete Merkmale kann die Verteilung durch die Häufigkeitsverteilung, für stetige Merkmale durch Histogramme dargestellt werden.
- Neben der grafischen Darstellung bieten Maßzahlen für Lokation, Streuung, etc. eine Möglichkeit, die Verteilung zu beschreiben.
- Die Maßzahlen besitzen verschiedene Voraussetzungen an das Skalenniveau und haben verschiedene Güteeigenschaften.
- Mit Quantilen kann ein Überblick über einen gesamten Datensatz gegeben werden. Dieser Überblick kann z.B. mit Boxplots visualisiert werden.